Análisis de Encuestas de Hogares

usando R

Andrés Gutiérrez, Stalyn Guerrero, Giovany Babativa y Cristian Téllez

11 de noviembre de 2026

Tabla de contenidos

Página legal 1

Resumen 2

1. Introducción 3
- 1.1. Justificación . . . 4
- 1.2. Uso del software R para el análisis de encuestas . . . 5
- 1.3. Estructura del documento . . . 5

2. Conceptos básicos en encuestas de hogares 9
- 2.1. Población objetivo y unidades de muestreo . . . 9
- 2.2. Diseños de muestreo . . . 10
  - 2.2.1. Factores de expansión . . . 10
  - 2.2.2. Conglomeración y selección en múltiples etapas . . . 11
  - 2.2.3. Estratificación . . . 12
- 2.3. Estimadores de muestreo . . . 12
- 2.4. El efecto de diseño (DEFF) . . . 14
- 2.5. Inferencia en encuestas complejas . . . 15
  - 2.5.1. Estimación puntual . . . 15
  - 2.5.2. Estimación de la varianza . . . 16
  - 2.5.3. Intervalos de confianza . . . 20

3. Análisis de variables categóricas 22
- 3.1. Preparación de los datos y especificación del diseño . . . 22
  - 3.1.1. Corroboraciones preparatorias . . . 24
  - 3.1.2. Definición del diseño de muestreo . . . 26
  - 3.1.3. Variables derivadas y subpoblaciones . . . 26
- 3.2. Estimación de parámetros descriptivos . . . 28
  - 3.2.1. Tamaños poblacionales . . . 28
  - 3.2.2. Proporciones . . . 36
- 3.3. Estimación de parámetros de asociación . . . 41
  - 3.3.1. Tablas cruzadas . . . 41
  - 3.3.2. Razón de odds . . . 47
- 3.4. Pruebas de hipótesis . . . 50
  - 3.4.1. Prueba de independencia de Rao-Scott . . . 53
- 3.5. Estimación de contrastes . . . 56
- 3.6. Visualización de variables categóricas . . . 61
  - 3.6.1. Gráficos de barras . . . 62
  - 3.6.2. Mapas temáticos . . . 71

4. Análisis de las variables continuas **80**
4.1. Estimación de parámetros descriptivos . . . 80
4.1.1. Totales . . . 80
4.1.2. Medias . . . 84
4.1.3. Razones . . . 88
4.2. Estimación de parámetros de distribución y desigualdad . . . 97
4.2.1. Varianza y desviación estándar . . . 97
4.2.2. Percentiles y medianas . . . 99
4.2.3. El coeficiente de Gini y la curva de Lorenz . . . 101
4.2.4. Correlaciones . . . 104
4.3. Pruebas de hipótesis . . . 106
4.4. Estimación de contrastes . . . 107
4.5. Visualización de variables continuas . . . 116
4.5.1. Histogramas . . . 117
4.5.2. Diagramas de caja (*boxplots*) . . . 120
4.5.3. Diagramas de dispersión . . . 122

5. Modelos de regresión **125**
5.1. Formulación del modelo . . . 126
5.2. Uso de los pesos de muestreo . . . 127
5.3. Estimación de los parámetros del modelo . . . 129
5.4. Diagnóstico del modelo . . . 134
5.4.1. Coeficiente de determinación . . . 134
5.4.2. Residuales . . . 136
5.4.3. Observaciones influyentes . . . 140
5.5. Inferencia sobre los parámetros del modelo . . . 145
5.6. Estimación y predicción . . . 147

6. Modelos lineales generalizados **153**
6.1. Modelo de regresión logística . . . 154
6.2. Modelo de regresión multinomial . . . 161
6.3. Modelo de regresión Gamma . . . 166

7. Modelos multinivel **169**
7.1. Motivación . . . 170
7.2. Incorporación de pesos de muestreo en modelos multinivel . . . 178
7.3. Modelo lineal multinivel . . . 180
7.3.1. Modelo nulo . . . 180
7.3.2. Modelo con intercepto aleatorio . . . 183
7.3.3. Modelo con intercepto y pendiente aleatoria . . . 186
7.4. Modelo logístico multinivel . . . 190
7.4.1. Modelo nulo logístico . . . 192
7.4.2. Modelo logístico con intercepto aleatorio . . . 194
7.4.3. Modelo logístico con intercepto y pendiente aleatoria . . . 197

I. Anexos **201**

8. Manejo de bases de datos con R **202**
8.1. Preparación del entorno de trabajo . . . 202
8.2. Carga e inspección inicial de la base . . . 204
8.3. Encadenamiento de operaciones . . . 206
8.3.1. `filter`: selección de registros . . . 207
8.3.2. `select`: seleccionar variables . . . 208
8.3.3. `arrange`: ordenamiento de filas . . . 208
8.3.4. `mutate`: creación o transformación de variables . . . 209
8.3.5. `summarise`: resúmenes descriptivos . . . 211
8.3.6. `group_by`: agrupación de casos . . . 212

9. Inferencia en poblaciones finitas **216**
9.1. Dos posibles inferencias . . . 216
9.2. La integración de ambas inferencias . . . 221
9.2.1. Método de la máxima verosimilitud . . . 221
9.2.2. Método de máxima pseudo-verosimilitud . . . 223

10. Imputación usando R **227**
10.1. Tres patrones para la ausencia de respuesta . . . 227
10.2. Algunos métodos de imputación . . . 239
10.2.1. Imputación por la media no condicional . . . 239
10.2.2. Imputación por la media condicional . . . 243
10.2.3. Imputación por *hot-deck* . . . 246
10.2.4. Imputación por regresión . . . 249
10.2.5. Imputación por el vecino más cercano . . . 251
10.2.6. Imputación por el vecino más cercano con regresión . . . 254
10.2.7. Imputación múltiple . . . 256

Referencias **264**

Listado de Figuras

3.1. Estimación del tamaño poblacional por zona geográfica . . . 63
3.2. Estimación del número de personas según condición de pobreza . . . 64
3.3. Estimación del número de personas por estado de ocupación y situación de pobreza . 65
3.4. Proporción de hombres en condición de pobreza por zona geográfica . . . 67
3.5. Proporciones de hombres pobres y no pobres por región . . . 68
3.6. Pirámide de población estimada por edad y sexo con intervalos de confianza del 95 % 70
3.7. Mapa de regiones geográficas de BigCity . . . 72
3.8. Proporción de hombres en condición de pobreza por región . . . 73
3.9. Coeficiente de variación de la proporción de pobreza por región . . . 75
3.10. Mapa bivariante: proporción de pobreza femenina rural y su coeficiente de variación por región . . . 77

4.1. Curva de Lorenz estimada para el ingreso per cápita . . . 103
4.2. Histograma ponderado del ingreso per cápita . . . 117
4.3. Histograma ponderado del ingreso por zona geográfica . . . 119
4.4. Histogramas ponderados y densidades del ingreso y gasto per cápita . . . 120
4.5. Cuartiles ponderados del logaritmo del ingreso y el gasto per cápita por zona . . . 121
4.6. Diagrama de dispersión entre ingreso y gasto per cápita . . . 123
4.7. Diagrama de dispersión entre ingreso y gasto por zona geográfica . . . 124

5.1. Diagrama de dispersión entre los logaritmos del ingreso y del gasto per cápita de los hogares (sin ponderar) . . . 132
5.2. Histograma de residuales estandarizados con curva de densidad estimada y distribución normal teórica . . . 137
5.3. Gráficos de residuales estandarizados frente a cada covariable del modelo . . . 139
5.4. Distancia de Cook para cada observación de la muestra . . . 141
5.5. Valores DfBetas por parámetro: observaciones influyentes señaladas en rojo . . . 144
5.6. Valores DfFits: observaciones influyentes sobre el ajuste global señaladas en rojo . . . 145
5.7. Estimaciones del logaritmo del gasto per cápita e intervalos de confianza para los primeros 100 hogares de la muestra . . . 151

6.1. Distribución de los parámetros del modelo logístico base . . . 158
6.2. Comparación de los parámetros del modelo logístico con y sin interacciones . . . 160
6.3. Intervalos de confianza para los coeficientes del modelo multinomial . . . 166

7.1. Modelo de regresión lineal simple para el logaritmo del gasto en función del logaritmo del ingreso (sin considerar estratos) . . . 172
7.2. Modelo con intercepto específico por estrato y pendiente común . . . 173
7.3. Modelo con pendiente específica por estrato e intercepto común . . . 175
7.4. Modelo con intercepto y pendiente específicos por estrato (ajuste independiente) . . . 176
7.5. Rectas de regresión estimadas por estrato: modelo con intercepto aleatorio . . . 186

7.6. Rectas de regresión estimadas por estrato: modelo con intercepto y pendiente aleatoria 189
7.7. Probabilidad de pobreza según el logaritmo del gasto, controlando por el tamaño del hogar . . . 192
7.8. Curvas de probabilidad predichas por estrato: modelo logístico con intercepto aleatorio 197
7.9. Curvas de probabilidad predichas por estrato: modelo logístico con intercepto y pendiente aleatoria . . . 200

10.1. Distribución del ingreso por zona y sexo con datos completos y bajo un patrón MCAR 230
10.2. Distribución del ingreso, total y por sexo, bajo un patrón MCAR . . . 231
10.3. Distribución del gasto, total y por sexo, bajo un patrón MCAR . . . 232
10.4. Distribución del gasto por zona y sexo bajo un patrón MAR . . . 234
10.5. Distribución del ingreso, total y por sexo, bajo un patrón MAR . . . 235
10.6. Distribución del gasto, total y por sexo, bajo un patrón MAR . . . 236
10.7. Distribución del ingreso bajo un patrón MNAR . . . 237
10.8. Distribución del gasto bajo un patrón MNAR . . . 238
10.9. Distribución del ingreso por zona y sexo bajo un patrón MNAR . . . 239
10.10 Distribución del ingreso original e imputado por la media no condicional . . . 242
10.11 Ingreso original e imputado por la media no condicional, por zona y sexo . . . 243
10.12 Distribución del ingreso original e imputado por la media condicional . . . 245
10.13 Ingreso original e imputado por la media condicional, por zona y sexo . . . 246
10.14 Distribución del ingreso original e imputado mediante hot-deck . . . 249
10.15 Distribución del ingreso original e imputado por regresión . . . 251
10.16 Distribución del ingreso original e imputado por el vecino más cercano . . . 254
10.17 Distribución del ingreso original e imputado por el vecino más cercano con regresión 256
10.18 Distribución del ingreso original y de los valores obtenidos mediante imputación múltiple 260

Listado de Tablas

3.1. Tamaño poblacional estimado por zona geográfica . . . 31
3.2. Tamaño muestral y tamaño poblacional estimado por grupo de edad . . . 32
3.3. Tamaño poblacional estimado por condición de pobreza . . . 33
3.4. Tamaño poblacional estimado por estado de ocupación . . . 34
3.5. Tamaño poblacional estimado por grupo de edad y sexo . . . 34
3.5. Tamaño poblacional estimado por grupo de edad y sexo . . . 35
3.6. Tamaño poblacional estimado por estado de ocupación y condición de pobreza . . . 35
3.6. Tamaño poblacional estimado por estado de ocupación y condición de pobreza . . . 36
3.7. Proporción de personas por zona geográfica . . . 38
3.8. Proporción de hombres y mujeres en zona urbana . . . 39
3.9. Distribución por zona en la subpoblación masculina . . . 39
3.10. Proporción de hombres por zona y condición de pobreza . . . 40
3.11. Tasa de desocupación de las mujeres por rango de edad . . . 41
3.12. Estructura general de una tabla de contingencia con R filas y C columnas . . . 42
3.13. Proporción de hombres y mujeres en condición de pobreza y no pobreza . . . 43
3.14. Tasa de desocupación por sexo . . . 44
3.15. Tasa de ocupación por sexo . . . 45
3.16. Proporción en condición de pobreza por región . . . 46
3.17. Tasa de pobreza por grupo de edad . . . 47
3.18. Proporciones conjuntas de sexo y condición de pobreza . . . 49
3.19. Tasas de desocupación por sexo para la prueba de hipótesis . . . 52
3.20. Prueba de diferencia de tasas de desocupación por sexo (población económicamente activa) . . . 52
3.21. Proporción en condición de pobreza por sexo . . . 57
3.22. Matriz de varianzas y covarianzas de la proporción de pobreza por sexo . . . 58
3.23. Tasa de desocupación por región . . . 59
3.24. Matriz de varianzas y covarianzas de la tasa de desocupación por región . . . 60
3.25. Proporción de pobreza entre mujeres rurales de 15 a 29 años, por región . . . 78

4.1. Estimación del total poblacional del ingreso per cápita con intervalo de confianza al 95 % . . . 82
4.2. Estimación del total poblacional del gasto per cápita con intervalo de confianza al 90 % 83
4.3. Total poblacional del ingreso per cápita desagregado por sexo . . . 84
4.4. Estimación de la media poblacional del ingreso per cápita . . . 85
4.5. Estimación de la media poblacional del gasto per cápita . . . 86
4.6. Media poblacional del gasto per cápita desagregada por zona . . . 87
4.7. Media poblacional del gasto per cápita desagregada por zona y región . . . 87
4.7. Media poblacional del gasto per cápita desagregada por zona y región . . . 88
4.8. Índice de masculinidad: hombres por cada 100 mujeres en la población . . . 89
4.9. Índice de masculinidad: hombres por cada 100 mujeres en zona rural . . . 90

4.10. Índice de envejecimiento: personas de 60 años o más por cada 100 menores de 15 años 91
4.11. Índice de envejecimiento por zona de residencia 92
4.12. Razón de dependencia demográfica por cada 100 personas de 15 a 64 años 93
4.13. Razón de dependencia demográfica por zona de residencia 93
4.14. Razón de dependencia económica potencial: personas no ocupadas por cada 100 ocupadas de 15 años o más 95
4.15. Razón de dependencia económica potencial por zona de residencia 95
4.16. Razón gasto/ingreso per cápita 96
4.17. Razón gasto/ingreso para las regiones 96
4.17. Razón gasto/ingreso para las regiones 97
4.18. Desviación estándar de los ingresos desagregada por zona 98
4.19. Estimación de la mediana de los gastos desagregada por zona 100
4.20. Estimación del primer cuartil de los gastos per cápita 101
4.21. Estimación del coeficiente de Gini para el ingreso per cápita 102
4.22. Matriz de varianzas y covarianzas ponderada entre ingreso y gasto 105
4.23. Diferencia de ingreso per cápita entre personas jefas de hogar por sexo 107
4.24. Ingreso medio estimado por región 108
4.24. Ingreso medio estimado por región 109
4.25. Contraste de ingresos medios: región North menos región South 110
4.26. Matriz de varianzas y covarianzas de los ingresos medios por región 111
4.27. Contrastes de ingresos medios entre regiones 112
4.28. Ingreso per cápita asociado a personas jefas de hogar, por sexo 113
4.29. Contraste de ingresos medios entre mujeres y hombres 113
4.30. Razón ingreso/gasto en el dominio de personas jefas de hogar por sexo 114
4.31. Contraste de la razón ingreso/gasto entre sexos 115
4.32. Diferencia rural menos urbana de las razones de dependencia demográfica 116

5.1. Valores DfBetas para las primeras diez observaciones de la muestra, con identificador del hogar 142
5.2. Las diez observaciones más influyentes según el criterio DfBetas, con identificador del hogar 143
5.3. Pruebas t e intervalos de confianza al 95 % para los parámetros del modelo 147
5.4. Matriz de varianzas y covarianzas de los coeficientes del modelo 149

6.1. Intervalos de confianza al 95 % para los parámetros del modelo logístico 156
6.1. Intervalos de confianza al 95 % para los parámetros del modelo logístico 157
6.2. Coeficientes del modelo logístico con interacciones 159
6.3. Probabilidades predichas de pobreza para perfiles seleccionados 161
6.4. Proporción estimada de personas por estado de empleo (de 15 años o más) 163
6.5. Coeficientes estimados del modelo de regresión multinomial 164
6.6. Coeficientes del modelo Gamma para el ingreso per cápita de los hogares 168

7.1. Interceptos y elasticidades de los modelos ilustrativos de la sección de motivación . . 177
7.1. Interceptos y elasticidades de los modelos ilustrativos de la sección de motivación . . 178
7.2. Interceptos estimados por estrato bajo pesos q-weighted (modelo nulo, primeros 5 estratos) 182
7.3. Correlación intraclase del modelo nulo (logaritmo del gasto por estrato) 183
7.4. Interceptos, elasticidad del ingreso y coeficiente de edad por estrato (5 estratos) . . . 185

7.5. Interceptos, elasticidades y coeficientes de edad del modelo con pendiente aleatoria por estrato (5 estratos) 188
7.6. Interceptos estimados por estrato en el modelo logístico nulo (primeros 5 estratos) . 194
7.7. Coeficientes y OR condicionales del modelo logístico con intercepto aleatorio (5 estratos) 196
7.8. Coeficientes y OR condicionales del modelo logístico con pendiente aleatoria (5 estratos) 198
7.8. Coeficientes y OR condicionales del modelo logístico con pendiente aleatoria (5 estratos) 199

10.1. Patrón no monótono de datos faltantes. Adaptación de *Applied Survey Data Analysis* (Heeringa et al. 2017). 228

Página legal

Este documento fue elaborado por Andrés Gutiérrez, Experto Regional en Estadísticas Sociales de la División de Estadísticas de la Comisión Económica para América Latina y el Caribe (CEPAL), y por Stalyn Guerrero, Giovany Babativa y Cristian Téllez, consultores de la misma División, bajo la coordinación de Rolando Ocampo, Director, y Xavier Mancero, Jefe de la Unidad de Estadísticas Sociales, de dicha División.

Este libro es el resultado de un compendio de las experiencias internacionales prácticas adquiridas por los autores en su asesoría a los países de América Latina y el Caribe desde la División de Estadísticas de la CEPAL. Se agradece a Álvaro Fuentes, Estadístico de la División de Estadísticas, y a Gabriel Mendes Borges, del Centro Latinoamericano y Caribeño de Demografía (CELADE)-División de Población de la CEPAL, por la lectura detallada de este documento y sus comentarios.

La autorización para reproducir total o parcialmente esta obra debe solicitarse a la Comisión Económica para América Latina y el Caribe (CEPAL), División de Documentos y Publicaciones, publicaciones.cepal@un.org. Los Estados Miembros de las Naciones Unidas y sus instituciones gubernamentales pueden reproducir esta obra sin autorización previa. Solo se les solicita que mencionen la fuente e informen a la CEPAL de tal reproducción.

Resumen

Las encuestas de hogares son una de las principales fuentes de información para caracterizar fenómenos sociales y económicos (como la pobreza, la desigualdad, el empleo y la educación) y para dar seguimiento al avance hacia los Objetivos de Desarrollo Sostenible. No obstante, el análisis de estas encuestas enfrenta un desafío técnico que a menudo pasa inadvertido: sus muestras no son aleatorias simples. Provienen de diseños complejos que combinan estratificación, selección en varias etapas, probabilidades de inclusión desiguales y factores de expansión ajustados mediante calibración. Aplicar a estos datos métodos concebidos para observaciones independientes e idénticamente distribuidas puede producir estimaciones sesgadas y medidas de precisión incorrectas. Según las características del diseño, los errores estándar pueden subestimarse o sobreestimarse, afectando los intervalos de confianza y las pruebas de hipótesis.

Este documento ofrece a investigadores y analistas los fundamentos teóricos y las herramientas computacionales necesarios para trabajar correctamente con encuestas de diseño complejo. El texto recorre todo el proceso de forma integrada: la definición del diseño muestral; la estimación de totales, tamaños, medias y proporciones, junto con sus intervalos de confianza; la formulación de pruebas de hipótesis; la modelación mediante técnicas de regresión, y la visualización adecuada de los datos.

1. Introducción

El análisis de encuestas con diseños complejos cuenta con una trayectoria consolidada en la literatura estadística, sustentada en el enfoque de inferencia basado en el diseño de muestreo. Como señalan Särndal et al. (2003) y Gutiérrez (2016), este enfoque reconoce a la distribución de probabilidad inducida por el proceso de selección de la muestra como el único mecanismo probabilístico que rige la inferencia. Bajo este paradigma, las propiedades estadísticas de los estimadores (como el insesgamiento, la precisión y la consistencia) se evalúan con respecto a la distribución de todas las posibles muestras que el diseño puede generar, sin imponer supuestos distribucionales sobre la variable de interés.

En este marco, la estimación de varianzas ha ocupado un lugar central y ha evolucionado en torno a tres grandes familias metodológicas complementarias. La primera, el método del último conglomerado (Hansen et al. 1953), simplifica la estructura multietápica de los diseños de muestreo al concentrar la variabilidad del estimador en las unidades primarias de muestreo (UPM), tratando la selección como si se realizara con reemplazo. La segunda, la linealización de Taylor (Woodruff 1971; Binder 1983), extiende este principio a parámetros no lineales (como medias, proporciones y razones) mediante una aproximación de primer orden que reduce el problema de estimación de la varianza al de un total. Finalmente, los métodos de replicación (Rust y Rao 1996) estiman la varianza a partir de la dispersión entre estimaciones obtenidas mediante réplicas sistemáticas de la muestra.

Paralelamente, en el ámbito de la modelización estadística, contribuciones fundamentales como las de Kish y Frankel (1974), Fuller (1975) y Binder (1983) sentaron las bases de la regresión ponderada y de la estimación de varianzas de coeficientes de regresión en diseños estratificados y de múltiples etapas. Sobre este desarrollo, el método de máxima pseudo-verosimilitud (MPV) (Skinner et al. 1989; Pfeffermann 1993) incorporó los pesos muestrales en la función de log-verosimilitud para producir estimadores consistentes bajo el diseño de muestreo, extendiendo así los modelos lineales generalizados de Nelder y Wedderburn (1972) al contexto de encuestas complejas.

Desde una perspectiva socioeconómica, una referencia fundamental para el análisis de encuestas de hogares es el trabajo de Deaton (1997), que establece un puente entre la teoría estadística, el análisis económico y las necesidades de información para el diseño y la evaluación de políticas públicas. En su libro, el autor articula los principios del muestreo con las herramientas de la microeconometría aplicada, explica cómo deben incorporarse las características del diseño muestral en la estimación y la inferencia, y desarrolla métodos para estudiar, a partir de microdatos, el bienestar, la pobreza, la desigualdad, los patrones de consumo, la demanda de los hogares y las decisiones de ahorro.

Heeringa et al. (2017) y Valliant et al. (2018) han sintetizado estas contribuciones en un marco analítico unificado que integra de manera coherente el diseño muestral, la ponderación y la modelización, constituyéndose en referencias estándar para la práctica contemporánea del análisis de encuestas complejas.

Este documento está dirigido a quienes analizan datos de encuestas de hogares, incluidos los equipos técnicos de las oficinas nacionales de estadística y otras instituciones públicas, así como docentes y profesionales de universidades, organismos internacionales y centros de investigación. Se presupone una formación en estadística o ciencia de datos, o experiencia profesional equivalente, con conocimientos básicos de teoría de muestreo, regresión lineal y logística, y un manejo introductorio de `R`. Su propósito es fortalecer las capacidades para estimar indicadores, evaluar su precisión y analizar relaciones entre variables incorporando el diseño muestral, tanto en la elaboración de resultados estadísticos oficiales como en el uso de microdatos para la investigación.

1.1. Justificación

A pesar de la riqueza metodológica disponible en la literatura especializada, persiste una brecha significativa entre el estado del arte y la práctica cotidiana del análisis de encuestas en la región. Una de las principales manifestaciones de esta brecha se relaciona con el acceso y uso del software estadístico. Algunos textos de referencia ampliamente reconocidos en el análisis de encuestas, como Cochran (1977) y Särndal et al. (2003), constituyen fuentes fundamentales desde el punto de vista teórico; sin embargo, no presentan ejemplos de aplicación real con software estadístico. Otros documentos están orientados principalmente hacia software con licencia, como `SAS`, `Stata` o `SPSS`, o bien no logran integrarse plenamente con un ecosistema computacional de software libre como `R`. En contraste, muchos tutoriales disponibles en línea sobre análisis de encuestas suelen privilegiar los aspectos operativos del software, pero rara vez alcanzan el nivel de profundidad conceptual necesario para un uso adecuado y responsable en la producción de estadísticas oficiales.

Adicionalmente, existe una fragmentación metodológica importante entre los distintos componentes que intervienen en el análisis de encuestas complejas. Con frecuencia, los fundamentos del diseño muestral, la gestión computacional de los datos, la estimación de parámetros descriptivos e inferenciales con corrección por diseño son abordados de manera separada, dificultando la construcción de flujos de trabajo integrales y reproducibles. En este contexto, el presente texto propone una integración coherente de estos elementos dentro de un único marco analítico implementado completamente en `R`.

Otro aspecto relevante corresponde a la contextualización regional de los ejemplos y aplicaciones. Una proporción considerable de los textos de referencia utiliza bases de datos foráneas, lo que limita parcialmente su aplicabilidad inmediata en América Latina. Con el propósito de acercar los contenidos a las realidades estadísticas de la región, este documento emplea una base de datos nativa de `R`, diseñada para replicar la estructura tradicional de las encuestas de hogares latinoamericanas y, por tanto, proporcionar ejemplos más cercanos a los problemas enfrentados por las oficinas nacionales de estadística y los equipos técnicos de la región. La base permite ilustrar la organización y el análisis de este tipo de encuestas; sus valores y composición son sintéticos y no buscan reproducir la realidad social de un país específico.

Finalmente, este documento constituye en sí mismo un ejercicio de investigación reproducible. El documento integra explicaciones, ecuaciones y código en R, de modo que el lector puede reproducir los cálculos y generar las tablas y los gráficos de los ejemplos. De esta manera, el lector no solo puede estudiar los métodos presentados, sino también replicarlos, modificarlos y adaptarlos a sus propios contextos y bases de datos, fortaleciendo así las capacidades analíticas y la transparencia en la producción estadística.

1.2. Uso del software R para el análisis de encuestas

La elección de `R` como entorno computacional para este documento no es arbitraria. `R` reúne al menos tres características que lo convierten en una opción idónea para el análisis de encuestas de hogares en el contexto latinoamericano.

En primer lugar, su condición de acceso libre. A diferencia de otros programas con costos de licencia que pueden resultar prohibitivos para muchas oficinas nacionales de estadística en países en desarrollo, `R` se distribuye bajo licencia GNU, lo que garantiza que los métodos presentados en este documento sean plenamente accesibles y replicables, independientemente de las restricciones presupuestarias que algunas veces aquejan a las instituciones públicas.

En segundo lugar, destaca su ecosistema especializado. El paquete `survey` (Lumley et al. 2026) implementa estimadores, calibración, linealización, replicación, modelos y pruebas ajustadas a diseños complejos. El paquete `srvyr` (Freedman Ellis y Schneider 2026) incorpora la sintaxis de `tidyverse` a estas herramientas. Su primera aplicación detallada aparece en el Capítulo 3 y se retoma en el Capítulo 4. Paquetes complementarios como `TeachingSampling` (Gutiérrez 2020) y `convey` (Jacob et al. 2024) amplían las posibilidades de análisis.

Finalmente, `R` ofrece una sólida integración con herramientas de reproducibilidad científica. En particular, su combinación con `Quarto` y con el ecosistema de `R Markdown`, que incluye herramientas como `bookdown`, permite generar documentos reproducibles en los que los resultados, las tablas y las figuras se generan directamente a partir del código fuente. Esta capacidad resulta especialmente relevante en el ámbito de las estadísticas oficiales, donde la trazabilidad y la transparencia metodológica son requisitos fundamentales.

A lo largo del libro se cargan librerías mediante `library()`, suponiendo que el lector ya tiene instalados los paquetes correspondientes en su computador. Antes de ejecutar los ejemplos, se recomienda consultar la sección Preparación del entorno de trabajo del apéndice A1, donde se reúnen los códigos para instalar los paquetes utilizados en el libro y cargarlos en la sesión de `R`. La instalación se realiza una vez, mientras que la carga debe repetirse en cada nueva sesión de trabajo.

1.3. Estructura del documento

Este documento está organizado siguiendo una progresión lógica que va desde los fundamentos conceptuales del muestreo hasta aplicaciones más avanzadas del modelamiento estadístico. La secuencia responde a una progresión didáctica: cada capítulo retoma herramientas anteriores y las aplica a preguntas más complejas, de modo que el lector pueda transitar de los principios básicos hacia herramientas analíticas más sofisticadas de manera coherente.

Las aplicaciones empíricas del libro se concentran en el ingreso, el gasto, la pobreza y el empleo, como ámbitos de interés frecuente en las encuestas de hogares. También se presentan algunos ejemplos demográficos sobre la estructura de la población por edad y sexo y las razones de dependencia demográfica y económica potencial. Esta selección permite ilustrar los procedimientos mediante ejemplos conectados entre sí y facilitar su reproducción e interpretación. Sin embargo, las herramientas presentadas pueden extenderse al análisis de otras variables investigadas en estas encuestas, como las relacionadas con educación, salud, vivienda y acceso a servicios, siempre que se consideren la población objetivo, la definición de los indicadores y las características del diseño muestral correspondiente.

El alcance de este libro se concentra en la etapa de análisis estadístico y supone la disponibilidad de un archivo de microdatos que contiene los factores de expansión y las variables necesarias para especificar el diseño muestral. En este sentido, la obra se concibe como un complemento de CEPAL (2023), donde se desarrollan en detalle los aspectos metodológicos y operativos correspondientes a las etapas previas de producción de una encuesta[1]. Ambas publicaciones deben entenderse como obras complementarias, cuya articulación permite abordar de manera integral los principales desafíos metodológicos de la producción y el análisis de encuestas de hogares.

En primer lugar, se abordan los fundamentos del diseño muestral. El análisis adecuado de una encuesta comienza necesariamente con la comprensión de su diseño probabilístico. Antes de estimar cualquier parámetro, el analista debe familiarizarse con tres elementos constitutivos: la población objetivo, entendida como el conjunto de unidades sobre las cuales se desean hacer inferencias; el marco de muestreo, que corresponde al dispositivo que permite ubicar e identificar dichas unidades; y las unidades de muestreo en cada etapa del diseño. Estos componentes determinan tanto la validez como el alcance de las inferencias posteriores. A continuación, se introducen los elementos computacionales que permiten materializar estos conceptos en un entorno aplicado. El documento introduce el manejo y transformación de variables mediante un ambiente de programación adecuado para la incorporación del diseño de muestreo, que constituye el eje central del flujo de análisis y garantiza que todas las operaciones estadísticas respeten dicha estructura.

Con el diseño de muestreo correctamente especificado, el documento comienza el análisis aplicado con variables categóricas: tamaños poblacionales, proporciones y asociaciones entre categorías. A continuación, extiende estas herramientas a variables continuas mediante totales, medias, razones y medidas de distribución y desigualdad. En ambos casos se estudian la precisión, las pruebas de hipótesis y los contrastes incorporando las características del diseño muestral.

Posteriormente, se desarrolla el análisis de relaciones entre variables a través del modelamiento estadístico, yendo más allá de la estadística descriptiva hacia un enfoque analítico e inferencial. En particular, se abordan los modelos de regresión lineal bajo diseños complejos, donde la incorporación explícita de los pesos muestrales resulta fundamental para obtener estimadores aproximadamente insesgados respecto al diseño. Este contexto pone de manifiesto la discusión entre el enfoque basado en el diseño y el enfoque basado en los modelos. Adicionalmente, los modelos lineales generalizados permiten analizar respuestas con distintas distribuciones, mientras que los modelos multinivel incorporan estructuras de agrupación entre las observaciones.

La organización de los capítulos sigue la arquitectura conceptual descrita anteriormente, avanzando desde los fundamentos hacia las aplicaciones más complejas. De esta forma, el capítulo 2 presenta los conceptos básicos para el análisis de encuestas de hogares, se explican los elementos centrales de un diseño de muestreo (estratificación, conglomeración y pesos de muestreo desiguales) y se introducen los principales estimadores de muestreo para totales, desarrollando los fundamentos para estimar su varianza y obtener intervalos de confianza.

En el Capítulo 3 se presenta el primer flujo completo de análisis en R: lectura e inspección de la encuesta, especificación del diseño, creación de variables y definición de dominios. Se estiman tamaños

[1] Procedimientos como la definción de los errores no muestrales, la construcción y documentación de los factores de expansión de personas y hogares, la verificación de la coherencia de los datos ponderados y la definición de criterios institucionales para la publicación de estimaciones por dominio. Estos aspectos, ampliamente abordados en CEPAL (2023), constituyen el marco metodológico sobre el cual se sustentan los procedimientos de análisis desarrollados en este libro.

poblacionales y proporciones, se estudian tablas cruzadas y razones de odds, y se introducen pruebas de hipótesis y contrastes con sus medidas de precisión. Los resultados se comunican mediante gráficos de barras y mapas temáticos.

En el Capítulo 4 se amplía ese flujo al análisis de variables numéricas. Se estudian totales, medias, razones, dispersión, percentiles, el coeficiente de Gini y la curva de Lorenz, así como la asociación lineal entre ingreso y gasto. Las pruebas y los contrastes ya utilizados para proporciones se extienden a medias y razones. El capítulo concluye con histogramas, diagramas de caja y diagramas de dispersión que preparan el paso a los modelos de regresión.

El capítulo 5 se enfoca en analizar relaciones entre variables y construir modelos estadísticos válidos bajo diseños complejos, cuando los supuestos tradicionales de independencia e idéntica distribución no se cumplen. Se presenta la evolución del problema desde los aportes iniciales hasta los desarrollos más recientes, y discute las implicaciones de trabajar con datos de encuestas en el contexto de los modelos de regresión. El capítulo también aborda la realización de pruebas de hipótesis, el diagnóstico de residuales y la identificación de observaciones influyentes.

En el capítulo 6 se extiende la modelación estadística a variables que no siguen una distribución normal (como variables binarias, multinomiales y estrictamente positivas). Para ello, se presenta un marco unificado basado en los modelos lineales generalizados, y se contrasta el enfoque clásico de máxima verosimilitud con el de máxima pseudo-verosimilitud, basado en ecuaciones de estimación ponderadas que incorporan los pesos muestrales.

En el capítulo 7 se introducen los modelos multinivel para analizar hogares agrupados en estratos. Mediante ejemplos de regresión lineal y logística, se estudian interceptos y pendientes que varían entre grupos y se examina cómo esta estructura permite representar la heterogeneidad entre estratos. También se explican las limitaciones de los ajustes utilizados para incorporar el diseño muestral.

Adicionalmente, el primer apéndice introduce el manejo de bases de datos en `R` mediante el entorno `tidyverse`, con énfasis en el paquete `dplyr`. A partir de una población sintética (`BigCity` del paquete `TeachingSampling`), se presenta un flujo básico de trabajo que incluye la carga de librerías, la inspección inicial de la base, el uso del operador de encadenamiento `%>%` (*pipeline*) y la aplicación de los principales verbos de `dplyr`: `filter()`, `select()`, `arrange()`, `mutate()`, `summarise()` y `group_by()`. El capítulo muestra cómo seleccionar registros y variables, ordenar datos, crear nuevas variables y producir resúmenes descriptivos, explicando tanto la lógica de los códigos como la interpretación de sus salidas. Este apéndice puede consultarse primero si el lector tiene poca experiencia usando `R`.

El segundo apéndice aborda la inferencia en poblaciones finitas y la diferencia entre la inferencia basada en modelos y la inferencia basada en el diseño muestral. A partir de ejemplos de simulación, muestra que en las encuestas complejas la aleatoriedad proviene principalmente de la selección de la muestra y que, por tanto, las estimaciones deben incorporar las probabilidades de inclusión y los pesos muestrales. Se presenta el método de máxima pseudo-verosimilitud como una extensión adecuada para datos de encuestas, donde cada contribución individual se pondera según sus probabilidades de inclusión.

Finalmente, el tercer apéndice aborda el tratamiento de los datos faltantes en las encuestas de hogares. Describe los diferentes mecanismos de ausencia de respuesta e ilustra sus efectos sobre la distribución de los datos. Mediante ejemplos reproducibles en `R`, se presentan algunos de los métodos de imputación más comúnmente usados por las oficinas nacionales de estadística. Además, compara

los resultados obtenidos con los datos originales y muestra cómo combinar las estimaciones de la imputación múltiple considerando el diseño muestral.

El lector que recorra en orden los capítulos estará en la capacidad de analizar una encuesta de hogares, al entender su diseño, procesar sus datos, estimar los indicadores de interés con la precisión estadística correcta y modelar las relaciones entre variables de manera válida bajo el diseño complejo. Esa capacidad es, en esencia, lo que la producción rigurosa de estadísticas sociales exige.

2. Conceptos básicos en encuestas de hogares

Las encuestas de hogares constituyen una de las principales herramientas para comprender la realidad social y económica de una población. A partir de ellas se obtiene información esencial sobre las condiciones de vida, el empleo, la educación, la salud y otros aspectos que orientan la formulación de políticas públicas y la toma de decisiones basadas en evidencia. El análisis riguroso de estas encuestas es fundamental para estudiar la realidad social, económica y demográfica de una población, así como para monitorear el progreso de los países en el cumplimiento de la Agenda 2030 y los Objetivos de Desarrollo Sostenible (Naciones Unidas 2021). Sin embargo, la validez de los análisis no depende únicamente del tamaño de la muestra o de la calidad de la recolección de datos, sino también de la manera en que la encuesta fue diseñada y de cómo dicho diseño se incorpora en el análisis estadístico. Ignorar el diseño de muestreo y aplicar métodos de análisis tradicionales (que asumen una muestra aleatoria simple) puede conducir a estimaciones sesgadas, errores en la inferencia y por ende conclusiones equivocadas.

En la práctica, las encuestas de hogares suelen utilizar diseños de muestreo complejos que combinan la estratificación, junto con la selección de informantes en varias etapas y ajustes a los factores de expansión que generan ponderadores desiguales. Este tipo de diseños busca optimizar recursos y mejorar la precisión de las estimaciones, e ignorar estas características invalida la representatividad de la información producida. Por ende, para obtener conclusiones válidas sobre la población, es necesario reconocer que la muestra no proviene de una selección aleatoria cualquiera, sino de un plan probabilístico cuidadosamente definido.

2.1. Población objetivo y unidades de muestreo

Gambino y Nascimento Silva (2009) mencionan que, desde la popularización de las encuestas de hogares en la década de 1940, se han evidenciado diversas tendencias asociadas a los avances tecnológicos tanto en las oficinas e institutos nacionales de estadística como en la sociedad en general, las cuales se aceleraron con la introducción de las herramientas computacionales. En las últimas décadas, la realización de encuestas se ha consolidado en distintos campos, especialmente en el sector gubernamental, mediante la producción de estadísticas oficiales que permiten el seguimiento de las políticas públicas. Asimismo, el uso del muestreo se ha extendido al ámbito académico, al sector privado y a los medios de comunicación, donde constituye una herramienta fundamental para la generación y el análisis de información (Groves et al. 2009).

Toda encuesta se encuentra asociada a una población finita compuesta por individuos o elementos sobre los cuales se desea obtener información. El conjunto de unidades sobre las que se producirán estimaciones y resultados recibe el nombre de población objetivo. Asimismo, las encuestas definen unidades de análisis, que corresponden a los distintos niveles de desagregación para los cuales se presentan estadísticas de interés, como personas, hogares o viviendas. En este contexto, el muestreo surge como una respuesta a la necesidad de obtener información estadística precisa sobre una población objetivo sin recurrir a la realización de un censo completo. Como señala Gutiérrez (2016),

una encuesta por muestreo estudia una parte de la población con el propósito de realizar inferencias sobre su conjunto.

Conviene distinguir entre diferetnes conceptos. La unidad de análisis es aquella sobre la que se formulan e interpretan los resultados; la unidad de observación es cada registro de la base de datos; y la unidad representada por el factor de expansión es la población a la que corresponde el peso de ese registro. En los ejemplos que se muestran en este libro, cada registro corresponde a una persona, aunque algunas variables describen al hogar y se repiten entre sus integrantes. Cuando el objetivo es analizar hogares, se selecciona una persona principal por hogar (Alexander 1987).

2.2. Diseños de muestreo

Las encuestas de hogares suelen basarse en diseños de muestreo complejos, caracterizados por tres elementos principales: factores de expansión desiguales, selección de unidades mediante conglomerados y múltiples etapas, y estratificación de la población. Estas características determinan la manera en que cada observación contribuye a las estimaciones y afectan tanto la estimación puntual como su precisión; por esta razón, deben incorporarse explícitamente en su análisis estadístico.

El principio de representatividad (Gutiérrez 2016) indica que cada unidad de la población posee una probabilidad conocida y distinta de cero de ser incluida en la muestra. Este paradigma constituye la principal garantía de que los resultados puedan generalizarse a la población de referencia. Bajo este enfoque, los estimadores de muestreo resultan ser insesgados (o aproximadamente insesgados) con respecto al diseño de muestreo, y no es necesario asumir ningún supuesto sobre distribuciones específicas para la variable de interés. Esta característica confiere a la inferencia basada en el diseño un carácter robusto y ampliamente aceptado en el análisis de encuestas de hogares.

2.2.1. Factores de expansión

Los factores de expansión (ponderadores, o pesos de muestreo) indican cuántas unidades de la población representa cada unidad seleccionada. En su forma más básica, se obtienen como el inverso multiplicativo de la probabilidad de inclusión de un elemento. Por consiguiente, cuando las unidades tienen probabilidades de selección diferentes, también reciben factores de expansión desiguales. Al especificar correctamente estos factores en el análisis, las estimaciones tienen en cuenta las particularidades del diseño y reflejan adecuadamente la estructura de la población.

No obstante, los pesos básicos de muestreo suelen requerir ajustes adicionales con el fin de mejorar la precisión y la robustez de las estimaciones. Uno de los ajustes más comunes corresponde al tratamiento de la no respuesta, mediante el cual los pesos de las unidades que sí respondieron se incrementan para representar también a aquellas unidades seleccionadas que no participaron en la encuesta, contribuyendo así a reducir posibles sesgos. Otro ajuste ampliamente utilizado es la calibración (Deville y Särndal 1992), que consiste en modificar los pesos para garantizar que las sumas ponderadas de ciertas variables auxiliares, como la edad o el sexo, coincidan con totales poblacionales conocidos provenientes de censos o proyecciones demográficas.

Los ajustes de los pesos no solo corrigen las imperfecciones derivadas de la no respuesta o la cobertura incompleta, sino que también fortalecen la coherencia entre la muestra y la población objetivo, garantizando que las inferencias sean estadísticamente válidas y comparables con otras fuentes oficiales (Kalton y Flores-Cervantes 2003). Los pesos calibrados tienden a reducir la varianza de

las estimaciones, mejorando su precisión sin alterar los totales poblacionales conocidos (Särndal y Lundström 2005). En consecuencia, la calibración no solo corrige, sino que también optimiza el uso de la información disponible, permitiendo obtener resultados más precisos.

Valliant y Dever (2017) presentan un marco sistemático para construir, ajustar y evaluar los pesos de una encuesta compleja, que abarca desde el cálculo de los pesos iniciales hasta los ajustes por falta de respuesta, la calibración con información auxiliar y su consideración en la estimación de varianzas. En consonancia con este enfoque, el paquete `weightflow` permite implementar estas etapas mediante un flujo de trabajo reproducible (Ferreira 2026).

Como muestran Korn y Graubard (1995), las estimaciones ponderadas y no ponderadas pueden diferir sustancialmente, lo que evidencia la importancia de utilizar métodos de análisis coherentes con el diseño de la encuesta. Naciones Unidas (2026, cap. 9) presenta el siguiente ejemplo. Supóngase un país conformado por dos regiones: la Región A, con 100 habitantes y un ingreso promedio de \$10.000, y la Región B, con 900 habitantes y un ingreso promedio de \$2.000. El ingreso promedio verdadero de la población es:

$$\theta = \frac{(100 \times 10.000) + (900 \times 2.000)}{100 + 900} = 2.800$$

Si se seleccionan 50 personas en cada región y se ignora el diseño de muestreo, asignando el mismo peso a todas las observaciones, el promedio estimado sería:

$$\hat{\theta} = \frac{(50 \times 10.000) + (50 \times 2.000)}{100} = 6.000$$

En este caso, la estimación sobrestima considerablemente el ingreso nacional, ya que la Región A, que representa únicamente el 10 % de la población, termina influyendo tanto como la Región B, que concentra el 90 %. En cambio, al aplicar pesos proporcionales a los tamaños poblacionales (1 para la Región A y 9 para la Región B), se obtiene la siguiente estimación:

$$\hat{\theta} = \frac{(1 \times 50 \times 10.000) + (9 \times 50 \times 2.000)}{(1 \times 50) + (9 \times 50)} = 2.800$$

Este resultado coincide con el valor verdadero de la población y muestra cómo el uso adecuado de los pesos corrige el sesgo introducido por un análisis que ignora el diseño de muestreo.

2.2.2. Conglomeración y selección en múltiples etapas

En las encuestas de hogares con diseños complejos, los marcos de muestreo suelen estar basados en áreas geográficas. Es decir, se construyen a partir de estructuras espaciales que vinculan a los hogares o personas con zonas delimitadas del territorio. Este tipo de marco de áreas facilita la organización territorial en unidades más manejables y permite implementar procesos de selección en varias etapas, manteniendo los principios del muestreo probabilístico. En estos diseños, las unidades primarias de muestreo (UPM) suelen corresponder a sectores censales, áreas de enumeración u otras divisiones territoriales, dentro de las cuales se construyen o actualizan listados de viviendas para las etapas posteriores de selección (Naciones Unidas 2005, cap. 4).

En la práctica, este tipo de diseños permite reducir los costos operativos y facilitar el trabajo de campo; sin embargo, también tiene implicaciones importantes sobre la precisión de las estimaciones. Cuando los hogares pertenecientes a un mismo conglomerado comparten características similares, la información adicional que aporta cada nueva observación dentro del conglomerado disminuye.

Por ejemplo, supóngase una encuesta que selecciona 100 conglomerados y, dentro de cada uno, 10 hogares, obteniendo así una muestra total de 1.000 hogares. Si los hogares de un mismo conglomerado presentan comportamientos muy parecidos (por ejemplo, niveles de ingreso cercanos, o todos cuentan con acceso a electricidad), la variabilidad efectiva de los datos en la muestra se reducirá considerablemente. En términos prácticos, la precisión obtenida podría ser equivalente a la de una muestra aleatoria simple de apenas 100 hogares (Kish y Frankel 1974). Analizar los 1.000 hogares como si fueran observaciones completamente independientes, ignorando la estructura de conglomeración, conduce a una subestimación de los errores estándar y, en consecuencia, a intervalos de confianza artificialmente estrechos y conclusiones potencialmente erróneas.

2.2.3. Estratificación

La estratificación consiste en dividir previamente la población en grupos mutuamente excluyentes, denominados estratos, y seleccionar una muestra independiente dentro de cada uno de ellos (Särndal et al. 2003). Los estratos pueden definirse a partir de criterios geográficos, administrativos, demográficos o socioeconómicos. En las encuestas de hogares, es frecuente utilizar combinaciones de región, área urbana o rural y características socioeconómicas para formar los estratos del diseño (CEPAL 2023).

Este procedimiento permite garantizar la presencia en la muestra de grupos relevantes que podrían quedar insuficientemente representados bajo una selección no estratificada. También puede mejorar la precisión de las estimaciones cuando las unidades pertenecientes a un mismo estrato son relativamente homogéneas y existen diferencias importantes entre los estratos. La asignación de la muestra entre ellos puede realizarse de manera proporcional a su tamaño o mediante asignaciones no proporcionales orientadas a satisfacer objetivos específicos de precisión (Cochran 1977; Gutiérrez 2016).

La estratificación también puede producir probabilidades de selección diferentes entre las unidades. Por ejemplo, una región pequeña puede recibir una fracción de muestreo mayor para asegurar un número suficiente de observaciones, mientras que una región más poblada puede recibir una fracción menor. Esta asignación desigual genera factores de expansión diferentes y refuerza la necesidad de considerar conjuntamente los estratos y los pesos de muestreo durante el análisis (Naciones Unidas 2005).

2.3. Estimadores de muestreo

Al analizar datos provenientes de encuestas complejas, es fundamental definir con precisión el parámetro de interés. Este corresponde a una cantidad fija, aunque generalmente desconocida, que se obtiene a partir de los valores de todas las unidades que conforman la población finita, denotada por U, y que resume alguna de sus características. Entre los parámetros más comunes se encuentran las proporciones, los totales, las medias, las razones, entre otros. Dado que, en la práctica, no es

posible observar a toda la población, las encuestas por muestreo permiten inferir estos parámetros a partir de una muestra, denotada como s.

En el muestreo probabilístico, cada unidad de la población tiene una probabilidad de inclusión conocida y mayor que cero de ser seleccionada en la muestra. Estas probabilidades constituyen la base para el cálculo de los pesos básicos de muestreo, los cuales se utilizan posteriormente para estimar los parámetros poblacionales mediante sumas ponderadas de los datos recolectados en la encuesta. Cuando el diseño y la selección se implementan correctamente, los estimadores resultantes son insesgados respecto del diseño; es decir, su valor esperado, calculado sobre todas las muestras posibles, coincide exactamente con el parámetro poblacional (Särndal et al. 2003).

La estimación de totales constituye un paso central en el análisis estadístico aplicado a poblaciones finitas. Gran parte de los indicadores de interés para la formulación de políticas públicas (como por ejemplo, el número de personas en situación de pobreza, el total de ocupados o el gasto agregado de los hogares) se derivan de un total poblacional. Por esta razón, comprender cómo se definen y estiman los totales resulta fundamental para garantizar la calidad y pertinencia de la información producida.

En términos formales, si y_k denota el valor de una variable de interés para la unidad $k \in U$, el total poblacional se define como

$$t_y = \sum_U y_k$$

Denotando a N como el tamano de la población, la media poblacional se define como $\bar{y} = \frac{t_y}{N}$. Dado que en la práctica solo se observa una muestra $s \subset U$, es necesario recurrir a estimadores que incorporen el diseño de muestreo. Por ejemplo, el estimador de Horvitz–Thompson (Horvitz y Thompson 1952) se expresa como

$$\hat{t}_y = \sum_{k \in s} d_k y_k \tag{2.1}$$

donde $d_k = 1/\pi_k$ corresponde al peso básico proveniente del diseño de muestreo y $\pi_k = \Pr(k \in s)$ es la probabilidad de inclusión de primer orden asociada al individuo k. En la práctica, los pesos básicos d_k suelen ajustarse para reflejar procesos adicionales como el ajuste por no respuesta o la calibración a totales poblacionales conocidos, obteniendo así nuevos pesos ajustados, denotados como w_k para todo $k \in s$. El uso de los pesos w_k permite mejorar la precisión y reducir sesgos en las estimaciones, especialmente cuando existen fuentes auxiliares de información confiables (Deville y Särndal 1992).

Toda estimación a partir de una muestra conlleva incertidumbre, puesto que las estimaciones varían de una muestra a otra debido a la propiedad de aleatoriedad del diseño. Esta incertidumbre se cuantifica mediante la varianza del estimador con la cual se puede calcular el error estándar (se) o el coeficiente de variación (cv). Estos indicadores son herramientas indispensables para evaluar la precisión de los totales estimados y, por tanto, para interpretar de manera adecuada la información estadística. Por ejemplo, un estimador insesgado para la varianza del estimador de Horvitz–Thompson (ecuación 2.1) puede expresarse como:

$$\widehat{Var}_p(\hat{t}_y) = \sum_{k \in s} \sum_{l \in s} (d_k d_l - d_{kl}) y_k y_l \tag{2.2}$$

En donde $d_{kl} = 1/\pi_{kl}$ y $\pi_{kl} = \Pr(k, l \in s)$ representan probabilidades de inclusión conjuntas. Para garantizar el insesgamiento en ecuación 2.2, el diseño muestral debe satisfacer $\pi_{kl} > 0$ para todo par de unidades $k, l \in U$.

Para comprender de manera más concreta la relevancia de considerar el diseño muestral en la estimación de totales y de sus varianzas, analicemos un ejemplo de Naciones Unidas (2026) que permite visualizar cómo el método de estimación se ajusta al esquema de selección adoptado. Suponga una población finita de tamaño $N = 6$, de la cual se selecciona una muestra aleatoria simple (MAS) sin reemplazo de tamaño $n = 3$. En dicha muestra se observan los valores $(y_1 = 10, y_2 = 14, y_3 = 18)$. Bajo este diseño, el estimador de Horvitz–Thompson del total poblacional se define como la suma de los valores observados divididos por sus probabilidades de inclusión, y su varianza estimada se obtiene a partir de las covarianzas inducidas por el proceso de selección. De esta forma, la estimación del total poblacional es $\hat{t}_y = 84$.

Como señala Gutiérrez (2016), para este diseño de muestreo particular, la expresión general de la varianza presentada en ecuación 2.2 se reduce a:

$$\widehat{Var}_{MAS}(\hat{t}_y) = \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S^2_{y_s}$$

donde $S^2_{y_s}$ corresponde a la varianza muestral de los valores observados. Sustituyendo los valores del ejemplo en la expresión anterior, se obtiene $\widehat{Var}_{MAS}(\hat{t}_y) = 96$. En contraste, si se omitiera la corrección por población finita, la varianza se calcularía mediante la expresión $\frac{N^2}{n} S^2_{y_s} = 192$. En este ejemplo, esa omisión multiplica por 2 la varianza estimada y produce un intervalo de confianza innecesariamente más amplio.

2.4. El efecto de diseño (DEFF)

De acuerdo con Kish (1965, 258), el efecto del diseño (*design effect*, DEFF) se define como el cociente entre la varianza de un estimador $\hat{\theta}$ bajo un diseño de muestreo complejo y la varianza que tendría ese mismo estimador bajo un muestreo aleatorio simple (MAS) con igual tamaño de muestra. Su estimación se expresa como:

$$\widehat{DEFF} = \frac{\widehat{Var}_p(\hat{\theta})}{\widehat{Var}_{MAS}(\hat{\theta})} \tag{2.3}$$

En donde, $\widehat{Var}_p(\hat{\theta})$ corresponde a la varianza estimada de $\hat{\theta}$ bajo el diseño complejo $p(\cdot)$, mientras que $\widehat{Var}_{MAS}(\hat{\theta})$ representa la varianza estimada del mismo estimador bajo un diseño MAS con igual tamaño muestral.

Este indicador permite cuantificar cuánto aumenta la varianza debido a la conglomeración y otras características propias de los diseños complejos en comparación con un muestreo simple. Según Naciones Unidas (2009, 40), el DEFF puede entenderse de tres maneras: como el factor de incremento

de la varianza frente al MAS, como una medida de la pérdida relativa de precisión o como una indicación del aumento en el tamaño de la muestra que sería necesario en un diseño complejo para alcanzar el mismo nivel de varianza que en un MAS. Según Park et al. (2003), el efecto del diseño de una encuesta está supeditado a los siguientes tres factores:

- Ponderadores desiguales: la presencia de pesos muestrales no uniformes suele incrementar ligeramente la varianza; por ello, el uso de pesos uniformes resulta ventajoso y explica por qué los diseños auto-ponderados son preferidos en las encuestas de hogares.
- Estratificación: cuando se aplica correctamente, puede disminuir la varianza, aunque en la práctica su efecto reductor suele ser moderado.
- Muestreo en varias etapas: generalmente incrementa la varianza, ya que las unidades dentro de un mismo conglomerado tienden a ser más homogéneas entre sí que en comparación con las de otros conglomerados.

En el análisis de encuestas, el DEFF constituye un indicador esencial para evaluar la precisión y eficiencia de las estimaciones, así como para orientar la planificación de futuros estudios. Un valor elevado evidencia que el diseño complejo introduce un incremento de la varianza, reduciendo la precisión de los resultados. Por el contrario, un valor cercano a uno indica que el diseño tiene un efecto mínimo sobre la varianza. Esta información permite a los lectores identificar si es necesario ajustar la ponderación, optimizar la estratificación o modificar el tamaño de muestra para aumentar la eficiencia en levantamientos posteriores.

La interpretación de un DEFF elevado debe realizarse con cautela, pues no necesariamente indica que el diseño de muestreo sea inadecuado. Su magnitud debe evaluarse en función del contexto y de las condiciones operativas de la encuesta. Aunque Naciones Unidas (2005) afirma que un valor superior a 2.5 o 3 podría considerarse inicialmente preocupante, este puede responder a restricciones presupuestarias, dificultades logísticas o decisiones orientadas a facilitar la participación de los informantes.

Por ejemplo, en algunas encuestas de hogares puede ser necesario seleccionar únicamente a una fracción de las personas elegibles dentro de cada vivienda. Asimismo, los problemas de cobertura y las tasas elevadas de no respuesta pueden incrementar la variabilidad de los pesos muestrales y, por esta vía, aumentar el DEFF. Gutiérrez y Babativa-Márquez (2023) presentan un análisis detallado de los efectos del diseño en las encuestas de hogares de América Latina a partir de la información disponible en el Banco de Datos de Encuestas de Hogares (BADEHOG) de la CEPAL.

2.5. Inferencia en encuestas complejas

Tal como destacan Heeringa et al. (2017), el cálculo de totales y medias poblacionales, junto con sus varianzas, ha sido esencial para el desarrollo de la teoría del muestreo probabilístico y la interpretación adecuada de los resultados de encuestas de hogares. La determinación de los totales poblacionales constituye uno de los pilares fundamentales del análisis de encuestas. Tanto las medias como las proporciones y las razones se derivan de estos totales. Un total se define como la suma de una variable específica (por ejemplo, ingreso o gasto) a nivel de toda la población.

En el análisis de encuestas de hogares, es habitual estimar estadísticas descriptivas como totales, medias y razones, las cuales permiten sintetizar las principales características de la población y proporcionan información relevante para la toma de decisiones y monitoreo de indicadores. En este

apartado se presentan los fundamentos teóricos de la inferencia basada en el diseño de muestreo, necesarios para estimar adecuadamente los distintos parámetros de interés y evaluar la incertidumbre asociada a dichas estimaciones.

2.5.1. Estimación puntual

Una vez definidas la población objetivo, las variables de interés y el diseño muestral, se procede a estimar los parámetros poblacionales correspondientes. Para establecer la notación del libro, se utilizará la letra h para identificar los estratos; la letra i para representar las unidades primarias de muestreo (UPM) contenidas en cada estrato; y la letra k para denotar las unidades finales observadas, como hogares o personas. Además, con el propósito de simplificar la escritura a lo largo de este documento, a menos que se indique lo contrario, $\sum_h$ denotará la suma sobre todos los estratos de la población; $\sum_i$ representará la suma sobre todas las UPM seleccionadas en la muestra dentro del estrato h; y $\sum_k$ corresponderá a la suma sobre todos los elementos observados en la muestra de la UPM i, perteneciente al estrato h de la población de interés. Con esta notación, el estimador de un total poblacional puede expresarse como:

$$\hat{t}_y = \sum_h \sum_i \sum_k w_{hik}\, y_{hik}$$

En esta expresión, w_{hik} representa el factor de expansión de la unidad k, perteneciente a la UPM i del estrato h, mientras que y_{hik} corresponde al valor observado de la variable de interés para esa misma unidad.

2.5.2. Estimación de la varianza

Algunos parámetros de interés pueden expresarse como combinaciones lineales de varios parámetros poblacionales. Considérese, en particular, la función:

$$f(\theta_1, \dots, \theta_J) = \sum_{j=1}^{J} a_j \theta_j,$$

donde a_j son constantes conocidas y θ_j representa el j-ésimo parámetro poblacional. Si $\hat{\theta}_j$ es un estimador de θ_j, entonces el estimador muestral de $f(\theta_1, \dots, \theta_J)$ se define como:

$$\hat{f} = \sum_{j=1}^{J} a_j \hat{\theta}_j \tag{2.4}$$

De esta manera, su varianza puede expresarse como:

$$Var(\hat{f}) = \sum_{j=1}^{J} a_j^2 Var(\hat{\theta}_j) \; + \; 2 \sum_{j=1}^{J-1} \sum_{k>j}^{J} a_j a_k \, Cov(\hat{\theta}_j, \hat{\theta}_k). \tag{2.5}$$

Este resultado es especialmente relevante, pues abarca numerosos casos de interés práctico que se desarrollarán a lo largo de este documento. No obstante, la estimación de la varianza bajo diseños de muestreo complejos puede resultar difícil, ya que depende de las características particulares de cada diseño. Para abordar esta dificultad, se han desarrollado diversos enfoques metodológicos que permiten cuantificar adecuadamente la incertidumbre y evaluar la precisión de las estimaciones. Con el apoyo de software estadístico especializado, estos métodos pueden implementarse de manera eficiente y contribuir a la obtención de resultados rigurosos y confiables.

2.5.2.1. Último conglomerado

El método del último conglomerado es un enfoque ampliamente utilizado para estimar la varianza de totales en encuestas con diseños de muestreo estratificados y multietápicos. Desarrollado por Hansen et al. (1953), este método simplifica el tratamiento de las distintas etapas de selección al concentrar la estimación de la varianza en las unidades primarias de muestreo (UPM). Para su aplicación, se supone que, dentro de cada estrato, las UPM se seleccionan de manera independiente y con reemplazo, posiblemente con probabilidades desiguales. La aplicación de este método requiere disponer de estimadores insesgados del total de la variable de interés para cada UPM seleccionada. Asimismo, cuando el diseño incorpora estratificación en la primera etapa, es necesario contar con al menos dos UPM seleccionadas en cada estrato, para que sea posible estimar la variabilidad entre conglomerados dentro de este.

Considere un diseño de muestreo en múltiples etapas donde se seleccionan n_h UPM en el estrato h, $(h = 1, \dots, H)$. Una estimación del total de la variable de interés en la UPM i del estrato h es:

$$\hat{t}_{y_i} = \sum_{k \in s_{hi}} w_{hik}\, y_{hik}$$

En donde s_{hi} corresponde a la muestra de unidades en la UPM i del estrato h; por tanto, un estimador insesgado del total poblacional se expresaría como

$$\hat{t}_y = \sum_h \sum_i \hat{t}_{y_i}$$

Según el método del último conglomerado, suponiendo que $\hat{\bar{t}}_{y_h} = (1/n_h) \sum_i \hat{t}_{y_i}$ es la media muestral de los totales estimados de las UPM en el estrato h, un estimador aproximado de la varianza de $\hat{t}_y$ se obtiene mediante al siguiente expresión:

$$\widehat{Var}(\hat{t}_y) = \sum_h \frac{n_h}{n_h - 1} \sum_i (\hat{t}_{y_i} - \hat{\bar{t}}_{y_h})^2 \tag{2.6}$$

Para más detalles, véase Hansen et al. (1953, 258) o Wolter (2007). Aunque este método se propuso originalmente para calcular varianzas de estimadores de totales, el método puede combinarse con otras técnicas para derivar varianzas de otros parámetros poblacionales más complejos. Esta flexibilidad hace que el método sea aplicable a diversos contextos de análisis de encuestas de hogares.

Aunque los métodos más sofisticados que consideran todas las etapas del diseño pueden ofrecer estimaciones de varianza ligeramente más precisas, su aplicación requiere información más detallada y

mayor complejidad computacional. Por el contrario, el método del último conglomerado proporciona una aproximación confiable y eficiente, especialmente útil al estimar totales o medias en encuestas de hogares.

Un supuesto fundamental de esta técnica es que, dentro de cada estrato, las UPM se eligen de forma independiente y con reemplazo. En la práctica, la mayoría de las encuestas selecciona sus UPM sin reemplazo, generando diseños más eficientes. En consecuencia, las varianzas calculadas bajo la hipótesis de independencia constituyen aproximaciones a las verdaderas varianzas de muestreo. Cuando la fracción muestral es pequeña, dichas aproximaciones suelen ser suficientemente precisas para su utilización por parte de las oficinas nacionales de estadística o de otros analistas.

2.5.2.2. Ecuaciones de estimación y linealización de Taylor

Muchos parámetros poblacionales pueden expresarse como soluciones de ecuaciones de estimación que involucran totales poblacionales. Aunque los detalles técnicos pueden ser complejos, la idea fundamental es que los mismos principios utilizados para estimar totales pueden aplicarse también para la estimación de varianzas. Este marco general hace que el método sea sencillo y flexible, facilitando su implementación en softwares estadísticos como `R`. Una ecuación de estimación poblacional genérica puede expresarse de la siguiente manera:

$$\sum_{k \in U} z_k(\theta) = 0,$$

donde $z_k(\cdot)$ es una función de estimación evaluada para la unidad k y θ representa el parámetro poblacional de interés. Estas ecuaciones proporcionan un marco general para definir y calcular diversos parámetros de la población, como totales, medias y razones. Las siguientes formulaciones muestran cómo distintos parámetros de interés pueden expresarse mediante ecuaciones de estimación que comparten una estructura común.

- Para el total poblacional, se define $z_k(\theta) = y_k - \theta/N$, de manera que la ecuación de estimación es $\sum_{k \in U}(y_k - \theta/N) = 0$. La solución de esta ecuación conduce a $\theta = \sum_{k \in U} y_k = t_y$, es decir, al total poblacional.
- De forma similar, para la media poblacional se utiliza $z_k(\theta) = y_k - \theta$, y la ecuación $\sum_{k \in U}(y_k - \theta) = 0$ tiene como solución $\theta = \left(\sum_{k \in U} y_k\right)/N = \bar{Y}$, correspondiente a la media de la población.

La idea de definir parámetros poblacionales como soluciones de ecuaciones de estimación conduce naturalmente a un método general para obtener los estimadores de muestreo. Bajo un diseño de muestreo probabilístico, la suma poblacional $\sum_{k \in U} z_k(\theta)$ puede estimarse mediante su versión ponderada en la muestra. En particular, si w_k corresponde al factor de expansión de la unidad k, se tiene que $\sum_{k \in s} w_k z_k(\theta)$ es un estimador insesgado, bajo el diseño, de la ecuación poblacional. En consecuencia, el estimador de muestreo $\hat{\theta}$ se define como la solución de la ecuación muestral ponderada

$$\sum_{k \in s} w_k z_k(\hat{\theta}) = 0. \tag{2.7}$$

Bajo condiciones de regularidad, esta sustitución permite obtener estimadores consistentes de una amplia variedad de parámetros poblacionales (Binder 1983).

Asimismo, mediante la linealización de Taylor es posible aproximar un estimador no lineal por una expresión lineal cuya varianza puede calcularse con los métodos habituales para estimadores de totales. Este enfoque, introducido tempranamente para el análisis de estadísticas complejas (Woodruff 1952), constituye la base de numerosos procedimientos utilizados actualmente para estimar las varianzas de medias, razones, proporciones y otros estimadores no lineales. El procedimiento consiste en aplicar una expansión de Taylor de primer orden a la ecuación de estimación, de modo que el estimador original se sustituya por una aproximación lineal. Para un parámetro escalar definido como la solución de una ecuación de estimación muestral, un estimador consistente de su varianza puede expresarse como:

$$\widehat{Var}_p(\hat{\theta}) \approx [\hat{J}(\hat{\theta})]^{-1}\, \widehat{Var}_p\left[\sum_{k\in s} w_k\, z_k(\hat{\theta})\right] [\hat{J}(\hat{\theta})]^{-1} \tag{2.8}$$

donde

$$\hat{J}(\hat{\theta}) = \sum_{k\in s} w_k \left[\frac{\partial z_k(\theta)}{\partial \theta}\right]_{\theta=\hat{\theta}}$$

Este resultado muestra cómo la linealización de Taylor convierte la estimación de varianzas de parámetros complejos en un problema de estimación de totales. Por ejemplo, para el caso de la razón poblacional $\theta = \frac{t_y}{t_x}$ entre los totales t_y y t_x, se define $z_k(\theta) = y_k - \theta x_k$. Así, la ecuación de estimación muestral toma la siguiente forma

$$\sum_{k\in s} w_k z_k(\theta) = \sum_{k\in s} w_k\,(y_k - \theta x_k) = 0$$

La solución de esta ecuación corresponde al estimador de razón

$$\hat{\theta} = \frac{\sum_{k\in s} w_k y_k}{\sum_{k\in s} w_k x_k} = \frac{\hat{t}_y}{\hat{t}_x}$$

Dado que la derivada de la función de estimación con respecto a θ es $\frac{\partial z_k(\theta)}{\partial \theta} = -x_k$, entonces $\hat{J}(\hat{\theta}) = -\sum_{k\in s} w_k x_k = -\hat{t}_x$. Al sustituir este resultado en la expresión general (ecuación 2.8), se obtiene:

$$\widehat{Var}_p(\hat{\theta}) \approx \frac{1}{\hat{t}_x^2}\widehat{Var}_p\left[\sum_{k\in s} w_k\left(y_k - \hat{\theta} x_k\right)\right]$$

Esta expresión muestra que la estimación de la varianza de un estimador no lineal puede reducirse a la estimación de la varianza de un total ponderado de su variable linealizada. En consecuencia, pueden aplicarse los procedimientos habituales para estimar la varianza de totales, incorporando adecuadamente las características del diseño muestral.

2.5.2.3. Bootstrap

Como alternativa a los métodos analíticos, se desarrollaron los métodos de replicación, que generan múltiples conjuntos de pesos o réplicas de la muestra, calculan el estimador de interés en cada una de ellas y utilizan la variabilidad entre las estimaciones replicadas para aproximar la varianza del estimador original. Su principal ventaja es que pueden aplicarse de manera relativamente uniforme a una amplia variedad de parámetros, incluso cuando la derivación analítica de la varianza resulta difícil (Rust y Rao 1996; Wolter 2007).

Por ejemplo, el Bootstrap es una herramienta de replicación robusta y versátil. Originalmente introducido por Efron (1979) para datos que no provenían de encuestas, su adaptación más usada para encuestas de hogares es el Bootstrap de Reescalamiento propuesto por Rao et al. (1992). Este método se ajusta de manera óptima a diseños de muestreo estratificados y multietápicos, y es ampliamente empleado para la estimación de varianzas en encuestas complejas. El procedimiento consiste en generar muchas réplicas de la muestra original, simulando extracciones repetidas de la población. Cada réplica se construye mediante la creación de columnas adicionales de pesos de replicación en la base de datos, siguiendo este proceso:

- Para cada estrato, se seleccionan aleatoriamente las UPM con reemplazo; algunas pueden repetirse y otras no aparecer. Cada UPM elegida se incorpora con todas sus observaciones. Si el tamaño de la muestra de primera etapa en el estrato h es mayor[1] que dos ($n_h > 2$), el número de UPM seleccionadas por réplica es $n_h - 1$.
- Este proceso se repite muchas veces, habitualmente cientos, generando un gran número de réplicas. La cantidad de veces que una UPM i del estrato h aparece en la réplica r se denota $n_{hi}^{(r)}$, variando entre 0 y $n_h - 1$.
- A partir de cada réplica se calculan nuevos pesos bootstrap para todas las unidades, reflejando cuántas veces fue seleccionada su UPM. El peso de la unidad k en la réplica r se calcula como:

$$w_{hik}^{(r)} = w_{hik} \times \frac{n_h}{n_h - 1} \times n_{hi}^{(r)}$$

  Si los pesos originales incluyen ajustes por no respuesta o calibración, estos deben aplicarse también a cada conjunto de pesos bootstrap.
- Para cada réplica r, se calcula el parámetro de interés $\hat{\theta}^{(r)}$ usando los pesos bootstrap $w_{hik}^{(r)}$. Asumiendo que $\tilde{\theta} = \frac{1}{R}\sum_{r=1}^{R} \hat{\theta}^{(r)}$, entonces la varianza del estimador se aproxima mediante la variabilidad entre todas las réplicas:

$$\widehat{Var}_B(\hat{\theta}) = \frac{1}{R}\sum_{r=1}^{R}\left(\hat{\theta}^{(r)} - \tilde{\theta}\right)^2 \tag{2.9}$$

Este enfoque asegura que la dispersión entre réplicas capture fielmente la incertidumbre del parámetro. El Bootstrap ofrece múltiples ventajas, a pesar de requerir un mayor procesamiento computacional, es eficaz para diseños de encuesta complejos y permite estimar parámetros difíciles de calcular con métodos tradicionales, como medianas u otras estadísticas no lineales. La simplicidad del método facilita su aplicación incluso sin software estadístico especializado. No obstante, su uso no es recomendable en encuestas repetidas con muestras superpuestas ni en situaciones con fracciones de muestreo grandes y tamaños de muestra pequeños (Bruch et al. 2011).

[1] En el caso en que $n_h = 2$, se selecciona una UPM y se duplican sus pesos, mientras que la otra UPM recibe peso cero.

2.5.3. Intervalos de confianza

Además de producir estimaciones puntuales, uno de los objetivos fundamentales de una encuesta es cuantificar la incertidumbre asociada a dichas estimaciones. En este contexto, los intervalos de confianza permiten construir un rango de valores plausibles para el parámetro poblacional de interés, incorporando explícitamente la variabilidad introducida por el diseño muestral. Un intervalo de confianza aproximado de nivel $(1-\alpha)100\,\%$ para el parámetro poblacional θ se construye como:

$$\hat{\theta} \pm t_{1-\alpha/2,df} \times \sqrt{\widehat{Var}(\hat{\theta})} \tag{2.10}$$

donde $\hat{\theta}$ corresponde al estimador por muestreo del parámetro poblacional θ; $\widehat{Var}(\hat{\theta})$ representa el estimador de varianza bajo el diseño complejo de la encuesta; y $t_{1-\alpha/2,df}$ es el cuantil de la distribución t de Student con df grados de libertad (Fuller 2009). En encuestas complejas, los grados de libertad suelen estar relacionados con la cantidad de unidades primarias de muestreo (UPM) y los estratos considerados en el diseño. Una aproximación común consiste en calcularlos como:

$$df = m - H$$

donde m representa el número total de UPM observadas en la muestra y H el número de estratos. Esta aproximación refleja la cantidad efectiva de información independiente disponible para estimar la variabilidad muestral. A medida que los grados de libertad aumentan, la distribución t de Student converge hacia la distribución normal estándar. Esta propiedad explica por qué muchas veces se utilizan aproximaciones normales para reportar intervalos de confianza, especialmente en encuestas de hogares de gran escala. Sin embargo, cuando el número de conglomerados es reducido o existen estratos con pocas UPM, la aproximación normal puede subestimar la incertidumbre y producir intervalos excesivamente estrechos.

3. Análisis de variables categóricas

En el análisis de encuestas de hogares, uno de los productos más habituales es la estimación de parámetros descriptivos asociados a variables categóricas, los cuales permiten sintetizar las principales características de la población. Estas medidas facilitan una representación clara y comprensible de fenómenos sociales a partir de información recolectada mediante muestras probabilísticas (CEPAL 2023).

Como explica Agresti (2019), las frecuencias y las proporciones se encuentran entre los indicadores descriptivos más utilizados para analizar variables categóricas. Las frecuencias representan el número de personas u hogares que pertenecen a cada categoría, como la cantidad de personas en condición de pobreza, mientras que las proporciones expresan el peso relativo de cada categoría dentro de la población, como el porcentaje de hogares en situación de hacinamiento. Aunque el análisis descriptivo de este tipo de variables se apoya principalmente en estos parámetros, también puede complementarse con medidas derivadas de variables numéricas, como los cuantiles y los indicadores de desigualdad que se estudiarán en el Capítulo 4.

Para estimar correctamente estas medidas a partir de una encuesta de hogares, es necesario comenzar por definir el diseño de muestreo. Este paso permite incorporar las características de la encuesta, incluidos los factores de expansión, las unidades primarias de muestreo y los estratos de selección. La adecuada especificación de estos elementos es fundamental para que las frecuencias, las proporciones y las demás estadísticas estimadas representen apropiadamente a la población objetivo y para que sus medidas de precisión reflejen la variabilidad introducida por el diseño muestral. Este capítulo aplica los fundamentos del diseño muestral estudiados en el capítulo 2. Se comienza por la preparación de los datos y se avanza desde la composición de la población hasta la comparación de grupos y la comunicación de resultados.

3.1. Preparación de los datos y especificación del diseño

Según Naciones Unidas (2009, sec. 7.8), es fundamental que la estructura del diseño muestral sea tenida en cuenta en el proceso de inferencia al estimar estadísticas oficiales basadas en encuestas de hogares. Como se ha insistido en este documento, ignorar los pesos puede sesgar las estimaciones y omitir la estructura del diseño puede producir errores estándar inadecuados. En este sentido los programas estadísticos incorporan funcionalidades específicas para manejar datos provenientes de encuestas con diseños complejos.

El archivo `sample.rds`, almacenado en la carpeta `data`, contiene una muestra bietápica estratificada de la población `BigCity`, disponible en el paquete `TeachingSampling` de `R` (Gutiérrez 2020). La selección se realiza en dos etapas: en la primera se seleccionan unidades primarias de muestreo (UPM) dentro de cada estrato y, en la segunda, hogares dentro de las UPM seleccionadas. La base reúne la información de las personas que integran esos hogares y conserva los identificadores de estrato, UPM y hogar, junto con los factores de expansión necesarios para el análisis.

El diseño de esta muestra sigue una metodología tradicional de las encuestas de hogares, descrita en CEPAL (2023, V, sec. B). Se recomienda al lector consultar esa sección para profundizar en la teoría detrás de estos diseños de muestreo y el proceso de selección. Es de aclarar que, la conceptualización de la selección de diseños de muestreo quedan fuera del alcance de este libro, cuyo propósito es el análisis de los datos de encuestas de hogares con `R`, incorporando el diseño muestral en la inferencia. Para estudiar los fundamentos y métodos de selección de muestras, pueden consultarse las obras de Kish (1965), Särndal et al. (2003) y Gutiérrez (2016).

Para implementar la selección de muestras en `R` existen paquetes especializados, como `sampling` (Tillé y Matei 2025), y `TeachingSampling` (Gutiérrez 2020). Estos paquetes ofrecen herramientas para seleccionar muestras probabilísticas bajo distintos diseños y constituyen recursos complementarios para quienes deseen estudiar o reproducir esta etapa del trabajo con encuestas.

De acuerdo con R Core Team (2026b), las bases de datos utilizadas en el análisis de encuestas pueden encontrarse en una amplia variedad de formatos, como `xlsx`, `dat`, `csv`, `parquet`, `sas7bdat`, `sav` y `txt`, entre otros. Sin embargo, una buena práctica consiste en importar la información desde cualquiera de estos formatos y guardarla posteriormente en un archivo con extensión `.rds`, un formato nativo de `R` que permite almacenar distintos tipos de objetos, como bases de datos, vectores, matrices o listas. Otro formato nativo de `R` es `.RData`, que permite guardar varios objetos en un mismo archivo. En contraste, los archivos `.rds` almacenan un único objeto, lo que facilita un manejo más controlado, explícito y reproducible de la información. Por esta razón, se recomienda utilizar preferentemente el formato `.rds` al documentar proyectos y desarrollar análisis reproducibles.

A continuación, se carga el archivo `sample.rds`, que se utilizará a lo largo de los capítulos aplicados para ilustrar la sintaxis computacional del análisis de encuestas:

```
library(tidyverse)

survey_data <- readRDS("../data/sample.rds")
```

El objeto `survey_data` contiene la información del archivo `sample.rds`: cada fila corresponde a una unidad observada y las columnas incluyen las variables de interés y la información del diseño muestral. El siguiente código computacional utiliza `glimpse()` para examinar el número de observaciones y variables, sus nombres, sus tipos de datos y una muestra de los valores registrados.

```
dplyr::glimpse(survey_data)
```

```
Rows: 2,605
Columns: 20
$ HHID        <chr> "idHH00031", "idHH00031", "idHH00031", "idHH00031", "idHH0~
$ Stratum     <chr> "idStrt001", "idStrt001", "idStrt001", "idStrt001", "idStr~
$ NIh         <int> 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9~
$ nIh         <dbl> 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2~
$ dI          <dbl> 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5, 4.5~
$ PersonID    <chr> "idPer01", "idPer02", "idPer03", "idPer04", "idPer05", "id~
$ PSU         <chr> "PSU0003", "PSU0003", "PSU0003", "PSU0003", "PSU0003", "PS~
$ Zone        <chr> "Rural", "Rural", "Rural", "Rural", "Rural", "Rural", "Rur~
$ Sex         <chr> "Male", "Female", "Female", "Male", "Female", "Female", "F~
```

```
$ Age         <int> 68, 56, 24, 26, 3, 61, 23, 5, 1, 59, 50, 33, 81, 76, 45, 4~
$ MaritalST   <fct> Married, Married, Married, Married, NA, Widowed, Separated~
$ Income      <dbl> 409.9, 409.9, 409.9, 409.9, 409.9, 823.8, 823.8, 823.8, 82~
$ Expenditure <dbl> 346.3, 346.3, 346.3, 346.3, 346.3, 392.2, 392.2, 392.2, 39~
$ Employment  <fct> Employed, Employed, Employed, Employed, NA, Employed, Inac~
$ Poverty     <fct> NotPoor, NotPoor, NotPoor, NotPoor, NotPoor, NotPoor, NotP~
$ dki         <dbl> 8.00, 8.00, 8.00, 8.00, 8.00, 8.00, 8.00, 8.00, 8.00, 8.00~
$ dk          <dbl> 36, 36, 36, 36, 36, 36, 36, 36, 36, 36, 36, 36, 42, 42, 42~
$ wk          <dbl> 34.5, 33.6, 33.6, 34.5, 33.6, 33.6, 33.6, 34.5, 33.6, 34.5~
$ Region      <fct> North, North, North, North, North, North, North, North, No~
$ CatAge      <ord> 60-69, 50-59, 20-29, 20-29, 0-9, 60-69, 20-29, 0-9, 0-9, 5~
```

La base de datos muestral contiene 2.605 registros individuales y 20 variables. Cada fila corresponde a una persona, identificada mediante `PersonID`, y se encuentra vinculada con su hogar a través de `HHID`. Además de variables sociodemográficas y económicas, como sexo, edad, estado civil, condición de empleo, ingreso, gasto[1] y situación de pobreza, la base incluye información necesaria para representar el diseño de muestreo complejo, como el estrato (`Stratum`), la unidad primaria de muestreo (`PSU`) y los factores de expansión (`wk`). También incorpora variables de clasificación geográfica y demográfica, como zona, región y grupo de edad.

La base `sample.rds` está organizada a nivel de personas. En la notación del libro, el peso de diseño y el factor de expansión final se representan, respectivamente, por `dk` y `wk`. Aunque el peso de diseño (`dk`) es común a los integrantes de un mismo hogar, el factor de expansión final (`wk`) puede diferir entre ellos debido a la calibración realizada a nivel de personas. Por tanto, debe distinguirse entre la unidad de observación y la unidad sobre la que se desea realizar la inferencia: al analizar personas, la suma de sus factores de expansión estima el tamaño poblacional; al analizar hogares, se requiere una sola observación y un factor de expansión por hogar.

La construcción y el tratamiento de factores de expansión para bases de personas y de hogares, así como los procedimientos para asegurar la coherencia entre ambos niveles, están fuera del alcance de este libro. El lector interesado puede consultar CEPAL (2023, IX, sec. E.2). En este sentido, para los ejemplos cuyo objetivo sea obtener estadísticas de hogares, se adoptará el método de la persona principal descrito por Alexander (1987). En este libro, esa persona será la jefa o el jefe del hogar, identificado mediante `PersonID == "idPer01"`. Por ende, se conservará su registro y se utilizará su factor de expansión final como factor del hogar. Así, cada hogar contribuirá una sola vez a las estimaciones. Esta elección constituye una convención explícita para los ejemplos y no garantiza, por sí sola, la coherencia entre las estimaciones de personas y hogares ni sustituye un factor de hogar específicamente construido para una encuesta.

3.1.1. Corroboraciones preparatorias

Antes de interpretar los resultados de una encuesta, conviene realizar comprobaciones que permitan detectar inconsistencias en la población representada por los factores de expansión. Por ejemplo, conviene verificar que la columna de factores de expansión no contenga valores faltantes, no finitos ni menores o iguales a cero, y que los factores correspondan a la unidad de análisis de la base. En una

[1] En este documento, las variables ingreso y gasto corresponden a valores mensuales per cápita del hogar, no a los totales del hogar ni a los ingresos o gastos propios de cada persona.

base organizada a nivel de personas, la suma de los pesos estima el total de personas representadas. Para estimar el total de hogares, se requiere una base de hogares o una regla explícita para seleccionar una observación por hogar y asignarle el peso correspondiente.

Otra corroboración simple consiste en sumar los factores de expansión en toda la base y por subpoblaciones. La suma de los factores de expansión debe contrastarse con el total proyectado de la población que la encuesta pretende representar. Cuando los pesos se han calibrado a ese total, su coincidencia es una propiedad esperada del procedimiento; aunque también conviene revisar otras desagregaciones o indicadores que no hayan intervenido directamente en el ajuste. La concordancia de estos diagnósticos respalda la coherencia de los resultados. Ante diferencias relevantes, corresponde revisar la cobertura, los valores faltantes, la clasificación de las unidades, los factores de expansión y la especificación del diseño antes de atribuirlas a características de la población.

Asimismo, el tamaño medio del hogar puede compararse con el censo o con otra referencia demográfica pertinente, considerando las diferencias de fecha, cobertura y definición de hogar. Otros indicadores útiles para estas comprobaciones son el índice de masculinidad y la razón de dependencia demográfica, cuya estimación se desarrolla en el capítulo 4. Su comparación con las proyecciones de población puede revelar diferencias que una revisión exclusivamente agregada no detectaría. El siguiente código computacional revisa la validez de los factores de expansión y calcula la población representada por la base, además del tamaño medio de los hogares observados en la muestra.

```
household_sizes <- survey_data %>%
  filter(!is.na(HHID)) %>%
  count(HHID, name = "household_size")

weight_check <- survey_data %>%
  summarise(
    observations = n(),
    missing_weights = sum(is.na(wk)),
    nonfinite_weights = sum(!is.na(wk) & !is.finite(wk)),
    nonpositive_weights = sum(!is.na(wk) & is.finite(wk) & wk <= 0),
    estimated_population = sum(wk, na.rm = TRUE),
    mean_sample_household_size = mean(household_sizes$household_size)
  )

weight_check
```

```
  observations missing_weights nonfinite_weights nonpositive_weights
1         2605               0                 0                   0
  estimated_population mean_sample_household_size
1               150266                       3.74
```

La base contiene 2.605 observaciones. Se encontraron 0 factores de expansión faltantes, 0 no finitos y 0 iguales o menores que cero. La suma de los factores es 150.266, que estima la población de personas representada por la base. El tamaño medio de los hogares observados en la muestra es de 3.74 personas. Este promedio es descriptivo y no una estimación ponderada del tamaño medio de los hogares de la población.

3.1.2. Definición del diseño de muestreo

Una vez cargada la encuesta de hogares en R, el siguiente paso es definir el diseño muestral del cual proviene dicha muestra. Para ello se utilizará el paquete `srvyr`, que surge como un complemento del paquete `survey`. Estas librerías permiten definir objetos tipo `survey.design`, a los que se aplican las funciones de estimación y análisis de encuestas, y que pueden ser combinadas con la programación del paquete `tidyverse`. A continuación, se muestra un ejemplo en el que se define el objeto `survey_design`, de clase `tbl_svy` y compatible con los métodos de `survey` para la encuesta:

```
options(survey.lonely.psu = "adjust")

library(survey)
library(srvyr)

survey_design <- survey_data %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  )
```

Como explica Lumley et al. (2026), la opción `options(survey.lonely.psu = "adjust")` define cómo el paquete `survey` debe tratar los estratos que contienen una sola UPM en la muestra. En estos estratos no es posible calcular directamente la variabilidad entre UPM, porque no existe una segunda unidad con la cual realizar la comparación. Con el método `"adjust"`, la contribución de la UPM solitaria a la varianza se calcula centrando su estimación en la media general de las UPM de la muestra, en lugar de utilizar la media del propio estrato. Este ajuste evita que la contribución del estrato sea omitida o quede indefinida y suele producir una estimación conservadora de la varianza. La opción no modifica las estimaciones puntuales, sino únicamente sus varianzas, errores estándar e intervalos de confianza. Su aplicación debe distinguirse del caso en el que una UPM sea seleccionada con probabilidad de inclusión uno. En cualquier caso, la contribución a la varianza debe especificarse mediante la información apropiada del diseño.

Así mismo, `survey_data` corresponde a la base de datos que contiene la muestra seleccionada. A partir de estos datos, la función `as_survey_design()` convierte la información en un objeto de clase `tbl_svy`, el cual almacena todos los elementos necesarios para describir el diseño muestral de la encuesta. Entre ellos se incluyen la variable de estratificación (`strata`), que identifica los estratos definidos en el diseño, junto con la variable que representa las unidades primarias de muestreo (UPM) o conglomerados seleccionados en la primera etapa del muestreo (`ids`). Asimismo, el argumento `weights` define la variable que contiene los factores de expansión asociados a cada observación. Finalmente, la opción `nest = TRUE` vuelve únicos dentro de cada estrato los identificadores de conglomerado que pudieran repetirse entre estratos.

3.1.3. Variables derivadas y subpoblaciones

A partir de la información original de la encuesta, también es posible construir algunas variables adicionales que serán utilizadas en los ejercicios desarrollados a lo largo de este capítulo. El siguiente

código computacional define una variable dicotómica que identifica si una persona se encuentra o no en condición de pobreza, considerando como pobres a quienes pertenecen a cualquiera de las categorías de pobreza registradas en la encuesta. Asimismo, se crea una variable que permite distinguir a las personas desempleadas del resto de la población y otra que clasifica a las personas en dos grupos de edad: menores de 18 años y personas de 18 años o más. Estas variables facilitarán la desagregación de los resultados y la comparación de indicadores entre distintos grupos de la población.

```
survey_design <- survey_design %>%
  mutate(
    poor = ifelse(Poverty != "NotPoor", 1, 0),
    unemployed = ifelse(Employment == "Unemployed", 1, 0),
    age_18 = case_when(
      is.na(Age) ~ NA_character_,
      Age < 18 ~ "< 18 years",
      TRUE ~ ">= 18 years"
    )
  )
```

En el código anterior se crean nuevas variables derivadas utilizando la función `mutate()` del paquete `dplyr`. Las variables `poor` y `unemployed` se construyen mediante la función `ifelse()`, que evalúa una condición lógica y asigna un valor dependiendo de si esta se cumple o no. En este caso, las variables toman el valor `1` cuando la persona se encuentra en condición de pobreza o desempleo, respectivamente, y `0` en caso contrario. Por su parte, la variable `age_18` se genera mediante la función `case_when()`, la cual permite definir categorías a partir de una o varias condiciones de forma más clara y flexible que `ifelse()`. Esta función resulta especialmente útil cuando se requiere construir variables categóricas con múltiples niveles. En el ejemplo, las personas menores de 18 años se clasifican en la categoría `"< 18 years"`, mientras que las edades observadas restantes se agrupan en la categoría `">= 18 years"`; las edades faltantes se conservan como tales. La variable `unemployed` identifica desocupación: el valor cero incluye tanto personas ocupadas como inactivas y no debe etiquetarse como «ocupado». Asimismo, se presupone que las categorías observadas de `Poverty` distintas de `"NotPoor"` corresponden a pobreza; los valores faltantes permanecen como `NA`.

Además de las variables categóricas definidas previamente, es necesario establecer subpoblaciones que permitan obtener estimaciones desagregadas y comparar los indicadores entre distintos grupos. El siguiente código computacional define seis subpoblaciones para los ejemplos del capítulo: población urbana, población rural, mujeres, hombres, población económicamente activa y población en edad de trabajar. Para esta base, las dos últimas se restringen a personas de 15 años o más. La población en edad de trabajar incluye también a las personas inactivas y constituye el denominador de la tasa de ocupación; mientras que la población económicamente activa incluye a las personas ocupadas y desocupadas y constituye el denominador de la tasa de desocupación.

```
urban_subset <- survey_design %>%
  filter(Zone == "Urban")

rural_subset <- survey_design %>%
  filter(Zone == "Rural")
```

```r
female_subset <- survey_design %>%
  filter(Sex == "Female")

male_subset <- survey_design %>%
  filter(Sex == "Male")

working_age_subset <- survey_design %>%
  filter(Age >= 15)

labor_force_subset <- survey_design %>%
  filter(
    Age >= 15,
    Employment %in% c("Employed", "Unemployed")
  )
```

Los dominios se obtienen filtrando el objeto de diseño ya construido. Así se conserva la información necesaria para estimar la variabilidad del dominio bajo el diseño original. Filtrar primero los microdatos y reconstruir después el diseño puede alterar esa información. Las copias de los dominios contienen las variables creadas hasta este punto; no se actualizan automáticamente si más adelante se modifica el objeto principal.

3.2. Estimación de parámetros descriptivos

Esta sección presenta los principales parámetros descriptivos utilizados para analizar variables categóricas en encuestas de hogares. En particular, se aborda la estimación de tamaños poblacionales, proporciones y distribuciones por dominios o subpoblaciones, incorporando los factores de expansión y la estructura del diseño muestral. Estos indicadores permiten describir la composición de la población y cuantificar la presencia relativa de distintos grupos de interés.

Con el diseño de muestreo ya especificado y los dominios de análisis definidos, esta sección estima tamaños poblacionales y proporciones, junto con sus medidas de precisión. En cada ejercicio se parte del objeto de diseño y se selecciona el dominio de interés; si se comparan categorías, estas se agrupan para obtener una estimación por grupo. El operador `%>%` conecta las operaciones, `group_by()` indica cómo se forman los grupos de comparación y `summarise()` solicita los resultados.

3.2.1. Tamaños poblacionales

En el análisis de encuestas de hogares, es fundamental estimar el tamaño de las distintas subpoblaciones y la proporción que cada una representa dentro de la población total (CEPAL 2023). Estas estimaciones permiten cuantificar grupos definidos por características demográficas o socioeconómicas y describir su importancia relativa. Por ejemplo, conocer el número y la proporción de personas que se encuentran por debajo de la línea de pobreza o han alcanzado un determinado nivel educativo contribuye a identificar brechas entre grupos, evaluar sus condiciones de bienestar y generar información relevante para el diseño de políticas públicas.

Las subpoblaciones se definen mediante variables categóricas que clasifican a las unidades de la población finita en grupos mutuamente excluyentes, como las distintas condiciones de actividad económica o los niveles educativos alcanzados. El tamaño de una subpoblación corresponde al número total de personas u hogares de la población que pertenecen a una categoría determinada. Para estimarlo a partir de una encuesta, se suman los pesos muestrales de las unidades clasificadas en esa categoría, dado que cada peso indica cuántas personas u hogares de la población representa la unidad observada en la muestra. A partir de estas estimaciones también puede calcularse la proporción que cada subpoblación representa respecto del total poblacional. Por ende, el estimador del tamaño de la población (Särndal et al. 2003), se define como:

$$\hat{N} = \sum_h \sum_i \sum_k w_{hik} \tag{3.1}$$

En donde, w_{hik} es el peso o factor de expansión de la unidad k en la UPM i del estrato h. Para estimar la varianza de $\hat{N}$, se agrupan las contribuciones ponderadas por UPM. La contribución de cada UPM se define como:

$$\hat{N}_{hi} = \sum_k w_{hik}.$$

Esta suma de pesos representa la contribución de la UPM i del estrato h al tamaño poblacional estimado. El promedio de las contribuciones en el estrato es:

$$\bar{\hat{N}}_h = \frac{1}{m_h} \sum_{i=1}^{m_h} \hat{N}_{hi}.$$

Aquí m_h es el número de UPM seleccionadas en el estrato h. El promedio permite medir la dispersión entre sus contribuciones. Bajo la aproximación con reemplazo en la primera etapa, sin corrección por población finita, la varianza estimada es (Särndal et al. 2003):

$$\widehat{\mathrm{Var}}(\hat{N}) = \sum_h \frac{m_h}{m_h - 1} \sum_{i=1}^{m_h} \left(\hat{N}_{hi} - \bar{\hat{N}}_h \right)^2. \tag{3.2}$$

Esta expresión mide la dispersión de las contribuciones de las UPM dentro de cada estrato; su raíz cuadrada es el error estándar de $\hat{N}$. Corresponde a la aproximación utilizada al especificar estratos, UPM y pesos sin el argumento `fpc`, como se hace en este capítulo. La fórmula supone $m_h > 1$; los estratos con una sola UPM requieren el tratamiento descrito en la preparación del diseño. Los pesos se consideran dados: si se desea incorporar la calibración a la estimación de la varianza, sus restricciones deben estar representadas en el objeto de diseño, y no únicamente en los valores de los pesos.

Asimismo, la estimación del tamaño de una subpoblación sigue el mismo principio que la estimación del tamaño total, pero se restringe a las unidades que presentan una característica determinada. Para estimar cuántas personas u hogares pertenecen a una categoría específica d, se identifica en la muestra a las unidades que cumplen dicha condición y se suman sus pesos muestrales. De esta manera, cada unidad contribuye a la estimación de acuerdo con el número de unidades de la población que representa:

$$\hat{N}_d = \sum_h \sum_i \sum_k w_{hik}\, I(y_{hik} = d) \tag{3.3}$$

donde $\hat{N}_d$ representa el tamaño estimado de la subpoblación perteneciente a la categoría d. Por su parte, $I(y_{hik} = d)$ es una variable binaria que toma el valor de 1 si la unidad k de la UPM i en el estrato h pertenece a la categoría d de la variable de interés y, y 0 en caso contrario. Si el total de la categoría d se fija mediante calibración a un control externo conocido, $\hat{N}_d$ coincide con ese control y su varianza respecto del diseño es nula cuando se incorpora esa restricción a la estimación de la varianza (Gutiérrez 2016). Introducir únicamente los pesos calibrados en `as_survey_design()` no comunica al programa dicha restricción. Para el tamaño de la subpoblación, la contribución de cada UPM está dada por:

$$\hat{N}_{hi,d} = \sum_k w_{hik} I(y_{hik} = d).$$

Esta suma incluye únicamente los pesos de las unidades que pertenecen a la categoría d. El promedio de estas contribuciones dentro del estrato se calcula como:

$$\bar{\hat{N}}_{h,d} = \frac{1}{m_h} \sum_{i=1}^{m_h} \hat{N}_{hi,d}.$$

El promedio considera todas las UPM seleccionadas en el estrato, incluidas aquellas cuya contribución al dominio es cero. Bajo los mismos supuestos utilizados para $\hat{N}$, su varianza estimada es:

$$\widehat{\mathrm{Var}}(\hat{N}_d) = \sum_h \frac{m_h}{m_h - 1} \sum_{i=1}^{m_h} \left(\hat{N}_{hi,d} - \bar{\hat{N}}_{h,d} \right)^2. \tag{3.4}$$

La fórmula cuantifica la variación entre las contribuciones de las UPM al tamaño del dominio d. Se conservan todas las UPM del diseño original: aquellas que no contienen personas del dominio aportan $\hat{N}_{hi,d} = 0$, y m_h sigue siendo el número de UPM seleccionadas en el estrato, no solamente el de las que contienen integrantes del dominio. El error estándar de $\hat{N}_d$ es la raíz cuadrada de esta varianza. Este procedimiento explica por qué los dominios se definen sobre el objeto de diseño completo.

La función `survey_total()` estima totales poblacionales incorporando los factores de expansión y el diseño muestral. Si se omite `x`, estima el tamaño de la población que se quiere representar. Su sintaxis general es:

```
survey_total(
  x = NULL,
  na.rm = FALSE,
  vartype = c("se", "ci", "var", "cv"),
  level = 0.95,
  deff = FALSE
)
```

El argumento `x` indica la variable cuyo total se desea estimar; si se omite, la función calcula el tamaño ponderado de unidades. El argumento `na.rm` excluye los valores faltantes del cálculo, pero no ajusta por sí mismo los efectos de la no respuesta. Su valor predeterminado es `FALSE`. Además, `vartype` permite solicitar una o varias medidas de precisión: error estándar (`"se"`), intervalo de confianza (`"ci"`), varianza (`"var"`) o coeficiente de variación (`"cv"`). `level` establece el nivel de confianza de los intervalos y su valor predeterminado es 0.95. Los intervalos también pueden calcularse con `confint()` sobre estimadores compatibles del paquete `survey`. Por último, `deff` indica si se devuelve el efecto de diseño.

Cuando se solicita `vartype = "ci"`, se construyen intervalos de confianza de Wald sumando y restando a la estimación el producto de su error estándar por un cuantil de la distribución t de Student Lumley (2010). Si se omite el argumento `df`, `srvyr` utiliza los grados de libertad del diseño con el que se realiza el cálculo, antes de dividirlo en los grupos definidos mediante `group_by()`. El argumento `level` fija el nivel de confianza, que en estos ejemplos es del 95 %, salvo cuando se indica otro nivel.

El siguiente código computacional utiliza el diseño muestral definido previamente para generar resúmenes por categoría de la variable `Zone`. Para ello, los datos se agrupan según la zona geográfica, lo que permite obtener resultados independientes para cada uno de estos dominios de estudio. A partir de este procedimiento se producen dos tipos principales de resultados. En primer lugar, se calcula el número de observaciones efectivamente recolectadas en la muestra, sin considerar los factores de expansión, usando la función `unweighted()`. En segundo lugar, se estima el tamaño poblacional asociado a cada dominio incorporando la información del diseño de muestreo. Junto con las estimaciones poblacionales también se obtienen medidas de precisión, como el error estándar y el intervalo de confianza. El objeto `zone_population_size` conserva estos resultados, que se presentan en la tabla 3.1. En las tablas del capítulo, EE indica el error estándar; «LI 95 %» e «LS 95 %» indican los límites inferior y superior del intervalo de confianza del 95 %.

```
zone_population_size <- survey_design %>%
  group_by(Zone) %>%
  summarise(
    n = unweighted(n()),
    size = survey_total(vartype = c("se", "ci"))
  )

zone_population_size
```

Tabla 3.1.: Tamaño poblacional estimado por zona geográfica

Zona	Muestra	Población	EE	LI 95 %	LS 95 %
Rural	1297	72102	3062	66039	78165
Urban	1308	78164	2847	72526	83802

En la salida, `n` cuenta los registros observados sin ponderar, mientras que `size` contiene el total poblacional estimado. Las columnas `size_se`, `size_low` y `size_upp` presentan, respectivamente, el error estándar y los límites del intervalo de confianza. El coeficiente de variación se calcula como el

error estándar dividido por la estimación; para expresarlo en porcentaje, se multiplica por 100. En el código, `unweighted(n())` obtiene el conteo muestral y `survey_total()` el total ponderado.

En efecto, el tamaño de muestra fue de 1.297 personas en la zona rural y de 1.308 en la zona urbana. A partir de estas muestras se estimó una población de 72.102 personas para la zona rural, con un error estándar de 3.062, y de 78.164 personas para la zona urbana, con un error estándar de 2.847. Considerando un nivel de confianza del 95 %, los intervalos de confianza para las estimaciones poblacionales fueron de 66.038,5 a 78.165,5 personas en la zona rural y de 72.526,2 a 83.801,8 personas en la zona urbana. El mismo procedimiento permite describir la distribución de la población por grupos de edad, manteniendo los factores de expansión y la estructura del diseño muestral.

Para este ejemplo se utiliza directamente `CatAge`, la variable que contiene los grupos de edad en `sample.rds`. Sus categorías son grupos decenales ordenados: de 0 a 9, de 10 a 19, de 20 a 29 años, y así sucesivamente hasta el grupo de 90 a 99 años. El siguiente código computacional agrupa el objeto de diseño por `CatAge` y obtiene el número de personas observadas en la muestra y el tamaño poblacional estimado de cada grupo, junto con su error estándar y su intervalo de confianza del 95 %, como se presenta en la tabla 3.2.

```
age_population_size <- survey_design %>%
  group_by(CatAge) %>%
  summarise(
    sample_size = unweighted(n()),
    size = survey_total(
      vartype = c("se", "ci"),
      level = 0.95
    ),
    .groups = "drop"
  )

age_population_size
```

Tabla 3.2.: Tamaño muestral y tamaño poblacional estimado por grupo de edad

Edad (años)	Muestra	Población	EE	LI 95 %	LS 95 %
0-9	468	27804	2396	23060.1	32548
10-19	509	28554	1815	24960.4	32148
20-29	478	27677	1966	23785.3	31569
30-39	347	19860	1401	17084.7	22634
40-49	300	17234	1198	14861.7	19606
50-59	220	11876	1090	9719.1	14034
60-69	162	9924	887	8166.4	11681
70-79	81	4700	740	3235.6	6165
80-89	34	2246	460	1336.4	3157
90-99	6	391	166	61.8	720

La tabla 3.2 distingue el tamaño muestral, que cuenta los registros observados, del tamaño poblacional, que suma sus factores de expansión. El grupo de 10-19 años presenta el mayor tamaño

poblacional estimado, con aproximadamente 28.554 personas. En conjunto, los 10 grupos reúnen 2605 observaciones y representan una población estimada de 150.266 personas. Los errores estándar y los intervalos de confianza describen la incertidumbre muestral de cada estimación.

Además de estas características demográficas, el análisis puede extenderse a las condiciones socioeconómicas de la población. A continuación, se aplica el mismo procedimiento para estimar el número de personas según los distintos niveles de pobreza.

```
poverty_population_size <- survey_design %>%
  group_by(Poverty) %>%
  summarise(
    size = survey_total(vartype = c("se", "ci"))
  )

poverty_population_size
```

Tabla 3.3.: Tamaño poblacional estimado por condición de pobreza

Pobreza	Población	EE	LI 95 %	LS 95 %
NotPoor	91398	4395	82696	100101
Extreme	21519	4949	11719	31319
Relative	37349	3695	30032	44666

La tabla 3.3 refleja una población en la que la mayoría de las personas no vive en pobreza, pero en la que esa aparente normalidad convive con una fractura difícil de considerar marginal: cerca de 58.868 personas se encuentran en pobreza relativa o extrema. De ellas, 21.519 padecen las privaciones más severas y 37.349 permanecen por debajo de los niveles de vida socialmente aceptables.

Otra variable categórica relevante en las encuestas de hogares es el estado de ocupación. En este caso, la información se agrupa según las categorías de la variable `Employment`, lo que permite obtener estimaciones separadas para cada condición de actividad laboral de la población. Mediante el uso de la función `group_by()` es posible desagregar las estimaciones en niveles más detallados, facilitando el análisis comparativo entre los distintos grupos ocupacionales. En el siguiente código computacional, primero se excluyen los registros con valores faltantes en la variable de empleo, garantizando que los resultados se calculen únicamente con personas con condición de ocupación observada. Posteriormente, para cada categoría de ocupación se estima el tamaño poblacional, junto con el error estándar y los intervalos de confianza.

```
employment_population_size <- survey_design %>%
  filter(!is.na(Employment)) %>%
  group_by(Employment) %>%
  summarise(
    size = survey_total(vartype = c("se", "ci"))
  )

employment_population_size
```

Tabla 3.4.: Tamaño poblacional estimado por estado de ocupación

Condición de actividad	Población	EE	LI 95 %	LS 95 %
Unemployed	4635	761	3129	6141
Inactive	41465	2163	37183	45748
Employed	61877	2540	56847	66907

A partir de los resultados presentados en la tabla 3.4, se estima que la población ocupada asciende a 61.877 personas. Por su parte, la población inactiva se estima en 41.465 personas, mientras que cerca de 4.635 personas se encontrarían desempleadas. En conjunto, las estimaciones muestran que los desempleados representan el grupo de menor tamaño, aunque la amplitud relativa de su intervalo de confianza indica una mayor incertidumbre en comparación con las estimaciones de la población ocupada e inactiva.

Las estimaciones también pueden desagregarse simultáneamente por más de una variable categórica. Por ejemplo, un primer análisis de las estructuras poblacionales consiste en estimar los tamaños entre el grupo de edad y el sexo. El código agrupa el diseño por edad y sexo con `group_by()` y guarda en `age_sex_population_size` el total estimado para cada combinación mediante `summarise()` y `survey_total()`. Como `CatAge` es un factor ordenado, `arrange(Sex, CatAge)` conserva el orden de los grupos desde el de menor edad hasta el de mayor edad. Como es posible que algunos grupos de edad no tengan un tamaño de muestra lo sufcientemente grande para producir cifras confiables, algunos de los intervalos de confianza resultan con límites inferiores menores a cero. En ese caso, se usa la función `mutate` para truncar estos valores en cero. La tabla 3.5 presenta únicamente tamaños poblacionales estimados y sus medidas de precisión, sin incluir el número de observaciones de la muestra.

```
age_sex_population_size <- survey_design %>%
  group_by(CatAge, Sex) %>%
  summarise(
    size = survey_total(
      vartype = c("se", "ci"),
      level = 0.95
    ),
    .groups = "drop"
  ) %>%
  mutate(size_low = pmax(size_low, 0)) %>%
  arrange(Sex, CatAge)

age_sex_population_size
```

Tabla 3.5.: Tamaño poblacional estimado por grupo de edad y sexo

Edad (años)	Sexo	Población	EE	LI 95 %	LS 95 %
0-9	Female	13973	1158	11681	16265
10-19	Female	13909	1196	11540	16277
20-29	Female	13773	1025	11743	15803

Tabla 3.5.: Tamaño poblacional estimado por grupo de edad y sexo

Edad (años)	Sexo	Población	EE	LI 95 %	LS 95 %
30-39	Female	11723	947	9849	13598
40-49	Female	9313	851	7628	10999
50-59	Female	6772	652	5480	8063
60-69	Female	5425	512	4412	6438
70-79	Female	2832	516	1812	3853
80-89	Female	1227	288	657	1798
90-99	Female	242	126	0	492
0-9	Male	13831	1642	10579	17083
10-19	Male	14645	1201	12267	17023
20-29	Male	13904	1362	11206	16602
30-39	Male	8136	782	6588	9684
40-49	Male	7920	665	6604	9237
50-59	Male	5105	648	3822	6387
60-69	Male	4498	618	3275	5722
70-79	Male	1868	382	1112	2623
80-89	Male	1019	320	386	1652
90-99	Male	149	108	0	363

La tabla 3.5 permite comparar el número estimado de mujeres y hombres dentro de cada grupo de edad. Por ejemplo, entre los 20 y los 29 años se estiman aproximadamente 13.773 mujeres y 13.904 hombres. Los errores estándar y los intervalos de confianza del 95 % describen la incertidumbre de cada estimación, incorporando los pesos, los estratos y las UPM del diseño muestral.

El siguiente código computacional estima el tamaño poblacional de cada combinación de estado ocupacional y condición de pobreza. Los resultados de la tabla 3.6 permiten describir la asociación entre ambas variables, sin establecer una relación causal.

```
employment_poverty_population_size <- survey_design %>%
  filter(!is.na(Employment)) %>%
  group_by(Employment, Poverty) %>%
  cascade(
    size = survey_total(vartype = c("se", "ci")),
    .fill = "Total"
  )

employment_poverty_population_size
```

Tabla 3.6.: Tamaño poblacional estimado por estado de ocupación y condición de pobreza

Condición de actividad	Pobreza	Población	EE	LI 95 %	LS 95 %
Unemployed	NotPoor	1768	405	966	2571
Unemployed	Extreme	1169	348	480	1859
Unemployed	Relative	1697	458	791	2604

Tabla 3.6.: Tamaño poblacional estimado por estado de ocupación y condición de pobreza

Condición de actividad	Pobreza	Población	EE	LI 95 %	LS 95 %
Unemployed	Total	4635	761	3129	6141
Inactive	NotPoor	24346	1736	20908	27784
Inactive	Extreme	6422	1321	3807	9037
Inactive	Relative	10697	1460	7806	13589
Inactive	Total	41465	2163	37183	45748
Employed	NotPoor	44600	2596	39460	49741
Employed	Extreme	5128	1122	2907	7349
Employed	Relative	12149	1347	9483	14816
Employed	Total	61877	2540	56847	66907
Total	Total	107977	3466	101115	114839

Entre las 61.877 personas ocupadas, 17.277 continúan en situación de pobreza, de las cuales 5.128 se encuentran en pobreza extrema y 12.149 en pobreza relativa. La vulnerabilidad es aún más visible entre las 41.465 personas inactivas, pues 17.119 viven en pobreza, mientras que entre las 4.635 personas desempleadas apenas 1.768 son clasificadas como no pobres y 2.866 padecen pobreza extrema o relativa. El comando `cascade()` extiende el resumen agrupado incorporando subtotales y un total general; `.fill = "Total"` identifica los niveles agregados. Los filtros de empleo delimitan aquí la población con condición de actividad observada y no implican una corrección por no respuesta.

3.2.2. Proporciones

Las proporciones permiten expresar el peso relativo que tienen determinados grupos dentro de la población. Por ejemplo, conocer el porcentaje de hogares que se encuentran por debajo de la línea de pobreza es esencial para evaluar desigualdades y caracterizar condiciones de bienestar. Para obtener este tipo de estimaciones, se calcula el promedio ponderado de la variable dicotómica, lo que asegura que la estimación represente adecuadamente la distribución poblacional. Al convertir las categorías originales en variables indicadoras, la proporción estimada se calcula como:

$$\hat{p}_d = \frac{\hat{N}_d}{\hat{N}} = \frac{\sum_h \sum_i \sum_k w_{hik}\, I(y_{hik} = d)}{\sum_h \sum_i \sum_k w_{hik}} \tag{3.5}$$

La proporción estimada $\hat{p}_d$ es una estadística no lineal, pues es el cociente de dos totales estimados que varían entre muestras. Por ello, aplicando la linealización de Taylor presentada en el capítulo 2 para estimadores de razón, su varianza se aproxima mediante (Gutiérrez 2016; Särndal et al. 2003):

$$\widehat{\mathrm{Var}}(\hat{p}_d) \approx \frac{\widehat{\mathrm{Var}}(\hat{N}_d) + \hat{p}_d^2 \widehat{\mathrm{Var}}(\hat{N}) - 2\hat{p}_d\, \widehat{\mathrm{Cov}}(\hat{N}_d, \hat{N})}{\hat{N}^2}. \tag{3.6}$$

La covarianza recoge la variación conjunta del numerador y del denominador, estimados a partir de la misma muestra; por ello, no deben tratarse como independientes. Con las contribuciones por UPM definidas anteriormente, se estima como:

$$\widehat{\text{Cov}}(\hat{N}_d, \hat{N}) = \sum_h \frac{m_h}{m_h - 1} \sum_{i=1}^{m_h} (\hat{N}_{hi,d} - \bar{\hat{N}}_{h,d})(\hat{N}_{hi} - \bar{\hat{N}}_h).$$

Esta expresión combina las desviaciones de las contribuciones al dominio y a la población respecto de sus respectivos promedios en cada estrato. De manera equivalente, se utiliza la variable linealizada $z_{hik} = I(y_{hik} = d) - \hat{p}_d$, se estima la varianza de su total ponderado y se divide por $\hat{N}^2$. La raíz cuadrada del resultado es el error estándar de la proporción; `survey_prop()` realiza este cálculo a partir del diseño especificado.

Cuando las proporciones estimadas toman valores cercanos a 0 o a 1, su precisión puede disminuir y las aproximaciones estadísticas tradicionales pueden resultar poco adecuadas. En estos casos, suele ser necesario disponer de tamaños de muestra mayores para obtener estimaciones suficientemente estables. Este problema adquiere especial importancia al analizar fenómenos poco frecuentes o muy concentrados, ya que pequeñas variaciones en la composición de la muestra pueden ocasionar cambios sustanciales en las proporciones estimadas (Korn y Graubard 1999).

Esta dificultad también afecta la construcción de los intervalos de confianza. Como señala Agresti (2019), los intervalos basados directamente en la aproximación normal pueden producir límites inferiores menores que 0 o límites superiores mayores que 1, resultados incompatibles con el rango de una proporción. Una alternativa consiste en construir el intervalo en la escala logit y transformarlo posteriormente a la escala original. Para una proporción estimada $\hat{p}_d$, el intervalo de confianza con nivel $1 - \alpha$ puede expresarse como

$$CI(\hat{p}_d; 1 - \alpha) = \left[\frac{\exp(L_d)}{1 + \exp(L_d)}, \frac{\exp(U_d)}{1 + \exp(U_d)} \right], \tag{3.7}$$

El intervalo transforma a la escala de proporciones los extremos calculados en la escala logit. El extremo inferior se obtiene como:

$$L_d = \log\left(\frac{\hat{p}_d}{1 - \hat{p}_d}\right) - t_{1-\alpha/2,df} \frac{\widehat{SE}(\hat{p}_d)}{\hat{p}_d(1 - \hat{p}_d)}$$

El valor L_d resta al logit estimado el margen de error correspondiente al nivel de confianza. El extremo superior se calcula sumando ese mismo margen:

$$U_d = \log\left(\frac{\hat{p}_d}{1 - \hat{p}_d}\right) + t_{1-\alpha/2,df} \frac{\widehat{SE}(\hat{p}_d)}{\hat{p}_d(1 - \hat{p}_d)}.$$

El valor U_d es el extremo superior en la escala logit. Al aplicar la transformación inversa del logit, los límites permanecen entre 0 y 1 para estimaciones interiores a ese rango. El término $t_{1-\alpha/2,df}$ es el cuantil correspondiente al nivel de confianza. Los grados de libertad dependen del diseño y del procedimiento; `survey::degf(survey_design)` permite consultar los disponibles en el diseño completo, que para diseños estratificados convencionales suelen corresponder al número de UPM menos

el número de estratos. No se sustituyen automáticamente por el número de personas del dominio. Los casos de proporción exactamente cero o uno requieren tratamiento específico. A continuación se ilustra cómo obtener la proporción de personas por zona usando el diseño muestral previamente definido.

```
zone_proportion <- survey_design %>%
  group_by(Zone) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

zone_proportion
```

Tabla 3.7.: Proporción de personas por zona geográfica

Zona	Proporción	EE	LI 95 %	LS 95 %
Rural	0.48	0.014	0.452	0.508
Urban	0.52	0.014	0.492	0.548

En este ejemplo, `survey_prop()` sin variable explícita estima la composición definida por la agrupación. `proportion = TRUE` solicita un procedimiento de intervalos para proporciones y `prop_method = "logit"` hace explícita la transformación descrita. La función no recibe una variable indicadora como primer argumento: las categorías se definen mediante `group_by()`. Para estimar una tasa se incorpora su indicadora como última variable de agrupación y, después de calcular las proporciones, se conserva la categoría de interés. La tabla 3.7 muestra una composición cercana al 48 % rural y al 52 % urbana, con sus errores estándar e intervalos. Las proporciones se expresan entre cero y uno; las diferencias entre proporciones multiplicadas por 100 se expresan en puntos porcentuales.

La función `survey_prop()` permite estimar la composición de las categorías de un objeto agrupado. Aquí se utiliza `proportion = TRUE` y `prop_method = "logit"`. En una agrupación con varias variables, las primeras definen los grupos condicionantes y la última las categorías cuya composición se estima. Así, `group_by(Zone, Poverty)` produce proporciones de pobreza dentro de cada zona. El orden de agrupación forma parte de la definición del indicador. El siguiente código computacional estima la composición por sexo de la población urbana.

```
urban_sex_proportion <- urban_subset %>%
  group_by(Sex) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
```

```
    )
  )

urban_sex_proportion
```

Tabla 3.8.: Proporción de hombres y mujeres en zona urbana

Sexo	Proporción	EE	LI 95 %	LS 95 %
Female	0.537	0.013	0.511	0.563
Male	0.463	0.013	0.437	0.489

La tabla 3.8 muestra una leve mayoría femenina en la población urbana: las mujeres representan el 53,7 %, con un intervalo de confianza entre 51,1 % y 56,3 %, frente al 46,3 % de los hombres, cuyo intervalo se sitúa entre 43,7 % y 48,9 %.

Para conocer cómo se distribuye la población masculina entre las zonas urbana y rural, el siguiente código computacional estima las proporciones de hombres según su zona de residencia, incorporando el diseño muestral previamente definido.

```
male_zone_proportion <- male_subset %>%
  group_by(Zone) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

male_zone_proportion
```

Tabla 3.9.: Distribución por zona en la subpoblación masculina

Zona	Proporción	EE	LI 95 %	LS 95 %
Rural	0.491	0.018	0.455	0.526
Urban	0.509	0.018	0.474	0.545

Los resultados de la tabla 3.9 revelan una población masculina repartida casi por igual entre lo urbano y lo rural: el 50,9 % reside en áreas urbanas, con un intervalo de confianza entre 47,4 % y 54,5 %, mientras que el 49,1 % habita en zonas rurales, con un intervalo entre 45,5 % y 52,6 %.

La función `group_by()` permite generar distintos niveles de desagregación mediante la combinación de dos o más variables categóricas. El siguiente código computacional ilustra esta posibilidad al estimar la composición por condición de pobreza dentro de cada zona de la población masculina. Este tipo de análisis permite caracterizar con mayor detalle las condiciones socioeconómicas de subpoblaciones específicas.

```
male_zone_poverty_proportion <- male_subset %>%
  group_by(Zone, Poverty) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

male_zone_poverty_proportion
```

Tabla 3.10.: Proporción de hombres por zona y condición de pobreza

Zona	Pobreza	Proporción	EE	LI 95 %	LS 95 %
Rural	NotPoor	0.549	0.063	0.424	0.668
Rural	Extreme	0.198	0.067	0.096	0.364
Rural	Relative	0.254	0.037	0.187	0.334
Urban	NotPoor	0.660	0.037	0.584	0.728
Urban	Extreme	0.113	0.025	0.073	0.171
Urban	Relative	0.227	0.026	0.180	0.283

La tabla 3.10 revela una geografía social particular. Mientras en las zonas urbanas el 66,0 % de los hombres se encuentra fuera de la pobreza, en las rurales esta proporción desciende al 54,9 %; mientras que la pobreza extrema aumenta del 11,3 % al 19,8 % al pasar de las zonas urbanas a las rurales. La pobreza relativa, en cambio, permanece más cercana entre ambos territorios.

Las variables cuantitativas también pueden agruparse en categorías. El siguiente código computacional compara la tasa de desocupación de las mujeres de 15 a 45 años, inclusive, con la de las mayores de 45 años. Se utiliza `labor_force_subset`, que ya contiene únicamente a las personas ocupadas y desocupadas de 15 años o más. El denominador de cada tasa es la fuerza de trabajo femenina del grupo correspondiente.

```
female_unemployment_rate <- labor_force_subset %>%
  filter(Sex == "Female") %>%
  mutate(
    age_range = if_else(
      Age <= 45,
      "De 15 a 45",
      "Mayores de 45"
    )
  ) %>%
  group_by(age_range, unemployed) %>%
  summarise(
    unemployment_rate = survey_prop(
      vartype = c("se", "ci"),
```

```
      prop_method = "logit"
    ),
    .groups = "drop"
  ) %>%
  filter(unemployed == 1) %>%
  select(-unemployed)

female_unemployment_rate
```

Tabla 3.11.: Tasa de desocupación de las mujeres por rango de edad

Edad (años)	Tasa	EE	LI 95 %	LS 95 %
De 15 a 45	0.0642	0.0156	0.0393	0.1031
Mayores de 45	0.0080	0.0080	0.0011	0.0563

La función `if_else()` define los dos grupos y asigna a las mujeres de 45 años al primero; mientras que `survey_prop()` estima la proporción de desocupadas dentro de cada grupo. El filtro `unemployed == 1` se aplica después del cálculo para conservar a las ocupadas en el denominador. El argumento `prop_method = "logit"` construye los intervalos de confianza en la escala logit y transforma sus límites de vuelta a la escala de proporciones.

La tabla 3.11 presenta una tasa de desocupación de 6.42 % para las mujeres de 15 a 45 años y de 0.8 % para las mayores de 45 años. La tabla muestra las tasas, sus errores estándar y los límites de los intervalos de confianza del 95 % en escala de cero a uno. La diferencia entre las estimaciones es descriptiva; evaluar su significación requiere un contraste que considere el diseño muestral.

3.3. Estimación de parámetros de asociación

Esta sección presenta herramientas para estudiar la relación entre variables categóricas en encuestas complejas. Las tablas cruzadas permiten describir cómo se distribuyen conjuntamente las categorías y comparar la composición entre grupos. La elección del denominador determina qué comparación expresa cada proporción y, por tanto, cómo deben interpretarse los resultados. A partir de estas distribuciones se introducen medidas de asociación y procedimientos de inferencia que incorporan los pesos y el diseño muestral.

3.3.1. Tablas cruzadas

De acuerdo con Heeringa et al. (2017) y Agresti (2019), además de analizar cada variable de manera individual, resulta especialmente relevante estudiar si existe asociación entre dos variables categóricas. Este tipo de análisis permite identificar patrones y relaciones que aportan información valiosa para la toma de decisiones y la comprensión de fenómenos sociales. Por ejemplo, en el ámbito de las políticas públicas es posible relacionar educación y empleo para diseñar estrategias orientadas al mercado laboral; en la evaluación de programas sociales, analizar diferencias en el acceso a servicios

de salud según el nivel de ingresos; y en investigación social, estudiar cómo variables demográficas y condiciones de vida se relacionan entre sí para comprender dinámicas y tendencias de la población.

Formalmente, sean x y y dos variables categóricas con R categorías para las filas y C categorías para las columnas, respectivamente. En el contexto de encuestas por muestreo, el interés suele centrarse en estimar la distribución conjunta de ambas variables, es decir, la proporción de unidades poblacionales que pertenecen simultáneamente a cada combinación posible de categorías. Para ello, las entradas de una tabla cruzada, también conocida como tabla de contingencia, se estiman mediante frecuencias ponderadas obtenidas a partir de los factores de expansión y del diseño muestral. La estimación del total poblacional asociado a cada celda (r, c) se define como:

$$\hat{N}_{rc} = \sum_h \sum_i \sum_k w_{hik}\ I(x_{hik} = r,\ y_{hik} = c),$$

donde w_{hik} representa el factor de expansión asociado al elemento k de la UPM i perteneciente al estrato h, mientras que $I(x_{hik} = r,\ y_{hik} = c)$ corresponde a una función indicadora que toma el valor de uno cuando la unidad observada pertenece simultáneamente a la categoría r de la variable x y a la categoría c de la variable y, y toma el valor de cero en cualquier otro caso.

Además de las frecuencias conjuntas, también es posible estimar los tamaños marginales por filas y columnas, definidos respectivamente como $\hat{N}_{r+} = \sum_{c=1}^{C} \hat{N}_{rc}$ y $\hat{N}_{+c} = \sum_{r=1}^{R} \hat{N}_{rc}$. Mientras que el total general se expresa como $\hat{N}_{++} = \sum_{r=1}^{R} \sum_{c=1}^{C} \hat{N}_{rc}$. Tradicionalmente, las tablas de contingencia se representan mediante arreglos bidimensionales de dimensión $R \times C$, donde R corresponde al número de filas y C al número de columnas. La tabla 3.12 presenta la estructura general de este tipo de tablas:

Tabla 3.12.: Estructura general de una tabla de contingencia con R filas y C columnas

Fila	1	2	⋯	C	Total
1	$\widehat{N}_{11}$	$\widehat{N}_{12}$	⋯	$\widehat{N}_{1C}$	$\widehat{N}_{1+}$
2	$\widehat{N}_{21}$	$\widehat{N}_{22}$	⋯	$\widehat{N}_{2C}$	$\widehat{N}_{2+}$
⋮	⋮	⋮	⋱	⋮	⋮
R	$\widehat{N}_{R1}$	$\widehat{N}_{R2}$	⋯	$\widehat{N}_{RC}$	$\widehat{N}_{R+}$
Total	$\widehat{N}_{+1}$	$\widehat{N}_{+2}$	⋯	$\widehat{N}_{+C}$	$\widehat{N}_{++}$

Sin embargo, las tablas de contingencia también pueden extenderse para incorporar más variables adicionales, generando subconjuntos o subtablas que permiten estudiar relaciones más complejas entre variables categóricas. A partir de los tamaños estimados, también pueden estimarse proporciones para cada celda de la tabla de contingencia, de la siguiente manera:

$$\hat{p}_{rc} = \frac{\hat{N}_{rc}}{\hat{N}_{++}}$$

Las proporciones condicionadas por fila y por columna son, respectivamente, $\hat{p}_{c|r} = \hat{N}_{rc}/\hat{N}_{r+}$ y $\hat{p}_{r|c} = \hat{N}_{rc}/\hat{N}_{+c}$. A diferencia de la distribución conjunta, cada distribución condicionada suma uno dentro de su grupo.

Aunque las tablas de contingencia se representan tradicionalmente como arreglos bidimensionales de dimensión $R \times C$, en las aplicaciones que siguen los resultados se presentan en formato largo. En esta disposición, cada combinación de categorías de las variables involucradas ocupa una fila de la tabla. Esta reorganización no altera las estimaciones contenidas en la tabla de contingencia original, sino que facilita la incorporación, para cada una de ellas, de medidas de precisión como el error estándar y los límites del intervalo de confianza.

Siguiendo con el análisis del ejemplo, se puede comparar la composición por sexo dentro de cada condición de pobreza. Para cada categoría de `poor`, el denominador es la población correspondiente a esa condición; por tanto, las proporciones muestran cómo se distribuye por sexo la población pobre y la no pobre. Para presentar las categorías con etiquetas, se crea una copia de `survey_design` en la que `poor` se convierte en factor. El objeto original conserva la variable numérica para los cálculos posteriores. El siguiente código estima las proporciones, sus errores estándar e intervalos de confianza, que se presentan en la tabla 3.13.

```
poverty_design <- survey_design %>%
  mutate(
    poor = factor(
      poor,
      levels = 0:1,
      labels = c("Not poor", "Poor")
    )
  )

poverty_sex_proportion <- poverty_design %>%
  group_by(poor, Sex) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

poverty_sex_proportion
```

Tabla 3.13.: Proporción de hombres y mujeres en condición de pobreza y no pobreza

Pobreza	Sexo	Proporción	EE	LI 95 %	LS 95 %
Not poor	Female	0.529	0.012	0.505	0.554
Not poor	Male	0.471	0.012	0.446	0.495
Poor	Female	0.524	0.016	0.492	0.555
Poor	Male	0.476	0.016	0.445	0.508

Los resultados indican que el 52,4 % de la población en condición de pobreza corresponde a mujeres, mientras que el 47,6 % corresponde a hombres. Para las mujeres, el intervalo de confianza al 95 % se encuentra entre 49,2 % y 55,5 %, mientras que para los hombres el intervalo correspondiente se ubica

entre 44,5 % y 50,8 %. Estas estimaciones permiten observar la distribución relativa de la pobreza según sexo, considerando además la incertidumbre inherente al proceso de muestreo.

Otro análisis de interés consiste en estimar la tasa de desocupación por sexo. El siguiente código computacional utiliza `labor_force_subset` y agrupa las observaciones por `Sex` y `unemployed` para calcular la proporción de desocupados dentro de cada sexo. La fila `unemployed == 1` se selecciona después de estimar las proporciones, para conservar a toda la fuerza de trabajo en el denominador. La tabla 3.14 presenta las tasas en escala de cero a uno, con sus errores estándar e intervalos de confianza; para expresarlas como porcentajes se multiplican por 100.

```
sex_unemployment_rate <- labor_force_subset %>%
  filter(!is.na(unemployed)) %>%
  group_by(Sex, unemployed) %>%
  summarise(
    unemployment_rate = survey_prop(
      proportion = TRUE,
      prop_method = "logit",
      vartype = c("se", "ci")
    ),
    .groups = "drop"
  ) %>%
  filter(unemployed == 1) %>%
  select(-unemployed)

sex_unemployment_rate
```

Tabla 3.14.: Tasa de desocupación por sexo

Sexo	Tasa	EE	LI 95 %	LS 95 %
Female	0.048	0.012	0.029	0.078
Male	0.084	0.015	0.059	0.118

La tasa de desocupación es de 4.8 % para las mujeres y de 8.39 % para los hombres. Sus errores estándar son 1.18 y 1.49 %, respectivamente.

Por otro lado, la tasa de ocupación por sexo se calcula entre las personas de 15 años o más con información observada sobre su condición de empleo, incluidas en `working_age_subset`. Su denominador comprende a todas las personas de ese universo —ocupadas, desocupadas e inactivas— y su numerador, únicamente a quienes están ocupadas. Para estimarla, el código crea el indicador `employed` y agrupa los datos por sexo y condición de ocupación; `survey_prop()` calcula la proporción de cada categoría dentro de cada sexo. Luego se conserva la categoría ocupada. Aplicar ese filtro antes del cálculo excluiría del denominador a las personas desocupadas e inactivas y alteraría la tasa.

```
sex_employment_rate <- working_age_subset %>%
  filter(!is.na(Employment)) %>%
  mutate(employed = Employment == "Employed") %>%
```

```
  group_by(Sex, employed) %>%
  summarise(
    employment_rate = survey_prop(
      proportion = TRUE,
      prop_method = "logit",
      vartype = c("se", "ci")
    ),
    .groups = "drop"
  ) %>%
  filter(employed) %>%
  select(-employed)

sex_employment_rate
```

En este cálculo, las tres opciones de `survey_prop()` cumplen funciones distintas. `proportion = TRUE` activa el procedimiento de intervalos para proporciones; no multiplica la estimación por 100 ni define su denominador, que aquí corresponde al dominio de personas de 15 años o más de cada sexo. `prop_method = "logit"` construye el intervalo en la escala logit con un cuantil de la distribución t de Student y aplica la transformación inversa a ambos límites para expresarlos en la escala de la proporción. Al omitir `df`, se utilizan los grados de libertad del diseño antes de la agrupación. Como la transformación inversa es no lineal, los límites pueden quedar a distancias distintas de la proporción estimada. Este método requiere que la proporción estimada esté estrictamente entre cero y uno.

Asimismo, el argumento `vartype = c("se", "ci")` solicita simultáneamente el error estándar y el intervalo de confianza, cuyo nivel predeterminado es 95 % (`level = 0.95`). Los valores faltantes se excluyen explícitamente con `filter(!is.na(Employment))` antes de agrupar: `survey_prop()` estima categorías a partir de la agrupación y no utiliza `na.rm` para eliminar una categoría faltante. El filtro final `filter(employed)` se aplica después de `summarise()`; hacerlo antes cambiaría el denominador y produciría una proporción igual a uno. Las opciones `.groups = "drop"` y `select(-employed)` dejan una tabla sin agrupación y retiran la columna indicadora, respectivamente.

Tabla 3.15.: Tasa de ocupación por sexo

Sexo	Tasa	EE	LI 95 %	LS 95 %
Female	0.430	0.026	0.379	0.483
Male	0.741	0.020	0.699	0.778

La tabla 3.15 presenta las estimaciones en escala de cero a uno. La tasa de ocupación es de 43.02 % para las mujeres y de 74.06 % para los hombres. Esto significa que, de cada 100 mujeres de 15 años o más, aproximadamente 43 están ocupadas; entre los hombres de esas edades, lo están aproximadamente 74 de cada 100. La diferencia estimada entre hombres y mujeres es de 31.04 puntos porcentuales; esta comparación es descriptiva y no constituye por sí sola una prueba de significación estadística. Los errores estándar son de 2.62 % para las mujeres y de 2.02 para los hombres. Los intervalos de confianza del 95 % van de 37.93 % a 48.26 % para las mujeres y de 69.87 % a 77.85 %

para los hombres. Nótese que la tasa de ocupación no es el complemento de la tasa de desocupación, pues sus denominadores son distintos: población en edad de trabajar y fuerza de trabajo, respectivamente.

Para comparar la distribución de la pobreza entre regiones, el siguiente código computacional agrupa el diseño por `Region` y `poor`. Así, `survey_prop()` estima las proporciones de personas pobres y no pobres dentro de cada región, junto con sus errores estándar e intervalos de confianza. Los resultados se presentan en la tabla 3.16.

```
region_poverty_proportion <- survey_design %>%
  group_by(Region, poor) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

region_poverty_proportion
```

Tabla 3.16.: Proporción en condición de pobreza por región

Región	Pobreza	Proporción	EE	LI 95 %	LS 95 %
North	0	0.641	0.055	0.526	0.742
North	1	0.359	0.055	0.258	0.474
South	0	0.656	0.043	0.566	0.737
South	1	0.344	0.043	0.263	0.434
Central	0	0.635	0.079	0.470	0.773
Central	1	0.365	0.079	0.227	0.530
West	0	0.599	0.047	0.504	0.687
West	1	0.401	0.047	0.313	0.496
East	0	0.548	0.088	0.374	0.711
East	1	0.452	0.088	0.289	0.626

Los resultados muestran diferencias regionales relevantes en la incidencia de la pobreza. La mayor proporción estimada se observa en Oriente, donde el 45,2 % de la población se encuentra en condición de pobreza, seguida de Occidente con 40,1 %; en contraste, Sur presenta la menor proporción, con 34,4 %, mientras que Norte y Centro registran valores de 35,9 % y 36,5 %, respectivamente. Sin embargo, estas diferencias deben interpretarse con cautela, ya que la precisión de las estimaciones varía considerablemente entre regiones: Oriente y Centro presentan los errores estándar más altos y, en consecuencia, intervalos de confianza más amplios. De hecho, el notable solapamiento de los intervalos de confianza sugiere que las diferencias observadas entre regiones no necesariamente reflejan diferencias estadísticamente significativas.

La tasa de pobreza por edad estima la proporción de personas de cada grupo etario que vive en hogares en condición de pobreza por ingresos. Se utilizan cuatro rangos de edad: 0 a 14, 15 a 29,

30 a 64 y 65 años o más. En este caso, los cuatro rangos pertenecen al universo del indicador. Se construyen a partir de `Age`, sin modificar `CatAge`. Para cada grupo, el denominador es la población de ese grupo con condición de pobreza observada. La variable `poor` reúne la pobreza extrema y la no extrema. El siguiente código computacional define los grupos de edad y estima la tasa de pobreza de cada uno.

```
poverty_age_table <- survey_design %>%
  filter(!is.na(Age), !is.na(poor)) %>%
  mutate(
    age_group = cut(
      Age,
      breaks = c(0, 15, 30, 65, Inf),
      labels = c("0-14", "15-29", "30-64", "65 años o más"),
      right = FALSE
    )
  ) %>%
  group_by(age_group, poor) %>%
  summarise(
    poverty_rate = survey_prop(
      vartype = c("se", "ci"),
      prop_method = "logit"
    ),
    .groups = "drop"
  ) %>%
  filter(poor == 1) %>%
  select(-poor)

poverty_age_table
```

La última variable de agrupación, `poor`, define las categorías cuya composición estima `survey_prop()` dentro de cada rango de edad. El filtro `poor == 1` se aplica después de estimar las proporciones, conservando en el denominador tanto a las personas pobres como a las no pobres. La tabla 3.17 presenta las estimaciones en una escala de cero a uno.

Tabla 3.17.: Tasa de pobreza por grupo de edad

Edad (años)	Tasa de pobreza	EE	LI 95 %	LS 95 %
0-14	0.511	0.0379	0.436	0.585
15-29	0.373	0.0423	0.294	0.460
30-64	0.322	0.0309	0.264	0.386
65 años o más	0.351	0.0374	0.281	0.428

La mayor tasa estimada corresponde al grupo de 0-14 años, con 51.09 %, y la menor al de 30-64 años, con 32.21 %. Las diferencias entre grupos deben interpretarse junto con sus errores estándar e intervalos de confianza del 95 %. Para evaluar diferencias se requiere un contraste que considere el diseño muestral y la covarianza entre estimaciones.

3.3.2. Razón de odds

De acuerdo con Agresti (2019), las *odds* de un evento son la razón entre la probabilidad de que ocurra y la probabilidad de que no ocurra, $p/(1-p)$. La razón de *odds* (*odds ratio*, OR) compara las *odds* de ese evento entre dos grupos y permite estudiar la asociación entre variables categóricas (Díaz Monroy et al. 2018). En este sentido, este parámetro permite evaluar cómo cambia dicha ventaja entre diferentes grupos de interés y constituye una herramienta fundamental en estudios sociales, económicos y de salud; además, esta medida también puede utilizarse para cuantificar la relación entre los niveles de una variable y un factor categórico, comparando las ventajas relativas de ocurrencia del evento en cada grupo.

Por ejemplo, suponga que se desea estudiar la asociación entre el sexo de las personas y la condición de pobreza. En particular, interesa evaluar si la ventaja relativa de pertenecer al grupo de personas no pobres frente al grupo de personas pobres es diferente entre mujeres y hombres. Para ello, puede expresarse la siguiente razón de *odds*:

$$OR = \frac{P(\text{pobreza} = 0 \mid \text{Sex} = \text{Female}) \big/ P(\text{pobreza} = 1 \mid \text{Sex} = \text{Female})}{P(\text{pobreza} = 0 \mid \text{Sex} = \text{Male}) \big/ P(\text{pobreza} = 1 \mid \text{Sex} = \text{Male})} \tag{3.8}$$

La expresión del numerador representa, entre las mujeres, la ventaja relativa de encontrarse en condición de no pobreza respecto de encontrarse en pobreza. De manera análoga, el denominador representa esa misma ventaja entre los hombres. Por tanto, la razón de odds compara ambas ventajas relativas y permite cuantificar si la asociación entre sexo y pobreza favorece más a un grupo que a otro.

Un valor igual a uno indicaría ausencia de asociación entre las variables, es decir, que la relación entre sexo y condición de pobreza es similar para hombres y mujeres. Valores superiores a uno indicarían una mayor ventaja relativa para las mujeres en comparación con los hombres, mientras que valores inferiores a uno sugerirían una mayor ventaja relativa para los hombres. En el contexto de encuestas de hogares, este tipo de medidas resulta especialmente útil para estudiar desigualdades sociodemográficas y brechas en condiciones de bienestar entre distintos grupos poblacionales (Heeringa et al. 2017).

Para estimar la razón de odds definida anteriormente, primero se necesitan las proporciones conjuntas de sexo y condición de pobreza, junto con sus varianzas y covarianzas. En la interfaz de fórmulas de `survey`, `~interaction(Sex, poor)` identifica las cuatro combinaciones de estas variables. El siguiente código computacional estima sus proporciones mediante `svymean()` y organiza las estimaciones, los errores estándar y los intervalos de confianza que se presentan en la tabla 3.18. El objeto resultante conserva las covarianzas necesarias para calcular después la razón de odds y su error estándar con `svycontrast()`. La Sección 3.5 desarrolla el uso de esta función para contrastes lineales.

```
sex_poverty_odds_contrast <- svymean(
  ~interaction(Sex, poor),
  design = survey_design,
  na.rm = TRUE
)
names(coef(sex_poverty_odds_contrast))
```

```
sex_poverty_odds_contrast
```

```
joint_ci <- confint(
  sex_poverty_odds_contrast,
  level = 0.95,
  df = degf(survey_design)
)

sex_poverty_joint_table <- tibble(
  domain = names(coef(sex_poverty_odds_contrast)),
  proportion = as.numeric(coef(sex_poverty_odds_contrast)),
  standard_error = as.numeric(SE(sex_poverty_odds_contrast)),
  lower = as.numeric(joint_ci[, 1]),
  upper = as.numeric(joint_ci[, 2])
)

sex_poverty_joint_table
```

Tabla 3.18.: Proporciones conjuntas de sexo y condición de pobreza

Sexo y pobreza	Proporción	EE	LI 95 %	LS 95 %
interaction(Sex, poor)Female.0	0.322	0.018	0.287	0.357
interaction(Sex, poor)Male.0	0.286	0.018	0.251	0.321
interaction(Sex, poor)Female.1	0.205	0.017	0.172	0.238
interaction(Sex, poor)Male.1	0.187	0.018	0.151	0.222

La expresión se construye con `quote()` para que `svycontrast()` la evalúe sobre las estimaciones. Los acentos graves delimitan los nombres de las celdas; estos se comprueban con `names(coef())`. El siguiente código computacional define la razón de odds y la estima mediante `svycontrast()`.

```
odds_ratio <- quote(
 (`interaction(Sex, poor)Female.0` /
  `interaction(Sex, poor)Female.1`) /
 (`interaction(Sex, poor)Male.0` /
  `interaction(Sex, poor)Male.1`)
)

sex_poverty_odds_ratio <- svycontrast(
  stat = sex_poverty_odds_contrast,
  contrasts = odds_ratio
)

sex_poverty_odds_ratio
```

```
         nlcon  SE
contrast  1.02 0.1
```

Una OR cercana a 1,02 indica odds de no pobreza aproximadamente 2 % mayores en mujeres que en hombres; no significa una probabilidad 2 % mayor ni establece una diferencia estadísticamente significativa.

El error estándar de esta razón depende de las covarianzas entre las cuatro celdas; no debe obtenerse tratando sus estimaciones como independientes.

3.4. Pruebas de hipótesis

Esta sección presenta procedimientos para evaluar hipótesis sobre variables categóricas considerando el diseño muestral de la encuesta. En particular, se abordan pruebas sobre diferencias de proporciones y pruebas de independencia para tablas de contingencia, con el propósito de determinar si las diferencias o asociaciones observadas en la muestra cuentan con respaldo estadístico en la población.

Para evaluar estas preguntas se utilizan pruebas de hipótesis; es decir, procedimientos estadísticos que permiten contrastar afirmaciones sobre parámetros poblacionales utilizando la información observada en la muestra. En el contexto de las encuestas de hogares, estas pruebas deben incorporar adecuadamente las características del diseño muestral con el fin de garantizar inferencias válidas y resultados confiables.

En términos generales, toda prueba de hipótesis se basa en el contraste entre dos proposiciones opuestas: la hipótesis nula, denotada por H_0, y la hipótesis alternativa, denotada por H_1. En el caso más común de una prueba bilateral, estas hipótesis se expresan como:

$$\begin{cases} H_0: & \theta = \theta_0 \\ H_1: & \theta \neq \theta_0 \end{cases}$$

donde θ representa el parámetro poblacional de interés y θ_0 un valor de referencia especificado bajo la hipótesis nula. Dependiendo del objetivo del análisis, la hipótesis alternativa también puede formularse de manera unilateral, por ejemplo, cuando se desea evaluar si $\theta > \theta_0$ o si $\theta < \theta_0$. En cualquier caso, el propósito de la prueba es determinar si la evidencia contenida en la muestra resulta suficientemente fuerte para rechazar la hipótesis nula en favor de la hipótesis alternativa.

Por ejemplo, las pruebas de hipótesis permiten evaluar si las diferencias observadas entre dos proporciones estimadas para distintos grupos reflejan diferencias en la población o si pueden atribuirse al error de muestreo (Korn y Graubard 1995). De esta forma, supóngase que p_H representa la tasa de desocupación de los hombres y p_M la tasa de desocupación de las mujeres dentro de la población económicamente activa. El parámetro de interés corresponde a la diferencia entre ambas tasas:

$$\Delta_p = p_H - p_M.$$

Para evaluar si las tasas de desocupación de hombres y mujeres son diferentes, se plantea el siguiente sistema de hipótesis bilateral:

$$\begin{cases} H_0: & \Delta_p = 0 \\ H_1: & \Delta_p \neq 0 \end{cases}$$

El estimador muestral de esta diferencia se define como $\hat{\Delta}_p = \hat{p}_H - \hat{p}_M$. Su error estándar debe considerar tanto las varianzas de las tasas estimadas como la covarianza entre ellas:

$$\widehat{se}(\hat{\Delta}_p) = \sqrt{\widehat{Var}(\hat{p}_H) + \widehat{Var}(\hat{p}_M) - 2\widehat{Cov}(\hat{p}_H, \hat{p}_M)}. \tag{3.9}$$

Una vez calculado el estimador y su error estándar, el contraste de hipótesis se realiza utilizando el siguiente estadístico de prueba:

$$t = \frac{\hat{\Delta}_p}{\widehat{se}(\hat{\Delta}_p)} \tag{3.10}$$

Bajo la hipótesis nula, el estadístico sigue aproximadamente una distribución t de Student con df grados de libertad. Los grados de libertad deben corresponder al procedimiento aplicado; `degf()` resume los del diseño, pero una prueba basada en un modelo puede descontar parámetros adicionales. Se utilizarán los grados de libertad devueltos por `svyttest()`. Bajo la hipótesis nula, valores absolutos elevados del estadístico t proporcionan evidencia en contra de la igualdad de las tasas. Un intervalo de confianza de nivel $(1-\alpha)100\,\%$ para la diferencia se construye combinando la estimación, su error estándar y el cuantil apropiado:

$$\hat{\Delta}_p \;\pm\; t_{1-\frac{\alpha}{2},\,df}\,\widehat{se}(\hat{\Delta}_p).$$

Este intervalo proporciona un rango de valores plausibles para la diferencia poblacional entre las tasas y constituye una herramienta útil para evaluar tanto la magnitud como la significación estadística de las diferencias observadas entre grupos. En `R`, estas pruebas pueden implementarse mediante la función `svyttest()` del paquete `survey`, la cual incorpora automáticamente los ajustes asociados al diseño muestral.

Asimismo, el valor-p se define como la probabilidad, suponiendo verdadera la hipótesis nula $H_0 : \Delta_p = 0$, de obtener un estadístico de prueba tan extremo o más extremo que el observado. Para el contraste bilateral de igualdad de tasas, se calcula como:

$$\text{valor-}p = 2\,\Pr(T \geq |t|)\,.$$

Aquí, T representa una variable aleatoria con distribución t de Student y df grados de libertad bajo H_0, mientras que t es el estadístico observado. Un valor-p pequeño indica mayor incompatibilidad entre los datos y la hipótesis nula. Si es menor que el nivel de significación α, se rechaza H_0; en caso contrario, no se rechaza. Nòtese que el valor-p no representa la probabilidad de que H_0 sea verdadera.

Para evaluar si la tasa de desocupación difiere entre hombres y mujeres, se utiliza la subpoblación `labor_force_subset`, creada previamente a partir del diseño completo. Dentro de este dominio, `unemployed` vale uno para las personas desocupadas y cero para las ocupadas. Su media ponderada por sexo estima la tasa de desocupación de cada grupo. Las personas inactivas y las menores de 15 años no forman parte del denominador. El siguiente código computacional recupera las tasas de desocupación por sexo calculadas previamente. Se fija `Female` como referencia para que la diferencia sea hombres menos mujeres. El intervalo devuelto por esta prueba es del 95 %.

```
sex_unemployment_rate
```

Tabla 3.19.: Tasas de desocupación por sexo para la prueba de hipótesis

Sexo	Tasa	EE	LI 95 %	LS 95 %
Female	0.048	0.012	0.029	0.078
Male	0.084	0.015	0.059	0.118

Las tasas por sexo, calculadas en `sex_unemployment_rate`, se presentan en la tabla 3.19. El siguiente código computacional utiliza `svyttest()` del paquete `survey` para contrastar la diferencia entre las tasas de desocupación de hombres y mujeres, incorporando el diseño muestral. Luego reúne la diferencia estimada, el estadístico, el valor-p, los grados de libertad y el intervalo de confianza para su presentación en una tabla.

```
ttest_unemployment_sex <- svyttest(
  unemployed ~ Sex,
  design = labor_force_subset %>%
    mutate(
      Sex = factor(Sex, levels = c("Female", "Male"))
    )
)

ttest_unemployment_sex
```

```
unemployment_test_summary <- tibble(
  estimated_difference = ttest_unemployment_sex$estimate,
  statistic = ttest_unemployment_sex$statistic,
  p_value = ttest_unemployment_sex$p.value,
  gl = ttest_unemployment_sex$parameter,
  ci_lower = ttest_unemployment_sex$conf.int[1],
  ci_upper = ttest_unemployment_sex$conf.int[2]
)

unemployment_test_summary
```

Tabla 3.20.: Prueba de diferencia de tasas de desocupación por sexo (población económicamente activa)

Diferencia	Estadístico t	Valor p	gl	LI 95 %	LS 95 %
0.036	2.18	0.031	118	0.003	0.068

La tabla 3.20 estima una diferencia de 3.59 puntos porcentuales entre la tasa de desocupación de los hombres y la de las mujeres. El estadístico es $t = 2.182$, con 118 grados de libertad y un valor-p de 0.031. El intervalo de confianza del 95 % para la diferencia va de 0.33 a 6.85 puntos porcentuales. Al nivel del 5 %, se rechaza la hipótesis nula de igualdad de tasas, por lo que la diferencia es estadísticamente significativa.

3.4.1. Prueba de independencia de Rao-Scott

Como se explicó en la sección anterior, una prueba de hipótesis es un procedimiento estadístico utilizado para evaluar si la evidencia observada en una muestra es compatible con una afirmación acerca de la población. En el contexto de tablas de contingencia, las pruebas de independencia permiten analizar si existe asociación entre dos variables categóricas (Agresti 2019).

En este caso, la hipótesis nula (H_0) establece que ambas variables son independientes; es decir, que la distribución de una variable no depende de las categorías de la otra. Bajo este supuesto, las diferencias observadas en la muestra se atribuyen únicamente a la variabilidad muestral y no a una relación real entre las variables en la población. Matemáticamente, esta hipótesis puede expresarse como:

$$H_0 : p^0_{rc} = p_{r+} \times p_{+c}, \quad \text{para todo } r = 1, \dots, R \text{ y } c = 1, \dots, C$$

En donde p^0_{rc} representa la proporción esperada en la celda (r, c) bajo el supuesto de independencia, mientras que p_{r+} y p_{+c} corresponden a las proporciones marginales de las filas y columnas, respectivamente. Bajo esta formulación, la hipótesis de independencia implica que la probabilidad conjunta de cada celda puede expresarse como el producto de sus probabilidades marginales.

En consecuencia, la prueba de independencia consiste en comparar las proporciones observadas o estimadas $\hat{p}_{rc}$ con las proporciones esperadas p^0_{rc} bajo la hipótesis nula. Cuando las diferencias entre ambas son pequeñas, la evidencia empírica resulta consistente con el supuesto de independencia. Por el contrario, discrepancias suficientemente grandes sugieren la existencia de asociación entre las variables y conducen al rechazo de H_0.

Como señalan Rao y Scott (1981), las características propias de los diseños muestrales complejos utilizados en las encuestas de hogares (estratificación, la selección por conglomerados y el uso de factores de expansión) modifican la estructura de variabilidad de los estimadores. En consecuencia, la prueba clásica de independencia basada en el estadístico χ^2 de Pearson no resulta, en general, adecuada para el análisis de tablas de contingencia construidas a partir de este tipo de encuestas, ya que ignora la variabilidad adicional inducida por el diseño de muestreo y, por tanto, puede conducir a inferencias incorrectas.

Con el propósito de corregir esta limitación, Fay (1979), Fellegi (1980) y Thomas y Rao (1987) propusieron algunos de los primeros ajustes al estadístico χ^2 de Pearson, apoyados en el efecto de diseño generalizado ($GDEFF$). Posteriormente, Rao y Scott (1984) amplió y formalizó el marco teórico de estas correcciones, dando lugar a lo que actualmente se conoce como la prueba de Rao-Scott. Este procedimiento ajusta la prueba de independencia para incorporar las características del diseño complejo y constituye una de las principales herramientas para el análisis de datos categóricos provenientes de encuestas por muestreo (Heeringa et al. 2017).

$$\chi^2_{RS} = \frac{n_{++}}{GDEFF} \sum_r \sum_c \frac{(\hat{p}_{rc} - p^0_{rc})^2}{p^0_{rc}} \tag{3.11}$$

En donde n_{++} representa el tamaño total de la muestra, $\hat{p}_{rc}$ corresponde a la proporción estimada en la celda (r, c) de la tabla de contingencia y p^0_{rc} denota la proporción esperada bajo la hipótesis nula de independencia, calculada a partir del producto de las proporciones marginales de filas y columnas. El término $GDEFF$ representa el efecto de diseño generalizado y mide cuánto se incrementa o

disminuye la variabilidad de las estimaciones como consecuencia del diseño complejo de la encuesta respecto a la variabilidad que se observaría bajo un muestreo aleatorio simple.

Bajo la hipótesis nula de independencia, H_0, el estadístico de Rao-Scott, χ^2_{RS}, puede aproximarse mediante una distribución χ^2 con $(R-1)(C-1)$ grados de libertad, donde R y C corresponden al número de categorías de las variables dispuestas en las filas y columnas de la tabla de contingencia, respectivamente. Sin embargo, en encuestas con diseños muestrales complejos también es habitual emplear una aproximación basada en la distribución F, ya que esta permite incorporar de manera más adecuada la variabilidad inducida por características del diseño complejo.

El paquete `survey` de `R` implementa estas pruebas mediante la función `svychisq()`. Al especificar `statistic = "F"`, la función utiliza la corrección de Rao-Scott de segundo orden y aproxima la distribución del estadístico mediante una distribución F. Este ajuste tiene en cuenta tanto la media como la variabilidad del estadístico de prueba e incorpora, además de los grados de libertad asociados al contraste de independencia, los grados de libertad disponibles en el diseño muestral para estimar dicha variabilidad. En `R`, los grados de libertad se obtienen mediante el comando `survey::degf(survey_design)`.

En la función `svychisq()`, el argumento `formula` especifica las dos variables categóricas cuya independencia se desea evaluar, mientras que `design` corresponde al objeto que contiene la información del diseño muestral previamente definido. Por su parte, `statistic = "F"` indica que la inferencia se realizará utilizando la aproximación basada en la distribución F. La decisión estadística se toma comparando el valor-p con el nivel de significancia establecido. Por ejemplo, para un nivel de significancia del 5 %, si el valor-p es superior a 0.05 no se rechaza H_0, por lo que no existe evidencia estadística suficiente para afirmar que las variables están asociadas. En cambio, si el valor-p es inferior a 0.05, se rechaza H_0, lo que proporciona evidencia de una asociación entre las variables categóricas analizadas.

A modo de ejemplo, para evaluar si la condición de pobreza es independiente del sexo, se puede ejecutar el siguiente código:

```
poverty_sex_test <- svychisq(
  formula = ~Sex + poor,
  design = survey_design,
  statistic = "F"
)

poverty_sex_test
```

```
    Pearson's X^2: Rao & Scott adjustment

data:  NextMethod()
F = 0.06, ndf = 1, ddf = 119, p-value = 0.8
```

El resultado de la prueba de independencia de Rao-Scott no proporciona evidencia de una asociación estadísticamente significativa entre el sexo y la condición de pobreza. En particular, el valor-p obtenido es considerablemente mayor que los niveles de significancia usuales, por lo que no se rechaza la hipótesis nula de independencia entre ambas variables. En consecuencia, con base en

la muestra analizada y teniendo en cuenta el diseño complejo de la encuesta, que dispone de 119 grados de libertad, no se observan diferencias estadísticamente significativas en la distribución de la condición de pobreza entre hombres y mujeres. El siguiente código computacional aplica el mismo procedimiento para evaluar la asociación entre condición de empleo y sexo.

```
employment_sex_test <- svychisq(
  formula = ~Sex + Employment,
  design = survey_design %>%
    filter(!is.na(Employment)),
  statistic = "F"
)

employment_sex_test
```

```
    Pearson's X^2: Rao & Scott adjustment

data:  NextMethod()
F = 62, ndf = 2, ddf = 201, p-value <0.0000000000000002
```

En este caso, para el contraste de independencia entre las variables `Sex` y `Employment`, el estadístico obtenido fue $F = 62,251$, con un valor-p de <0.001, lo que proporciona evidencia estadísticamente significativa para rechazar la hipótesis nula de independencia entre ambas variables. En consecuencia, los resultados sugieren que sí existe una asociación significativa entre el sexo y la condición de empleo en la población de estudio. El siguiente código computacional aplica la prueba de independencia entre la condición de pobreza y la región.

```
poverty_region_test <- svychisq(
  formula = ~Region + poor,
  design = survey_design,
  statistic = "F"
)

poverty_region_test
```

```
    Pearson's X^2: Rao & Scott adjustment

data:  NextMethod()
F = 0.5, ndf = 3, ddf = 358, p-value = 0.7
```

Por otro lado, esta prueba de independencia entre las variables `Region` y `poor`, da como resultado $F = 0,48794$, con un valor-p de 0.691. Dado que este valor-p es considerablemente mayor que niveles de significancia convencionales, no existe evidencia suficiente para rechazar la hipótesis nula de independencia. Por tanto, los resultados sugieren que, bajo el diseño muestral considerado, no se observa una asociación estadísticamente significativa entre la región y la condición de pobreza.

3.5. Estimación de contrastes

Cuando se analizan conjuntamente dos variables categóricas, es posible examinar cómo se distribuye una de ellas dentro de los grupos definidos por la otra. Por ejemplo, puede estudiarse la proporción de personas en situación de pobreza por sexo, zona de residencia o condición de actividad. Cada una de estas categorías define una subpoblación específica, para la cual pueden estimarse proporciones y sus correspondientes medidas de precisión (Korn y Graubard 1999; Heeringa et al. 2017).

Sin embargo, la estimación separada de estas proporciones no siempre es suficiente. Con frecuencia, el interés principal consiste en determinar cuánto difieren dos grupos y si la brecha observada es suficientemente grande en relación con la incertidumbre asociada al muestreo. Para ello, pueden construirse contrastes lineales que expresen la diferencia entre dos proporciones estimadas y permitan obtener su error estándar, intervalo de confianza y, cuando corresponda, una prueba de significancia.

Según Heeringa et al. (2017), para formular estas comparaciones se utilizan los contrastes, que constituyen una herramienta flexible para evaluar combinaciones lineales de parámetros poblacionales. En términos generales, un contraste se define como:

$$f\left(\theta_1, \theta_2, \ldots, \theta_J\right) = \sum_{j=1}^{J} a_j \theta_j,$$

donde los coeficientes a_j son constantes conocidas y θ_j representan los parámetros de interés. Este enfoque permite formular y evaluar una amplia variedad de comparaciones entre grupos, incluyendo diferencias entre medias, comparaciones múltiples y combinaciones más complejas de parámetros.

Supóngase, por ejemplo, que se desea comparar la proporción de mujeres en situación de pobreza con la proporción correspondiente a los hombres. Este contraste puede expresarse como $\hat{p}_F - \hat{p}_M$, donde $\hat{p}_F$ representa la proporción estimada de mujeres en pobreza y $\hat{p}_M$ la proporción estimada de hombres en la misma condición.

`svyby()` estima un parámetro (`formula`) dentro de los grupos de `by`; `FUN = svymean` indica la media de la indicadora. `na.rm = TRUE` excluye faltantes del cálculo y `vartype` solicita medidas de precisión. `covmat = TRUE` conserva las covarianzas entre estimaciones. `vcov()` recupera esa matriz y `svycontrast()` combina los coeficientes sin perderla. Una tabla que solo conserva estimaciones y errores estándar individuales no contiene todas esas covarianzas.

Al solicitar `vartype = "ci"`, `svyby()` obtiene los límites mediante el método de intervalo correspondiente al estimador indicado en `FUN`. En los ejemplos del libro que emplean `svymean()` o `svyratio()` dentro de `svyby()`, esos límites se calculan con la aproximación normal. El siguiente código computacional estima las proporciones de pobreza por sexo y conserva sus covarianzas para los contrastes posteriores.

```
sex_poverty_contrast <- svyby(
  formula = ~poor,
  by = ~Sex,
  design = survey_design,
  FUN = svymean,
  na.rm = TRUE,
```

```
  covmat = TRUE,
  vartype = c("se", "ci")
)

sex_poverty_contrast
```

Tabla 3.21.: Proporción en condición de pobreza por sexo

Sexo	Proporción	EE	LI 95 %	LS 95 %
Female	0.389	0.032	0.327	0.451
Male	0.395	0.037	0.323	0.466

A partir de las estimaciones de la tabla 3.21, el siguiente código computacional utiliza `svycontrast()` para calcular la proporción de mujeres en pobreza menos la de hombres y obtener el error estándar de esa diferencia.

```
sex_poverty_estimate <- setNames(
  as.numeric(sex_poverty_contrast[["poor"]]),
  sex_poverty_contrast[["Sex"]]
)

sex_poverty_estimate["Female"] - sex_poverty_estimate["Male"]
```

```
  Female
-0.00532
```

Para estimar correctamente la variabilidad asociada a esta diferencia debe incorporarse la covarianza entre ambas estimaciones, ya que estas no provienen de dos muestras independientes. En efecto, hombres y mujeres pueden pertenecer a los mismos hogares y, además, los hogares de ambos grupos son seleccionados dentro de las mismas unidades primarias de muestreo (UPM). Por consiguiente, las dos proporciones comparten la estructura de dependencia inducida por el diseño de muestreo. Esto implica que las variaciones observadas en una estimación pueden estar relacionadas con las de la otra y, por tanto, que su covarianza no puede suponerse igual a cero. En este contexto, el error estándar de la diferencia (contraste) debe calcularse aplicando las propiedades de la varianza e incorporando explícitamente dicha covarianza, de la siguiente forma:

$$\widehat{se}\left(\hat{p}_F - \hat{p}_M\right) = \sqrt{\widehat{Var}\left(\hat{p}_F\right) + \widehat{Var}\left(\hat{p}_M\right) - 2\,\widehat{Cov}\left(\hat{p}_F, \hat{p}_M\right)}$$

El siguiente código computacional extrae la matriz de varianzas y covarianzas con `vcov()` y conserva sus nombres de fila como una columna para presentarla en la tabla 3.22.

```
sex_poverty_vcov <- vcov(sex_poverty_contrast)

sex_poverty_vcov
```

```
sex_poverty_vcov_table <- as.data.frame(sex_poverty_vcov) %>%
  tibble::rownames_to_column("domain")

sex_poverty_vcov_table
```

Tabla 3.22.: Matriz de varianzas y covarianzas de la proporción de pobreza por sexo

Sexo	Mujeres	Hombres
Female	0.000998	0.000918
Male	0.000918	0.001342

El siguiente código computacional calcula el error estándar de la diferencia a partir de la matriz anterior. Para ello, obtiene la raíz cuadrada de la suma de las varianzas de ambas proporciones menos dos veces su covarianza.

```
sqrt(
  sex_poverty_vcov["Female", "Female"] +
    sex_poverty_vcov["Male", "Male"] -
    2 * sex_poverty_vcov["Female", "Male"]
)
```

```
[1] 0.0224
```

No obstante, el paquete `survey` permite realizar este procedimiento de forma directa mediante la función `svycontrast`, la cual calcula tanto el contraste lineal como su error estándar asociado. Para obtener la diferencia entre las proporciones de mujeres y hombres en condición de pobreza, se utiliza el siguiente código:

```
poverty_sex_difference <- svycontrast(
  stat = sex_poverty_contrast,
  contrasts = list(
    sex_difference = c(Female = 1, Male = -1)
  )
)

as.data.frame(poverty_sex_difference)
```

```
               contrast sex_difference
sex_difference -0.00532         0.0224
```

De lo que se concluye que la diferencia estimada entre las proporciones de mujeres y hombres en estado de pobreza es -0,5 puntos porcentuales, con un error estándar de 2,2 puntos porcentuales. Dada la magnitud del error estándar respecto de la diferencia, la estimación no debe interpretarse por sí sola como evidencia de una menor proporción de pobreza entre las mujeres.

El siguiente código computacional estima las tasas de desocupación por región y conserva sus covarianzas para los contrastes posteriores. Se utiliza `labor_force_subset`, de modo que el denominador es la fuerza de trabajo de cada región. Los resultados se presentan en la tabla 3.23 y se expresan en escala de cero a uno.

```
region_unemployment_rate <- svyby(
  formula = ~ unemployed,
  by = ~ Region,
  design = labor_force_subset,
  FUN = svymean,
  na.rm = TRUE,
  covmat = TRUE,
  vartype = c("se", "ci")
)

region_unemployment_rate
```

Tabla 3.23.: Tasa de desocupación por región

Región	Tasa	EE	LI 95 %	LS 95 %
North	0.078	0.029	0.021	0.134
South	0.097	0.032	0.034	0.161
Central	0.062	0.019	0.025	0.099
West	0.068	0.020	0.030	0.106
East	0.050	0.022	0.008	0.092

Las tasas de desocupación estimadas son 7.8 % en Norte, 9.73 % en Sur, 6.19 % en Centro, 6.81 % en Occidente y 5.02 % en Oriente.

Una vez estimadas las tasas de desocupación por región, se comparan Norte menos Centro, Sur menos Centro y Occidente menos Oriente. La matriz siguiente utiliza el orden de columnas Norte, Sur, Centro, Occidente y Oriente. En el código, los coeficientes se asignan por nombre para que el resultado no dependa de su posición en la salida.

$$\begin{bmatrix} 1 & 0 & -1 & 0 & 0 \\ 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{bmatrix}$$

El error estándar de cada contraste requiere considerar tanto las varianzas de las tasas regionales como sus covarianzas. El siguiente código computacional extrae esta matriz y la organiza en una tabla, conservando los nombres de las regiones.

```
region_unemployment_vcov <- vcov(region_unemployment_rate)

region_unemployment_vcov
```

```
region_unemployment_vcov_table <- as.data.frame(region_unemployment_vcov) %>%
  tibble::rownames_to_column("domain")

region_unemployment_vcov_table
```

Tabla 3.24.: Matriz de varianzas y covarianzas de la tasa de desocupación por región

Región	Norte	Sur	Centro	Occidente	Oriente
North	0.00083	0.00000	0.000000	0.00000	0.000000
South	0.00000	0.00104	0.000000	0.00000	0.000000
Central	0.00000	0.00000	0.000363	0.00000	0.000000
West	0.00000	0.00000	0.000000	0.00038	0.000000
East	0.00000	0.00000	0.000000	0.00000	0.000463

La tabla 3.24 permite examinar las covarianzas estimadas. Si la selección por región se realiza de manera independiente, las covarianzas entre estimadores de regiones distintas pueden ser nulas. Esta conclusión debe apoyarse en el diseño y no únicamente en ceros impresos tras redondear. A continuación se calculan los errores estándar de cada diferencia conservando el término de covarianza.

```
# North - Central
sqrt(
  region_unemployment_vcov["North", "North"] +
    region_unemployment_vcov["Central", "Central"] -
    2 * region_unemployment_vcov["North", "Central"]
)
```

```
[1] 0.0345
```

```
# South - Central
sqrt(
  region_unemployment_vcov["South", "South"] +
    region_unemployment_vcov["Central", "Central"] -
    2 * region_unemployment_vcov["South", "Central"]
)
```

```
[1] 0.0375
```

```
# West - East
sqrt(
  region_unemployment_vcov["West", "West"] +
    region_unemployment_vcov["East", "East"] -
    2 * region_unemployment_vcov["West", "East"]
)
```

```
[1] 0.029
```

Alternativamente, el paquete `survey` permite calcular estos contrastes de manera directa mediante la función `svycontrast`, la cual obtiene tanto las diferencias estimadas entre tasas como sus respectivos errores estándar. En este caso, la estimación de los contrastes definidos anteriormente se realiza de la siguiente manera:

```
unemployment_region_differences <- svycontrast(
  stat = region_unemployment_rate,
  contrasts = list(
    north_center = c(North = 1, Central = -1),
    south_center = c(South = 1, Central = -1),
    west_east = c(West = 1, East = -1)
  )
)

unemployment_region_differences %>%
  data.frame()
```

```
             contrast     SE
north_center   0.0161 0.0345
south_center   0.0354 0.0375
west_east      0.0180 0.0290
```

Las diferencias entre las tasas de desocupación son 1.61 puntos porcentuales para Norte menos Centro, 3.54 para Sur menos Centro y 1.8 para Occidente menos Oriente. Sus errores estándar son 3.45, 3.75 y 2.9 puntos porcentuales, respectivamente. Estos contrastes individuales no constituyen una prueba conjunta ni incorporan un ajuste por comparaciones múltiples.

3.6. Visualización de variables categóricas

La visualización de variables categóricas es fundamental en el análisis de encuestas de hogares, ya que permite comunicar de manera clara la distribución de grupos poblacionales y las comparaciones entre ellos. Los gráficos deben permitir que la representación visual corresponda a estimaciones válidas a nivel poblacional.

La construcción de los gráficos presentados en este documento se basa en el enfoque conocido como la gramática de los gráficos, el cual concibe cada visualización como la combinación de distintos componentes que se agregan: los datos, las correspondencias entre variables y atributos visuales, los elementos geométricos, las escalas, las facetas y el sistema de coordenadas (Wilkinson 2005). Este enfoque se implementa en `R` mediante el paquete `ggplot2`, que permite construir representaciones gráficas de manera sistemática y flexible (Wickham, Chang, et al. 2026). Las estimaciones obtenidas con los paquetes `survey` y `srvyr`, incluidos los factores de expansión y las medidas de incertidumbre, se utilizan como insumos para elaborar los gráficos.

3.6.1. Gráficos de barras

La construcción de gráficos de barras en `R` requiere, como paso previo, obtener las estimaciones que se desean representar visualmente. En el contexto de encuestas complejas, estas estimaciones pueden calcularse mediante las funciones `survey_total()` o `survey_prop()` del paquete `srvyr`, dependiendo de si el interés se centra en totales poblacionales o proporciones. El siguiente código computacional carga `ggplot2`, que se utilizará para representar estas estimaciones.

```
library(ggplot2)
```

Para representar adecuadamente la variabilidad de las estimaciones derivada del diseño muestral, los gráficos de barras deberían incorporar los correspondientes intervalos de confianza obtenidos mediante los procedimientos descritos en este capítulo. De esta manera, el gráfico no solo muestra la magnitud de las estimaciones puntuales, sino también la incertidumbre asociada a cada una de ellas, lo que permite realizar una interpretación más completa de los resultados. A continuación, se ilustra este procedimiento utilizando las estimaciones del tamaño poblacional según zona de residencia. Los resultados se presentan en la figura 3.1.

```
zone_size <- survey_design %>%
  group_by(Zone) %>%
  summarise(
    size = survey_total(vartype = c("se", "ci"))
  )

zone_colors <- c(Urban = "#48C9B0", Rural = "#117864")

ggplot(
  data = zone_size,
  aes(
    x = Zone,
    y = size,
    ymax = size_upp,
    ymin = size_low,
    fill = Zone
  )
) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_errorbar(
    position = position_dodge(width = 0.9),
    width = 0.3
  ) +
  scale_fill_manual(values = zone_colors) +
  theme_bw() +
  theme(legend.position = "top")
```

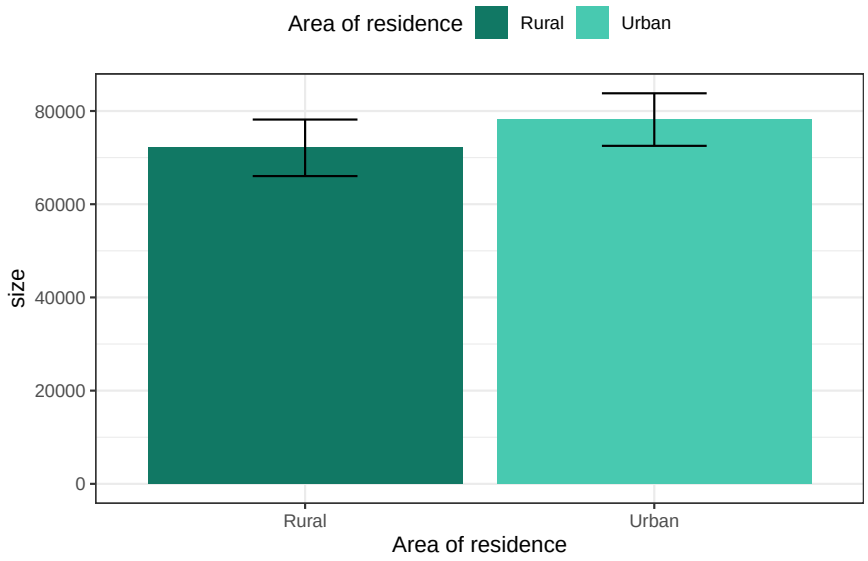


Figura 3.1.: Estimación del tamaño poblacional por zona geográfica

El código comienza estimando, para cada categoría de la variable `Zone`, el tamaño poblacional mediante `survey_total()`, teniendo en cuenta el diseño muestral complejo. Además de la estimación puntual, se solicitan el error estándar y los límites del intervalo de confianza mediante `vartype = c("se", "ci")`, cuyos resultados se almacenan en el objeto `zone_size`. Posteriormente, se define una paleta de colores específica para las zonas urbana y rural y se construye el gráfico con `ggplot2`. En la estética del gráfico, `size` determina la altura de cada barra, mientras que `size_low` y `size_upp` establecen los límites inferior y superior de las barras de error. La función `geom_bar()` representa los tamaños poblacionales estimados y `geom_errorbar()` añade los intervalos de confianza correspondientes. Finalmente, `scale_fill_manual()` asigna los colores definidos previamente, `theme_bw()` aplica un formato visual limpio y `theme(legend.position = "top")` ubica la leyenda en la parte superior del gráfico.

El procedimiento anterior puede extenderse naturalmente a variables con más de dos categorías. En estos casos, el gráfico de barras facilita la comparación simultánea de las estimaciones correspondientes a cada categoría y, al incorporar sus intervalos de confianza, permite apreciar también la precisión asociada a cada una de ellas. A modo de ejemplo, a continuación se presenta la distribución estimada de la población según su condición de pobreza; los resultados gráficos se muestran en la figura 3.2.

```
poverty_size <-
  survey_design %>%
  group_by(Poverty) %>%
  summarise(
    size = survey_total(vartype = c("se", "ci"))
  )

ggplot(
  data = poverty_size,
  aes(
```

```
    x = Poverty,
    y = size,
    ymax = size_upp,
    ymin = size_low,
    fill = Poverty
  )
) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_errorbar(
    position = position_dodge(width = 0.9),
    width = 0.3
  ) +
  theme_bw() +
  theme(legend.position = "top")
```

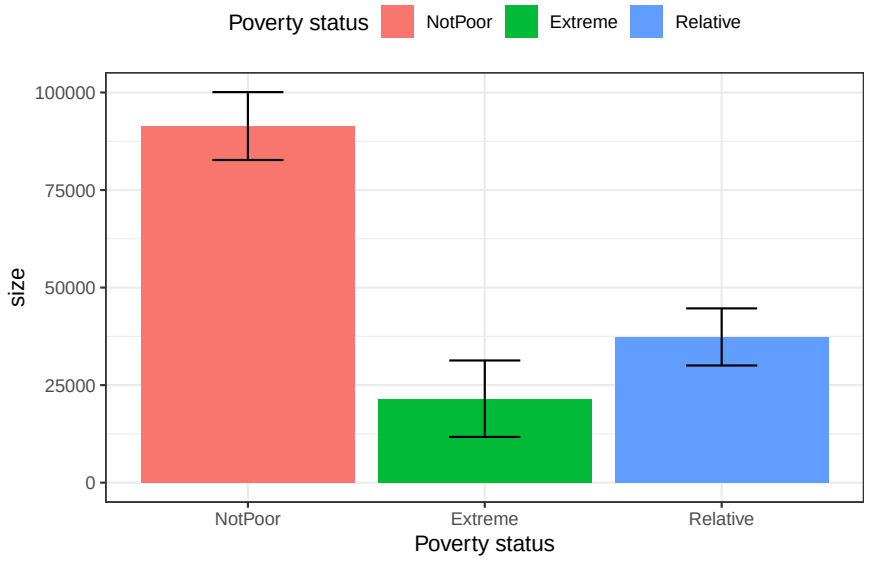


Figura 3.2.: Estimación del número de personas según condición de pobreza

Una de las ventajas de los gráficos de barras es que pueden extenderse fácilmente al análisis conjunto de dos variables categóricas. En este contexto, permiten comparar las estimaciones correspondientes a las distintas combinaciones de categorías y apreciar de manera visual las diferencias entre grupos. A modo de ejemplo, se presenta la estimación del número de personas según su condición de pobreza y estado de ocupación, cuyos resultados se muestran en la figura 3.3, obtenida con el siguiente código computacional.

```
employment_poverty_size <- survey_design %>%
  filter(!is.na(Employment)) %>%
  group_by(Employment, Poverty) %>%
  summarise(
    size = survey_total(vartype = c("se", "ci"))
```

```
  )

ggplot(
  employment_poverty_size,
  aes(
    x = Poverty,
    y = size,
    fill = Employment,
    ymin = size_low,
    ymax = size_upp
  )
) +
  geom_col(position = position_dodge(width = 0.9)) +
  geom_errorbar(
    position = position_dodge(width = 0.9),
    width = 0.3
  ) +
  labs(
    x = "Condición de pobreza",
    y = "Personas estimadas",
    fill = "Condición de actividad"
  ) +
  theme_bw() +
  theme(legend.position = "top")
```

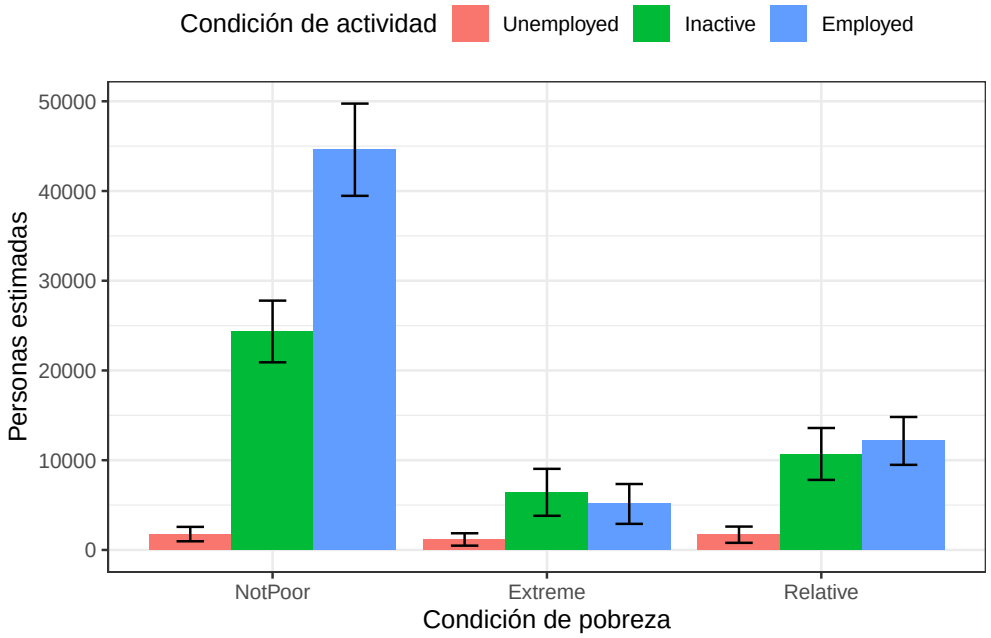


Figura 3.3.: Estimación del número de personas por estado de ocupación y situación de pobreza

El gráfico usa las categorías originales de `Employment` y excluye sus faltantes: no confunde inactividad con ocupación ni asigna a los faltantes una condición laboral no observada.

Este tipo de análisis gráfico resulta especialmente útil para examinar posibles intersecciones de vulnerabilidad, ya que permite representar simultáneamente dos o más características de la población y comparar los resultados entre distintos grupos. Además de mostrar conteos o tamaños poblacionales estimados, los gráficos de barras pueden emplearse para representar proporciones, junto con sus correspondientes medidas de precisión. A modo de ejemplo, se presenta la proporción estimada de hombres en condición de pobreza según zona de residencia, incorporando los intervalos de confianza asociados a cada estimación. Se muestran las tres categorías de pobreza dentro de cada zona de la población masculina. Los resultados se muestran en la figura 3.4, obtenida con el siguiente código computacional.

```
male_zone_poverty_proportion <-
  male_subset %>%
  group_by(Zone, Poverty) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  )

ggplot(
  data = male_zone_poverty_proportion,
  aes(
    x = Poverty,
    y = proportion,
    ymax = proportion_upp,
    ymin = proportion_low,
    fill = Zone
  )
) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_errorbar(
    position = position_dodge(width = 0.9),
    width = 0.3
  ) +
  scale_fill_manual(values = zone_colors) +
  theme_bw() +
  theme(legend.position = "top")
```

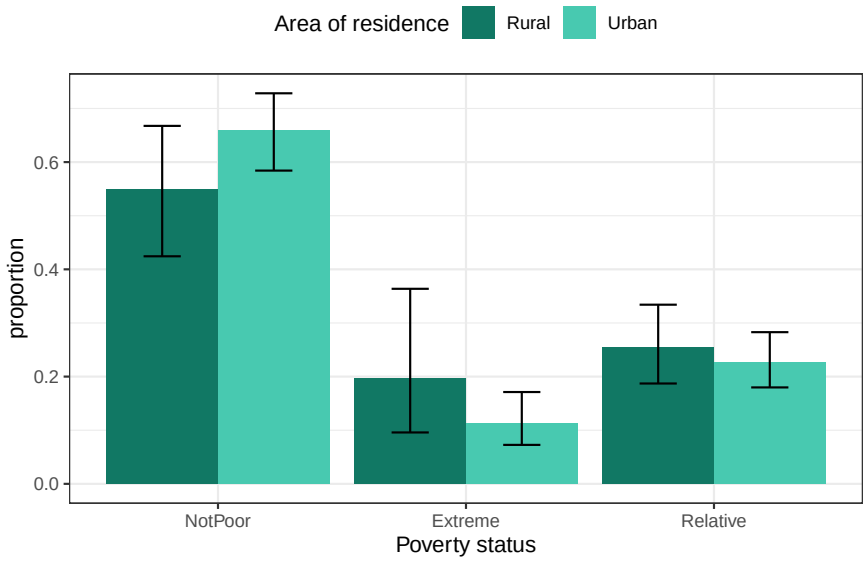


Figura 3.4.: Proporción de hombres en condición de pobreza por zona geográfica

De manera análoga, este tipo de representación puede extenderse a niveles más detallados de desagregación geográfica. Por ejemplo, es posible comparar, entre regiones, las proporciones de hombres pobres y no pobres e incorporar sus correspondientes intervalos de confianza. Esta representación permite observar la composición de la población masculina de cada región según la condición de pobreza y evaluar la precisión de las estimaciones. La leyenda identifica las categorías como «No pobre» y «Pobre»; el mapa posterior selecciona únicamente la categoría `poor == 1`. Los resultados se presentan en la figura 3.5, obtenida con el siguiente código computacional.

```
male_region_poverty_proportion <-
  male_subset %>%
  group_by(Region, poor) %>%
  summarise(
    proportion = survey_prop(
      vartype = c("se", "ci"),
      proportion = TRUE,
      prop_method = "logit"
    )
  ) %>%
  data.frame()

ggplot(
  data = male_region_poverty_proportion,
  aes(
    x = Region,
    y = proportion,
    ymax = proportion_upp,
    ymin = proportion_low,
    fill = factor(
```

```
      poor,
      levels = c(0, 1),
      labels = c("No pobre", "Pobre")
    )
  )
) +
  geom_bar(stat = "identity", position = "dodge") +
  geom_errorbar(
    position = position_dodge(width = 0.9),
    width = 0.3
  ) +
  scale_fill_discrete(name = "Condición de pobreza") +
  theme_bw() +
  theme(legend.position = "top")
```

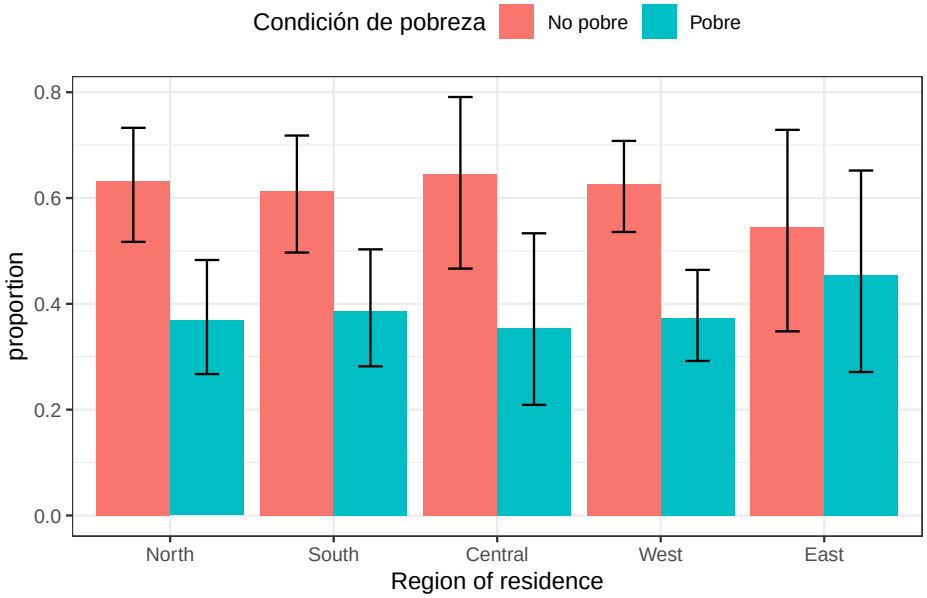


Figura 3.5.: Proporciones de hombres pobres y no pobres por región

Otra forma de representar los tamaños poblacionales es la pirámide por edad y sexo de la figura 3.6, obtenida con el siguiente código computacional. Se utilizan las estimaciones y los intervalos de confianza de la tabla 3.5, almacenados en `age_sex_population_size`. Los hombres se sitúan a la izquierda, en azul, y las mujeres a la derecha, en rosa; los grupos de menor edad aparecen en la base. La longitud de cada barra representa el número estimado de personas y las líneas negras muestran sus intervalos de confianza del 95 %.

```
ggplot(
  age_sex_population_size,
  aes(
    x = factor(CatAge, levels = unique(CatAge)),
```

```
    y = if_else(Sex == "Male", -size, size),
    ymin = if_else(Sex == "Male", -size_upp, size_low),
    ymax = if_else(Sex == "Male", -size_low, size_upp),
    fill = Sex
  )
) +
  geom_col(width = 0.8) +
  geom_errorbar(width = 0.2) +
  geom_hline(yintercept = 0) +
  coord_flip() +
  scale_y_continuous(
    limits = function(x) c(-max(abs(x)), max(abs(x))),
    labels = function(x) format(
      abs(x),
      big.mark = ".",
      decimal.mark = ","
    )
  ) +
  scale_fill_manual(
    values = c(Male = "#4A90D9", Female = "#E78AB5"),
    breaks = c("Male", "Female"),
    labels = c("Hombres", "Mujeres")
  ) +
  labs(
    x = "Grupo de edad (años)",
    y = "Personas",
    fill = NULL
  ) +
  theme_bw() +
  theme(legend.position = "top")
```

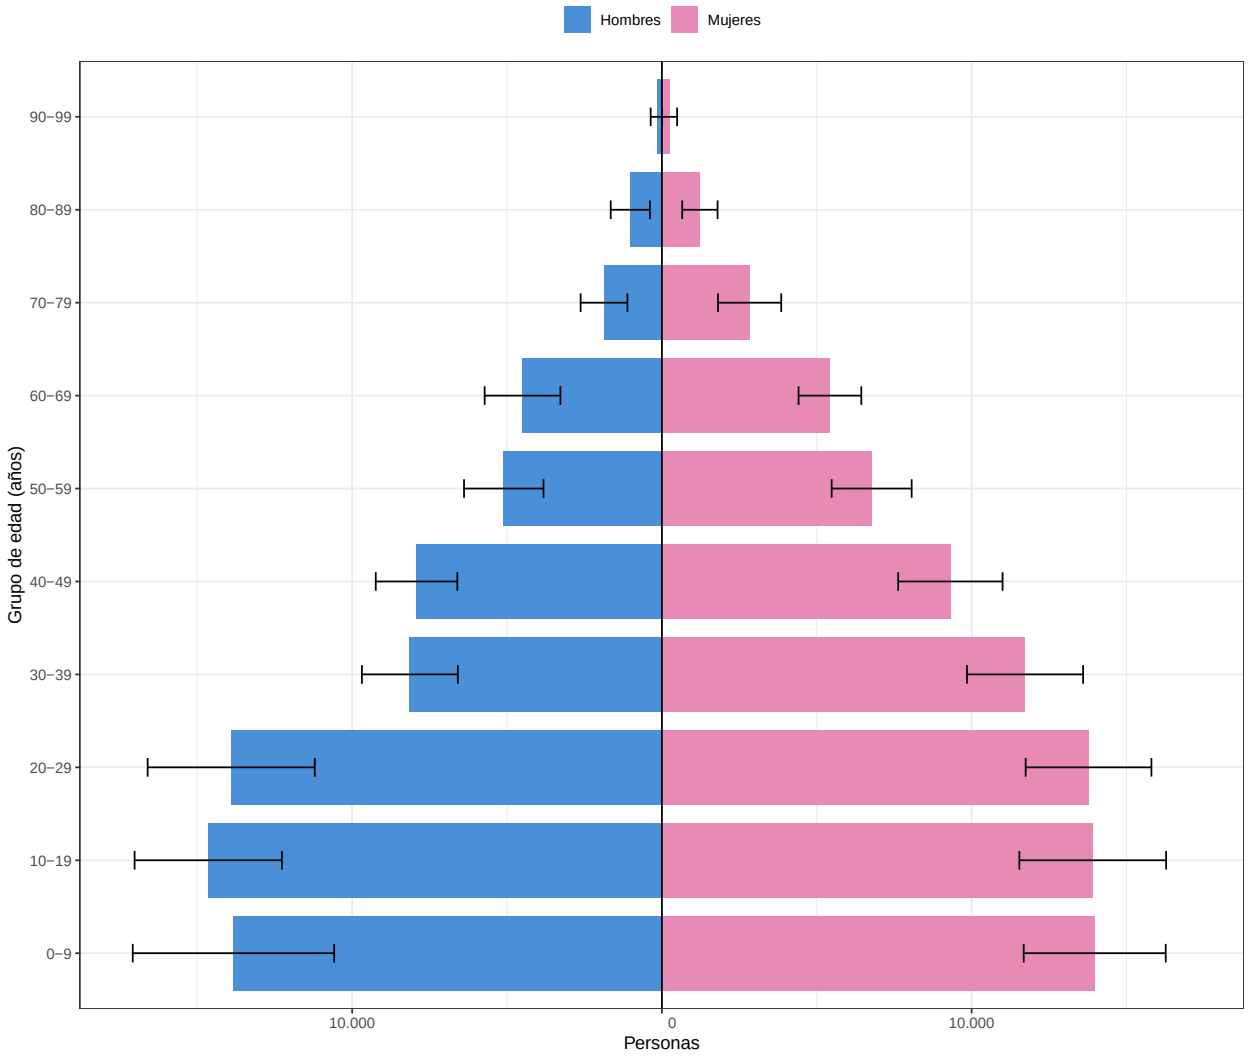


Figura 3.6.: Pirámide de población estimada por edad y sexo con intervalos de confianza del 95 %

En el código, `ggplot()` utiliza directamente el objeto `age_sex_population_size`. Dentro de `aes()`, `factor(CatAge, levels = unique(CatAge))` conserva el orden de los grupos de edad del objeto, previamente ordenado, mientras que `if_else()` determina la posición de las barras y de sus intervalos según el sexo. Los tamaños de los hombres se multiplican por menos uno únicamente para dibujarlos a la izquierda; no representan poblaciones negativas. Al invertir el signo, también se intercambian los extremos del intervalo: el inferior pasa a ser `-size_upp` y el superior, `-size_low`. `geom_col()` utiliza las estimaciones ya calculadas y equivale a `geom_bar(stat = "identity")`; `geom_errorbar()` incorpora sus intervalos. `coord_flip()` orienta las barras horizontalmente, `scale_y_continuous()` establece una escala simétrica con valores absolutos a ambos lados. Finalmente, `scale_fill_manual()` asigna los colores y las etiquetas de la leyenda, y `theme_bw()` conserva el estilo de los gráficos anteriores.

La pirámide muestra que el grupo de 10-19 años reúne el mayor tamaño poblacional estimado. En ese grupo se estiman aproximadamente 13.909 mujeres y 14.645 hombres. Las barras de error permiten apreciar la incertidumbre de cada tamaño estimado, pero la comparación visual de sus intervalos

no sustituye una prueba de contraste entre sexos que considere la covarianza de las estimaciones.

Las categorías de `CatAge` tienen una amplitud uniforme de diez años, de `0-9` a `90-99`, lo que facilita comparar los tamaños de los grupos en la pirámide. En la muestra hay observaciones de ambos sexos en los diez grupos decenales. Las edades más avanzadas tienen pocas observaciones y requieren especial atención a la incertidumbre de sus estimaciones. La forma del gráfico, por sí sola, no permite atribuir diferencias a la fecundidad, la mortalidad o la migración.

Las estimaciones por edad y sexo también permiten construir indicadores de la estructura demográfica de la población. Por ejemplo, la razón de dependencia demográfica relaciona el número de personas menores de 15 años y de 65 años o más con el número de personas de 15 a 64 años. Su estimación requiere considerar conjuntamente la incertidumbre de los tamaños poblacionales del numerador y del denominador, así como su covarianza. En la sección de estimación de razones se desarrolla esta aplicación y se muestra cómo obtener sus medidas de precisión incorporando el diseño muestral.

3.6.2. Mapas temáticos

Como explica Tennekes (2018), los mapas temáticos constituyen una herramienta de visualización especialmente útil en el análisis de encuestas de hogares, ya que permiten representar la distribución territorial de indicadores sociales y demográficos. En este contexto, las estimaciones calculadas en secciones anteriores pueden proyectarse directamente sobre estas unidades geográficas, facilitando así la identificación de patrones espaciales y desigualdades regionales. De acuerdo con Pebesma et al. (2026), Tennekes (2026) y Pebesma (2018), para construir este tipo de mapas en `R` se requiere información geoespacial en formato *shapefile*, la cual contiene los polígonos asociados a cada unidad geográfica de análisis. En este capítulo se utiliza el archivo `shapeBigCity/BigCity.shp`, cuyas regiones corresponden a las definidas en la base de datos `BigCity`.

El siguiente código computacional carga las librerías `sf` y `tmap` para trabajar con la información geográfica y vincularla con los resultados de la encuesta. La librería `sf` permite leer y manipular objetos espaciales modernos, mientras que `tmap` proporciona herramientas para elaborar mapas temáticos. La instrucción `tmap_mode("plot")` establece el modo de visualización estática de los mapas, apropiado para documentos y reportes. Finalmente, la función `read_sf()` importa el archivo geográfico `BigCity.shp`, almacenándolo en el objeto `bigcity_shape`, el cual contiene los polígonos correspondientes a las regiones de análisis.

```
library(sf)
library(tmap)
tmap_mode("plot")
bigcity_shape <- read_sf("../data/shapeBigCity/BigCity.shp") %>%
  mutate(
    Region = recode(
      Region,
      Norte = "North",
      Sur = "South",
      Centro = "Central",
      Occidente = "West",
      Oriente = "East"
```

```
    )
  )
```

La columna `Region` del mapa se recodifica al inglés para que sus nombres coincidan con los de `sample.rds` y permitan unir el mapa con las estimaciones. La recodificación se realiza en el objeto cargado en R y conserva el archivo geográfico original. Con el *shapefile* cargado, el siguiente código computacional genera el mapa de la figura 3.7 mediante `tm_shape()` y `tm_polygons()`.

```
tm_shape(bigcity_shape) +
  tm_polygons(col = "Region")
```

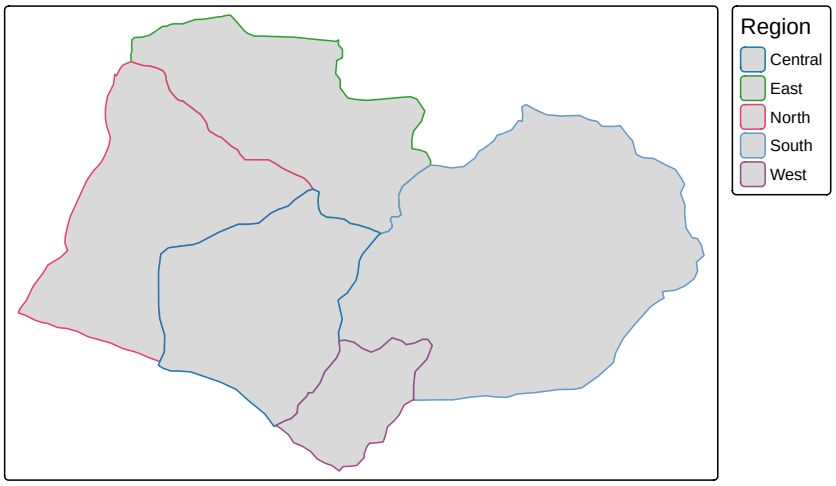


Figura 3.7.: Mapa de regiones geográficas de BigCity

Por ejemplo, si se desea representar geográficamente la proporción de hombres en condición de pobreza por región, mostrada previamente en la figura 3.5, es necesario integrar las estimaciones obtenidas con la información espacial del shapefile. En el siguiente código computacional, el objeto `male_region_poverty_proportion`, que contiene las proporciones estimadas para cada región, se vincula con el archivo geográfico mediante la función `left_join()`. Posteriormente, se filtran únicamente las observaciones correspondientes a la categoría de pobreza (`poor == 1`), de manera que el mapa represente exclusivamente la distribución espacial de la población masculina en condición de pobreza.

```
shape_region_map <- tm_shape(
  bigcity_shape %>%
    left_join(
      male_region_poverty_proportion %>%
        filter(poor == 1),
      by = "Region"
    )
)
```

Una vez construido el objeto espacial con las estimaciones de interés, los puntos de corte de la escala de color se calculan a partir del rango observado de las proporciones de hombres pobres. Así, los colores permiten distinguir mejor las diferencias entre regiones cuando las estimaciones se concentran en un tramo reducido de la escala de cero a uno. El siguiente código computacional representa esta distribución regional en la figura 3.8; sus colores deben interpretarse según los intervalos indicados en la leyenda.

```
poverty_estimates <- male_region_poverty_proportion %>%
  filter(poor == 1) %>%
  pull(proportion)
poverty_breaks <- pretty(
  range(poverty_estimates, na.rm = TRUE),
  n = 5
)
shape_region_map +
  tm_polygons(
    fill = "proportion",
    fill.scale = tm_scale_intervals(
      breaks = poverty_breaks,
      values = "YlOrRd"
    ),
    fill.legend = tm_legend(
      title = "Poverty proportion",
      na.show = FALSE
    )
  )
```

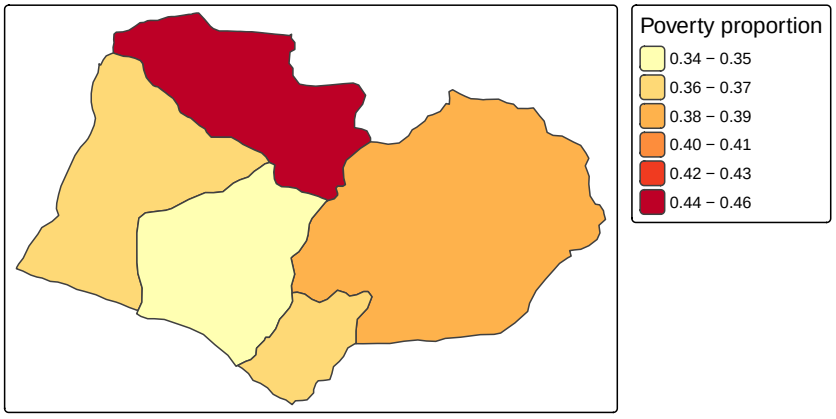


Figura 3.8.: Proporción de hombres en condición de pobreza por región

Otro uso de los mapas en encuestas, señalado por CEPAL (2023), es la visualización de la precisión

de las estimaciones. Por ejemplo, usando el coeficiente de variación de la proporción de pobreza por región es posible identificar las áreas donde las estimaciones son menos confiables, como se muestra en la figura 3.9.

El siguiente código calcula y representa geográficamente el coeficiente de variación de la proporción de pobreza por región. En primer lugar, se estima la proporción de pobreza agrupando por `Region` y `poor` y aplicando `survey_prop()`; después se conserva la categoría `poor == 1`. El argumento `vartype = "cv"` solicita el cálculo del coeficiente de variación de cada estimación. Posteriormente, se definen los intervalos de clasificación de la escala de color mediante el objeto `cv_breaks`, y las estimaciones se integran con la información geográfica del shapefile usando `left_join()`. Finalmente, mediante las funciones `tm_shape()` y `tm_polygons()` del paquete `tmap`, se construye el mapa que representa espacialmente los coeficientes de variación utilizando una escala de colores en blanco y negro y ajustando la proporción del mapa con `tm_layout(asp = 0)`.

```
region_poverty_cv <- survey_design %>%
  filter(!is.na(poor)) %>%
  group_by(Region, poor) %>%
  summarise(
    proportion = survey_prop(
      proportion = TRUE,
      prop_method = "logit",
      vartype = "cv"
    ),
    .groups = "drop"
  ) %>%
  filter(poor == 1) %>%
  select(-poor)

cv_breaks <- c(0, 0.1, 0.2, Inf)
shape_cv_map <- tm_shape(
  bigcity_shape %>%
    left_join(region_poverty_cv, by = "Region")
)

shape_cv_map +
  tm_polygons(
    fill = "proportion_cv",
    fill.scale = tm_scale_intervals(
      breaks = cv_breaks,
      values = c("#F2F2F2", "#8C8C8C", "#1A1A1A")
    ),
    fill.legend = tm_legend(
      title = "CV de la proporción",
      na.show = FALSE
    )
  ) +
  tm_layout(asp = 0)
```

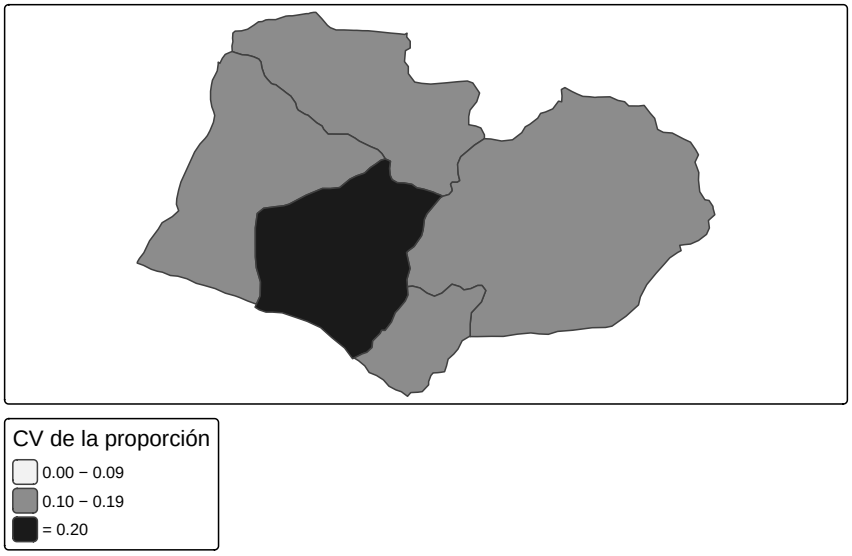


Figura 3.9.: Coeficiente de variación de la proporción de pobreza por región

Los polígonos con tonos más oscuros corresponden a regiones donde la proporción estimada presenta mayor variabilidad relativa. El CV se expresa como razón, de modo que 0,1 equivale al 10 %; no representa el error estándar en %. Un coeficiente de variación elevado indica menor precisión relativa, pero no permite atribuirla únicamente a un tamaño muestral insuficiente, pues también puede reflejar la ponderación y otras características del diseño.

De acuerdo con Prener et al. (2025) y Wilke (2025), cuando se desea representar simultáneamente dos variables (por ejemplo, la proporción de pobreza y su coeficiente de variación) es posible construir un mapa bivariante utilizando `ggplot2` junto con los paquetes `biscale` y `cowplot`. Este tipo de visualización permite identificar regiones con alta pobreza y alta incertidumbre en la estimación de forma conjunta, como se presenta en la figura 3.10. El siguiente código estima la proporción de mujeres en condición de pobreza en zonas rurales para cada región, incorporando además el cálculo del coeficiente de variación de las estimaciones, generando una fila por región. El denominador es la población femenina rural de cada región; el CV expresa precisión relativa y no incertidumbre absoluta.

```
region_sex_poverty_proportion <- survey_design %>%
  filter(Zone == "Rural", Sex == "Female") %>%
  filter(!is.na(poor)) %>%
  group_by(Region, poor) %>%
  summarise(
    proportion = survey_prop(
      proportion = TRUE,
      prop_method = "logit",
      vartype = "cv"
    ),
    .groups = "drop"
  ) %>%
```

```
  filter(poor == 1) %>%
  select(-poor)
```

El siguiente código construye un mapa bivariado que permite visualizar simultáneamente la proporción de pobreza femenina rural y el coeficiente de variación asociado a dicha estimación por región. En primer lugar, se integran las estimaciones contenidas en `region_sex_poverty_proportion` con la información geográfica del shapefile mediante `left_join()`. Posteriormente, la función `bi_class()` del paquete `biscale` clasifica conjuntamente las variables `proportion` y `proportion_cv` en una cuadrícula de (3×3) categorías (`dim = 3`), empleando el método de clasificación de Fisher (`style = "fisher"`). Luego, con `ggplot2` y `geom_sf()`, se genera el mapa temático utilizando colores bivariados definidos por `bi_scale_fill()`, mientras que `bi_theme()` aplica un estilo minimalista y se elimina la leyenda predeterminada.

A continuación, la función `bi_legend()` crea una leyenda especializada que permite interpretar simultáneamente ambas dimensiones del mapa: el coeficiente de variación y la pobreza femenina rural. Finalmente, mediante las funciones `ggdraw()` y `draw_plot()` del paquete `cowplot`, se combinan el mapa y la leyenda en una única visualización.

```
library(biscale)
library(cowplot)

bivariate_shape <- bigcity_shape %>%
  left_join(region_sex_poverty_proportion, by = "Region")

k <- 3
bivariate_palette <- "DkViolet"
bivariate_data <- bi_class(
  bivariate_shape,
  y = proportion,
  x = proportion_cv,
  dim = k,
  style = "fisher"
)

bivariate_map <- ggplot() +
  geom_sf(
    data = bivariate_data,
    aes(fill = bi_class, geometry = geometry),
    colour = "white",
    size = 0.1
  ) +
  bi_scale_fill(pal = bivariate_palette, dim = k) +
  bi_theme() +
  theme(legend.position = "none")

bivariate_legend <- bi_legend(
  pal = bivariate_palette,
```

```
  dim = k,
  xlab = "Coefficient of variation",
  ylab = "Rural female poverty",
  size = 6
)

ggdraw() +
  draw_plot(bivariate_map, 0.02, 0.04, 0.68, 0.9) +
  draw_plot(bivariate_legend, 0.67, 0.25, 0.3, 0.38)
```

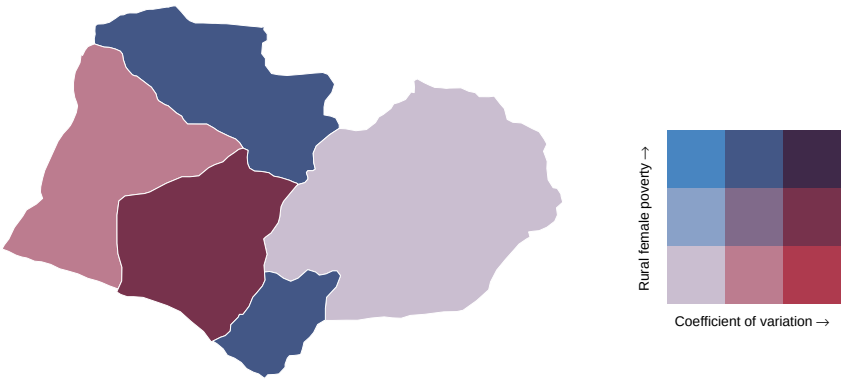


Figura 3.10.: Mapa bivariante: proporción de pobreza femenina rural y su coeficiente de variación por región

En este mapa, cada celda de la leyenda combina un tono de la proporción de pobreza (eje vertical) con un tono del coeficiente de variación (eje horizontal), permitiendo identificar simultáneamente regiones con alta pobreza y alta incertidumbre en la estimación. Este tipo de representación puede ayudar a priorizar una evaluación del diseño y de la precisión en zonas geográficas específicas; por sí solo, sin embargo, no determina automáticamente que deba ampliarse el tamaño muestral.

Al desagregar los resultados por territorio y características sociodemográficas, algunas estimaciones directas pueden presentar una precisión limitada. El siguiente código computacional ilustra esta situación al estimar la proporción de pobreza entre las mujeres rurales de 15 a 29 años de cada región y resumir su precisión, incorporando los factores de expansión, los estratos y las UPM del diseño muestral.

```
rural_young_women <- survey_design %>%
  filter(
```

```
    Sex == "Female",
    Zone == "Rural",
    Age >= 15,
    Age <= 29,
    !is.na(poor)
  )

rural_young_women_sizes <- rural_young_women %>%
  group_by(Region) %>%
  summarise(
    sample_size = unweighted(n()),
    .groups = "drop"
  )

rural_young_women_poverty <- rural_young_women %>%
  group_by(Region, poor) %>%
  summarise(
    poverty_rate = survey_prop(
      vartype = "cv",
      proportion = FALSE,
      prop_method = "logit"
    ),
    .groups = "drop"
  ) %>%
  filter(poor == 1) %>%
  left_join(rural_young_women_sizes, by = "Region") %>%
  transmute(
    Region,
    sample_size,
    poverty_rate,
    cv_percent = 100 * poverty_rate_cv
  )

rural_young_women_poverty
```

Tabla 3.25.: Proporción de pobreza entre mujeres rurales de 15 a 29 años, por región

Región	Tamaño muestral	Proporción de pobreza	CV (%)
Norte	56	0,2979	34,40
Sur	33	0,3199	27,12
Centro	29	0,4487	42,54
Occidente	34	0,5291	19,72
Oriente	43	0,5467	26,62

La tabla 3.25 muestra que los tamaños muestrales de estos dominios oscilan entre 29 y 56 mujeres, mientras que los coeficientes de variación van del 19,72 % al 42,54 %. Centro presenta la menor

precisión relativa, seguido de Norte, lo que exige cautela al interpretar las estimaciones y comparar regiones. Cuando la precisión de las estimaciones directas resulta insuficiente para los usos previstos, los métodos de estimación en áreas pequeñas (SAE, por sus siglas en inglés) ofrecen una alternativa al incorporar información auxiliar y modelos que permiten compartir información entre dominios (Rao y Molina 2015). Su aplicación requiere evaluar la disponibilidad información auxiliar, los supuestos del modelo y la incertidumbre de las estimaciones obtenidas.

Nótese que el tamaño muestral corresponde al número de mujeres observadas en cada dominio. La proporción reúne las categorías de pobreza extrema y relativa. El coeficiente de variación se calcula como el error estándar dividido por la estimación, multiplicado por 100.

4. Análisis de las variables continuas

El capítulo anterior se centró en variables categóricas. En este se estudian variables numéricas y las relaciones entre ellas, con ejemplos basados en el ingreso y el gasto. Se presentan estimaciones descriptivas y sus medidas de precisión, pruebas y contrastes, y herramientas gráficas para explorar distribuciones y asociaciones. El código siguiente carga los datos y los paquetes necesarios para ejecutar el capítulo de forma independiente.

```
library(tidyverse)
library(survey)
library(srvyr)
survey_data <- readRDS("../data/sample.rds")
```

Con los datos cargados, se define el diseño muestral que se utilizará para realizar la inferencia apropiada en este capítulo.

```
options(survey.lonely.psu = "adjust")
survey_design <- survey_data %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  )
```

4.1. Estimación de parámetros descriptivos

Las medidas descriptivas resumen distintos aspectos de una variable numérica, desde su nivel y dispersión hasta su distribución y desigualdad. En esta sección se explica cómo estimarlas con el diseño muestral y cómo evaluar su precisión.

4.1.1. Totales

Como se ha señalado anteriormente, el total poblacional de una variable de interés puede estimarse mediante una suma ponderada; cuando los factores de expansión están calibrados, corresponde al estimador de calibración (Deville y Särndal 1992). Se pondera el valor observado en cada unidad por su factor de expansión. En un diseño de muestreo con estratificación y selección en varias etapas, este estimador se expresa como:

$$\hat{t}_y = \sum_h \sum_i \sum_k w_{hik}\, y_{hik}, \tag{4.1}$$

donde h identifica el estrato, i la unidad primaria de muestreo y k la unidad final observada. El término y_{hik} representa el valor de la variable de interés para la unidad k perteneciente a la unidad primaria i del estrato h, mientras que w_{hik} corresponde a su factor de expansión. De este modo, cada unidad de la muestra representa a un determinado número de unidades de la población, y la suma ponderada permite reconstruir el total poblacional.

La varianza de $\hat{t}_y$ puede estimarse mediante el método del último conglomerado presentado en la sección 2.5.2.1. Siguiendo su notación, la contribución de cada UPM se define como:

$$\hat{t}_{y_i} = \sum_{k \in s_{hi}} w_{hik} y_{hik}.$$

Esta cantidad suma los valores ponderados de las unidades observadas en la UPM i; el estrato h queda implícito para mantener la notación de aquella sección. El promedio de estas contribuciones en el estrato es:

$$\hat{\bar{t}}_{y_h} = \frac{1}{n_h} \sum_{i=1}^{n_h} \hat{t}_{y_i}.$$

Aquí n_h es el número de UPM seleccionadas en el estrato h. Este promedio sirve de referencia para calcular la dispersión entre UPM. La varianza estimada se expresa como (Hansen et al. 1953; Wolter 2007):

$$\widehat{\mathrm{Var}}(\hat{t}_y) = \sum_h \frac{n_h}{n_h - 1} \sum_{i=1}^{n_h} \left(\hat{t}_{y_i} - \hat{\bar{t}}_{y_h} \right)^2. \tag{4.2}$$

La expresión suma, sobre los estratos, la dispersión de las contribuciones de las UPM respecto de su promedio en cada estrato. Su raíz cuadrada es el error estándar de $\hat{t}_y$. Se utiliza la aproximación de selección independiente con reemplazo de las UPM, sin corrección por población finita, coherente con el objeto `survey_design` definido en este capítulo. La fórmula requiere al menos dos UPM por estrato; para estratos con una sola UPM se aplica el tratamiento especificado al preparar el diseño. Al tomar $y_{hik} = 1$, se recupera la fórmula del tamaño poblacional $\hat{N}$ del capítulo anterior; al tomar $y_{hik} = I(k \in d)$, se obtiene la correspondiente al tamaño de la subpoblación $\hat{N}_d$. Aquí n_h representa la misma cantidad de UPM que se denotó por m_h en esas fórmulas.

En `R`, la función `survey_total()` se utiliza para estimar totales a partir del objeto de diseño. Esta función incorpora automáticamente los factores de expansión y la estructura del diseño, garantizando que las estimaciones reflejen correctamente el modelo de inferencia.

Los argumentos generales de `survey_total()` se presentaron en la Sección 3.2.1. La diferencia es que ahora se suministra una variable como `Income` o `Expenditure`; con `x = 1` se recuperaría el tamaño poblacional. Se mantienen `vartype`, `level` y el tratamiento explícito de faltantes. El siguiente ejemplo presenta cómo estimar totales y sus intervalos de confianza para diferentes variables de interés en `R`, utilizando la función `survey_total()`, cuyos resultados se presentan en la tabla 4.1:

```
income_total_table <- survey_design %>%
  summarise(
    total = survey_total(
      Income,
      vartype = c("se", "ci"),
      deff = TRUE
    )
  )

income_total_table
```

Tabla 4.1.: Estimación del total poblacional del ingreso per cápita con intervalo de confianza al 95 %

Total	EE	LI 95 %	LS 95 %	Efecto de diseño
85793667	4778674	76331414	95255920	11

De la tabla, se obtiene que la estimación corresponde a la suma ponderada del ingreso per cápita asociado a las personas representadas por la encuesta. No debe interpretarse como el ingreso total de los hogares. Este valor incorpora los factores de expansión y las características del diseño muestral. El error estándar asociado a esta estimación es de 4.778.674, lo que refleja la variabilidad muestral del estimador. A partir de este valor se construye un intervalo de confianza del 95 %, cuyos límites inferior y superior son 76.331.414 y 95.255.920, respectivamente. El efecto de diseño (`deff`), en el sentido desarrollado por Kish (1965), es cercano a 11: la varianza supera considerablemente la del diseño de referencia. Su magnitud refleja el efecto combinado del diseño y la ponderación y no debe interpretarse como una pérdida ligera de precisión.

Para continuar ilustrando el uso de la función `survey_total()`, estimemos el total poblacional del gasto per cápita, pero ahora calculando el intervalo de confianza al 90 %. El siguiente código realiza esta estimación, presentada en la tabla 4.2:

```
expenditure_total_table <- survey_design %>%
  summarise(
    total = survey_total(
      Expenditure,
      vartype = "ci",
      level = 0.9,
      deff = TRUE
    )
  )

expenditure_total_table
```

Tabla 4.2.: Estimación del total poblacional del gasto per cápita con intervalo de confianza al 90 %

Total	LI 90 %	LS 90 %	Efecto de diseño
55677504	51360469	59994539	10.2

Para un dominio d, el total se estima incorporando la indicadora $I(k \in d)$, que vale uno si la unidad pertenece al dominio y cero en caso contrario. El estimador del total del dominio es:

$$\hat{t}_d = \sum_h \sum_i \sum_k w_{hik} y_{hik} I(k \in d). \tag{4.3}$$

Esta suma ponderada incluye únicamente los valores de las unidades que pertenecen al dominio. Su varianza se estima mediante el método del último conglomerado:

$$\widehat{\text{Var}}(\hat{t}_d) = \sum_h \frac{n_h}{n_h - 1} \sum_{i=1}^{n_h} \left(\hat{t}_{d_i} - \hat{\bar{t}}_{d_h} \right)^2, \tag{4.4}$$

La varianza mide la dispersión de las contribuciones de las UPM al total del dominio. Cada contribución se define como:

$$\hat{t}_{d_i} = \sum_{k \in s_{hi}} w_{hik} y_{hik} I(k \in d).$$

Esta cantidad suma los valores ponderados del dominio dentro de la UPM i del estrato h. Su promedio en el estrato se obtiene mediante:

$$\hat{\bar{t}}_{d_h} = \frac{1}{n_h} \sum_{i=1}^{n_h} \hat{t}_{d_i}.$$

El promedio considera las n_h UPM seleccionadas en el estrato. Se mantienen los supuestos de la fórmula del total poblacional y todas las UPM del diseño, incluidas aquellas sin integrantes del dominio, cuya contribución es cero; n_h no se restringe a las UPM que contienen unidades de d.

Para estimar el total poblacional del ingreso per cápita por sexo, el siguiente código computacional utiliza la función `group_by()` para agrupar por la variable de interés, junto con `cascade()` de la librería `srvyr`, que permite agregar una fila con el total general al final de la tabla. De esta manera, se pueden obtener fácilmente los totales por categoría y el total global dentro del mismo marco de resumen, como se muestra en la tabla 4.3.

```
income_total_by_sex_table <- survey_design %>%
  group_by(Sex) %>%
  cascade(
    total = survey_total(
      Income,
      vartype = c("se", "ci"),
```

```
      level = 0.95
    ),
    .fill = "Total income"
  )

income_total_by_sex_table
```

Tabla 4.3.: Total poblacional del ingreso per cápita desagregado por sexo

Sexo	Total	EE	LI 95 %	LS 95 %
Female	44153820	2324452	39551172	48756467
Male	41639847	2870194	35956576	47323118
Total income	85793667	4778674	76331414	95255920

Los totales por sexo son sumas ponderadas del ingreso per cápita asociado a las personas de cada grupo y dependen también del tamaño poblacional de cada uno. Por tanto, no miden directamente una brecha de ingreso medio entre mujeres y hombres. Para comparar los ingresos medios per cápita, se deben estimar las medias por sexo y contrastar su diferencia. Como se observa en los códigos anteriores, una forma práctica de obtener las estimaciones del total, su error estándar y su intervalo de confianza es mediante el argumento `vartype`, especificando las opciones `"se"` y `"ci"` respectivamente.

4.1.2. Medias

Según Gutiérrez (2016), la estimación de la media poblacional ocupa un lugar central en las encuestas de hogares, ya que muchos de los indicadores utilizados para el análisis socioeconómico corresponden a valores promedio, como el ingreso medio del hogar, el gasto per cápita o las horas promedio trabajadas. Este tipo de parámetros permite resumir el comportamiento general de las variables de interés y describir las tendencias centrales de la población objetivo. El estimador de la media poblacional puede expresarse como una razón no lineal entre dos totales poblacionales, los cuales se estiman de la siguiente manera:

$$\hat{\bar{y}} = \frac{\hat{t}_y}{\hat{N}} = \frac{\sum_h \sum_i \sum_k w_{hik}\ y_{hik}}{\sum_h \sum_i \sum_k w_{hik}} \tag{4.5}$$

De acuerdo con Särndal et al. (2003), dado que $\hat{\bar{y}}$ no es una estadística lineal, su varianza suele estimarse mediante una aproximación. Por esta razón, es necesario recurrir a métodos de remuestreo o a la linealización de Taylor para aproximar su varianza. En este caso particular, utilizando series de Taylor, la varianza se define como:

$$\widehat{Var}\left(\hat{\bar{y}}\right) \approx \frac{\widehat{Var}\left(\hat{t}_y\right) + \hat{\bar{y}}^2\ \widehat{Var}\left(\hat{N}\right) - 2\ \hat{\bar{y}}\ \widehat{Cov}\left(\hat{t}_y, \hat{N}\right)}{\hat{N}^2} \tag{4.6}$$

Como se puede observar, el cálculo de la varianza de la media poblacional implica componentes analíticos complejos, como la covarianza entre el total estimado y el tamaño poblacional estimado. Sin embargo, el paquete `srvyr` en `R` facilita estos cálculos al incorporar funciones que estiman directamente la media, su error estándar, el intervalo de confianza y el efecto del diseño. A continuación, se presenta la sintaxis para estimar el ingreso per cápita medio de la población, junto con su intervalo de confianza del 95 %, cuyos resultados se presentan en la tabla 4.4:

```
income_mean_table <- survey_design %>%
  summarise(
    mean = survey_mean(
      Income,
      vartype = c("se", "ci"),
      level = 0.95,
      deff = TRUE
    )
  )

income_mean_table
```

Tabla 4.4.: Estimación de la media poblacional del ingreso per cápita

Media	EE	LI 95 %	LS 95 %	Efecto de diseño
571	28.5	515	627	8.82

La función `survey_mean()` recibe una magnitud continua y no se solicita `proportion = TRUE`. Como se aprecia, los argumentos utilizados en la función `survey_mean()` son similares a los de `survey_total()`. En este caso, `vartype` permite obtener el error estándar (`"se"`) y el intervalo de confianza (`"ci"`), mientras que el argumento `deff = TRUE` solicita el cálculo del efecto del diseño. El ingreso per cápita medio estimado es de aproximadamente 571 dólares, con un error estándar de 28,5 dólares y un intervalo de confianza del 95 % entre 515 y 627 dólares. Además, el efecto de diseño estimado es de 8,82, lo que significa que la varianza de la media bajo el diseño muestral complejo es 8,82 veces mayor que la que se obtendría con un muestreo aleatorio simple de igual tamaño. Este valor evidencia una pérdida considerable de eficiencia, posiblemente asociada con la magnitud de la variabilidad del ingreso entre las unidades primarias de muestreo.

De forma análoga, es posible estimar la media de los gastos per cápita, empleando la misma estructura de código, presentada en la tabla 4.5:

```
expenditure_mean_table <- survey_design %>%
  summarise(
    mean = survey_mean(
      Expenditure,
      vartype = c("se", "ci"),
      level = 0.95,
      deff = TRUE
    )
```

```
  )

expenditure_mean_table
```

Tabla 4.5.: Estimación de la media poblacional del gasto per cápita

Media	EE	LI 95 %	LS 95 %	Efecto de diseño
371	13.3	344	397	6.02

La media estimada del gasto es de 371 dólares, con un error estándar de 13,3. El intervalo de confianza se extiende entre 344 y 397, mientras que el efecto de diseño de 6,02 resume la relación de varianzas respecto del diseño de referencia; no identifica por sí solo qué componente del diseño explica esa diferencia.

Para un dominio d con tamaño estimado $\hat{N}_d > 0$, la media se estima como el cociente entre su total $\hat{t}_d$ y su tamaño $\hat{N}_d = \sum_h \sum_i \sum_k w_{hik} I(k \in d)$. El estimador de la media del dominio es:

$$\hat{\bar{y}}_d = \frac{\hat{t}_d}{\hat{N}_d} = \frac{\sum_h \sum_i \sum_k w_{hik} y_{hik} I(k \in d)}{\sum_h \sum_i \sum_k w_{hik} I(k \in d)}. \tag{4.7}$$

El cociente divide el total estimado de la variable en el dominio por el número estimado de unidades que lo integran. Al ser una razón no lineal, su varianza se aproxima mediante linealización de Taylor:

$$\widehat{\mathrm{Var}}(\hat{\bar{y}}_d) \approx \frac{\widehat{\mathrm{Var}}(\hat{t}_d) + \hat{\bar{y}}_d^{\,2} \widehat{\mathrm{Var}}(\hat{N}_d) - 2\hat{\bar{y}}_d \widehat{\mathrm{Cov}}(\hat{t}_d, \hat{N}_d)}{\hat{N}_d^2}. \tag{4.8}$$

Las varianzas y la covarianza se estiman con el diseño completo, asignando contribución cero a las unidades ajenas al dominio. La covarianza incorpora la variación conjunta del total y del tamaño estimados del dominio, que no son independientes; la raíz cuadrada de esta expresión proporciona el error estándar de la media del dominio (Särndal et al. 2003).

El siguiente código computacional estima la media del gasto por zona mediante `cascade()`, que añade una fila con la estimación general. El argumento `.fill = "Mean expenditure"` asigna ese rótulo a dicha fila; las restantes muestran las estimaciones de las zonas urbana y rural. La tabla 4.6 presenta las medias y sus medidas de precisión.

```
expenditure_mean_by_zone_table <- survey_design %>%
  group_by(Zone) %>%
  cascade(
    mean = survey_mean(
      Expenditure,
      level = 0.95,
      vartype = c("se", "ci")
    ),
```

```
    .fill = "Mean expenditure"
  )

expenditure_mean_by_zone_table
```

Tabla 4.6.: Media poblacional del gasto per cápita desagregada por zona

Zona	Media	EE	LI 95 %	LS 95 %
Rural	274	10.3	254	294
Urban	460	22.2	416	504
Mean expenditure	371	13.3	344	397

La media general estimada del gasto es de 371 dólares. Por zona, el gasto medio es de 460 dólares en el área urbana y de 274 en la rural. Aunque los intervalos de confianza muestran mayor incertidumbre en la zona urbana, no se superponen; esto sugiere una diferencia entre las medias estimadas. Para examinarla por región, el siguiente código computacional estima el gasto medio para las combinaciones de zona y región.

```
expenditure_mean_by_zone_region_table <- survey_design %>%
  group_by(Zone, Region) %>%
  cascade(
    mean = survey_mean(
      Expenditure,
      level = 0.95,
      vartype = c("se", "ci")
    ),
    .fill = "Mean expenditure"
  )

expenditure_mean_by_zone_region_table
```

Tabla 4.7.: Media poblacional del gasto per cápita desagregada por zona y región

Zona	Región	Media	EE	LI 95 %	LS 95 %
Rural	North	307	18.4	271	343
Rural	South	317	14.6	288	346
Rural	Central	337	42.8	252	422
Rural	West	242	11.1	220	264
Rural	East	242	22.8	197	287
Rural	Mean expenditure	274	10.3	254	294
Urban	North	402	48.0	307	497
Urban	South	497	62.5	373	621
Urban	Central	531	53.1	426	636
Urban	West	376	20.9	334	417

Tabla 4.7.: Media poblacional del gasto per cápita desagregada por zona y región

Zona	Región	Media	EE	LI 95 %	LS 95 %
Urban	East	466	45.3	377	556
Urban	Mean expenditure	460	22.2	416	504
Mean expenditure	Mean expenditure	371	13.3	344	397

El gasto medio varía de forma importante según la zona de residencia y la región. En el área rural, los mayores promedios se observan en las regiones Centro, Sur y Norte, mientras que Occidente y Oriente presentan los valores más bajos. En el área urbana, el gasto medio es superior en todas las regiones y alcanza sus niveles más altos en Centro, Sur y Oriente. No obstante, algunas estimaciones regionales, especialmente las de Centro rural y Sur urbano, presentan errores estándar relativamente elevados, por lo que deben interpretarse con mayor cautela.

4.1.3. Razones

Las proporciones del capítulo anterior constituyen un caso particular de razón de totales. La razón poblacional es un parámetro no lineal definido como el cociente entre los totales de dos variables de interés. Permite cuantificar la relación entre ambas variables y resulta especialmente útil para construir indicadores relativos, comparar grupos y analizar su evolución a lo largo del tiempo. En las encuestas de hogares, este parámetro se utiliza ampliamente para calcular indicadores como el número de hombres por cada mujer, la proporción de personas ocupadas respecto de la población en edad de trabajar y la prevalencia de la subalimentación (FAO 2026).

Dado que la razón corresponde al cociente entre dos parámetros (totales) poblacionales desconocidos, tanto el numerador como el denominador deben ser estimados a partir de la muestra. Siendo t_y el total de la variable y y t_x el total de la variable x, la razón poblacional se define como $R = \frac{t_y}{t_x}$ y su estimador puntual se expresa como:

$$\hat{R} = \frac{\hat{t}_y}{\hat{t}_x} = \frac{\sum_h \sum_i \sum_k w_{hik}\, y_{hik}}{\sum_h \sum_i \sum_k w_{hik}\, x_{hik}} \tag{4.9}$$

Como $\hat{R}$ es una función no lineal de dos totales estimados, su varianza puede aproximarse mediante linealización de Taylor. Para $\hat{t}_x \neq 0$, siguiendo la notación utilizada para la media, se obtiene (Särndal et al. 2003):

$$\widehat{\mathrm{Var}}(\hat{R}) \approx \frac{\widehat{\mathrm{Var}}(\hat{t}_y) + \hat{R}^2 \widehat{\mathrm{Var}}(\hat{t}_x) - 2\hat{R}\, \widehat{\mathrm{Cov}}(\hat{t}_y, \hat{t}_x)}{\hat{t}_x^2}. \tag{4.10}$$

Las varianzas de los totales y su covarianza se estiman considerando los estratos, las UPM y los pesos del diseño. El término de covarianza recoge la variación conjunta del numerador y del denominador, calculados sobre la misma muestra, por lo que no deben suponerse independientes. De manera equivalente, es poisble estimar la varianza del total ponderado de la variable linealizada $z_{hik} = y_{hik} - \hat{R}x_{hik}$ mediante el método del último conglomerado y dividir por $\hat{t}_x^2$. La raíz cuadrada de la

varianza aproximada es el error estándar de $\hat{R}$. La función `survey_ratio()` realiza esta estimación y permite obtener las correspondientes medidas de precisión.

Como primer ejemplo de aplicación, se estima el índice de masculinidad (*sex ratio*, en inglés), definido como el número de hombres por cada 100 mujeres en la población representada por la encuesta. Su estimador es:

$$\hat{R}_{\text{SR}} = 100\frac{\hat{N}_{\text{hombres}}}{\hat{N}_{\text{mujeres}}}. \tag{4.11}$$

Un valor igual a 100 indica que existe el mismo número de hombres y mujeres; un valor superior a 100 refleja una mayor cantidad de hombres y un valor inferior a 100 una mayor cantidad de mujeres. Por ejemplo, un índice de 95 representa 95 hombres por cada 100 mujeres. El código utiliza las indicadoras `Sex == "Male"` y `Sex == "Female"` para definir los totales del numerador y del denominador. El factor 100 se incorpora al numerador para que la estimación, su error estándar y su intervalo de confianza se expresen en la misma escala.

```
sex_ratio_table <- survey_design %>%
  summarise(
    ratio = survey_ratio(
      numerator = 100 * (Sex == "Male"),
      denominator = (Sex == "Female"),
      level = 0.95,
      vartype = c("se", "ci"
    )
  )
  )

sex_ratio_table
```

Tabla 4.8.: Índice de masculinidad: hombres por cada 100 mujeres en la población

Índice	EE	LI 95 %	LS 95 %
89.8	2.83	84.2	95.4

La tabla 4.8 estima 89.75 hombres por cada 100 mujeres. El error estándar es 2.83 y el intervalo de confianza del 95 % va de 84.15 a 95.36. El índice estimado es inferior a 100, lo que describe una mayor cantidad de mujeres que de hombres en la población representada. A continuación se estima el mismo indicador en el dominio rural, conservando las características del diseño completo.

```
rural_subset <- survey_design %>%
  filter(Zone == "Rural")

rural_sex_ratio_table <- rural_subset %>%
  summarise(
    ratio = survey_ratio(
```

```
      numerator = 100 * (Sex == "Male"),
      denominator = (Sex == "Female"),
      level = 0.95,
      vartype = c("se", "ci"
    )
  )
  )

rural_sex_ratio_table
```

Tabla 4.9.: Índice de masculinidad: hombres por cada 100 mujeres en zona rural

Índice	EE	LI 95 %	LS 95 %
93.6	3.09	87.4	99.8

La tabla 4.9 estima 93.62 hombres por cada 100 mujeres en la zona rural. Su error estándar es 3.09 y el intervalo de confianza del 95 % va de 87.43 a 99.82. Como el intervalo no incluye el valor 100, al nivel del 5 % existe evidencia de una diferencia entre las cantidades de hombres y mujeres en este dominio.

Una aplicación demográfica de las razones es el índice de envejecimiento (*Ageing Index*, en inglés). De acuerdo con la definición de Comisión Económica para América Latina y el Caribe (2022), se calcula como el número de personas de 60 años o más por cada 100 personas de 0 a 14 años. Su estimador es:

$$\hat{R}_{\mathrm{AI}} = 100\frac{\hat{N}_{60+}}{\hat{N}_{0-14}}. \tag{4.12}$$

Las siglas inglesas identifican los indicadores en la notación adoptada en el libro; no implican que todas las fuentes utilicen los mismos cortes de edad o denominadores. Por ello, las definiciones operativas de cada ejemplo se especifican a continuación.

Un valor inferior a 100 indica que hay menos personas de 60 años o más que menores de 15 años; un valor superior a 100 indica que las primeras superan a las segundas. Se utiliza `Age` para identificar directamente a las personas de 60 años o más y a las menores de 15 años. El corte de 15 años divide el intervalo decenal `10-19`; por ello, estos conjuntos deben calcularse desde `Age`, no agregando categorías completas de `CatAge`. Este corte de 60 años corresponde a la definición adoptada para el índice y se distingue del de 65 años utilizado más adelante en la razón de dependencia total.

El objeto `aging_design` conserva los pesos personales, los estratos y las UPM del diseño completo y delimita el dominio con edad observada. `older_person` identifica a las personas de 60 años o más y `young_person` a las menores de 15 años. El numerador `aging_units` incorpora el factor 100, de modo que la estimación, su error estándar y los límites del intervalo quedan expresados en personas mayores por cada 100 menores de 15 años. Si hubiera edades faltantes, la estimación correspondería al dominio con edad informada y sería necesario evaluar esa ausencia antes de generalizar el resultado. El siguiente código computacional construye las indicadoras de los grupos de edad y estima el índice de envejecimiento.

```
aging_design <- survey_design %>%
  filter(!is.na(Age)) %>%
  mutate(
    older_person = as.numeric(Age >= 60),
    young_person = as.numeric(Age < 15),
    aging_units = 100 * older_person
  )

aging_index <- aging_design %>%
  summarise(
    aging = survey_ratio(
      numerator = aging_units,
      denominator = young_person,
      vartype = c("se", "ci"),
      level = 0.95
    )
  )

aging_index
```

Tabla 4.10.: Índice de envejecimiento: personas de 60 años o más por cada 100 menores de 15 años

Índice	EE	LI 95 %	LS 95 %
40.8	3.78	33.3	48.3

La tabla 4.10 estima 40.82 personas de 60 años o más por cada 100 menores de 15 años. Su error estándar es 3.78 y el intervalo de confianza del 95 % va de 33.34 a 48.29. `survey_ratio()` estima la varianza mediante linealización e incorpora la covarianza entre los totales de ambos grupos de edad. El índice describe su tamaño relativo y no representa un porcentaje de la población total; por ello, puede superar 100.

Para representar el índice de envejecimiento en un dominio d, se utiliza la notación $\hat{R}_{\mathrm{AI},d}$. El siguiente código computacional desagrega esta estimación por zona de residencia mediante `group_by(Zone)`. Cada zona constituye un dominio del diseño completo y el denominador corresponde al total estimado de menores de 15 años de esa misma zona.

```
zone_aging_index <- aging_design %>%
  group_by(Zone) %>%
  summarise(
    aging = survey_ratio(
      numerator = aging_units,
      denominator = young_person,
      vartype = c("se", "ci"),
      level = 0.95
    ),
    .groups = "drop"
```

```
  )

zone_aging_index
```

Tabla 4.11.: Índice de envejecimiento por zona de residencia

Zona	Índice	EE	LI 95 %	LS 95 %
Rural	30.7	4.19	22.4	39.0
Urban	52.3	6.32	39.8	64.8

La tabla 4.11 presenta un índice de 30.72 en la zona rural y de 52.32 en la urbana. En cada caso, el valor indica cuántas personas de 60 años o más se estiman por cada 100 menores de 15 años del dominio. Los intervalos de confianza describen la incertidumbre de las estimaciones.

Otra aplicación demográfica de las razones es la razón de dependencia total (*Total Dependency Ratio*, en inglés), que describe la composición por edad de la población. Adoptando la definición de CEPALSTAT, el estimador estaría dado por el número de personas de 0 a 14 años y de 65 años o más por cada 100 personas de 15 a 64 años. Su estimador está dado por:

$$\hat{R}_{\text{TDR}} = 100 \times \frac{\hat{N}_{0-14} + \hat{N}_{65+}}{\hat{N}_{15-64}}. \tag{4.13}$$

Se utiliza la edad individual `Age` para identificar directamente los grupos de 0 a 14, de 15 a 64 y de 65 años o más. Los cortes de 15 y 65 años dividen intervalos decenales de `CatAge`, por lo que se mantienen en `Age` para conservar la definición del indicador. El objeto `dependency_design` conserva el diseño muestral y excluye únicamente los registros sin edad observada; por tanto, si hubiera edades faltantes, el resultado correspondería al dominio con edad informada y requeriría evaluar esa ausencia antes de extenderlo a toda la población. Las variables indicadoras identifican los grupos del numerador y del denominador. Multiplicar la primera por 100 permite expresar tanto la estimación como su error estándar e intervalo en personas por cada 100 personas de 15 a 64 años. El siguiente código computacional estima la razón de dependencia demográfica a partir de las indicadoras de edad.

```
dependency_design <- survey_design %>%
  filter(!is.na(Age)) %>%
  mutate(
    dependent_age = as.numeric(Age < 15 | Age >= 65),
    reference_age = as.numeric(Age >= 15 & Age < 65),
    dependency_units = 100 * dependent_age
  )

dependency_ratio <- dependency_design %>%
  summarise(
    dependency = survey_ratio(
      numerator = dependency_units,
```

```
      denominator = reference_age,
      vartype = c("se", "ci"),
      level = 0.95
    )
  )

dependency_ratio
```

Tabla 4.12.: Razón de dependencia demográfica por cada 100 personas de 15 a 64 años

Razón	EE	LI 95 %	LS 95 %
57.2	4.16	49	65.5

La tabla 4.12 estima 57.23 personas en los grupos de 0 a 14 años y de 65 años o más por cada 100 personas de 15 a 64 años. Su error estándar es 4.16 y el intervalo de confianza del 95 % va de 48.98 a 65.47. `survey_ratio()` estima la varianza mediante linealización, incorporando la covarianza entre los totales del numerador y del denominador; no trata estos totales como estimaciones independientes.

El siguiente código computacional estima la razón de dependencia demográfica por zona de residencia. `group_by(Zone)` define los dominios dentro del diseño completo, conservando sus estratos, UPM y factores de expansión, sin construir diseños nuevos a partir de archivos separados.

```
zone_dependency_ratio <- dependency_design %>%
  group_by(Zone) %>%
  summarise(
    dependency = survey_ratio(
      numerator = dependency_units,
      denominator = reference_age,
      vartype = c("se", "ci"),
      level = 0.95
    ),
    .groups = "drop"
  )

zone_dependency_ratio
```

Tabla 4.13.: Razón de dependencia demográfica por zona de residencia

Zona	Razón	EE	LI 95 %	LS 95 %
Rural	61.5	8.37	45.0	78.1
Urban	53.5	3.03	47.5	59.5

La tabla 4.13 presenta una razón estimada de 61.52 en la zona rural y de 53.47 en la urbana, siempre por cada 100 personas de 15 a 64 años de la zona correspondiente. Los intervalos describen la

incertidumbre de cada estimación. Para evaluar la diferencia entre zonas se requiere estimar directamente su contraste, considerando también la covarianza entre ambas razones, como se desarrolla en la sección de contrastes.

También puede definirse una razón de dependencia económica potencial (*Economic Dependency Ratio*, en inglés). En este ejemplo se relaciona el número de personas no ocupadas de 15 años o más, que incluye a las desocupadas y a las inactivas, con el número de personas ocupadas de esas edades. Su estimador es:

$$\hat{R}_{\text{EDR},15+} = 100\frac{\hat{N}_{\text{no ocupadas, }15+}}{\hat{N}_{\text{ocupadas, }15+}}. \tag{4.14}$$

El resultado se expresa en personas no ocupadas por cada 100 ocupadas de 15 años o más. A diferencia de la razón de dependencia demográfica, que clasifica a las personas únicamente por su edad, esta medida utiliza su condición de actividad. Es una aproximación potencial: no identifica quién sostiene económicamente a quién, ni considera directamente pensiones, transferencias, otros ingresos o los recursos compartidos dentro de los hogares. Por ello, una persona no ocupada puede contar con ingresos propios y una persona ocupada puede recibir apoyo económico.

El objeto `economic_dependency_design` define el dominio de personas de 15 años o más con condición de actividad observada. Se conservan los pesos personales, los estratos y las UPM del diseño completo. `not_employed` identifica a las personas desocupadas o inactivas y `employed` a las ocupadas; `economic_dependency_units` incorpora el factor 100 para que todas las medidas de la tabla queden en la misma escala. Los faltantes de `Employment` se excluyen explícitamente, de modo que su presencia exigiría evaluar el alcance del dominio con información observada antes de generalizar los resultados. No se utiliza la subpoblación de fuerza de trabajo, pues aquí las personas inactivas forman parte del numerador. El siguiente código computacional estima la razón de dependencia económica en el dominio definido.

```
economic_dependency_design <- survey_design %>%
  filter(Age >= 15, !is.na(Employment)) %>%
  mutate(
    not_employed = as.numeric(
      Employment %in% c("Unemployed", "Inactive")
    ),
    employed = as.numeric(Employment == "Employed"),
    economic_dependency_units = 100 * not_employed
  )

economic_dependency_ratio <- economic_dependency_design %>%
  summarise(
    dependency = survey_ratio(
      numerator = economic_dependency_units,
      denominator = employed,
      vartype = c("se", "ci"),
      level = 0.95
    )
  )
```

```
economic_dependency_ratio
```

Tabla 4.14.: Razón de dependencia económica potencial: personas no ocupadas por cada 100 ocupadas de 15 años o más

Razón	EE	LI 95 %	LS 95 %
74.5	4.27	66	83

La tabla 4.14 estima 74.5 personas no ocupadas por cada 100 ocupadas de 15 años o más. El error estándar es 4.27 y el intervalo de confianza del 95 % va de 66.04 a 82.96. La varianza se obtiene mediante linealización e incorpora la covarianza entre los totales del numerador y del denominador. El siguiente código computacional estima la razón de dependencia económica por zona mediante `group_by(Zone)`, manteniendo las características del diseño y el dominio de edad y condición de actividad definidos previamente.

```
zone_economic_dependency_ratio <- economic_dependency_design %>%
  group_by(Zone) %>%
  summarise(
    dependency = survey_ratio(
      numerator = economic_dependency_units,
      denominator = employed,
      vartype = c("se", "ci"),
      level = 0.95
    ),
    .groups = "drop"
  )

zone_economic_dependency_ratio
```

Tabla 4.15.: Razón de dependencia económica potencial por zona de residencia

Zona	Razón	EE	LI 95 %	LS 95 %
Rural	82.6	7.08	68.6	96.6
Urban	68.2	5.28	57.7	78.6

En la tabla 4.15 se estiman 82.59 personas no ocupadas por cada 100 ocupadas de 15 años o más en la zona rural y 68.18 en la urbana. La dependencia demográfica y la económica potencial responden a preguntas distintas y utilizan poblaciones de referencia diferentes: sus valores no son directamente intercambiables.

Otro ejemplo frecuente de estimación de razones en las encuestas de hogares es la razón entre el gasto y el ingreso, la cual permite analizar patrones de consumo y aproximarse a la capacidad de los hogares para sostener sus niveles de gasto (OECD 2013). A continuación, se muestra cómo estimar este indicador, cuyos resultados se presentan en la tabla 4.16:

```
expenditure_income_ratio_table <- survey_design %>%
  summarise(
    ratio = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
      vartype = c("se", "ci")
    )
  )

expenditure_income_ratio_table
```

Tabla 4.16.: Razón gasto/ingreso per cápita

Razón	EE	LI 95 %	LS 95 %
0.649	0.023	0.603	0.695

En este caso, se especificaron la variable de gasto como numerador (`numerator`), la variable de ingreso como denominador (`denominator`), el nivel de confianza (`level`) utilizado para la construcción de los intervalos de confianza y las medidas de precisión requeridas mediante el argumento (`vartype`). Como se puede observar, la razón entre el gasto y el ingreso es cercana a 0,65. Esto indica que el gasto agregado estimado equivale aproximadamente a 65 por cada 100 unidades del ingreso agregado estimado; el intervalo de confianza al 95 % va de 0,60 a 0,69.

Ahora bien, otro análisis de interés es estimar la razón de gastos en cada una de las regiones. A continuación, se presentan los códigos computacionales, los cuales dan origen a las estimaciones presentadas en la tabla 4.17.

```
regional_expenditure_income_ratio_table <- survey_design %>%
  group_by(Region) %>%
  summarise(
    ratio = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
      vartype = c("se", "ci")
    )
  )

regional_expenditure_income_ratio_table
```

Tabla 4.17.: Razón gasto/ingreso para las regiones

Región	Razón	EE	LI 95 %	LS 95 %
North	0.627	0.034	0.559	0.695

Tabla 4.17.: Razón gasto/ingreso para las regiones

Región	Razón	EE	LI 95 %	LS 95 %
South	0.674	0.062	0.553	0.796
Central	0.752	0.043	0.667	0.837
West	0.606	0.042	0.522	0.690
East	0.600	0.054	0.493	0.708

La razón entre el gasto y el ingreso presenta diferencias entre las regiones. No obstante, los intervalos de confianza se superponen ampliamente, por lo que las diferencias observadas entre las regiones no necesariamente representan diferencias estadísticamente significativas. En conjunto, los resultados indican que las razones entre gasto e ingreso agregados se sitúan aproximadamente entre 0,60 y 0,75, con una mayor proporción en la región Centro.

4.2. Estimación de parámetros de distribución y desigualdad

Los totales, las medias y las razones estudiados hasta aquí pueden complementarse con medidas que describan la dispersión, la posición relativa de las observaciones y la desigualdad de la distribución. Debido a su naturaleza no lineal, la forma funcional de los estimadores y la cuantificación de su incertidumbre deben tratarse usando procedimientos de linealización de Taylor o los métodos de replicación.

4.2.1. Varianza y desviación estándar

La dispersión de los valores en la población es distinta del error estándar de un estimador: la primera describe heterogeneidad; el segundo cuantifica incertidumbre muestral. En las encuestas de hogares, la estimación de medidas de dispersión es fundamental para evaluar el grado de heterogeneidad de la población respecto de las variables analizadas. Ya sea que una encuesta mida el consumo de alcohol en la población adulta o el índice de masa corporal de los niños en edad escolar, una desviación estándar poblacional pequeña indica una mayor homogeneidad en la población, mientras que una desviación estándar grande indica una población más heterogénea (SAS Institute Inc. 2012).

En particular, estudiar la variabilidad de los ingresos permite identificar diferencias económicas entre los hogares y aporta información relevante para el diagnóstico de la desigualdad y el diseño de políticas públicas. Una de las medidas de dispersión más utilizadas es la desviación estándar, que cuantifica cuánto se alejan, en promedio, los valores respecto de la media. Una desviación estándar pequeña indica que los ingresos se encuentran relativamente concentrados alrededor del promedio y, por tanto, que la población es más homogénea en términos económicos. Por el contrario, una desviación estándar elevada refleja una mayor dispersión y, en consecuencia, diferencias más marcadas entre los ingresos de los hogares.

De acuerdo con Heeringa et al. (2017), la desviación estándar poblacional se estima mediante una transformación no lineal del estimador de la varianza poblacional, $\widehat{S}_y^2$. Esta transformación incorpora, además, una corrección por grados de libertad basada en el número de observaciones válidas, denotado por n. En consecuencia, el estimador de la desviación estándar poblacional se expresa como:

$$\hat{s}_y = \sqrt{\frac{n}{n-1} \cdot \hat{S}_y^2} = \sqrt{\frac{n}{n-1} \frac{\sum_h \sum_i \sum_k w_{hik} \left(y_{hik} - \hat{\bar{y}}\right)^2}{\sum_h \sum_i \sum_k w_{hik}}}$$

El error estándar de la desviación estándar puede aproximarse mediante el método delta a partir de la varianza estimada de la medida de dispersión (Särndal et al. 2003). Para estimar la desviación estándar de una variable numérica en encuestas de hogares mediante `R`, se estima primero la varianza poblacional con la función `survey_var()` y, posteriormente, se obtiene su raíz cuadrada. A continuación, se ilustra este procedimiento mediante la estimación de la desviación estándar del ingreso desagregada por zona.

```
income_dispersion_by_zone_table <- survey_design %>%
  group_by(Zone) %>%
  summarise(
    Var = survey_var(
      Income,
      level = 0.95,
      vartype = c("se", "ci"),
      na.rm = TRUE
    )
  ) %>%
  mutate(
    Sd = sqrt(Var),
    Sd_low = sqrt(pmax(Var_low, 0)),
    Sd_upp = sqrt(Var_upp)
  )

income_dispersion_by_zone_table
```

Tabla 4.18.: Desviación estándar de los ingresos desagregada por zona

Zona	Varianza	Var.: EE	Var.: LI 95 %	Var.: LS 95 %	DE	DE: LI 95 %	DE: LS 95 %
Rural	96274	13794	68960	123588	310	263	352
Urban	338628	81241	177763	499494	582	422	707

`Var_se` es el error estándar de la varianza y no el de la desviación estándar. Los límites de esta última se obtienen transformando los de la varianza; el inferior se restringe a cero antes de aplicar la raíz si la aproximación produce un límite negativo.

Los argumentos de la función `survey_var()` son equivalentes a los utilizados previamente para la estimación de medias y totales. Los resultados de la tabla 4.18 muestran que los ingresos presentan una dispersión considerablemente mayor en la zona urbana que en la rural. En la zona rural, la desviación estándar alcanza 310 dólares, mientras que en la zona urbana se eleva a 582 dólares. Los intervalos describen la incertidumbre de cada medida de dispersión. Para realizar una prueba formal de su diferencia se necesitaría estimar el contraste correspondiente.

4.2.2. Percentiles y medianas

Los percentiles permiten identificar puntos específicos de la distribución de una variable de interés y determinar los valores por debajo de los cuales se encuentra una proporción determinada de la población. En las encuestas de hogares, estas medidas resultan especialmente útiles para caracterizar la distribución de variables económicas y sociales, como el ingreso, el gasto o las horas trabajadas. Por ejemplo, los percentiles de ingreso pueden utilizarse para identificar a la población perteneciente al 10 % superior de la distribución con fines tributarios (UNECE 2011), o para focalizar subsidios dirigidos a los hogares ubicados en los percentiles más bajos. La mediana, correspondiente al valor que divide a la población en dos partes iguales es poco sensible a valores extremos, razón por la cual suele considerarse una medida robusta de tendencia central.

La función de distribución estima la proporción de personas cuyo valor no supera un umbral, retomando la estimación de proporciones del capítulo anterior. Los percentiles constituyen un caso particular de los cuantiles. En términos generales, el cuantil de orden q (con $0 < q < 1$) es el valor que deja por debajo una proporción q de la población. Cuando esta proporción se expresa en una escala de 0 a 100, el cuantil se denomina percentil. La estimación de cuantiles en encuestas complejas se basa en el uso de estimadores ponderados y en la estimación de la función de distribución acumulada (FDA) de la población (Schulze Waltrup y Kauermann 2016). Para una población finita de tamaño N, un estimador de esta distribución está dado por:

$$\hat{F}(x) = \frac{\sum_h \sum_i \sum_k w_{hik}\, I(y_k \leq x)}{\sum_h \sum_i \sum_k w_{hik}} \tag{4.15}$$

en donde la función $I(y_k \leq x)$ es una variable indicadora que toma el valor uno si $y_k \leq x$ y cero en otro caso. Una vez estimada la FDA utilizando los pesos del diseño muestral, el cuantil q-ésimo de una variable y se define como el menor valor de y para el cual la FDA es mayor o igual que q. En particular, la mediana estimada es el valor donde la FDA estimada es mayor o igual a 0.5. Para la estimación de cuantiles en encuestas complejas, se ordenan las observaciones en orden ascendente (estadísticas de orden) de forma que $y_{(1)} \leq y_{(2)} \leq ... \leq y_{(n)}$ y se identifica el valor de j ($j = 1, ..., n$) tal que:

$$\hat{F}\left(y_{(j)}\right) \leq q \leq \hat{F}\left(y_{(j+1)}\right)$$

La estimación numérica depende de la regla elegida para resolver los saltos de la distribución ponderada. En los ejemplos se explicita `qrule = "math"`; otras reglas permiten interpolación y pueden dar valores diferentes. La elección del intervalo mediante `interval_type` es una decisión distinta de la regla del cuantil.

Woodruff (1952) propone el método de inversión de la función de distribución acumulada como procedimiento para construir intervalos de confianza de cuantiles. Por su parte, Kovar et al. (1988) analiza la estimación de la varianza y la construcción de intervalos de confianza para percentiles y medianas, y muestra que los métodos de replicación presentan un desempeño satisfactorio para estos parámetros no lineales en encuestas con diseños muestrales complejos.

Tanto los estimadores de cuantiles como los métodos para estimar sus varianzas se encuentran implementados en `R`. En particular, la función `survey_median()` permite estimar la mediana y obtener, de manera conjunta, su error estándar y su intervalo de confianza. Al igual que otros

parámetros poblacionales, la mediana puede estimarse para diferentes dominios de estudio, como la zona geográfica, el sexo o los grupos de edad. A continuación, se presenta la sintaxis empleada para estimar la mediana del gasto per cápita por zona a partir de la base de datos de ejemplo.

```
expenditure_median_by_zone_table <- survey_design %>%
  group_by(Zone) %>%
  summarise(
    median = survey_median(
      Expenditure,
      qrule = "math",
      level = 0.95,
      vartype = c("se", "ci")
    )
  )

expenditure_median_by_zone_table
```

Tabla 4.19.: Estimación de la mediana de los gastos desagregada por zona

Zona	Mediana	EE	LI 95 %	LS 95 %
Rural	241	11.0	214	258
Urban	381	19.8	337	416

A partir de la tabla 4.19 se concluye que el gasto mediano presenta una diferencia importante entre zonas. En el área rural, la mediana estimada es de 241 dólares, lo que indica que la mitad de la población rural tiene gastos inferiores a este valor y la otra mitad registra gastos superiores. En la zona urbana, la mediana asciende a 381 dólares, es decir, aproximadamente un 58 % más que en la zona rural. Los intervalos de confianza no se superponen, lo que sugiere una diferencia clara en los niveles centrales de gasto entre ambas zonas. Aunque la estimación urbana presenta un error estándar mayor, los resultados muestran consistentemente que el gasto mediano es más elevado en las áreas urbanas.

Cuando el objetivo es estimar un percentil distinto de la mediana, puede utilizarse la función `survey_quantile()`. De acuerdo con Dorfman y Valliant (1993), algunos procedimientos para construir intervalos de confianza de cuantiles pueden presentar un desempeño menos satisfactorio que otras alternativas disponibles. En particular, el argumento `interval_type = "score"` emplea un método de inversión para determinar los límites del intervalo, en lugar de calcularlos directamente a partir de la función de influencia del percentil.

A modo de ejemplo, a continuación se presenta la sintaxis para estimar el percentil 25 del gasto. Los resultados obtenidos se muestran en la tabla 4.20.

```
expenditure_first_quartile_table <- survey_design %>%
  summarise(
    quantile = survey_quantile(
      Expenditure,
      quantiles = 0.25,
```

```
      qrule = "math",
      level = 0.95,
      vartype = c("se", "ci"),
      interval_type = "score"
    )
  )

expenditure_first_quartile_table
```

Tabla 4.20.: Estimación del primer cuartil de los gastos per cápita

Cuartil 1	EE	LI 95 %	LS 95 %
200	13.8	163	218

De los resultados anteriores, el percentil 25 del gasto se estima en 200 dólares, lo que indica que aproximadamente una cuarta parte de la población presenta niveles de gasto iguales o inferiores a este valor, mientras que el 75 % restante registra gastos superiores. El error estándar de 13,8 dólares refleja la incertidumbre asociada a la estimación.

4.2.3. El coeficiente de Gini y la curva de Lorenz

El tema sobre desigualdad económica trasciende el ámbito estrictamente estadístico y constituye uno de los temas centrales del análisis social contemporáneo. La desigualdad económica se relaciona con la persistencia de brechas en el acceso a oportunidades, la baja movilidad social y el debilitamiento de la cohesión social. En este contexto, su medición rigurosa resulta fundamental para producir diagnósticos sólidos y orientar el diseño, la implementación y la evaluación de políticas públicas integrales dirigidas a reducir las desigualdades y promover el desarrollo social inclusivo (CEPAL 2025, 32-33).

Entre los indicadores más ampliamente utilizados para cuantificar la desigualdad económica se encuentra el coeficiente de Gini (G), el cual mide el grado de concentración del ingreso comparando la distribución observada con una situación hipotética de igualdad perfecta. Este coeficiente toma valores entre 0 y 1, donde $G = 0$ representa igualdad perfecta y $G = 1$ corresponde al máximo nivel de desigualdad posible. En consecuencia, cuanto más cercano a uno sea el coeficiente, mayor será la concentración del ingreso en una proporción reducida de la población.

En el contexto de las encuestas de hogares, la estimación del coeficiente de Gini debe incorporar adecuadamente las características del diseño muestral, incluyendo los factores de expansión, la estratificación y la conglomeración. Siguiendo a Binder y Kovačević (1995) y Langel y Tillé (2013), el estimador ponderado del coeficiente de Gini puede expresarse en función de la posición acumulada de cada observación en la distribución del ingreso, así:

$$\hat{G} = \frac{2 \sum_h \sum_i \sum_k w^*_{hik} \, \hat{F}_{hik} \, y_{hik}}{\hat{\bar{y}}} - 1 \tag{4.16}$$

donde $w^*_{hik} = \frac{w_{hik}}{\sum_h \sum_i \sum_k w_{hik}}$ corresponde al peso muestral normalizado, $\hat{F}_{hik}$ representa la función de distribución acumulada (FDA) estimada para la observación k dentro del conglomerado i del estrato h, y $\hat{\bar{y}}$ denota la media ponderada de la variable de ingreso en la población.

Con respecto a la estimación de la varianza, Osier (2009) desarrolla un procedimiento de linealización que aproxima el estimador no lineal mediante una variable linealizada. A partir de este desarrollo, Jacob et al. (2024) presenta su implementación en `R` mediante la función `svygini()`. Para ello, primero se prepara el diseño completo mediante `convey_prep()`, antes de definir posibles dominios para este tipo de estimación. El nuevo objeto `gini_design` conserva la información adicional que requieren los métodos de desigualdad. Luego, la función `svygini()` calcula el índice de Gini utilizando la variable de ingreso y el diseño de encuesta complejo especificado.

A continuación, se presenta la sintaxis utilizada para estimar el coeficiente de Gini en la base de datos de ejemplo, cuyos resultados se muestran en la tabla 4.21.

```
library(convey)
gini_design <- convey_prep(survey_design)
gini <- svygini(~Income, design = gini_design)
income_gini_table <- data.frame(
  Gini = coef(gini),
  standard_error = SE(gini),
  ci_lower = confint(gini)[1],
  ci_upper = confint(gini)[2]
)

income_gini_table
```

Tabla 4.21.: Estimación del coeficiente de Gini para el ingreso per cápita

	Gini	EE	LI 95 %	LS 95 %
Income	0.413	0.019	0.377	0.45

El coeficiente de Gini estimado indica un grado apreciable de desigualdad en la distribución del ingreso y evidencia una concentración relevante de los ingresos en una parte de la población.

Las proporciones acumuladas de personas retoman la lógica de composición del capítulo anterior, ahora ordenando a la población por ingreso per cápita. Por su parte, la curva de Lorenz representa gráficamente la distribución del ingreso mediante la relación entre la proporción acumulada de la población, ordenada de menor a mayor ingreso, y la proporción acumulada del ingreso total que le corresponde (Lorenz 1905). La diagonal de 45 grados representa una situación hipotética de igualdad perfecta, en la que cada proporción acumulada de la población concentra una proporción equivalente del ingreso total.

El coeficiente de Gini se obtiene como la razón entre el área comprendida entre la curva de Lorenz y la línea de igualdad y el área total situada bajo dicha línea (Deaton 1997). Dado que esta última área es igual a un medio, el coeficiente también puede expresarse como el doble del área situada entre ambas curvas. En consecuencia, cuanto más próxima se encuentre la curva de Lorenz a la línea

de igualdad, más equitativa será la distribución del ingreso; por el contrario, una mayor distancia entre ambas indica un grado más elevado de desigualdad.

En encuestas con diseños muestrales complejos, la estimación de las ordenadas de la curva de Lorenz y de sus varianzas debe incorporar las ponderaciones y las demás características del diseño muestral (Kovačević y Binder 1997). El siguiente código computacional utiliza `svylorenz()` para estimar la curva de Lorenz representada en la figura 4.1.

```
clorenz <- svylorenz(
  formula = ~Income,
  design = gini_design,
  quantiles = seq(0, 1, .05),
  alpha = .05,
  plot = TRUE
)
```

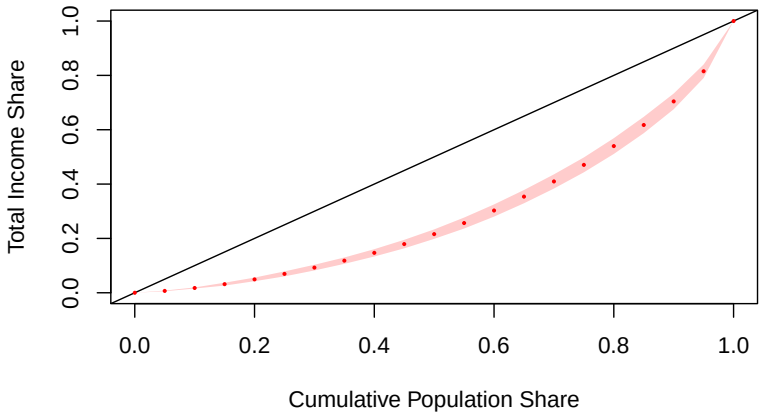


Figura 4.1.: Curva de Lorenz estimada para el ingreso per cápita

El argumento `formula = ~Income` especifica la variable de ingreso sobre la cual se calculará la distribución acumulada. El argumento `design = gini_design` indica el objeto de diseño muestral previamente definido, el cual contiene la información relacionada con pesos, estratos y conglomerados de la encuesta. Por su parte, `quantiles = seq(0, 1, .05)` define los puntos de la distribución en los cuales se evaluará la curva de Lorenz, generando proporciones acumuladas desde 0 hasta 1 en incrementos de 0.05. Finalmente, el argumento `alpha = .05` establece un nivel de significación del 5 %, lo que equivale a construir intervalos de confianza del 95 % para las estimaciones asociadas a la curva.

A partir de la figura 4.1, se observa un grado considerable de desigualdad en la distribución del ingreso per cápita, dado que la curva de Lorenz se sitúa claramente por debajo de la línea de igualdad perfecta. Su marcada curvatura muestra que los grupos ubicados en la parte inferior de la distribución concentran una proporción reducida del ingreso total, mientras que una participación considerable se acumula entre las personas de mayores ingresos. La curva se separa de la línea

de igualdad en los tramos intermedios y vuelve a encontrarse con ella al acumular el total de la población y del ingreso. La reducida participación acumulada del ingreso en los primeros tramos muestra su concentración entre las personas de mayores ingresos. Por su parte, la banda sombreada representa la incertidumbre asociada a la estimación de la curva.

4.2.4. Correlaciones

En el capítulo anterior se estudió asociación entre categorías. Ahora se describe la relación lineal entre magnitudes numéricas. En el estudio de encuestas de hogares, además de describir variables de forma individual, es importante analizar cómo se relacionan dos variables entre sí. Una de las herramientas más utilizadas para este propósito es el coeficiente de correlación de Pearson, el cual mide la fuerza y la dirección de la relación lineal entre dos variables numéricas. Este coeficiente toma valores entre –1 y 1. Un valor positivo indica que ambas variables tienden a aumentar simultáneamente, mientras que un valor negativo señala que cuando una variable aumenta, la otra tiende a disminuir. Por su parte, valores cercanos a cero sugieren la ausencia de una relación lineal fuerte entre las variables analizadas. Por ejemplo, en una encuesta de hogares puede ser de interés estudiar qué tan fuerte es la asociación entre el ingreso per cápita y su nivel de gasto. Este tipo de análisis permite comprender mejor los patrones económicos y sociales en la población.

Supóngase que se dispone de dos variables numéricas de interés, denotadas por x y y, observadas en la encuesta compleja. De acuerdo con Heeringa et al. (2017), la asociación lineal entre ambas variables puede estimarse mediante el coeficiente de correlación de Pearson ponderado, definido como la covarianza ponderada entre x y y dividida por el producto de sus desviaciones estándar ponderadas. Esta estandarización elimina la influencia de las unidades de medida y permite evaluar tanto la dirección como la intensidad de la relación lineal. Si $\hat{\bar{x}}$ y $\hat{\bar{y}}$ representan las estimaciones de las medias poblacionales de x y y, respectivamente, el coeficiente de correlación ponderado se expresa como:

$$\hat{\rho}_{xy} = \frac{\sum_h \sum_i \sum_k w_{hik}(y_{hik} - \hat{\bar{y}})(x_{hik} - \hat{\bar{x}})}{\sqrt{\sum_h \sum_i \sum_k w_{hik}(y_{hik} - \hat{\bar{y}})^2} \sqrt{\sum_h \sum_i \sum_k w_{hik}(x_{hik} - \hat{\bar{x}})^2}} \tag{4.17}$$

La covarianza entre variables describe su distribución conjunta en la población. Es distinta de la covarianza entre estimadores obtenida con `vcov()` en los contrastes del capítulo anterior.

El siguiente código computacional utiliza `svyvar()` del paquete `survey` para estimar la matriz de varianzas y covarianzas del ingreso y el gasto per cápita, incorporando el diseño muestral. Luego organiza los resultados con los nombres de las variables para presentarlos en la tabla 4.22. Esta matriz también permite calcular la correlación entre ambas variables.

```
cov_matrix <- svyvar(~Income + Expenditure, design = survey_design)
```

```
income_expenditure_covariance_table <- data.frame(
  Variable = rownames(cov_matrix),
  as.matrix(cov_matrix)
) %>%
```

```
  slice(1:2)

income_expenditure_covariance_table
```

Tabla 4.22.: Matriz de varianzas y covarianzas ponderada entre ingreso y gasto

	Variable	Ingreso	Gasto
Income	Income	243719	98337
Expenditure	Expenditure	98337	77887

La función `svyvar` estima la matriz de varianzas y covarianzas considerando el diseño muestral. A partir de dicha matriz puede obtenerse la correlación aplicando las siguientes instrucciones:

```
cov_xy <- cov_matrix[1, 2]
sd_x <- sqrt(cov_matrix[1, 1])
sd_y <- sqrt(cov_matrix[2, 2])

weighted_cor <- cov_xy / (sd_x * sd_y)
weighted_cor
```

```
[1] 0.714
```

Si además se desea realizar inferencia estadística sobre la correlación, por ejemplo obtener errores estándar o intervalos de confianza, pueden utilizarse métodos de replicación compatibles con el paquete `survey`. El siguiente código computacional ilustra otra opción: estimar directamente la correlación entre ingreso y gasto con `svycor()` del paquete `jtools` (Long 2026).

```
library(jtools)

svycor(
  ~Income + Expenditure,
  design = survey_design,
  sig.stats = FALSE
)
```

```
            Income Expenditure
Income        1.00        0.71
Expenditure   0.71        1.00
```

La llamada anterior presenta la correlación sin solicitar pruebas ni intervalos. La correlación entre el ingreso y el gasto es relativamente alta, con un coeficiente de Pearson estimado de 0,71. Esto indica que, en términos generales, los hogares con mayores ingresos tienden a registrar también niveles de gasto más elevados. Los valores iguales a 1 en la diagonal corresponden a la correlación de cada variable consigo misma. Finalmente, este resultado refleja una asociación lineal y no debe interpretarse como evidencia de una relación causal.

4.3. Pruebas de hipótesis

En el análisis de datos provenientes de encuestas de hogares no basta con estudiar cada variable de manera aislada, sino que también es fundamental comparar grupos y evaluar si las diferencias observadas entre ellos reflejan desigualdades reales en la población o si podrían explicarse simplemente por el error de muestreo. Por ejemplo, una pregunta de interés consiste en determinar si existen diferencias estadísticamente significativas en el ingreso medio entre hogares dirigidos por hombres y hogares dirigidos por mujeres. Este tipo de análisis permite identificar brechas sociales y económicas, además de generar evidencia útil para el diseño y evaluación de políticas públicas.

La lógica de hipótesis nula y alternativa se introdujo en la Sección 3.4. Aquí se conserva ese mismo marco referencial. Por ejemplo, para la diferencia de medias se estima la diferencia puntual, junto con su error estándar, incorporando la covarianza entre estimaciones de dominios. De esta manera, supóngase que $\bar{y}_1$ y $\bar{y}_2$ representan las medias poblacionales de una variable y en dos dominios distintos, como los hogares con jefatura masculina y femenina. En este caso, el parámetro de interés corresponde a la diferencia entre ambas medias:

$$\Delta = \bar{y}_1 - \bar{y}_2$$

Su estimador muestral se define como:

$$\hat{\Delta} = \hat{\bar{y}}_1 - \hat{\bar{y}}_2$$

Su error estándar se estima mediante la siguiente expresión:

$$\widehat{se}(\hat{\Delta}) = \sqrt{\widehat{Var}(\hat{\bar{y}}_1) + \widehat{Var}(\hat{\bar{y}}_2) - 2\widehat{Cov}(\hat{\bar{y}}_1, \hat{\bar{y}}_2)}$$

La presencia del término de covarianza, ya estudiado al comparar proporciones, es importante porque las estimaciones de ambos dominios suelen provenir de la misma muestra y, por tanto, no necesariamente son independientes. Una vez calculado el estimador y su error estándar, se aplica el procedimiento descrito en la Sección 3.4, sustituyendo $\hat{\Delta}_p$ por $\hat{\Delta}$. El estadístico de prueba, su distribución de referencia y el intervalo de confianza se construyen de la misma manera, utilizando los grados de libertad devueltos por `svyttest()`.

El siguiente código computacional crea primero el objeto `survey_design_heads`, que conserva únicamente las observaciones correspondientes a las personas jefas de hogar, identificadas mediante `PersonID == "idPer01"`, sin perder las características del diseño muestral. Posteriormente, la función `svyttest()` compara el ingreso medio entre las categorías de la variable `Sex`. Se fija `Female` como referencia: el resultado representa hombres menos mujeres. La prueba devuelve un intervalo del 95 %. Para este ejemplo se aplica la convención del capítulo 3: se conserva el registro de la persona principal de cada hogar y se utiliza su factor de expansión como aproximación al peso del hogar. Así se compara el ingreso per cápita entre hogares con jefatura masculina y femenina, con las limitaciones señaladas para esta aproximación. Finalmente, se reúnen la diferencia estimada, el estadístico, el valor-p, los grados de libertad y el intervalo de confianza.

```r
survey_design_heads <- survey_design %>%
  filter(PersonID == "idPer01") %>%
  mutate(Sex = factor(Sex, levels = c("Female", "Male")))

ttest_sex <- svyttest(Income ~ Sex, design = survey_design_heads)
```

```r
df_res <- tibble(
  estimated_difference = ttest_sex$estimate,
  statistic = ttest_sex$statistic,
  p_value = ttest_sex$p.value,
  gl = ttest_sex$parameter,
  ci_lower = ttest_sex$conf.int[1],
  ci_upper = ttest_sex$conf.int[2]
)
income_sex_test_table <- df_res

income_sex_test_table
```

Tabla 4.23.: Diferencia de ingreso per cápita entre personas jefas de hogar por sexo

Diferencia	Estadístico t	Valor p	gl	LI 95 %	LS 95 %
122	2.76	0.007	118	34.7	210

A partir de los resultados presentados en la tabla 4.23, se estima que el ingreso per cápita de los hogares asociado a los hombres jefes de hogar es aproximadamente 122 dólares mayor al asociado a las mujeres jefas de hogar. Dado que el valor p obtenido es 0.00664, inferior al nivel de significación establecido de $\alpha = 0,05$, se rechaza la hipótesis nula de igualdad de medias y se concluye que la diferencia observada es estadísticamente significativa. Esta conclusión es consistente con el intervalo de confianza del 95 %, que no incluye el valor cero. En conjunto, los resultados aportan evidencia de que, en la población representada por la encuesta, el ingreso per cápita asociado a las mujeres jefas de hogar es significativamente menor que el asociado a los hombres jefes de hogar, bajo el diseño y el dominio considerados.

4.4. Estimación de contrastes

La comparación de medias presentada en la sección anterior puede extenderse a otras diferencias de interés entre grupos poblacionales. Por ejemplo, se pueden comparar los ingresos medios entre regiones o las razones de gasto e ingreso entre hogares con jefatura masculina y femenina. Estas diferencias se expresan mediante contrastes que combinan las estimaciones de cada grupo y utilizan sus varianzas y covarianzas para cuantificar la incertidumbre. En esta sección se muestra cómo construirlos y cómo estimar varias comparaciones por pares, cada una con su respectivo intervalo de confianza.

La definición general de contraste, sus coeficientes y las funciones `svyby()`, `vcov()` y `svycontrast()` se presentaron en la Sección 3.5. Aquí se sustituyen las proporciones por medias y, después, por

razones, aunque se conserva la matriz de covarianzas mediante `covmat = TRUE`. Por ejemplo, si se quiere comparar los ingresos medios de dos subpoblaciones particulares (las regiones Norte y Sur) se puede usar el contraste $\bar{y}_{Norte} - \bar{y}_{Sur}$. Dado que la muestra cubre cinco regiones en total, el contraste debe construirse asignando coeficientes únicamente a las regiones involucradas en la comparación y dejando coeficientes iguales a cero para las demás regiones. De esta manera, el contraste se define como:

$$1 \times \hat{\bar{y}}_{Norte} + (-1) \times \hat{\bar{y}}_{Sur} + 0 \times \hat{\bar{y}}_{Centro} + 0 \times \hat{\bar{y}}_{Occidente} + 0 \times \hat{\bar{y}}_{Oriente}.$$

Esta expresión indica que el contraste corresponde a la diferencia entre las medias estimadas de las regiones Norte y Sur, mientras que las demás regiones no participan en la comparación. De forma matricial, el contraste puede escribirse como:

$$[1,\, -1,\, 0,\, 0,\, 0] \times \begin{bmatrix} \hat{\bar{y}}_{Norte} \\ \hat{\bar{y}}_{Sur} \\ \hat{\bar{y}}_{Centro} \\ \hat{\bar{y}}_{Occidente} \\ \hat{\bar{y}}_{Oriente} \end{bmatrix}.$$

En consecuencia, el vector de contraste asociado a esta comparación es $[1, -1, 0, 0, 0]$, donde los coeficientes positivos y negativos indican las poblaciones que se desean comparar y los ceros representan las poblaciones excluidas del contraste. En `R`, estos procedimientos se encuentran disponibles mediante la función `svycontrast()` del paquete `survey`. El siguiente código computacional estima las medias regionales de ingreso, conserva sus covarianzas y organiza los resultados para presentarlos en la tabla 4.24.

```
region_mean_contrast <- svyby(
  formula = ~ Income,
  by = ~ Region,
  design = survey_design,
  FUN = svymean,
  na.rm = TRUE,
  covmat = TRUE,
  vartype = c("se", "ci")
)
```

```
regional_income_means_table <- region_mean_contrast

regional_income_means_table
```

Tabla 4.24.: Ingreso medio estimado por región

Región	Ingreso	EE	LI 95 %	LS 95 %
North	552	55.4	444	661
South	626	62.4	503	748

Tabla 4.24.: Ingreso medio estimado por región

Región	Ingreso	EE	LI 95 %	LS 95 %
Central	651	61.5	530	771
West	517	46.2	426	608
East	542	71.7	401	682

La función `svyby()` estima el ingreso medio por región, de acuerdo con el diseño de muestreo `survey_design`. El argumento `formula = ~Income` especifica la variable numérica de interés, mientras que `by = ~Region` define los dominios para los cuales se realizará la estimación. La opción `FUN = svymean` indica que debe calcularse la media del ingreso en cada región y `na.rm = TRUE` excluye las observaciones con valores faltantes. Por su parte, `vartype = c("se", "ci")` solicita el error estándar y el intervalo de confianza de cada media estimada. Estos intervalos utilizan la aproximación normal, como se explica en la Sección 3.5. Finalmente, `covmat = TRUE` calcula la matriz de varianzas y covarianzas entre las estimaciones regionales, lo que permite realizar posteriormente contrastes o comparaciones entre ellas.

Luego, la función `svycontrast()` devuelve el contraste estimado y su error estándar, como se muestra en la tabla 4.25. Los argumentos de esta función son los promedios de los ingresos estimados (`stat`) y las constantes de contraste (`contrasts`). Para los contrastes lineales de esta sección, el error estándar se calcula a partir de la matriz de varianzas y covarianzas de las estimaciones que se comparan. Si se aplica `confint()` directamente al resultado de `svycontrast()`, el intervalo de Wald utiliza por defecto un cuantil normal. En las tablas de contrastes de esta sección se adopta una distribución t de Student con los grados de libertad del diseño utilizado en cada comparación. Los límites se calculan explícitamente con `qt()` y `degf()`. Para estos contrastes se obtienen los mismos límites al usar `confint()` con `df = degf(diseño)` y el mismo nivel de confianza. El siguiente código computacional estima la diferencia entre los ingresos medios de Norte y Sur mediante `svycontrast()` y reúne el contraste, su error estándar y su intervalo de confianza para presentarlos en la tabla.

```
contrast_region_ns <- svycontrast(
  stat = region_mean_contrast,
  contrasts = list(
    north_south_difference = c(North = 1, South = -1)
  )
)
```

```
critical <- qt(0.975, df = degf(survey_design))
north_south_income_contrast_table <- tibble(
  contrast = names(coef(contrast_region_ns)),
  estimate = as.numeric(coef(contrast_region_ns)),
  standard_error = as.numeric(SE(contrast_region_ns)),
  lower = estimate - critical * standard_error,
  upper = estimate + critical * standard_error
)

north_south_income_contrast_table
```

Tabla 4.25.: Contraste de ingresos medios: región North menos región South

Contraste	Estimación	EE	LI 95 %	LS 95 %
north_south_difference	-73.4	83.4	-239	91.8

La estimación de la diferencia de medias indica que el ingreso promedio en la región Norte es aproximadamente 73,4 dólares inferior al observado en la región Sur. Sin embargo, el error estándar de 83,4 es mayor que la diferencia estimada, lo que refleja una incertidumbre considerable. Por tanto, no hay evidencia suficiente para concluir que exista una diferencia estadísticamente significativa entre ambas regiones. Nótese que estos mismos resultados podrían obtenerse realizando explícitamente el proceso de construcción del estimador del contraste y de su varianza estimada. El siguiente código computacional inicia este cálculo directo restando el ingreso medio estimado de Sur al de Norte.

```
# Paso 1: diferencia de las estimaciones (North - South)
region_income_mean <- setNames(
  as.numeric(region_mean_contrast[["Income"]]),
  region_mean_contrast[["Region"]]
)

region_income_mean["North"] - region_income_mean["South"]
```

```
North
-73.4
```

El siguiente código computacional obtiene la matriz de varianzas y covarianzas y la organiza con los nombres de las regiones para presentarla en la tabla 4.26. De ella se extraen los elementos correspondientes a Norte y Sur. Las covarianzas estimadas entre las regiones son todas nulas, lo que resulta coherente con el diseño muestral, dado que la estratificación se realizó por región y la selección de la muestra se efectuó de manera independiente en cada estrato. En consecuencia, los estimadores regionales no comparten unidades muestrales y su covarianza bajo el diseño es igual a cero.

```
# Paso 2: matriz de varianzas y covarianzas
region_vcov <- vcov(region_mean_contrast)
```

```
df_vcov <- region_vcov %>%
  as.data.frame() %>%
  tibble::rownames_to_column("Region")

regional_income_covariance_table <- df_vcov

regional_income_covariance_table
```

Tabla 4.26.: Matriz de varianzas y covarianzas de los ingresos medios por región

Región	Norte	Sur	Centro	Occidente	Oriente
North	3065	0	0	0	0
South	0	3894	0	0	0
Central	0	0	3778	0	0
West	0	0	0	2136	0
East	0	0	0	0	5136

Para calcular el error estándar de la diferencia (contraste) se usarán las propiedades de la varianza, de la siguiente forma:

$$\widehat{se}\left(\hat{\bar{y}}_{Norte} - \hat{\bar{y}}_{Sur}\right) = \sqrt{\widehat{Var}\left(\hat{\bar{y}}_{Norte}\right) + \widehat{Var}\left(\hat{\bar{y}}_{Sur}\right) - 2\,\widehat{Cov}\left(\hat{\bar{y}}_{Norte}, \hat{\bar{y}}_{Sur}\right)}$$

Para evitar inconsistencias por redondeo, el siguiente código computacional calcula el error estándar de la diferencia Norte menos Sur directamente a partir de la matriz estimada de varianzas y covarianzas.

```
sqrt(
  region_vcov["North", "North"] +
    region_vcov["South", "South"] -
    2 * region_vcov["North", "South"]
)
```

```
[1] 83.4
```

Este resultado corresponde al mismo obtenido anteriormente con la función `svycontrast()`.

Además de comparar únicamente dos poblaciones, los contrastes permiten estimar varias comparaciones de interés entre diferentes grupos. Por ejemplo, supóngase que se desea comparar los ingresos medios entre distintas regiones geográficas. En particular, podrían considerarse contrastes como $\bar{y}_{Norte} - \bar{y}_{Centro}$, $\bar{y}_{Sur} - \bar{y}_{Centro}$ y $\bar{y}_{Occidente} - \bar{y}_{Oriente}$. Cada una de estas expresiones representa un contraste lineal específico entre medias regionales. De manera conjunta, dichos contrastes pueden organizarse mediante la siguiente matriz de contrastes:

$$\begin{bmatrix} 1 & 0 & -1 & 0 & 0 \\ 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{bmatrix}$$

Se estiman varias diferencias, sin realizar aquí una prueba conjunta ni un ajuste de comparaciones múltiples. El orden de columnas es Norte, Sur, Centro, Occidente y Oriente; el código asigna coeficientes por nombre. En esta matriz, cada fila define un contraste distinto y cada columna corresponde a una de las regiones consideradas en el análisis. Los coeficientes positivos y negativos indican las medias que participan en cada comparación, mientras que los ceros representan las regiones que no intervienen en el contraste correspondiente. El siguiente código computacional

estima estos contrastes y organiza las diferencias regionales, sus errores estándar y sus intervalos de confianza para presentarlos en la tabla 4.27.

```
contrast_regions <- svycontrast(
  stat = region_mean_contrast,
  contrasts = list(
    north_center = c(North = 1, Central = -1),
    south_center = c(South = 1, Central = -1),
    west_east = c(West = 1, East = -1)
  )
)
```

```
critical <- qt(0.975, df = degf(survey_design))
regional_income_contrasts_table <- tibble(
  contrast = names(coef(contrast_regions)),
  estimate = as.numeric(coef(contrast_regions)),
  standard_error = as.numeric(SE(contrast_regions)),
  lower = estimate - critical * standard_error,
  upper = estimate + critical * standard_error
)

regional_income_contrasts_table
```

Tabla 4.27.: Contrastes de ingresos medios entre regiones

Contraste	Estimación	EE	LI 95 %	LS 95 %
north_center	-98.4	82.7	-262	65.4
south_center	-25.0	87.6	-198	148.4
west_east	-24.7	85.3	-194	144.1

También pueden construirse contrastes para comparar el ingreso per cápita según el sexo de la persona jefa del hogar. El siguiente código computacional utiliza `survey_design_heads` para estimar la media de cada grupo y organizar las estimaciones y sus medidas de precisión, presentadas en la tabla 4.28.

```
sex_mean_contrast <- svyby(
  formula = ~ Income,
  by = ~ Sex,
  design = survey_design_heads,
  FUN = svymean,
  na.rm = TRUE,
  covmat = TRUE,
  vartype = c("se", "ci")
)
```

```
income_means_by_sex_table <- sex_mean_contrast %>%
  as_tibble()

income_means_by_sex_table
```

Tabla 4.28.: Ingreso per cápita asociado a personas jefas de hogar, por sexo

Sexo	Ingreso	EE	LI 95 %	LS 95 %
Female	442	23.5	396	488
Male	564	34.0	498	631

En este caso, el contraste de interés está dado por $\bar{y}_F - \bar{y}_M$, el cual permite cuantificar la diferencia entre el ingreso medio de las mujeres y el correspondiente a los hombres. El siguiente código computacional estima esta diferencia mediante `svycontrast()` y organiza su error estándar e intervalo de confianza para presentarlos en la tabla 4.29.

```
contrast_sex <- svycontrast(
  stat = sex_mean_contrast,
  contrasts = list(
    sex_difference = c(Female = 1, Male = -1)
  )
)
```

```
critical <- qt(0.975, df = degf(survey_design_heads))
income_sex_contrast_table <- tibble(
  contrast = names(coef(contrast_sex)),
  estimate = as.numeric(coef(contrast_sex)),
  standard_error = as.numeric(SE(contrast_sex)),
  lower = estimate - critical * standard_error,
  upper = estimate + critical * standard_error
)

income_sex_contrast_table
```

Tabla 4.29.: Contraste de ingresos medios entre mujeres y hombres

Contraste	Estimación	EE	LI 95 %	LS 95 %
sex_difference	-122	44.3	-210	-34.7

A partir de estos resultados, se concluye que, el ingreso per cápita asociado a hombres jefes de hogar supera aproximadamente en 122 dólares al asociado a mujeres jefas de hogar, con un error estándar estimado de 44,3 dólares.

Un contraste lineal también puede combinar razones estimadas, aunque cada razón sea una función no lineal de totales. En este ejemplo se utiliza ingreso/gasto, la orientación inversa de gasto/ingreso

empleada anteriormente. Un ejemplo de ello consiste en comparar la relación entre ingresos y gastos según el sexo del jefe de hogar. En este caso, primero se estima la razón ingreso-gasto para cada grupo y posteriormente se construye el contraste entre dichas razones. El siguiente código computacional estima las razones ingreso/gasto por sexo y organiza sus medidas de precisión para presentarlas en la tabla 4.30.

```
sex_ratio_contrast <- svyby(
  formula = ~ Income,
  by = ~ Sex,
  denominator = ~ Expenditure,
  design = survey_design_heads,
  FUN = svyratio,
  na.rm = TRUE,
  covmat = TRUE,
  vartype = c("se", "ci")
)
```

```
income_expenditure_ratio_by_sex_table <- sex_ratio_contrast

income_expenditure_ratio_by_sex_table
```

Tabla 4.30.: Razón ingreso/gasto en el dominio de personas jefas de hogar por sexo

Sexo	Razón	EE	LI 95 %	LS 95 %
Female	1.42	0.051	1.31	1.52
Male	1.59	0.072	1.45	1.74

El siguiente código computacional utiliza `svycontrast()` para comparar las razones ingreso/gasto de los hogares con jefatura femenina y masculina, incorporando el diseño muestral. La diferencia, su error estándar y su intervalo de confianza se presentan en la tabla 4.31.

```
contrast_sex_ratio <- svycontrast(
  stat = sex_ratio_contrast,
  contrasts = list(
    sex_difference = c(Female = 1, Male = -1)
  )
)
```

```
critical <- qt(0.975, df = degf(survey_design_heads))
sex_ratio_contrast_table <- tibble(
  contrast = names(coef(contrast_sex_ratio)),
  estimate = as.numeric(coef(contrast_sex_ratio)),
  standard_error = as.numeric(SE(contrast_sex_ratio)),
  lower = estimate - critical * standard_error,
  upper = estimate + critical * standard_error
```

```
)

sex_ratio_contrast_table
```

Tabla 4.31.: Contraste de la razón ingreso/gasto entre sexos

Contraste	Estimación	EE	LI 95 %	LS 95 %
sex_difference	-0.178	0.088	-0.352	-0.003

A partir de dichos resultados, puede concluirse que el contraste mujeres menos hombres es aproximadamente -0,178; la razón ingreso/gasto es mayor para los hombres en este dominio.

Finalmente, la comparación demográfica de la sección de estimación de razones puede formalizarse mediante la diferencia entre la zona rural y la urbana, cuyo estimador está dado por

$$\hat{\Delta}_{\text{TDR}} = \hat{R}_{\text{TDR,rural}} - \hat{R}_{\text{TDR,urbana}}$$

.

Y su varianza estimada es:

$$\widehat{Var}(\hat{\Delta}_{\text{TDR}}) = \widehat{Var}(\hat{R}_{\text{TDR,rural}}) + \widehat{Var}(\hat{R}_{\text{TDR,urbana}}) - 2\widehat{Cov}(\hat{R}_{\text{TDR,rural}}, \hat{R}_{\text{TDR,urbana}}).$$

La covarianza se obtiene estimando conjuntamente las razones con `svyby()`, `svyratio()` y `covmat = TRUE`. Esta covarianza entre dominios es distinta de la covarianza entre numerador y denominador incorporada al linealizar cada razón. `svycontrast()` combina las estimaciones y su matriz completa de varianzas y covarianzas. Los coeficientes se asignan por nombre para conservar la orientación rural menos urbana aunque cambie el orden de las filas. El siguiente código computacional estima la diferencia rural menos urbana de las razones de dependencia.

```
zone_dependency_joint <- svyby(
  ~dependency_units,
  ~Zone,
  design = dependency_design,
  denominator = ~reference_age,
  FUN = svyratio,
  covmat = TRUE
)
dependency_difference <- svycontrast(
  zone_dependency_joint,
  setNames(
    ifelse(zone_dependency_joint$Zone == "Rural", 1, -1),
    names(coef(zone_dependency_joint))
  )
)
dependency_ci <- confint(
```

```
  dependency_difference,
  level = 0.95,
  df = degf(dependency_design)
)
dependency_contrast_table <- tibble(
  contrast = "Rural - Urban",
  difference = as.numeric(coef(dependency_difference)),
  standard_error = as.numeric(SE(dependency_difference)),
  lower = as.numeric(dependency_ci[1, 1]),
  upper = as.numeric(dependency_ci[1, 2])
)

dependency_contrast_table
```

Tabla 4.32.: Diferencia rural menos urbana de las razones de dependencia demográfica

Contraste	Diferencia	EE	LI 95 %	LS 95 %
Rural - Urban	8.05	8.9	-9.57	25.7

La tabla 4.32 estima una diferencia de 8.05 personas por cada 100 personas de 15 a 64 años entre la zona rural y la urbana. El signo positivo indica una mayor razón rural y el negativo una mayor razón urbana. Su error estándar es 8.9; el intervalo de confianza del 95 % va de -9.57 a 25.68. `confint()` calcula el intervalo con 119 grados de libertad del diseño. Como el intervalo incluye el cero, al nivel del 5 % no se rechaza la igualdad de las razones. La comparación describe diferencias de estructura etaria entre zonas y no una diferencia directa en dependencia económica.

4.5. Visualización de variables continuas

La representación gráfica de variables continuas constituye un componente fundamental del análisis de encuestas de hogares. Los gráficos bien diseñados permiten examinar la forma de las distribuciones, identificar tendencias y explorar relaciones entre variables, lo que facilita tanto la interpretación de los resultados como su comunicación a distintos públicos. En este contexto, es importante que las representaciones gráficas incorporen, cuando corresponda, las características del diseño muestral (Lumley 2010). En particular, el uso de los factores de expansión permite que la distribución representada refleje adecuadamente a la población de interés, en lugar de limitarse a describir únicamente las observaciones incluidas en la muestra.

La gramática de gráficos se introdujo en la Sección 3.6. Aquí se aplica a distribuciones y relaciones numéricas. Los pesos permiten representar su composición estimada, pero no generan por sí solos intervalos de confianza ni incorporan toda la inferencia bajo el diseño. El paquete `patchwork` (Pedersen 2025) permite disponer varios gráficos en una misma composición. El siguiente código computacional carga los paquetes necesarios para construir y combinar las visualizaciones.

```
library(ggplot2)
library(patchwork)
```

4.5.1. Histogramas

Un histograma es una representación gráfica de la distribución de una variable numérica continua, construida a partir de rectángulos cuya altura es proporcional a la frecuencia de observaciones dentro de determinados intervalos. En el contexto de las encuestas de hogares, los histogramas ponderados permiten aproximar la distribución de la variable de interés en la población, incorporando los factores de expansión asociados al diseño muestral.

A continuación, se presenta el histograma ponderado de la variable `Income`, construido incorporando los pesos muestrales (`wk`) con el fin de representar la distribución estimada del ingreso en la población. Los resultados obtenidos se muestran en la figura 4.2:

```
weighted_income_hist <- ggplot(
  data = survey_data,
  aes(x = Income, weight = wk)
) +
  geom_histogram(
    aes(y = after_stat(density)),
    bins = 30
  ) +
  labs(x = "Ingreso mensual per cápita", y = "Densidad") +
  ggtitle("Histograma ponderado")

weighted_income_hist
```

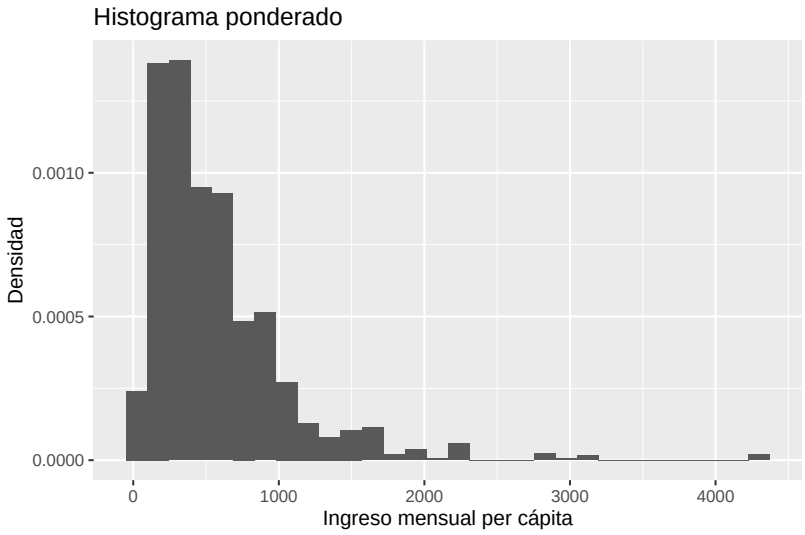


Figura 4.2.: Histograma ponderado del ingreso per cápita

En este código, se inicia la construcción del gráfico utilizando la base de datos `survey_data`. Dentro de `aes()`, el argumento `x = Income` indica que la variable representada en el eje horizontal corresponde al ingreso, mientras que `weight = wk` incorpora los pesos muestrales para construir un histograma ponderado que refleje la distribución estimada en la población. La función `geom_histogram()` genera el histograma y, mediante `aes(y = after_stat(density))`, la altura de las barras se expresa en términos de densidad en lugar de frecuencias absolutas. La opción `bins = 30` fija el número de intervalos. `labs()` identifica las unidades del eje horizontal y la densidad del eje vertical; el área de las barras, y no su altura aislada, representa proporciones. `ggtitle()` añade el título.

Para comparar la distribución del ingreso entre zonas urbanas y rurales, se presenta un histograma ponderado en paneles separados y con escalas comunes, como se muestra en la figura 4.3, obtenida con el siguiente código computacional.

```
zone_colors <- c(Urban = "#48C9B0", Rural = "#117864")

weighted_zone_hist <- ggplot(
  survey_data,
  aes(x = Income, weight = wk)
) +
  geom_histogram(
    aes(y = after_stat(density)),
    bins = 30,
    fill = "#48C9B0"
  ) +
  facet_wrap(
    ~ Zone,
    ncol = 1,
    labeller = labeller(Zone = c(Urban = "Urbana", Rural = "Rural"))
  ) +
  labs(
    x = "Ingreso mensual per cápita",
    y = "Densidad",
    title = "Distribución ponderada del ingreso por zona"
  )

weighted_zone_hist
```

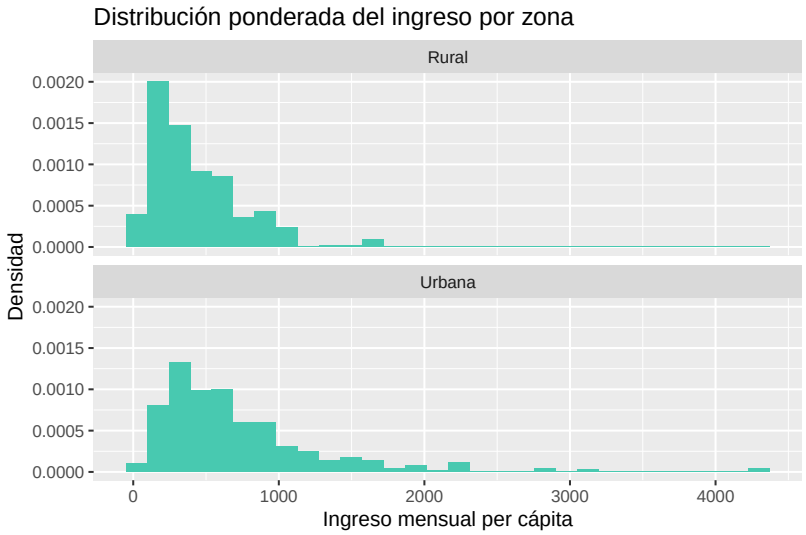


Figura 4.3.: Histograma ponderado del ingreso por zona geográfica

Cada panel muestra la distribución ponderada del ingreso per cápita para una zona. `facet_wrap(~ Zone, ncol = 1)` separa las zonas en filas y conserva escalas comunes, de modo que las alturas y los rangos del eje horizontal se puedan comparar directamente. Las etiquetas de los paneles se presentan en español. Se utilizan los mismos 30 intervalos en ambos paneles; el eje vertical muestra densidades, por lo que el área de las barras representa proporciones.

Además, es posible superponer curvas de densidad suavizadas mediante la función `geom_density()`, lo que permite representar de manera continua la forma de la distribución de la variable analizada. Este tipo de gráfico facilita la identificación de características como la asimetría, la concentración de los valores y la posible presencia de múltiples modas. En la figura 4.4, obtenida con el siguiente código computacional, se presentan los histogramas del ingreso y el gasto junto con sus respectivas curvas de densidad estimadas. Para disponer ambos gráficos uno al lado del otro, se utiliza el operador `|` del paquete `patchwork`, que permite combinar distintas visualizaciones en una misma composición gráfica.

```
weighted_expenditure_hist <- ggplot(
  survey_data,
  aes(x = Expenditure, weight = wk)
) +
  geom_histogram(
    aes(y = after_stat(density)),
    bins = 30
  ) +
  labs(x = "Gasto mensual per cápita", y = "Densidad")

(weighted_income_hist + geom_density(fill = "blue", alpha = 0.3)) |
  (weighted_expenditure_hist + geom_density(fill = "green", alpha = 0.3))
```

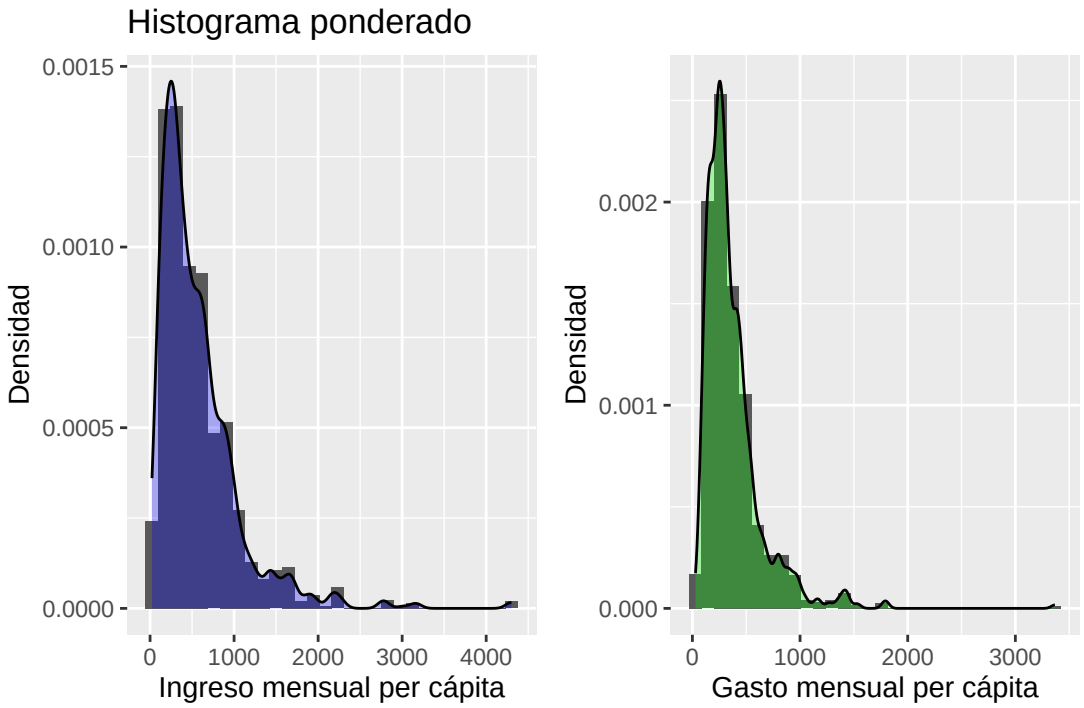


Figura 4.4.: Histogramas ponderados y densidades del ingreso y gasto per cápita

4.5.2. Diagramas de caja (*boxplots*)

Introducidos por Tukey (1977), los diagramas de caja (*boxplots*) permiten identificar valores atípicos y evaluar la dispersión de la distribución. Son una representación gráfica que resume una variable mediante estadísticas basadas en cuartiles, permitiendo identificar la mediana, la dispersión de los datos y la presencia de valores atípicos. En el contexto de encuestas de hogares, este tipo de gráfico resulta útil para comparar distribuciones entre distintos grupos poblacionales de manera compacta y visualmente intuitiva.

Los cuartiles y la mediana corresponden a los conceptos de la Sección 4.2.2. Las cajas resumen la dispersión y no son intervalos de confianza de la mediana. Para incorporar las ponderaciones y el diseño muestral, se utiliza `svyboxplot()` del paquete `survey`, que calcula y representa diagramas de caja directamente a partir del objeto de diseño. Como el ingreso y el gasto presentan asimetría y valores altos, se muestran en escala logarítmica: esta comprime la cola superior y facilita comparar los valores centrales entre zonas. En esta escala, las distancias representan cambios multiplicativos. La transformación requiere valores positivos, condición que cumplen ambas variables en esta base. Las fórmulas especifican la variable graficada a la izquierda de `~` y el grupo de comparación a la derecha. El argumento `design` especifica el diseño muestral, `horizontal = TRUE` dispone las cajas horizontalmente y `col` asigna un color a cada zona. `par(mfrow = c(1, 2))` organiza los dos gráficos en una fila, y `par(old_par)` restaura la configuración gráfica anterior. El siguiente código computacional genera la figura 4.5.

```
survey_design_log <- survey_design %>%
  mutate(
```

```
    log_Income = log(Income),
    log_Expenditure = log(Expenditure)
  )

old_par <- par(no.readonly = TRUE)
par(mfrow = c(1, 2))

svyboxplot(
  log_Income ~ Zone,
  design = survey_design_log,
  horizontal = TRUE,
  col = zone_colors,
  xlab = "Logaritmo del ingreso mensual per cápita",
  ylab = "Zona",
  main = "Ingreso por zona"
)

svyboxplot(
  log_Expenditure ~ Zone,
  design = survey_design_log,
  horizontal = TRUE,
  col = zone_colors,
  xlab = "Logaritmo del gasto mensual per cápita",
  ylab = "Zona",
  main = "Gasto por zona"
)

par(old_par)
```

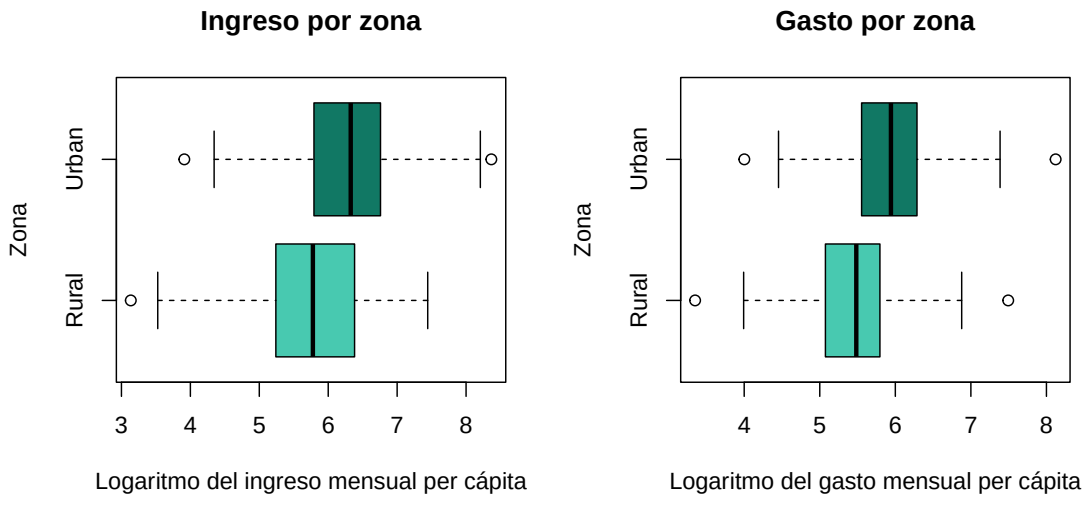


Figura 4.5.: Cuartiles ponderados del logaritmo del ingreso y el gasto per cápita por zona

La figura 4.5 compara las distribuciones del ingreso y el gasto per cápita en escala logarítmica entre las zonas urbana y rural. Los bigotes se extienden hasta los valores observados más extremos que quedan dentro de 1,5 rangos intercuartílicos; con el valor predeterminado de `all.outliers = FALSE`, solo se muestran como puntos los extremos más alejados. Las diferencias entre medianas y cajas se interpretan en escala logarítmica y reflejan cambios relativos, no diferencias absolutas en dólares.

4.5.3. Diagramas de dispersión

Los diagramas de dispersión permiten examinar la relación entre dos variables numéricas. En esta sección se compara el ingreso con el gasto mensual per cápita. Ambas variables presentan distribuciones asimétricas y valores altos, por lo que se representan en escala logarítmica: esta comprime los valores extremos y facilita apreciar la concentración y los patrones de asociación. Como las dos variables son positivas en esta base, es posible aplicar esta transformación; en esa escala, las distancias expresan cambios multiplicativos y no diferencias absolutas. En el primer gráfico, el tamaño de cada punto representa el peso muestral de la observación, lo que ayuda a explorar cuánta población representa. Esta codificación visual no sustituye el ajuste de un modelo ni incorpora por sí misma la incertidumbre del diseño. El siguiente código computacional construye la figura 4.6.

```
weighted_basic_scatter <- ggplot(
  data = survey_data,
  aes(y = Income, x = Expenditure)
) +
  geom_point(aes(size = wk), alpha = 0.3) +
  scale_x_log10() +
  scale_y_log10() +
  labs(
    x = "Gasto mensual per cápita (escala log10)",
    y = "Ingreso mensual per cápita (escala log10)"
  )

weighted_basic_scatter
```

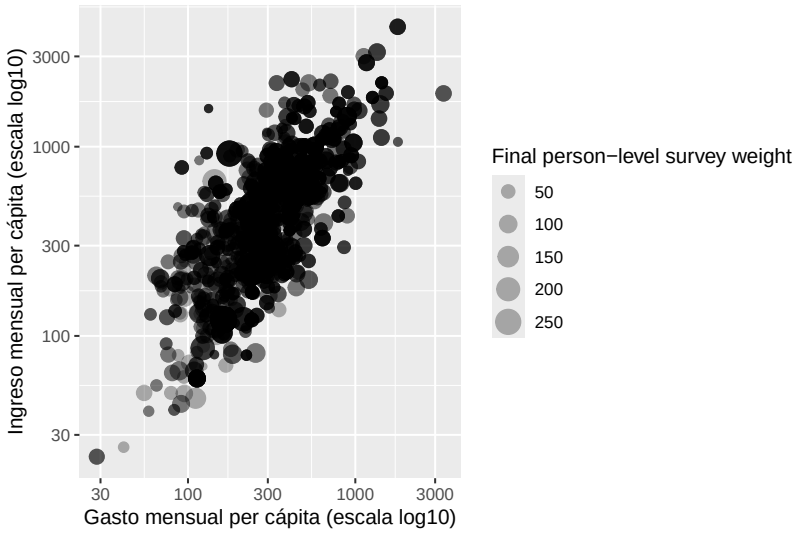


Figura 4.6.: Diagrama de dispersión entre ingreso y gasto per cápita

La transparencia, fijada en 0,3 para todas las observaciones, facilita la lectura de las zonas con mayor concentración de puntos.

Adicionalmente, es posible incorporar variables de agrupamiento en los diagramas de dispersión mediante los argumentos `shape` y `color`, los cuales permiten diferenciar visualmente las observaciones según categorías específicas de la población. Esto facilita la identificación de patrones diferenciados entre grupos y mejora la interpretación de la relación entre las variables analizadas. Un ejemplo de este tipo de representación se presenta en la figura 4.7, obtenida con el siguiente código computacional.

```
weighted_zone_scatter <- ggplot(
  data = survey_data,
  aes(y = Income, x = Expenditure, shape = Zone)
) +
  geom_point(aes(size = wk, color = Zone), alpha = 0.3) +
  labs(
    size = "Peso",
    x = "Gasto mensual per cápita (escala log10)",
    y = "Ingreso mensual per cápita (escala log10)"
  ) +
  scale_color_manual(values = zone_colors) +
  scale_x_log10() +
  scale_y_log10()

weighted_zone_scatter
```

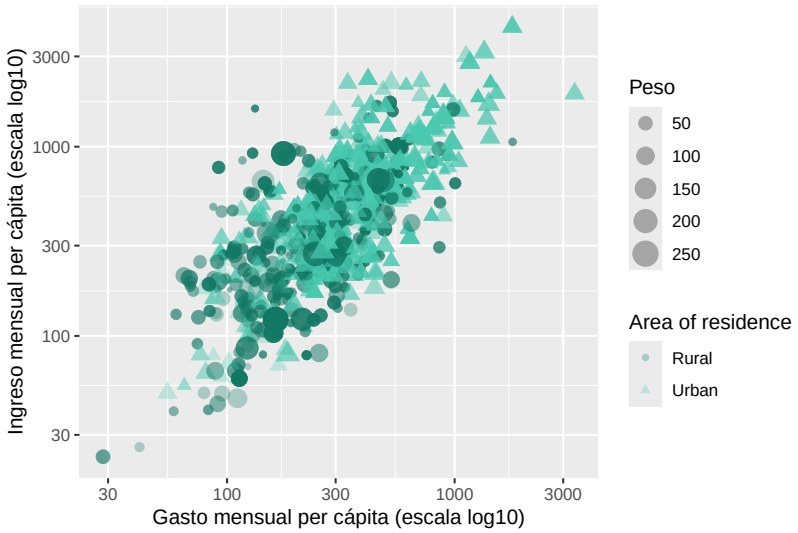


Figura 4.7.: Diagrama de dispersión entre ingreso y gasto por zona geográfica

La figura 4.7 mantiene las mismas escalas logarítmicas del gráfico anterior y diferencia las zonas por color y forma. Así se pueden comparar los patrones entre zonas sin que los valores altos compriman la mayor parte de los puntos. La escala logarítmica cambia la lectura de los ejes: por ejemplo, un mismo tramo visual corresponde a una razón constante entre valores, no a una diferencia fija en dólares.

Las distribuciones y la correlación permiten reconocer heterogeneidad y patrones de asociación. Junto con las herramientas para variables categóricas, preparan el estudio de modelos de regresión del capítulo siguiente, donde se analizarán varias variables simultáneamente incorporando el diseño muestral.

5. Modelos de regresión

Los modelos de regresión constituyen una de las herramientas más utilizadas en el análisis de datos provenientes de encuestas, ya que permiten estudiar la relación entre una variable de interés y un conjunto de variables explicativas (Chambers y Skinner 2003; Heeringa et al. 2017). A través de estos modelos, es posible evaluar cómo cambian determinadas características de la población según factores demográficos, sociales o económicos observados en la muestra. No obstante, la validez de los resultados obtenidos depende de una adecuada especificación del modelo y de la correcta consideración de las características del diseño muestral de la encuesta.

En términos generales, los modelos de regresión buscan describir y cuantificar la asociación entre una variable respuesta (dependiente) y una o más variables explicativas (independientes), proporcionando elementos para la interpretación estadística y la formulación de inferencias sobre la población de estudio.

Por ejemplo, es posible analizar el comportamiento del gasto per cápita de los hogares como variable de respuesta, en función del ingreso per cápita, la edad y el sexo del jefe de hogar, la zona y la región de residencia, consideradas variables explicativas. Utilizando información proveniente de encuestas de hogares, este tipo de modelos permite identificar patrones de asociación, cuantificar la asociación de distintos factores socioeconómicos con el gasto y generar evidencia empírica útil para el diseño, seguimiento y evaluación de políticas públicas.

Como explica Pfeffermann (2011), dado que las encuestas de hogares están sustentadas en diseños de muestreo complejos, los métodos clásicos de regresión, desarrollados bajo supuestos de muestreo aleatorio simple, pueden resultar inapropiados. Ignorar el diseño puede sesgar los coeficientes cuando la selección es informativa o el modelo está mal especificado y, aun cuando los coeficientes no cambien de manera apreciable, puede producir errores estándar y pruebas de hipótesis incorrectos.

En consecuencia, el análisis de datos provenientes de encuestas exige una atención detallada al diseño de muestreo. La incorporación de los pesos de la encuesta y los ajustes correspondientes a la estratificación y la conglomeración permite obtener inferencias válidas y precisas. Adicionalmente, en algunos casos se han propuesto alternativas simplificadas, como el uso de pesos normalizados o enfoques de ponderación aproximada, que buscan equilibrar la complejidad metodológica con la factibilidad práctica del análisis.

El estudio de la regresión bajo diseños de muestreo complejos cuenta con una trayectoria bien documentada. Como señalaron Kish y Frankel (1974), estos diseños afectan las inferencias derivadas de modelos de regresión. Posteriormente, Fuller (1975) desarrolló estimadores de varianza apoyados en técnicas de linealización para modelos de regresión lineal múltiple con ponderación desigual y métodos específicos para diseños estratificados y de dos etapas.

Más adelante, Shah et al. (1977) y Binder (1983) abordaron el problema de las violaciones a los supuestos clásicos al trabajar con datos de encuestas mediante alternativas de inferencia robusta para los parámetros. En paralelo, las distribuciones muestrales de los estimadores de regresión en

poblaciones finitas se incorporaron a procedimientos para estimar varianzas bajo esquemas complejos.

En los años siguientes, Skinner et al. (1989) y Fuller (2002) ampliaron estos aportes mediante estimadores de varianza para los coeficientes de regresión que incorporan la estratificación y la conglomeración, así como mediante compendios de métodos de estimación aplicables a modelos de regresión en encuestas complejas. La discusión reciente incluye, además, métodos de ponderación *q-weighted* y evidencia empírica sobre su utilidad.

5.1. Formulación del modelo

Los modelos de regresión bajo diseños de muestreo complejos permiten trascender las estadísticas descriptivas y estudiar asociaciones o realizar predicciones. Su correcta aplicación abre la posibilidad de examinar cómo las características sociodemográficas y económicas se asocian con distintos resultados de interés, aportando evidencia clave para la formulación de políticas públicas. Como explican Fox y Weisberg (2019), la formulación más básica corresponde al modelo de regresión lineal simple, el cual describe la relación entre una variable respuesta y una única variable explicativa mediante la siguiente expresión:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

En donde y representa la variable de respuesta (dependiente), x la variable explicativa (independiente), β_0 el intercepto del modelo, β_1 el coeficiente asociado a la variable independiente y ε el término de error, que recoge la variabilidad no explicada por el modelo y puede interpretarse como la diferencia entre el valor observado y el valor estimado por el modelo, denotado por $\hat{y}_k$.

En muchas aplicaciones empíricas, y especialmente en el análisis de encuestas de hogares, el fenómeno de interés depende simultáneamente de múltiples factores (Heeringa et al. 2017). En estos casos se emplean modelos de regresión lineal múltiple, los cuales incorporan varias variables explicativas:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon,$$

donde cada coeficiente β_j cuantifica la asociación entre la variable respuesta y la correspondiente covariable x_j, manteniendo constantes las demás variables incluidas en el modelo. De manera más compacta, el modelo puede expresarse utilizando notación matricial como:

$$y_k = \mathbf{x}_k \beta + \varepsilon_k, \quad k = 1, \dots, n, \tag{5.1}$$

donde $\mathbf{x}_k = [1, x_{1k}, \dots, x_{pk}]$ representa el vector de covariables asociado a la unidad k, mientras que $\beta = [\beta_0, \beta_1, \dots, \beta_p]'$ corresponde al vector de parámetros desconocidos. Los modelos de regresión lineal se sustentan en una serie de supuestos teóricos que garantizan la validez de las estimaciones y de las inferencias derivadas del modelo. En primer lugar, se asume que el valor esperado de los residuos condicionado a las covariables es igual a cero, es decir, $E(\varepsilon_k \mid \mathbf{x}_k) = 0$, lo que implica la ausencia de sesgos sistemáticos en la estimación de la variable respuesta. Asimismo, se supone homogeneidad de la varianza de los errores, de modo que la variabilidad residual permanece constante

para todos los valores de las covariables, esto es, $Var(\varepsilon_k \mid \mathbf{x}_k) = \sigma^2$. Adicionalmente, se considera que los errores siguen una distribución normal con media cero y varianza constante, expresada como $\varepsilon_k \mid \mathbf{x}_k \sim N(0, \sigma^2)$, y que los residuos asociados a distintas observaciones son independientes entre sí, de manera que $Cov(\varepsilon_k, \varepsilon_j \mid \mathbf{x}_k, \mathbf{x}_j) = 0$.

En este contexto, el valor esperado de la variable respuesta condicionado al conjunto de covariables puede expresarse como:

$$E(y \mid \mathbf{x}) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

Los supuestos anteriores corresponden al modelo lineal clásico con errores normales, independientes y de varianza constante. En el análisis de encuestas complejas, la estimación de la incertidumbre incorpora las características del diseño muestral, como se desarrolla a continuación. Por ello, conviene distinguir los supuestos sobre la relación media entre las variables de los utilizados para calcular los errores estándar (Chambers y Skinner 2003).

5.2. Uso de los pesos de muestreo

Cuando se trabaja con datos provenientes de encuestas basadas en diseños muestrales complejos, los supuestos clásicos de los modelos de regresión rara vez se cumplen de manera estricta, puesto que las observaciones no provienen de muestras aleatorias simples e independientes, sino de esquemas de selección que incorporan elementos como estratificación, conglomeración y probabilidades desiguales de selección. Por ejemplo, la presencia de conglomeración puede violar el supuesto de independencia de los errores, ya que individuos pertenecientes a un mismo hogar, segmento o área geográfica tienden a compartir características similares. Del mismo modo, las probabilidades desiguales de selección y los ajustes de ponderación pueden generar heterogeneidad en la varianza de las observaciones, incumpliendo el supuesto de homocedasticidad.

En este contexto, surge una pregunta fundamental: ¿de qué manera deben incorporarse los pesos muestrales en los modelos de regresión? La respuesta no es sencilla, ya que los pesos de la encuesta reflejan no solo las probabilidades de selección, sino también diversos ajustes asociados a la no respuesta, calibración y correcciones de cobertura. Aunque su utilización permite producir estimaciones representativas de la población, la incorporación directa de ponderaciones en los modelos también puede reducir la eficiencia estadística e incrementar la variabilidad de los estimadores.

En términos generales, Pfeffermann (2011) distingue dos enfoques principales para abordar este problema. El primero corresponde al enfoque basado en el diseño muestral, cuyo objetivo es obtener inferencias válidas para la población objetivo respetando las características del proceso de selección de la muestra. De acuerdo con Heeringa et al. (2017), desde esta perspectiva, los pesos muestrales son esenciales para corregir las probabilidades desiguales de inclusión y producir estimaciones insesgadas de los coeficientes de regresión. Sin embargo, este enfoque no protege frente a posibles errores de especificación del modelo; es decir, aun cuando las estimaciones sean válidas desde el punto de vista del diseño, el modelo puede no representar adecuadamente las relaciones existentes en la población.

El segundo corresponde al enfoque orientado al modelo, según el cual los pesos no son necesariamente requeridos siempre que el modelo esté correctamente especificado y el mecanismo de muestreo sea no informativo. Bajo este supuesto, las relaciones entre las variables observadas en la muestra

coinciden con las de la población, de manera que el diseño muestral no introduce sesgos relevantes en la estimación de los parámetros. Desde esta perspectiva, incorporar ponderaciones podría incluso resultar contraproducente, al aumentar innecesariamente la varianza de los estimadores y, en consecuencia, los errores estándar.

Según Skinner et al. (1989), la discusión sobre la conveniencia de utilizar ponderaciones en modelos de regresión ha sido ampliamente desarrollada en la literatura especializada. En la práctica, una recomendación metodológica frecuente consiste en estimar los modelos tanto con ponderaciones como sin ellas y comparar posteriormente los resultados obtenidos (Naciones Unidas 2026). Si la inclusión de los pesos produce cambios importantes en los coeficientes estimados o modifica las conclusiones sustantivas del análisis, ello sugiere que el diseño de muestreo es informativo o que el modelo presenta problemas de especificación, por lo que el uso de ponderaciones resulta aconsejable. La comparación entre ajustes ponderados y no ponderados constituye un diagnóstico, pero la estabilidad de los coeficientes no basta para justificar la omisión de los pesos. Esa decisión requiere considerar el objetivo inferencial, la especificación del modelo y el mecanismo de selección de la muestra. Asimismo, debe distinguirse la decisión de ponderar los coeficientes del tratamiento de la estratificación y la conglomeración al estimar su incertidumbre.

En términos aplicados, esta decisión suele depender del propósito analítico del estudio. Cuando el objetivo es realizar inferencia descriptiva y producir estimaciones representativas de la población, la utilización de ponderaciones es indispensable. En cambio, en contextos de inferencia analítica orientados al estudio de asociaciones, relaciones causales o contrastes de hipótesis, pueden emplearse tanto modelos ponderados como no ponderados, especialmente cuando el modelo incorpora variables relacionadas con el diseño muestral, como estratos o conglomerados. No obstante, el uso de modelos no ponderados debe justificarse cuidadosamente, dado que implica asumir condiciones más restrictivas sobre el mecanismo de selección de la muestra y la correcta especificación del modelo estadístico.

En resumen, cuando se opta por ponderar, las ponderaciones corrigen posibles sesgos de sobre o subrepresentación de determinados grupos y contribuyen a obtener estimaciones de varianza más exactas. Dentro del enfoque basado en el diseño, esto permite que los resultados se aproximen a valores insesgados comparables a los que se obtendrían en un censo completo, incluso cuando el modelo no esté formulado de manera óptima. Sin embargo, cuando los pesos presentan gran dispersión, pueden aumentar la varianza de los parámetros estimados y volver inestables las estimaciones, razón por la que en contextos explicativos o analíticos los modelos sin ponderar pueden, en ocasiones, arrojar resultados más consistentes y eficientes.

La selección adecuada de las variables explicativas y la consideración del mecanismo de selección de la muestra son fundamentales para el análisis. Además de estas decisiones, algunas implementaciones utilizan versiones reescaladas de los pesos originales. A continuación, se presentan dos formas habituales de reescalamiento, que modifican la suma de los pesos, pero no corrigen una especificación incorrecta del modelo ni reducen la dispersión relativa de las ponderaciones:

1. Pesos tipo Senado: este procedimiento ajusta los pesos de manera que su suma coincida con el tamaño de la muestra, en lugar del tamaño de la población. Esta transformación multiplica todos los pesos por una constante y conserva su dispersión relativa; por tanto, no constituye un recorte de pesos extremos. Las nuevas ponderaciones son $w_k^{Senate} = w_k \times \frac{n}{\sum w_k}$.
2. Pesos normalizados: en este enfoque los pesos originales se reescalan para que su suma sea igual a uno. Al ser también una multiplicación por una constante común, el reescalamiento

no reduce por sí mismo la variabilidad relativa de los pesos ni sustituye la especificación del diseño; su efecto sobre las varianzas depende del método y del software utilizados. Las nuevas ponderaciones son $w_k^{Normalized} = \frac{w_k}{\sum w_k}$.

Es importante destacar que, en ambos métodos, los pesos ajustados se obtienen mediante transformaciones multiplicativas directas de los pesos muestrales originales. Por ello, no deben emplearse para calcular tamaños o totales poblacionales. Asimismo, estos procedimientos no alteran las estimaciones de razones, como medias o proporciones, ya que en tales casos los pesos se cancelan en el cociente. En la práctica, el uso de estos ajustes puede considerarse una solución pragmática en contextos donde no se dispone de software especializado para encuestas. No obstante, cuando se cuenta con herramientas como los paquetes `survey` y `srvyr` en `R`, descritos en los capítulos anteriores, el reescalamiento deja de ser necesario, pues dichos paquetes realizan el tratamiento adecuado para preservar tanto la representatividad como las propiedades inferenciales del modelo.

5.3. Estimación de los parámetros del modelo

De acuerdo con Molina y Skinner (1992) y Binder (2011), en términos del ajuste de modelos de regresión con encuestas de hogares, se han desarrollado metodologías inferenciales avanzadas que integran las fuentes de incertidumbre en un mismo marco analítico, buscando reflejar tanto la estructura del diseño como los supuestos y limitaciones del modelo. Entre las aproximaciones más relevantes se encuentran la pseudo-verosimilitud y la inferencia combinada.

El método de pseudo-verosimilitud extiende las técnicas tradicionales de máxima verosimilitud para ajustarlas a las particularidades de los diseños muestrales complejos. En este enfoque, la distribución de muestreo definida por el diseño ocupa un rol central, mientras que la distribución del modelo pasa a un segundo plano. Si bien en contextos de modelos bien especificados los estimadores basados en pseudo-verosimilitud tienden a ser insesgados o consistentes, su principal virtud radica en evitar los sesgos que se originarían al ignorar el diseño muestral. En términos prácticos, este método traduce el modelo tradicional en uno que respeta la forma en que los datos fueron obtenidos, garantizando inferencias más sólidas.

En contraste, la inferencia combinada propone un marco unificado en el que se integran simultáneamente la variabilidad del muestreo y la incertidumbre del modelo. Considerar ambas fuentes permite caracterizar de manera más completa la variabilidad total, aunque sus propiedades dependen del diseño y de la especificación del modelo. Un desarrollo teórico más detallado de este enfoque, acompañado de simulaciones computacionales, se presenta en el segundo anexo.

Además, tal como explica Wolter (2007), cuando se desea estimar los parámetros de un modelo de regresión lineal a partir de una muestra con un diseño complejo, el enfoque estándar cambia. En consecuencia, los estimadores tradicionales, como los obtenidos por máxima verosimilitud o mínimos cuadrados, pueden resultar sesgados y producir errores estándar poco confiables. Frente a esta situación, los métodos de estimación de varianza, como la linealización de Taylor y el bootstrap, son válidos en la medida en que su implementación reproduzca las características pertinentes del diseño.

Según Fuller (2002) y Chambers y Skinner (2003), en el caso de un modelo de regresión lineal simple, la estimación de β_1 bajo un esquema de muestreo complejo se realiza, mediante un estimador ponderado, que puede expresarse de la siguiente forma:

$$\hat{\beta}_1 = \frac{\sum_h \sum_i \sum_k w_{hik}\,(y_{hik} - \hat{\bar{y}})(x_{hik} - \hat{\bar{x}})}{\sum_h \sum_i \sum_k w_{hik}\,(x_{hik} - \hat{\bar{x}})^2} = \frac{\hat{t}_{xy}}{\hat{t}_{xx}} \tag{5.2}$$

En donde $\hat{\bar{y}} = \hat{t}_y/\hat{N}$ y $\hat{\bar{x}} = \hat{t}_x/\hat{N}$ corresponden a las medias estimadas de las variables de estudio y auxiliar, respectivamente, mientras que w_{hik} representa los pesos de muestreo asociados a cada unidad de observación. Esta formulación incorpora explícitamente dichos pesos, lo que permite considerar las probabilidades desiguales de selección y las características propias del diseño muestral. Asimismo, la varianza estimada de $\hat{\beta}_1$ puede aproximarse como:

$$\widehat{Var}\left(\hat{\beta}_1\right) \approx \frac{\widehat{Var}(\hat{t}_{xy}) + \hat{\beta}_1^2 \widehat{Var}(\hat{t}_{xx}) - 2\hat{\beta}_1 \widehat{Cov}(\hat{t}_{xy}, \hat{t}_{xx})}{(\hat{t}_{xx})^2} \tag{5.3}$$

Si $\hat{\beta}_1$ corresponde al estimador de la pendiente en un modelo de regresión lineal simple ponderado, entonces el estimador del intercepto $\hat{\beta}_0$ está dado por

$$\hat{\beta}_0 = \hat{\bar{y}} - \hat{\beta}_1 \hat{\bar{x}}$$

Nótese que la varianza de $\hat{\beta}_0$ depende simultáneamente de los estimadores $\hat{\bar{y}}$, $\hat{\bar{x}}$ y $\hat{\beta}_1$. Por esta razón, su aproximación puede obtenerse mediante las propiedades de la varianza de combinaciones lineales de estimadores, en conjunto con técnicas de linearización de Taylor. A partir de este procedimiento se deriva la matriz de varianzas y covarianzas de los coeficientes del modelo, de la cual se obtienen tanto los errores estándar como las covarianzas asociadas a las estimaciones de los parámetros.

De acuerdo con Kish y Frankel (1974), en el caso de la regresión múltiple, si $\hat{\beta}$ representa el estimador de β, entonces la varianza de cada coeficiente se estima considerando su interdependencia con los demás parámetros, lo que se refleja en la construcción de una matriz de varianzas-covarianzas que recoge tanto la variabilidad individual como las covarianzas entre todos los estimadores. Este cálculo requiere utilizar totales ponderados de cuadrados y productos cruzados de todas las combinaciones entre la variable dependiente y y el conjunto de predictores $\mathbf{x} = (1, x_1, \ldots, x_p)$. En términos generales:

$$\widehat{Var}(\hat{\beta}) = \hat{\Sigma} = \begin{bmatrix} \widehat{Var}(\hat{\beta}_0) & \widehat{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \cdots & \widehat{Cov}(\hat{\beta}_0, \hat{\beta}_p) \\ \widehat{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \widehat{Var}(\hat{\beta}_1) & \cdots & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_p) \\ \vdots & \vdots & \ddots & \vdots \\ \widehat{Cov}(\hat{\beta}_0, \hat{\beta}_p) & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_p) & \cdots & \widehat{Var}(\hat{\beta}_p) \end{bmatrix}$$

En este capítulo se mostrará cómo implementar estos modelos en `R` mediante las librerías `survey` y `srvyr`, junto con `tidyverse` para organizar el flujo de trabajo. Se abordará la especificación del diseño muestral, la estimación de modelos lineales, así como la obtención de errores estándar y pruebas de hipótesis ajustadas al diseño, integrando los fundamentos teóricos con ejemplos prácticos reproducibles. Para ejemplificar los conceptos desarrollados hasta este punto, se empleará la misma base de datos utilizada a lo largo del libro. El siguiente código computacional carga los paquetes y los datos, prepara las variables categóricas y define el diseño de muestreo que se utilizará en los modelos del capítulo.

```r
library(survey)
library(srvyr)
library(tidyverse)

data(BigCity, package = "TeachingSampling")
survey_data <- readRDS("../data/sample.rds") %>%
  mutate(
    Stratum = factor(Stratum),
    Sex = factor(Sex, levels = c("Male", "Female")),
    Zone = factor(Zone, levels = c("Rural", "Urban"))
  )

survey_design <- survey_data %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  ) %>%
  filter(PersonID == "idPer01", Income > 0, Expenditure > 0)

survey_data <- survey_design$variables
```

La base `sample.rds` conserva los nombres de las variables y utiliza etiquetas y categorías en inglés. En `Region`, las categorías `North`, `South`, `Central`, `West` y `East` corresponden a Norte, Sur, Centro, Occidente y Oriente; `CatAge` contiene grupos decenales ordenados: `0-9`, `10-19`, `20-29`, y así sucesivamente hasta `90-99`.

En este capítulo se trabaja con una observación por hogar, identificada mediante `PersonID == "idPer01"`, y se utiliza el factor de expansión `wk` del jefe, siguiendo la convención descrita en la sección 3.1. La muestra de análisis contiene 696 hogares con ingreso y gasto positivos, condición necesaria para calcular sus logaritmos naturales. La edad y el sexo corresponden al jefe del hogar; las categorías de referencia son hombre, zona rural y región Norte.

Con el objetivo de ajustar un modelo de regresión entre los logaritmos del ingreso y del gasto per cápita, resulta conveniente explorar previamente la relación existente entre ambas variables. Para ello, se construye un diagrama de dispersión mediante `ggplot2`, el cual permite evaluar visualmente la forma y la intensidad de la asociación. El resultado se presenta en la figura 5.1, obtenida con el siguiente código computacional.

```r
unweighted_plot <- ggplot(
  data = survey_data,
  aes(x = log(Income), y = log(Expenditure))
) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Logaritmo del ingreso per cápita",
```

```
    y = "Logaritmo del gasto per cápita"
  )

unweighted_plot
```

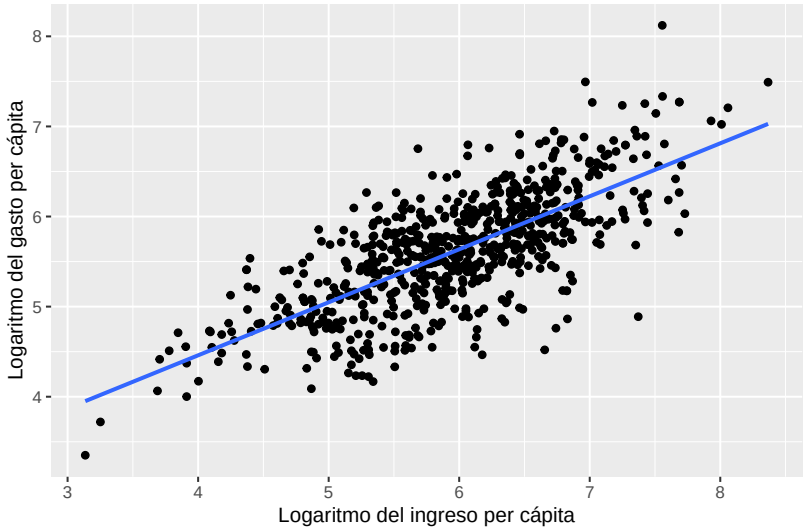


Figura 5.1.: Diagrama de dispersión entre los logaritmos del ingreso y del gasto per cápita de los hogares (sin ponderar)

Los datos muestrales conservan una relación positiva y aproximadamente lineal entre los logaritmos del ingreso y del gasto per cápita, aunque se observa dispersión alrededor de la recta ajustada. Una vez completada la exploración gráfica de los datos, se procede al ajuste de los modelos de regresión lineal.

El siguiente código computacional ajusta un modelo lineal mediante `svyglm()` del paquete `survey`, incorporando los factores de expansión y las demás características del diseño muestral. En este caso, la expresión `log(Expenditure) ~ log(Income) + Age + Sex + Zone + Region` especifica que el logaritmo del gasto per cápita se modela en función del logaritmo del ingreso per cápita, la edad y el sexo del jefe de hogar, la zona y la región de residencia; es decir, se ajusta una regresión lineal múltiple en escala logarítmica, cuyo coeficiente del ingreso representa la elasticidad del gasto respecto al ingreso, manteniendo constantes las demás variables. El argumento `design = survey_design` indica que el modelo debe utilizar el objeto de diseño muestral previamente definido, mientras que `family = stats::gaussian()` especifica que se ajusta un modelo lineal con distribución normal, equivalente a una regresión lineal clásica.

```
fit_svy <- svyglm(
  log(Expenditure) ~ log(Income) + Age + Sex + Zone + Region,
  design = survey_design,
  family = stats::gaussian()
)

fit_svy
```

```
Stratified 1 - level Cluster Sampling design (with replacement)
With (238) clusters.
Called via srvyr
Sampling variables:
  - ids: PSU
  - strata: Stratum
  - weights: wk

Call:  svyglm(formula = log(Expenditure) ~ log(Income) + Age + Sex +
    Zone + Region, design = survey_design, family = stats::gaussian())

Coefficients:
  (Intercept)    log(Income)            Age      SexFemale      ZoneUrban
      2.38093        0.53684       -0.00189        0.00287        0.14988
  RegionSouth  RegionCentral     RegionWest     RegionEast
      0.05829        0.21195        0.00762        0.00544

Degrees of Freedom: 695 Total (i.e. Null);  111 Residual
Null Deviance:      293
Residual Deviance: 128  AIC: NA
```

La salida anterior corresponde al ajuste de un modelo de regresión lineal en el que el logaritmo de `Expenditure` se explica a partir del logaritmo de `Income` y de las variables `Age`, `Sex`, `Zone` y `Region`. Como explica Wooldridge (2020), la interpretación de los coeficientes depende de cuáles variables se expresan en logaritmos. En este modelo, tanto el gasto como el ingreso per cápita están en logaritmos, por lo que el coeficiente de `log(Income)` representa directamente una elasticidad: un ingreso 1 % mayor se asocia con un gasto aproximadamente $\hat{\beta}_1$ % mayor, manteniendo constantes las demás variables. En cambio, para la edad, incorporada en su escala original, un año adicional se asocia con una variación porcentual de $100[\exp(\hat{\beta}_{\text{Age}}) - 1]$. Para las variables categóricas, esa misma transformación expresa la diferencia porcentual respecto de la categoría de referencia. La exponencial convierte el coeficiente en una razón entre niveles de gasto ajustados; restar uno y multiplicar por cien permite expresar cuánto aumenta o disminuye el gasto respecto del nivel de comparación.

Por lo tanto, los resultados indican la existencia de una relación positiva entre ingreso y gasto, de modo que, manteniendo constantes las demás variables, un ingreso per cápita 1 % mayor se asocia con un gasto per cápita aproximadamente 0.537 % mayor. Asimismo, se evidencian diferencias asociadas a las características sociodemográficas incluidas en el modelo: residir en zona urbana se asocia con un gasto per cápita aproximadamente 16.17 % mayor que en zona rural, mientras que pertenecer a un hogar con jefatura femenina se asocia con un gasto 0.29 % mayor que con jefatura masculina. Cada año adicional de edad del jefe se asocia con un gasto aproximadamente 0.19 % menor. Respecto de la región Norte, las diferencias estimadas son 6.00 % para Sur, 23.61 % para Centro, 0.76 % para Occidente y 0.55 % para Oriente. Estas diferencias se obtienen mediante $100[\exp(\hat{\beta}_j) - 1]$ y describen asociaciones en la escala multiplicativa, sin establecer efectos causales. El intercepto estimado, igual a 2.381, representa el valor esperado del logaritmo del gasto para la categoría de referencia del modelo cuando el ingreso per cápita es igual a uno y la edad es cero; este perfil queda fuera del rango observado de edad de los jefes, por lo que su interpretación es principalmente algebraica.

5.4. Diagnóstico del modelo

De acuerdo con Fox y Weisberg (2019), en el análisis de encuestas de hogares, la evaluación de un modelo estadístico constituye un aspecto importante que contribuye a valorar la validez de las inferencias. Un modelo adecuadamente especificado no depende únicamente de la selección de las covariables, sino también del examen de los supuestos que sustentan la consistencia y confiabilidad de los resultados.

En el caso de los modelos de regresión lineal aplicados a encuestas complejas, resulta necesario examinar distintos aspectos relacionados con la calidad del ajuste y el comportamiento de los errores. Como se indicó anteriormente, entre ellos se encuentran la capacidad explicativa del modelo, la normalidad y homogeneidad de la varianza de los residuos, la independencia entre errores y la posible presencia de observaciones influyentes o valores atípicos que puedan afectar las estimaciones (Li y Valliant 2015).

Estas verificaciones adquieren particular importancia en el contexto de diseños muestrales complejos, donde características como la estratificación, la conglomeración y el uso de factores de expansión pueden intensificar problemas asociados con la heterocedasticidad, la dependencia entre observaciones o la sensibilidad a valores extremos. Por esta razón, el diagnóstico del modelo no debe limitarse a los supuestos clásicos de la regresión, sino incorporar también las particularidades derivadas del diseño de la encuesta. La aplicación sistemática de estos procedimientos permite evaluar la solidez del modelo, fortalecer la confianza en las inferencias y asegurar que los resultados obtenidos sean representativos y útiles tanto para la investigación social aplicada como para el análisis de políticas públicas.

5.4.1. Coeficiente de determinación

Una de las medidas más utilizadas para evaluar el ajuste de un modelo de regresión es el coeficiente de determinación, denotado por R^2. Este indicador cuantifica la proporción de la variabilidad de la variable dependiente que es explicada por el modelo (Fox y Weisberg 2019). Sus valores oscilan entre cero y uno: cuanto más cercano se encuentre a la unidad, mayor será la capacidad explicativa del modelo; en contraste, valores próximos a cero indican un bajo nivel de explicación de la variabilidad observada. La magnitud del R^2 no debe evaluarse en términos absolutos, sino considerando el fenómeno estudiado y el tipo de información disponible.

El coeficiente se calcula a partir de las sumas de cuadrados totales y de error, como $R^2 = 1 - \frac{SSE}{SST}$; en donde SST representa la suma de cuadrados totales y SSE la suma de cuadrados del error. Según Heeringa et al. (2017), en encuestas con diseños de muestreo complejos, esta medida debe ajustarse para incorporar la estructura del diseño y los pesos muestrales. El estimador ponderado del coeficiente de determinación se define como:

$$\hat{R}^2 = 1 - \frac{\widehat{SSE}}{\widehat{SST}}$$

donde $\widehat{SSE} = \sum_h \sum_i \sum_k w_{hik} \, (y_{hik} - x_{hik}\hat{\beta})^2$ es la suma ponderada de errores al cuadrado; mientras que $\widehat{SST} = \sum_h \sum_i \sum_k w_{hik} \, (y_{hik} - \hat{\bar{y}})^2$ representa la suma total ponderada de cuadrados.

De acuerdo con Pfeffermann (2011), dado que el R^2 tiende a incrementarse conforme se incorporan más variables al modelo, conviene complementar su interpretación con el coeficiente de determinación ajustado (R^2_{adj}), el cual introduce una penalización en función del número de covariables incluidas y del tamaño muestral. Este coeficiente se define como $\hat{R}^2_{adj} = 1 - \frac{(n-1)}{(n-p)}(1 - \hat{R}^2)$, donde n corresponde al número de observaciones, p representa el número de parámetros estimados y $\hat{R}^2$ denota el coeficiente de determinación ponderado definido previamente.

De esta manera, el ajuste permite evaluar la capacidad explicativa del modelo controlando el efecto derivado de la incorporación de nuevas variables. Este ajuste facilita una comparación más equitativa entre modelos con distinto número de predictores y resulta particularmente útil en el análisis de encuestas, donde la complejidad del diseño y el uso de ponderaciones pueden influir notablemente en la magnitud del R^2.

El siguiente código computacional obtiene los componentes necesarios para calcular el coeficiente de determinación R^2. Para estimar la suma total ponderada de cuadrados ($\widehat{SST}$), ajusta primero un modelo nulo que incluye únicamente el intercepto.

```
null_model <- svyglm(log(Expenditure) ~ 1, design = survey_design)

s1 <- summary(fit_svy)
s0 <- summary(null_model)

wsst <- s0$dispersion[1]
wsse <- s1$dispersion[1]
```

La estimación del coeficiente de determinación y su contraparte ajustada se obtiene a partir del siguiente cálculo:

```
n <- nrow(survey_design)
p <- length(coef(fit_svy))
r2 <- 1 - wsse / wsst
r2_adj <- 1 - ((n - 1) / (n - p)) * (1 - r2)

r2
```

```
[1] 0.5645
```

```
r2_adj
```

```
[1] 0.5594
```

Los resultados muestran un R^2 de 0,5645 y un R^2 ajustado de 0,5594. Estos coeficientes resumen la proporción de variabilidad del logaritmo del gasto per cápita explicada por el conjunto de covariables; no corresponden a la variabilidad del gasto en su escala original.

5.4.2. Residuales

En el diagnóstico de modelos, el análisis de los residuales es una de las herramientas más relevantes (Fox y Weisberg 2019). Si el modelo está correctamente especificado, los residuales actúan como una aproximación de los errores no observados y permiten evaluar, de forma indirecta, si los supuestos del modelo se cumplen razonablemente en los datos. Su revisión sistemática permite identificar posibles desviaciones en la especificación, lo que ayuda a determinar si el ajuste es adecuado o si, por el contrario, es necesario reconsiderar la forma funcional del modelo o el método de estimación utilizado.

Según Heeringa et al. (2017), en encuestas con diseños de muestreo complejos, los residuales de Pearson constituyen una herramienta habitual para evaluar las discrepancias entre los valores observados y los valores esperados bajo el modelo ajustado. Estos se definen como:

$$r_k = \frac{y_k - \hat{\mu}_k}{\sqrt{\widehat{Var}(\hat{\mu}_k)/w_k}},$$

donde $\hat{\mu}_k = \mathbf{x}_k^\top \hat{\beta}$ representa la estimación del valor esperado de y_k bajo el modelo ajustado, w_k corresponde al peso muestral asociado a la unidad k, y $\widehat{Var}(\hat{\mu}_k)$ denota la varianza estimada bajo la familia del modelo.

Los residuales de Pearson también se utilizan para evaluar aspectos clave del ajuste del modelo, en particular la normalidad y la homogeneidad de la varianza de los errores. De forma complementaria, el gráfico de residuos frente a valores ajustados constituye una herramienta diagnóstica especialmente informativa, ya que su inspección visual permite detectar posibles patrones sistemáticos que sugieran incumplimientos de los supuestos de independencia o heterocedasticidad.

La normalidad de los errores puede examinarse como diagnóstico, aunque no es un requisito estricto para la estimación de los coeficientes y su importancia inferencial depende del método de varianza y del tamaño de la muestra. Para ello, una herramienta estándar es el gráfico cuantil-cuantil (QQ-plot), el cual compara los cuantiles de los residuos observados con los cuantiles teóricos de una distribución normal con la misma media y varianza. Una alineación aproximada de los puntos sobre la recta de 45° indica que el supuesto de normalidad resulta razonable dentro del contexto del modelo.

De acuerdo con Valliant (2024), a continuación, estos diagnósticos se aplican a los modelos previamente ajustados. Para ello, se utiliza el paquete `svydiags`, una extensión del paquete `survey` para el diagnóstico de modelos estimados bajo diseños muestrales complejos. Este paquete permite obtener los residuales estandarizados de manera directa, facilitando la evaluación de los supuestos del modelo en este tipo de contextos:

```
library(svydiags)

stdresids <- as.numeric(svystdres(fit_svy)$stdresids)
survey_design$variables <-
  survey_design$variables %>%
  mutate(stdresids = stdresids)
```

El análisis de normalidad puede complementarse con el histograma de los residuales estandarizados, presentado en la figura 5.2, obtenida con el siguiente código computacional. El histograma sugiere una desviación respecto a la curva normal teórica (en rojo), pero la inspección gráfica por sí sola no constituye una prueba formal ni demuestra que el modelo sea inválido. La distribución de los residuos (representada en azul) permite examinar la concentración central y las colas respecto de la curva normal. Las posibles discrepancias deben valorarse junto con los demás diagnósticos, teniendo presente que el modelo ya utiliza una transformación logarítmica de la variable dependiente.

```
ggplot(
  data = survey_design$variables,
  aes(x = stdresids)
) +
  geom_histogram(
    aes(y = ..density..),
    colour = "black",
    fill = "blue",
    alpha = 0.3
  ) +
  geom_density(size = 1, colour = "blue") +
  geom_function(
    fun = dnorm,
    colour = "red",
    size = 1
  ) +
  labs(y = "")
```

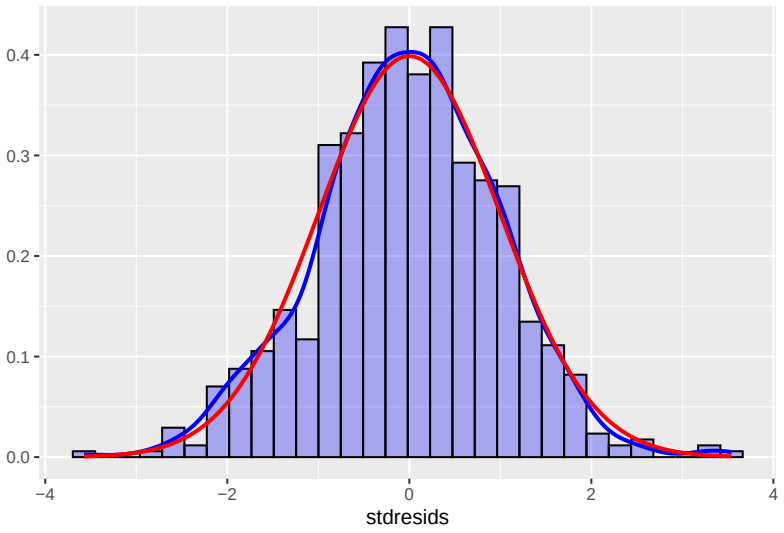


Figura 5.2.: Histograma de residuales estandarizados con curva de densidad estimada y distribución normal teórica

Según Chambers y Skinner (2003), la homocedasticidad de los errores (varianza constante) constituye uno de los supuestos centrales en los modelos de regresión. Su incumplimiento afecta la eficiencia

de los estimadores y las varianzas basadas exclusivamente en el modelo; las varianzas robustas ajustadas al diseño ofrecen protección adicional, aunque no corrigen una especificación incorrecta de la media. Dado que los residuos representan las discrepancias entre los valores observados y los valores ajustados por el modelo, su análisis en función de los valores predichos o de las covariables constituye una herramienta diagnóstica fundamental. Bajo un modelo adecuadamente especificado, se espera que los residuos se distribuyan de forma aleatoria alrededor de cero, sin patrones estructurados; en cambio, la aparición de formas sistemáticas (como estructuras en embudo o curvaturas) sugiere la presencia de heterocedasticidad (varianza no constante) o posibles relaciones funcionales no captadas por la especificación del modelo.

Para evaluar este supuesto, se analizan gráficamente los residuos en función de los valores estimados $\hat{\mu}_k$ o de covariables específicas del modelo. La aparición de patrones sistemáticos en estos gráficos constituye evidencia de heterocedasticidad o de posibles problemas de especificación funcional. El siguiente código computacional construye gráficos de residuos frente a las covariables del modelo y los combina con `patchwork` en la figura 5.3.

```
library(patchwork)

g1 <- ggplot(
  data = survey_design$variables,
  aes(x = log(Income), y = stdresids)
) +
  geom_point() +
  geom_hline(yintercept = 0)

g2 <- ggplot(
  data = survey_design$variables,
  aes(x = Zone, y = stdresids)
) +
  geom_point() +
  geom_hline(yintercept = 0)

g3 <- ggplot(
  data = survey_design$variables,
  aes(x = Sex, y = stdresids)
) +
  geom_point() +
  geom_hline(yintercept = 0)

g4 <- ggplot(
  data = survey_design$variables,
  aes(x = Age, y = stdresids)
) +
  geom_point() +
  geom_hline(yintercept = 0)

g5 <- ggplot(
  data = survey_design$variables,
```

```
  aes(x = Region, y = stdresids)
) +
  geom_point() +
  geom_hline(yintercept = 0)

(g1 | g4) / (g2 | g3) / g5
```

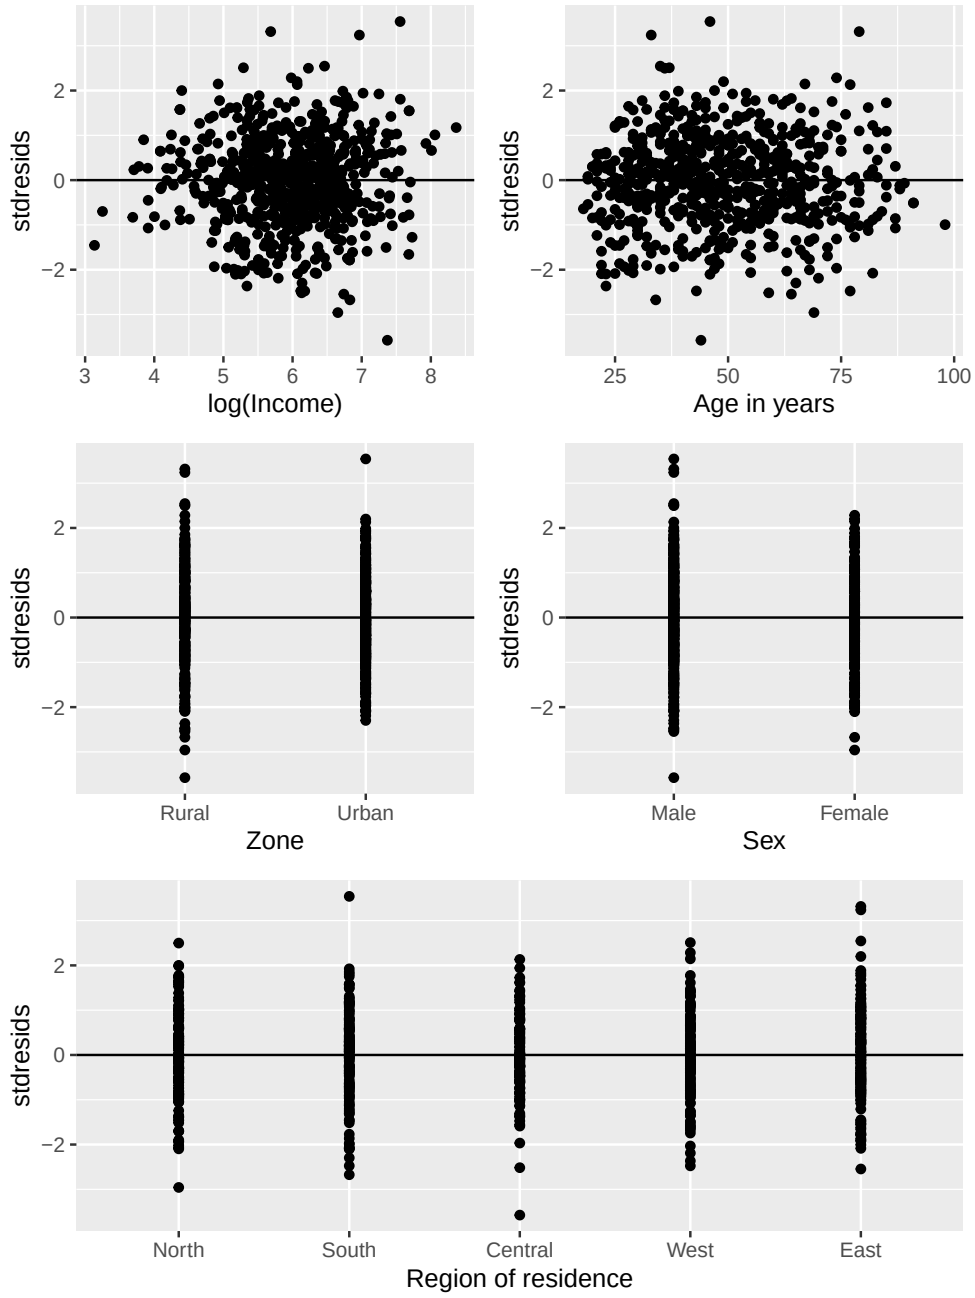


Figura 5.3.: Gráficos de residuales estandarizados frente a cada covariable del modelo

La figura 5.3 presenta los gráficos de dispersión de los residuos estandarizados frente a las covariables del modelo. En conjunto, estos resultados permiten examinar posibles limitaciones en la especificación funcional. En particular, los gráficos frente a `log(Income)` y `Age` permiten buscar curvaturas o cambios en la dispersión que no estén captados por el modelo. Por su parte, en los gráficos asociados a `Zone`, `Sex` y `Region` se compara la dispersión de los residuos entre categorías, lo que contribuye a evaluar diferencias en la variabilidad condicional o en el ajuste de la media entre grupos.

5.4.3. Observaciones influyentes

En el análisis diagnóstico, la identificación de observaciones influyentes es una técnica de especial importancia. Estas son unidades muestrales cuyo impacto sobre el ajuste del modelo resulta desproporcionado respecto al resto de la muestra. Conviene subrayar que una observación influyente no necesariamente corresponde a un valor atípico: mientras un atípico puede estar alejado del patrón general de los datos sin afectar sustancialmente el ajuste, una observación influyente puede alterar de manera significativa las estimaciones de los parámetros, incluso si no luce inusual.

Según Heeringa et al. (2017, 213), la distancia de Cook mide el impacto que tendría la eliminación de la observación k sobre el ajuste global del modelo, al combinar simultáneamente la magnitud del residuo, la varianza estimada del modelo y su apalancamiento (*leverage*). En el contexto de encuestas con diseños muestrales complejos, la distancia de Cook suele denotarse como c_k y su expresión incorpora explícitamente los pesos muestrales. Para evaluar la magnitud de este estadístico, se utiliza una aproximación basada en su comparación con una distribución F, mediante la expresión:

$$\frac{(df - p + 1)\, c_k}{df} \sim F_{(p,\, df-p)},$$

Donde p denota los parámetros del modelo y df representa los grados de libertad asociados al diseño muestral. En la práctica, una observación puede considerarse influyente si su distancia de Cook supera valores de referencia aproximados entre 2 y 3. El siguiente código computacional genera la figura 5.4.

```
cook_values <- svyCooksD(fit_svy, doplot = TRUE)
```

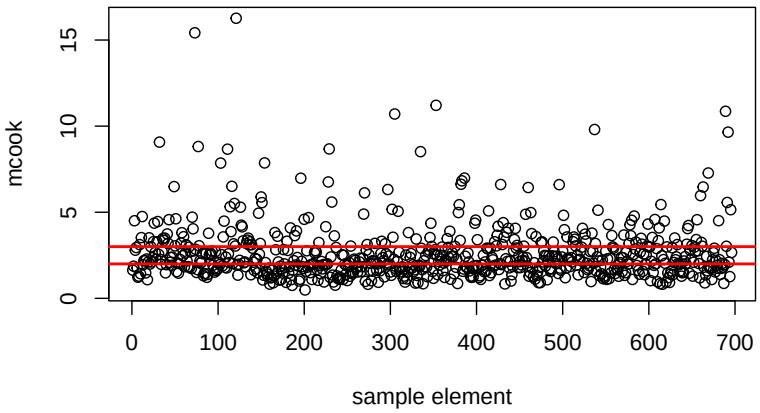


Figura 5.4.: Distancia de Cook para cada observación de la muestra

En `R`, se evalúa la presencia de observaciones influyentes mediante la distancia de Cook, estimada con la función `svyCooksD` del paquete `svydiags`. Los resultados obtenidos se presentan en la figura 5.4, en donde se observa que 177 de los 696 hogares superan el umbral de referencia de 3 y la distancia máxima es 16,27. Bajo este criterio diagnóstico, estas observaciones requieren una revisión más detallada de su influencia sobre el ajuste, sin que ello implique eliminarlas automáticamente.

Otro estadístico que mide el grado de influencia de una observación es el DFBETAS, denotado como $D_f\text{Beta}_{(k)j}$, que mide el cambio que experimenta el coeficiente de regresión $\hat{\beta}_j$ cuando la observación k es eliminada del proceso de estimación. En consecuencia, esta medida evalúa la influencia individual de cada observación sobre los parámetros del modelo, identificando aquellas unidades cuya presencia altera de manera importante las estimaciones obtenidas. Valores elevados de $D_f\text{Beta}_{(k)j}$ indican que la observación ejerce una influencia considerable sobre el coeficiente correspondiente, lo que puede afectar la estabilidad e interpretación del modelo.

Como criterio práctico de diagnóstico, Li y Valliant (2015) señalan que una observación suele considerarse influyente sobre el coeficiente $\hat{\beta}_j$ cuando

$$\left|D_f\text{Beta}_{(k)j}\right| \geq \frac{z}{\sqrt{n_I \times DEFF}},$$

Donde z toma comúnmente valores de 2 o 3, n_I representa el número de UPMs seleccionadas en la muestra de la primera etapa y $DEFF$ corresponde al efecto de diseño asociado a la variable respuesta. A continuación, se evalúa la influencia de las observaciones sobre los coeficientes del modelo de ejemplo mediante la función `svydfbetas`. Los resultados de las primeras diez observaciones se presentan en la tabla 5.1, junto con el identificador del hogar (`HHID`). Las columnas Beta 0 a Beta 8 siguen el orden de los coeficientes del modelo: intercepto, logaritmo del ingreso, edad, sexo femenino, zona urbana y regiones Sur, Centro, Occidente y Oriente.

```
d_dfbetas <- data.frame(t(svydfbetas(fit_svy)$Dfbetas))
colnames(d_dfbetas) <- paste0("Beta_", 0:(length(coef(fit_svy)) - 1))
dfbetas_first_ten_table <- d_dfbetas %>%
  slice(1:10L) %>%
  mutate(HHID = survey_data$HHID[1:10], .before = 1)

dfbetas_first_ten_table
```

Tabla 5.1.: Valores DfBetas para las primeras diez observaciones de la muestra, con identificador del hogar

ID del hogar	Beta 0	Beta 1	Beta 2	Beta 3	Beta 4	Beta 5	Beta 6	Beta 7	Beta 8
idHH00031	-0.0009	0.0044	0.0267	-0.0114	-0.0147	-0.0255	-0.0251	-0.0300	-0.0253
idHH00041	-0.0055	0.0068	0.0037	0.0069	-0.0057	-0.0064	-0.0071	-0.0081	-0.0073
idHH20680	-0.0307	0.0244	-0.0149	0.0161	0.0083	0.0266	0.0238	0.0309	0.0231
idHH00064	-0.0227	0.0229	-0.0559	0.0240	0.0145	0.0355	0.0337	0.0434	0.0320
idHH20700	0.0043	0.0007	-0.0038	-0.0030	-0.0051	-0.0102	-0.0094	-0.0111	-0.0100
idHH20705	-0.0053	0.0067	0.0042	-0.0013	-0.0046	-0.0059	-0.0061	-0.0067	-0.0065
idHH20845	-0.0020	0.0008	0.0013	0.0014	-0.0025	0.0036	0.0037	0.0037	0.0033
idHH20854	0.0162	-0.0114	0.0008	-0.0099	0.0147	-0.0198	-0.0203	-0.0210	-0.0175
idHH20858	-0.0017	-0.0050	0.0054	0.0060	-0.0114	0.0202	0.0216	0.0208	0.0197
idHH20859	0.0188	-0.0202	-0.0180	-0.0237	-0.0098	0.0282	0.0342	0.0335	0.0303

A partir de los valores DFBETA de cada observación y coeficiente del modelo, el siguiente código computacional calcula el correspondiente umbral de influencia a partir de los resultados generados por la función `svydfbetas`. Con base en este criterio, se construye una variable dicotómica que permite clasificar las observaciones según su nivel de influencia sobre las estimaciones del modelo. Los resultados de esta clasificación se presentan en la tabla 5.2.

```
d_dfbetas$id <- 1:nrow(d_dfbetas)
d_dfbetas <- reshape2::melt(d_dfbetas, id.vars = "id")
cutoff <- svydfbetas(fit_svy)$cutoff
d_dfbetas <- d_dfbetas %>%
  mutate(
    criterion = ifelse(abs(value) > cutoff, "Yes", "No" )
  )

label_text <- d_dfbetas %>%
  filter(criterion == "Yes") %>%
  arrange(desc(abs(value))) %>%
  slice(1:10L)

influential_dfbetas_table <- label_text %>%
  mutate(HHID = survey_data$HHID[id]) %>%
  dplyr::select(-id) %>%
```

```
  relocate(HHID)

influential_dfbetas_table
```

Tabla 5.2.: Las diez observaciones más influyentes según el criterio DfBetas, con identificador del hogar

ID del hogar	Parámetro	Valor	Criterio
idHH20102	Beta_3	-0.4100	Yes
idHH18379	Beta_8	-0.3663	Yes
idHH39024	Beta_8	-0.3663	Yes
idHH20102	Beta_2	0.3482	Yes
idHH20102	Beta_8	-0.3244	Yes
idHH02136	Beta_0	0.2910	Yes
idHH20102	Beta_4	0.2684	Yes
idHH35243	Beta_7	0.2684	Yes
idHH18379	Beta_4	0.2682	Yes
idHH39024	Beta_4	0.2682	Yes

Los resultados muestran que 106 combinaciones de observación y coeficiente superan el umbral establecido por el criterio DFBETAS, lo que indica que dichas unidades ejercen una influencia importante sobre la estimación de algunos coeficientes del modelo, sugiriendo la presencia de unidades con alto impacto sobre la estabilidad del ajuste. La figura 5.5, obtenida con el siguiente código computacional, muestra la representación gráfica de los valores de D_fBeta junto con el umbral de referencia utilizado para identificar observaciones influyentes. En la figura, los puntos resaltados en rojo corresponden a las observaciones que exceden dicho umbral y que, por tanto, requieren una revisión más detallada dentro del proceso de diagnóstico del modelo.

```
ggplot(d_dfbetas, aes(y = abs(value), x = id)) +
  geom_point(aes(col = criterion)) +
  geom_text(
    data = label_text,
    angle = 45,
    vjust = -1,
    aes(label = id)
  ) +
  geom_hline(aes(yintercept = cutoff)) +
  facet_wrap(. ~ variable, nrow = 3) +
  scale_color_manual(
    values = c("Yes" = "red", "No" = "black")
  )
```

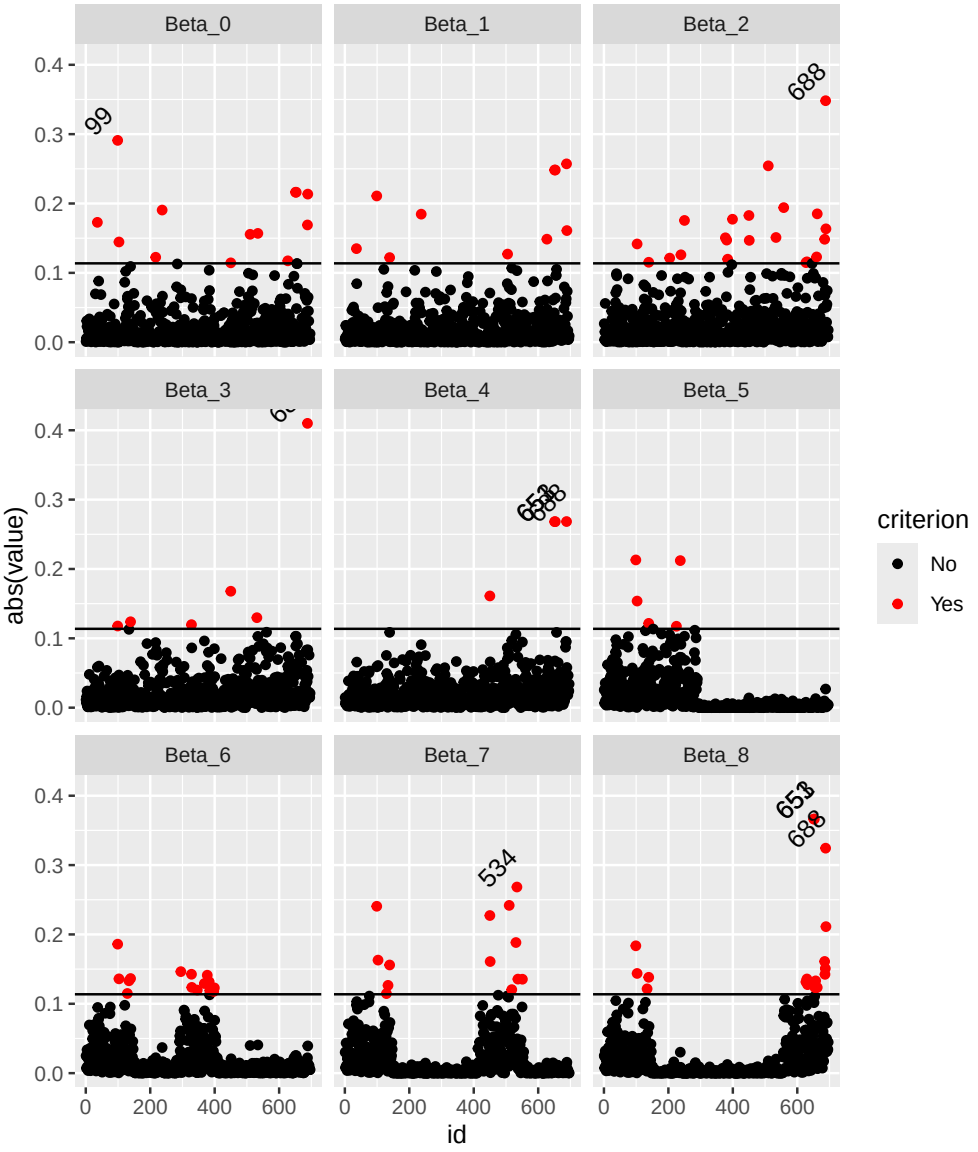


Figura 5.5.: Valores DfBetas por parámetro: observaciones influyentes señaladas en rojo

Por último, el estadístico DFFITS, denotado por $D_f\text{Fits}_{(k)}$, mide la influencia que ejerce la observación k sobre los valores ajustados del modelo. En particular, este estadístico evalúa cuánto cambian las predicciones del modelo cuando una observación es eliminada del proceso de estimación. En consecuencia, valores elevados de $D_f\text{Fits}_{(k)}$ indican observaciones con capacidad de alterar de manera importante el ajuste global del modelo y, por tanto, potencialmente influyentes en el proceso de inferencia. Una observación se considera influyente si:

$$|D_f\text{Fits}_{(k)}| \geq z\sqrt{\frac{p}{n \times DEFF}}$$

Donde z toma comúnmente valores de 2 o 3, mientras que n representa el tamaño muestral total de elementos incluidos en la encuesta y $DEFF$ es el efecto de diseño asociado a la variable respuesta.

En R, el cálculo de este estadístico puede realizarse mediante la función **svydffits** del paquete **svydiags**, la cual obtiene las medidas de influencia considerando explícitamente la estructura del diseño muestral. El siguiente código computacional genera la figura 5.6.

```
d_dffits <- data.frame(
  dffits = svydffits(fit_svy)$Dffits,
  id = 1:length(svydffits(fit_svy)$Dffits)
)
cutoff <- svydffits(fit_svy)$cutoff
d_dffits <- d_dffits %>%
  mutate(
    cutoff_criterion = ifelse(abs(dffits) > cutoff, "Yes", "No")
  )

ggplot(d_dffits, aes(y = abs(dffits), x = id)) +
  geom_point(aes(col = cutoff_criterion)) +
  geom_hline(yintercept = cutoff) +
  scale_color_manual(
    values = c("Yes" = "red", "No" = "black")
  )
```

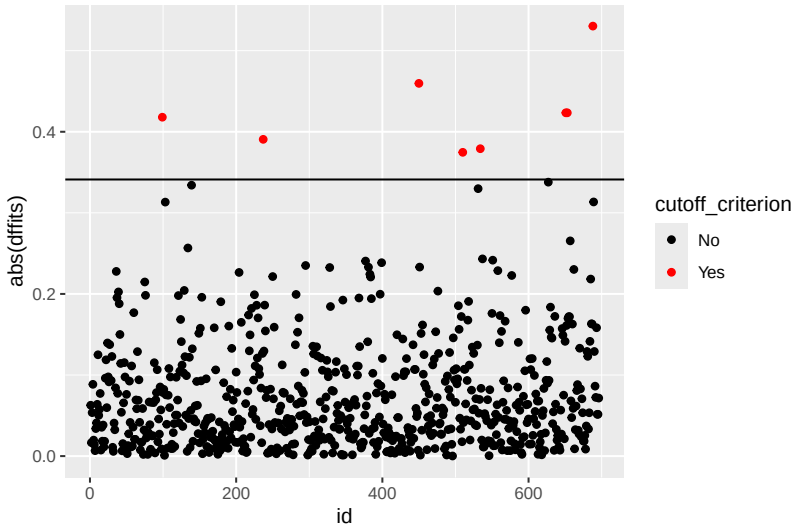


Figura 5.6.: Valores DfFits: observaciones influyentes sobre el ajuste global señaladas en rojo

Los resultados gráficos correspondientes se presentan en la figura 5.6, en donde se identifican 8 observaciones que superan el umbral de influencia (señaladas en rojo).

5.5. Inferencia sobre los parámetros del modelo

Una vez evaluado el ajuste del modelo y examinados los supuestos asociados a los errores, el siguiente paso consiste en determinar la significación estadística de los parámetros estimados. Este análisis

permite establecer si las covariables incluidas en el modelo aportan información relevante para explicar la variabilidad de la variable respuesta. De acuerdo con Chambers y Skinner (2003) y Heeringa et al. (2017), en modelos ajustados con datos provenientes de encuestas complejas, las pruebas de hipótesis sobre los coeficientes de regresión se construyen utilizando estimadores de varianza consistentes con el diseño muestral. Para evaluar el efecto de una covariable asociada al parámetro β_j, se considera usualmente el contraste

$$H_0 : \beta_j = 0 \qquad \text{frente a} \qquad H_1 : \beta_j \neq 0.$$

El estadístico de prueba correspondiente se define como

$$t_j = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\widehat{Var}(\hat{\beta}_j)}} \tag{5.4}$$

el cual, bajo la hipótesis nula sigue aproximadamente una distribución t de Student con df grados de libertad asociados al diseño muestral (usualmente definidos como el número de unidades primarias de muestreo menos el número de estratos). La decisión inferencial se basa en comparar el valor absoluto del estadístico t_j con el valor crítico de la distribución de referencia. Cuando el valor observado del estadístico resulta suficientemente grande en magnitud, se rechaza la hipótesis nula y se concluye que la covariable correspondiente presenta una asociación estadísticamente significativa con la variable respuesta. Por tanto, el valor-p cuantifica qué tan compatible es el resultado observado con la hipótesis nula $H_0 : \beta_j = 0$. En una prueba bilateral, corresponde a la probabilidad, suponiendo verdadera dicha hipótesis, de obtener un estadístico de prueba tan extremo o más extremo que el observado, en cualquiera de las dos direcciones. A partir del estadístico t_j de la expresión (5.4), se calcula como:

$$\text{valor-}p = 2\ \Pr\big(T \geq |t_j|\big)\,.$$

En donde T sigue una distribución t de Student con df grados de libertad bajo H_0. Un valor-p pequeño indica mayor incompatibilidad con la hipótesis nula; si es menor que α, se rechaza H_0 al nivel de significación α. Las mismas propiedades distribucionales permiten construir intervalos de confianza para los coeficientes de regresión. Así, un intervalo de confianza al nivel $(1-\alpha)\times 100\,\%$ para el parámetro β_j está dado por

$$\hat{\beta}_j \pm t_{1-\frac{\alpha}{2},\,df}\sqrt{\widehat{Var}(\hat{\beta}_j)}, \tag{5.5}$$

donde $t_{1-\frac{\alpha}{2},\,df}$ representa el cuantil de orden $1-\alpha/2$ de la distribución t de Student con df grados de libertad.

Para implementar estos procedimientos en `R`, se utilizan las funciones `summary.svyglm` y `confint.svyglm`, las cuales permiten obtener, respectivamente, las pruebas de significación basadas en el estadístico t y los intervalos de confianza de los coeficientes estimados bajo el diseño muestral complejo. Los resultados correspondientes se presentan en la tabla 5.3. El siguiente código computacional extrae las estimaciones y los resultados de las pruebas de los coeficientes del modelo.

```r
summary_table <- summary(fit_svy)$coefficients %>%
  as.data.frame() %>%
  tibble::rownames_to_column("Parameter")

confidence_table <- confint(fit_svy) %>%
  as.data.frame() %>%
  tibble::rownames_to_column("Parameter")

summary_table <- dplyr::left_join(
  summary_table,
  confidence_table,
  by = "Parameter"
)

summary_table
```

Tabla 5.3.: Pruebas t e intervalos de confianza al 95 % para los parámetros del modelo

Parámetro	Estimación	EE	Estadístico	Valor p	LI 95 %	LS 95 %
(Intercept)	2.3809	0.1938	12.2875	0.0000	1.9970	2.7649
log(Income)	0.5368	0.0326	16.4452	0.0000	0.4722	0.6015
Age	-0.0019	0.0010	-1.8023	0.0742	-0.0040	0.0002
SexFemale	0.0029	0.0456	0.0629	0.9500	-0.0875	0.0933
ZoneUrban	0.1499	0.0439	3.4168	0.0009	0.0630	0.2368
RegionSouth	0.0583	0.0601	0.9700	0.3341	-0.0608	0.1774
RegionCentral	0.2120	0.0588	3.6028	0.0005	0.0954	0.3285
RegionWest	0.0076	0.0537	0.1417	0.8876	-0.0989	0.1141
RegionEast	0.0054	0.0617	0.0883	0.9298	-0.1167	0.1276

Los resultados del modelo indican que el logaritmo de `Income` presenta una asociación estadísticamente significativa con la variable de interés, el logaritmo de `Expenditure`. Esta asociación resulta altamente significativa desde el punto de vista estadístico (valor-p: <0.001), lo que proporciona evidencia de una relación positiva entre ambas variables. La elasticidad estimada es 0,537, con un intervalo de confianza del 95 % entre 0,472 y 0,602. Por su parte, `ZoneUrban` y `RegionCentral` también presentan asociaciones estadísticamente significativas (valores-p: <0.001 y <0.001, respectivamente). La edad presenta un valor-p de 0.0742 y `SexFemale`, de 0.95; para las regiones Sur, Occidente y Oriente los valores-p son 0.334, 0.888 y 0.93, respectivamente, por lo que la evidencia no resulta concluyente al nivel convencional del 5 %.

5.6. Estimación y predicción

Según Heeringa et al. (2017), los modelos de regresión cumplen dos objetivos fundamentales: el primero consiste en explicar la variabilidad de la variable respuesta a partir de las covariables disponibles, propósito que ha sido desarrollado a lo largo de este capítulo; el segundo corresponde

a la predicción del valor esperado de la variable de interés para nuevas observaciones, tanto dentro como fuera del dominio muestral. La siguiente expresión representa el valor esperado de la variable respuesta y_k condicionada al vector de covariables observadas $\mathbf{x}_k$.

$$\hat{\mu}_k = \hat{E}(y_k \mid \mathbf{x}_k) = \mathbf{x}_k \hat{\beta} \tag{5.6}$$

En otras palabras, el modelo utiliza la información disponible de las variables explicativas para estimar el valor promedio esperado de la variable de interés para la unidad k. Asimismo, la varianza asociada a la estimación del valor esperado, definida como $Var(\hat{\mu}_k) = Var(\mathbf{x}_k\hat{\beta})$, puede estimarse mediante la siguiente expresión:

$$\widehat{Var}(\hat{\mu}_k) = \mathbf{x}_k' \, \hat{\Sigma} \, \mathbf{x}_k \tag{5.7}$$

En donde $\hat{\Sigma} = \widehat{Var}(\hat{\beta})$ corresponde a la matriz de varianzas y covarianzas estimada de los parámetros del modelo de regresión. Esta expresión cuantifica únicamente la incertidumbre del valor medio estimado debida a los coeficientes. Como explican Fox y Weisberg (2019), un intervalo de predicción para una nueva respuesta debe incorporar además la variabilidad residual. En consecuencia, aquellas unidades cuyos valores de las covariables estén asociados a regiones con mayor incertidumbre en la estimación de los coeficientes presentarán varianzas más elevadas. Por tanto, la precisión de las estimaciones depende directamente de la precisión con la que se estimen los coeficientes del modelo. Las estimaciones, los errores estándar y las pruebas de los coeficientes del modelo se presentan en la tabla 5.3.

Con base en esas estimaciones, el valor esperado de la variable respuesta para el hogar k puede expresarse como:

$$\begin{aligned}\widehat{E}[\log(Expenditure_k) \mid \mathbf{x}_k] = {} & 2.38093 + 0.53684 \log(Income_k) - 0.00189 Age_k \\ & + 0.00287 I(Sex_k = \text{Female}) + 0.14988 I(Zone_k = \text{Urban}) \\ & + 0.05829 I(Region_k = \text{South}) + 0.21195 I(Region_k = \text{Central}) \\ & + 0.00762 I(Region_k = \text{West}) + 0.00544 I(Region_k = \text{East}).\end{aligned}$$

En la expresión anterior, $I(\cdot)$ representa una variable indicadora y el subíndice k identifica al hogar. La variable respuesta y_k corresponde ahora al logaritmo del gasto per cápita. Las predicciones y sus intervalos se expresan en esa escala; exponenciarlos no produce automáticamente la media aritmética del gasto en su escala original. El siguiente código calcula las predicciones del modelo de regresión para las diez primeras observaciones incluidas en la muestra, utilizando la matriz de diseño y el vector de coeficientes estimados:

```
x_obs <- model.matrix(fit_svy) %>%
  data.frame() %>%
  as.matrix()

hat_beta <- coef(fit_svy)
hat_mu <- as.numeric(x_obs %*% hat_beta)
hat_mu %>%
  head(10)
```

```
 [1] 5.482 5.873 4.690 4.862 5.434 6.209 5.580 5.281 5.961 6.061
```

En primer lugar, la instrucción `model.matrix(fit_svy)` construye la matriz de diseño asociada al modelo ajustado, incorporando automáticamente las variables explicativas. A continuación, `coef(fit_svy)` extrae explícitamente el vector de coeficientes estimados; posteriormente, se obtienen las estimaciones mediante el producto matricial `x_obs %*% hat_beta`. Finalmente, la función `head(10)` permite visualizar las primeras diez estimaciones obtenidas.

Para calcular la varianza de las estimaciones se requiere la matriz de varianzas y covarianzas de los parámetros del modelo. Los elementos de la diagonal principal corresponden a las varianzas de los parámetros estimados, mientras que los elementos fuera de la diagonal representan las covarianzas entre pares de coeficientes. El siguiente código computacional extrae esta matriz y la organiza con las etiquetas Beta 0 a Beta 8, siguiendo el orden de los coeficientes descrito anteriormente, para presentarla en la tabla 5.4.

```
regression_covariance_table <- vcov(fit_svy) %>%
  as.data.frame() %>%
  tibble::rownames_to_column("Parameter") %>%
  mutate(
    Parameter = paste("Beta", 0:(length(coef(fit_svy)) - 1))
  )

regression_covariance_table
```

Tabla 5.4.: Matriz de varianzas y covarianzas de los coeficientes del modelo

Parámetro	Beta 0	Beta 1	Beta 2	Beta 3	Beta 4	Beta 5	Beta 6	Beta 7	Beta 8
Beta 0	0.0375	-0.0059	0	-0.0029	0.0033	-0.0035	-0.0022	-0.0020	-0.0061
Beta 1	-0.0059	0.0011	0	0.0004	-0.0008	0.0003	0.0002	0.0002	0.0010
Beta 2	0.0000	0.0000	0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
Beta 3	-0.0029	0.0004	0	0.0021	-0.0001	0.0004	0.0002	0.0000	-0.0001
Beta 4	0.0033	-0.0008	0	-0.0001	0.0019	0.0000	-0.0004	-0.0004	-0.0009
Beta 5	-0.0035	0.0003	0	0.0004	0.0000	0.0036	0.0013	0.0014	0.0014
Beta 6	-0.0022	0.0002	0	0.0002	-0.0004	0.0013	0.0035	0.0015	0.0016
Beta 7	-0.0020	0.0002	0	0.0000	-0.0004	0.0014	0.0015	0.0029	0.0016
Beta 8	-0.0061	0.0010	0	-0.0001	-0.0009	0.0014	0.0016	0.0016	0.0038

En términos computacionales, esto implica combinar el vector de covariables de cada observación con la matriz $\hat{\Sigma}$ para obtener la precisión de las predicciones individuales. El siguiente código calcula la varianza asociada a las predicciones obtenidas a partir del modelo de regresión:

```
cov_beta <- vcov(fit_svy) %>%
  as.matrix()

mu_variance <- diag(x_obs %*% cov_beta %*% t(x_obs))
mu_variance %>%
  head(10)
```

```
       1        2        3        4        5        6        7        8
0.002309 0.003809 0.004191 0.004368 0.002215 0.004216 0.002498 0.003708
       9       10
0.001967 0.003291
```

El intervalo de confianza, que proporciona un rango de valores plausibles para el valor esperado de la variable respuesta condicionado a las covariables observadas, se obtiene mediante:

$$\mathbf{x}_k\hat{\beta} \pm t_{(1-\frac{\alpha}{2},df)}\sqrt{\mathbf{x}_k' \, \hat{\Sigma} \, \mathbf{x}_k}$$

El siguiente código computacional utiliza `predict(fit_svy, type = "link")` para estimar el valor medio en la escala del predictor lineal, es decir, mediante la combinación lineal de las covariables y los coeficientes del modelo (Lumley et al. 2026). Después obtiene los intervalos de confianza con `confint()`.

```
hat_mu <- data.frame(predict(fit_svy, type = "link"))
mu_ci <- data.frame(confint(predict(fit_svy, type = "link")))
colnames(mu_ci) <- c("lower_limit", "upper_limit")
```

Las estimaciones obtenidas a partir del modelo, junto con sus respectivos intervalos de confianza, pueden visualizarse gráficamente en la figura 5.7, obtenida con el siguiente código computacional.

```
pred <- cbind(hat_mu, mu_ci)
pred$log_income <- log(survey_data$Income)
pd <- position_dodge(width = 0.2)
ggplot(
  pred %>% slice(1:100L),
  aes(x = log_income, y = link)
) +
  geom_errorbar(
    aes(ymin = lower_limit, ymax = upper_limit),
    width = .1,
    linetype = 1
  ) +
  geom_point(size = 2, position = pd) +
  labs(
    x = "Logaritmo del ingreso per cápita",
    y = "Logaritmo del gasto per cápita estimado"
  ) +
  theme_bw()
```

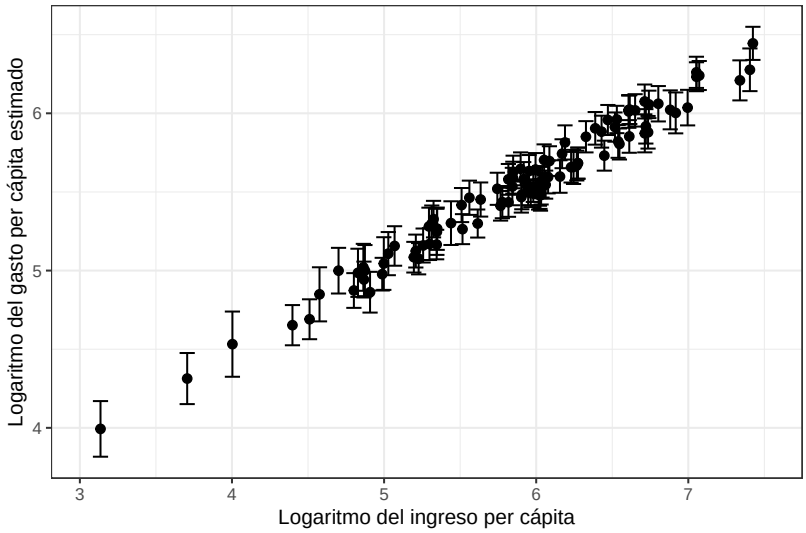


Figura 5.7.: Estimaciones del logaritmo del gasto per cápita e intervalos de confianza para los primeros 100 hogares de la muestra

Cuando el interés se centra en realizar predicciones para valores de las covariables que se encuentran fuera del rango observado en la muestra, la extrapolación puede incrementar la incertidumbre y hacer que los resultados dependan en mayor medida de la forma funcional asumida. Para una nueva unidad k, con vector de covariables $\mathbf{x}_{k,\text{nuevo}}$, la media condicional se define como

$$\mu_{k,\text{nuevo}} = E\left(y_{k,\text{nuevo}} \mid \mathbf{x}_{k,\text{nuevo}}\right) = \mathbf{x}'_{k,\text{nuevo}}\beta,$$

y su estimador está dado por

$$\hat{\mu}_{k,\text{nuevo}} = \mathbf{x}'_{k,\text{nuevo}}\hat{\beta}.$$

La varianza estimada de esta predicción es

$$\widehat{Var}\left(\hat{\mu}_{k,\text{nuevo}}\right) = \mathbf{x}'_{k,\text{nuevo}}\hat{\Sigma}\mathbf{x}_{k,\text{nuevo}},$$

donde $\hat{\Sigma} = \widehat{Var}(\hat{\beta})$ corresponde a la matriz estimada de varianzas y covarianzas de los coeficientes de regresión.

Si el interés fuera predecir $y_{k,\text{nuevo}}$ y no únicamente su media condicional, sería necesario incorporar adicionalmente la variabilidad residual del modelo. En ese caso,

$$\widehat{Var}\left(\hat{\mu}_{k,\text{nuevo}} + \varepsilon_{k,\text{nuevo}}\right) = \mathbf{x}'_{k,\text{nuevo}}\hat{\Sigma}\mathbf{x}_{k,\text{nuevo}} + \hat{\sigma}^2_{y|x}.$$

En donde $\hat{\sigma}^2_{y|x}$ corresponde a la varianza residual estimada; es decir, la parte de la variabilidad de la variable respuesta que no es explicada por las covariables incluidas en el modelo. La incorporación

de este segundo componente es fundamental cuando se desea predecir sobre unidades no observadas, ya que reconoce explícitamente la existencia de variabilidad individual alrededor de la media estimada.

En consecuencia, los intervalos de predicción suelen ser más amplios que los intervalos de confianza para la media, reflejando una mayor incertidumbre asociada a la predicción de valores individuales. De esta manera, el intervalo de predicción para una nueva observación puede expresarse como:

$$\mathbf{x}_k\hat{\beta} \pm t_{(1-\frac{\alpha}{2},df)}\sqrt{\mathbf{x}_k^\top\hat{\Sigma}\ \mathbf{x}_k + \hat{\sigma}_{yx}^2} \tag{5.8}$$

En el siguiente ejemplo se estima la media condicional del logaritmo del gasto per cápita para un nuevo perfil de hogar y su intervalo de confianza. El perfil corresponde a un hogar cuyo jefe tiene 45 años (`Age`), es de sexo masculino (`Male`), reside en zona urbana (`Urban`) de la región Norte (`North`) y tiene un ingreso per cápita (`Income`) igual a 1600. Este perfil puede definirse en `R` mediante el siguiente conjunto de datos:

```
new_data <- data.frame(
  Income = 1600,
  Age = 45,
  Sex = "Male",
  Zone = "Urban",
  Region = "North"
)

new_prediction <- predict(fit_svy, newdata = new_data, type = "link")
new_prediction
```

```
  link   SE
1 6.41 0.05
```

```
new_prediction_interval <- confint(new_prediction)
new_prediction_interval
```

```
  2.5 % 97.5 %
1 6.305  6.507
```

Para este perfil, la predicción del logaritmo del gasto per cápita es 6,406, con un intervalo de confianza del 95 % entre 6,305 y 6,507. En primer lugar, el objeto `new_data` especifica los valores de las covariables incluidas en el modelo. Posteriormente, la función `predict()` calcula la predicción puntual asociada a dicha observación. El argumento `newdata = new_data` indica que la predicción debe realizarse utilizando la nueva información suministrada, mientras que `type = "link"` solicita el resultado en la escala del predictor lineal. Finalmente, `confint()` aplicado al resultado de `predict.svyglm()` produce un intervalo de confianza para el valor medio estimado; no incorpora automáticamente el término residual requerido para un intervalo de predicción individual.

6. Modelos lineales generalizados

Nelder y Wedderburn (1972) introdujeron los modelos lineales generalizados como un marco capaz de integrar diversos métodos estadísticos ampliamente utilizados, como la regresión logística, los modelos log-lineales para datos de conteo y otros modelos avanzados de regresión para variables continuas. Posteriormente, McCullagh y Nelder (1989) sistematizaron esta formulación, que permitió extender las herramientas de regresión más allá de los escenarios en los que la variable respuesta sigue una distribución normal. Cuando la variable de interés no es continua o los supuestos del modelo lineal clásico no se satisfacen, los modelos lineales generalizados constituyen una alternativa adecuada para modelar las relaciones de interés.

La necesidad de esta generalización surge porque los modelos lineales clásicos asumen, entre otras cosas, normalidad y homogeneidad de varianza en los errores, condiciones que no se cumplen cuando se analizan variables categóricas, proporciones o conteos. En este tipo de situaciones, los modelos lineales generalizados ofrecen un marco flexible para modelar adecuadamente la relación entre las variables mediante la selección de una distribución de probabilidad apropiada para la respuesta y una función de enlace que conecte la media de dicha distribución con el predictor lineal.

Para ilustrar los modelos de este capítulo se utiliza la muestra almacenada en `sample.rds`. El siguiente bloque carga las librerías, define la condición de pobreza (`poor`), calcula el tamaño del hogar (`household_size`) contando los integrantes de cada `HHID` y construye el diseño muestral. A partir de este diseño se seleccionan las unidades de análisis correspondientes a cada ejemplo.

```
options(digits = 4)
library(tidyverse)
library(survey)
library(srvyr)
library(broom)
library(jtools)

survey_data <- readRDS("../data/sample.rds") %>%
  add_count(HHID, name = "household_size") %>%
  mutate(
    Stratum = factor(Stratum),
    poor = factor(
      Poverty != "NotPoor",
      levels = c(FALSE, TRUE),
      labels = c("Not poor", "Poor")
    )
  )

survey_design <- survey_data %>%
  as_survey_design(
```

```
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  )
```

6.1. Modelo de regresión logística

De acuerdo con McCullagh y Nelder (1989) y Agresti (2019), cuando la variable de interés es dicotómica, tomando valores de cero o uno, el modelo lineal clásico no resulta adecuado debido a que puede generar predicciones fuera del intervalo $(0, 1)$. Para abordar estas limitaciones, el modelo de regresión logística constituye uno de los modelos más utilizados para analizar variables binarias. Además, en el contexto de encuestas de hogares, la regresión logística puede emplearse para analizar la asociación entre una condición de interés, como la pobreza, y características sociodemográficas de los individuos o los hogares.

Considere, una variable dicotómica $Y_k \in \{0, 1\}$, cuya esperanza es $\theta_k = Pr(Y_k = 1)$. El modelo de regresión logística relaciona dicha probabilidad con un conjunto de variables explicativas mediante la función de enlace logit, definida como

$$\log\left(\frac{\theta_k}{1-\theta_k}\right) = \beta_0 + \beta_1 x_{k1} + \cdots + \beta_p x_{kp} = \mathbf{x}_k\beta \tag{6.1}$$

En donde β es el vector de coeficientes de regresión asociado a las covariables. Esta transformación logit convierte el intervalo restringido de probabilidades $(0, 1)$ en toda la recta real, permitiendo modelar la relación entre la respuesta y las variables auxiliares mediante un predictor lineal. De manera equivalente, la probabilidad de éxito puede expresarse mediante la siguiente relación:

$$\theta_k = Pr(Y_k = 1 \mid \mathbf{x}_k) = \frac{\exp(\mathbf{x}_k\beta)}{1 + \exp(\mathbf{x}_k\beta)} \tag{6.2}$$

De manera equivalente, la probabilidad de que la unidad no presente la característica de interés es $Pr(Y_k = 0 \mid \mathbf{x}_k) = 1 - \theta_k$. Bajo esta parametrización, cada coeficiente de β representa el efecto de una covariable sobre el logaritmo de la razón de probabilidades de que ocurra el evento de interés, manteniendo constantes las demás variables del modelo. Según Heeringa et al. (2017), la estimación de los parámetros puede realizarse mediante el enfoque de pseudo-máxima verosimilitud. Este método, abordado con detalle en el segundo anexo, incorpora los factores de expansión en la función de verosimilitud convencional con el fin de obtener estimadores consistentes respecto de la población objetivo. En este sentido, para este modelo, la función de pseudo-verosimilitud para el modelo logístico se define como

$$PL(\beta) = \prod_k \left[\theta_k^{y_k}\left\{1-\theta_k\right\}^{1-y_k}\right]^{w_k}$$

En donde el subíndice k representa una unidad observada de la muestra. Asimismo, θ_k denota la probabilidad de que la unidad k de la UPM i en el estrato h presente la característica de interés,

y_k corresponde al valor observado de la variable dicotómica para dicha unidad y w_k representa el factor de expansión asociado a la observación.

Dado que la contribución de cada observación al proceso de estimación está determinada por su respectivo factor de expansión, la función de pseudo-verosimilitud refleja adecuadamente las características del diseño complejo de la encuesta. Además, la maximización de esta función resulta equivalente a maximizar su logaritmo, entonces el problema se reduce a optimizar la siguiente función:

$$\ell(\beta) = \sum_k w_k \left[y_k \log(\theta_k) + (1 - y_k) \log(1 - \theta_k) \right] \tag{6.3}$$

Esta expresión constituye la función objetivo utilizada por los algoritmos de optimización numérica para obtener el estimador de los parámetros del modelo. Es importante señalar que la función anterior no corresponde a una verosimilitud en sentido estricto bajo el diseño complejo de la encuesta. Por esta razón, se utiliza el término *pseudo-verosimilitud* y los estimadores obtenidos mediante su maximización son conocidos como estimadores de pseudo-máxima verosimilitud (*Pseudo Maximum Likelihood Estimators*, PMLE).

De acuerdo con Molina y Skinner (1992) y Chambers y Skinner (2003), bajo condiciones de regularidad, estos estimadores son consistentes y asintóticamente normales, constituyendo la base de procedimientos de inferencia para el análisis de datos de encuestas complejas. Como explica Binder (1983) las varianzas se estiman mediante técnicas de linealización de Taylor, las cuales incorporan explícitamente las características del diseño complejo de muestreo.

La matriz de varianzas y covarianzas de los parámetros estimados, denotada por $\text{Var}(\hat{\beta}) = \Sigma$, se obtiene a partir de una aproximación lineal de las ecuaciones de estimación alrededor del verdadero valor de los parámetros. Esta matriz describe la precisión de los estimadores, ya que sus elementos diagonales corresponden a las varianzas de cada coeficiente, mientras que los elementos fuera de la diagonal representan las covarianzas entre pares de coeficientes. Su estimación constituye la base para el cálculo de errores estándar, la construcción de intervalos de confianza y la realización de pruebas de hipótesis sobre los parámetros del modelo.

Para analizar los factores asociados a la condición de pobreza en la encuesta de ejemplo, el siguiente código computacional ajusta un modelo de regresión logística utilizando como variables explicativas la edad, el sexo y la situación laboral del jefe, junto con el tamaño del hogar. Estas características demográficas y laborales son habituales en el análisis de los correlatos de la pobreza (Anyanwu 2014). En este ejemplo, la pobreza se define a partir del ingreso: `poor` toma la categoría `Poor` para `Extreme` o `Relative`, y `Not poor` para `NotPoor`. Se trabaja con una observación por hogar, identificada mediante `PersonID == "idPer01"`, y se utiliza el factor de expansión `wk` del jefe, siguiendo la convención descrita en la sección 3.1. Dado que los datos provienen de una encuesta con diseño muestral complejo, la estimación se realiza mediante la función `svyglm()` del paquete `survey`, especificando `family = quasibinomial()` para indicar que la variable respuesta es dicotómica y que se utilizará la función de enlace logit. Esta elección conserva los coeficientes y las varianzas basadas en el diseño que se obtendrían con la familia binomial, y evita la advertencia sobre respuestas ponderadas no enteras.

```
household_design <- survey_design %>%
  filter(PersonID == "idPer01") %>%
  mutate(
    Sex = factor(Sex, levels = c("Male", "Female")),
    Employment = relevel(Employment, ref = "Employed")
  )

logit_model <- svyglm(
  formula = poor ~ Age + Sex + Employment + household_size,
  family = quasibinomial(),
  design = household_design
)
```

En la especificación del modelo, el argumento `formula = poor ~ Age + Sex + Employment + household_size` define la relación entre la variable respuesta `poor` y las covariables incluidas en el predictor lineal (`Age`, `Sex`, `Employment` y `household_size`). Para las variables categóricas, la función genera automáticamente las variables indicadoras correspondientes y estima sus efectos con respecto a una categoría de referencia. Por su parte, el argumento `design = household_design` incorpora la información del diseño muestral para los hogares seleccionados. Las categorías de referencia son jefatura masculina y jefe ocupado. La muestra de análisis contiene 696 hogares, de los cuales 225 son pobres; estos conteos corresponden a observaciones muestrales, sin ponderar.

El objeto resultante, `logit_model`, contiene los parámetros estimados, sus medidas de precisión y las estadísticas necesarias para realizar inferencia sobre la relación entre la condición de pobreza y las variables explicativas consideradas en el modelo. El siguiente código computacional organiza los coeficientes del modelo logístico, sus medidas de precisión y sus exponenciales para presentarlos en la tabla.

```
logistic_intervals_table <- logit_results %>%
  mutate(OR = exp(estimate)) %>%
  select(
    term,
    estimate,
    std.error,
    p.value,
    conf.low,
    conf.high,
    OR
  )

logistic_intervals_table
```

Tabla 6.1.: Intervalos de confianza al 95 % para los parámetros del modelo logístico

Parámetro	Estimación	EE	Valor p	LI 95 %	LS 95 %	OR
(Intercept)	-1.7217	0.4252	0.0001	-2.5641	-0.8794	0.1788

Tabla 6.1.: Intervalos de confianza al 95 % para los parámetros del modelo logístico

Parámetro	Estimación	EE	Valor p	LI 95 %	LS 95 %	OR
Age	-0.0071	0.0078	0.3597	-0.0225	0.0082	0.9929
SexFemale	0.4521	0.2468	0.0696	-0.0368	0.9411	1.5717
EmploymentUnemployed	2.4380	0.7007	0.0007	1.0498	3.8262	11.4500
EmploymentInactive	0.1693	0.3272	0.6058	-0.4788	0.8174	1.1845
household_size	0.2990	0.0671	0.0000	0.1660	0.4319	1.3485

Los resultados de la tabla 6.1 muestran las estimaciones de los coeficientes de regresión, sus exponenciales, errores estándar, intervalos de confianza y valores-p. Los errores estándar y los límites de confianza se mantienen en la escala de los coeficientes β. En la regresión logística, $\exp(\beta_j)$ representa el *odds ratio* asociado a una covariable, manteniendo constantes las demás variables.

Manteniendo constantes las demás variables, el *odds ratio* de pobreza asociado a cada integrante adicional del hogar es 1.35, con un intervalo de confianza del 95 % entre 1.18 y 1.54. Al ser mayor que uno, indica mayores *odds* de pobreza asociadas con un mayor tamaño del hogar. Asimismo, el *odds ratio* de los hogares con jefe desocupado respecto de aquellos con jefe ocupado es 11.45, con un intervalo de confianza del 95 % entre 2.86 y 45.89. Esta última estimación presenta una incertidumbre considerable, pues solo se observan 16 jefes desocupados. Los odds ratios superiores a uno indican mayores odds de pobreza respecto de la comparación correspondiente, pero no expresan cuántas veces mayor es esa probabilidad. Estas asociaciones no establecen efectos causales.

La figura 6.1 presenta la distribución de los estimadores de los coeficientes de regresión. Se observa que los intervalos de confianza asociados a la desocupación del jefe y al tamaño del hogar no incluyen el valor cero, lo que proporciona evidencia de una asociación estadísticamente significativa. En contraste, la edad, la jefatura femenina y la inactividad del jefe presentan valores-p de 0.360, 0.070 y 0.606, respectivamente, por lo que no se encuentra evidencia suficiente de asociación al nivel del 5 % una vez controladas las demás covariables incluidas en el modelo. El siguiente código computacional genera el gráfico mediante `plot_summs()` del paquete `jtools` (Long 2026) y las geometrías horizontales de `ggstance` (Henry et al. 2024), para visualizar los coeficientes y sus intervalos.

```
library(ggstance)
plot_summs(
  logit_model,
  scale = TRUE,
  plot.distributions = TRUE
)
```

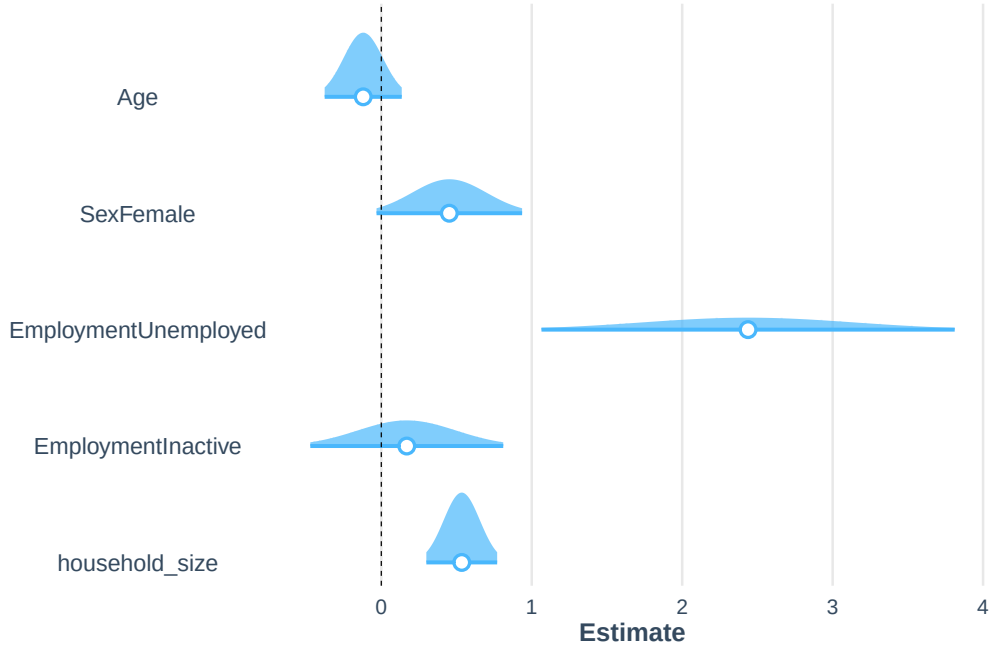


Figura 6.1.: Distribución de los parámetros del modelo logístico base

El modelo puede ampliarse incorporando términos de interacción para evaluar si el efecto de una variable explicativa depende de los valores que toma otra. En este caso, se incluye una interacción entre el sexo del jefe y el tamaño del hogar mediante el término `Sex:household_size`, con el objetivo de analizar si la relación entre el número de integrantes y las *odds* de pobreza es la misma para hogares con jefatura masculina y femenina. Sin este término, el modelo asume que la pendiente del tamaño del hogar sobre el logit de pobreza es idéntica para ambos tipos de jefatura. En cambio, al incorporar la interacción, se permite que dicha pendiente varíe, capturando posibles diferencias en la forma en que el tamaño del hogar se asocia con la pobreza en cada grupo. Los resultados del modelo ajustado se presentan en la tabla 6.2. El siguiente código computacional ajusta este modelo y reúne los coeficientes, sus errores estándar, los intervalos de confianza y sus exponenciales para facilitar la comparación.

```
interaction_logit_model <- svyglm(
  formula = poor ~ Age + Sex + Employment +
    household_size + Sex:household_size,
  family = quasibinomial(),
  design = household_design
)
```

```
interaction_logistic_coefficients_table <- interaction_logit_results %>%
  mutate(OR = exp(estimate)) %>%
  select(
    term,
    estimate,
    std.error,
    p.value,
```

```
    conf.low,
    conf.high,
    OR
  )

interaction_logistic_coefficients_table
```

Tabla 6.2.: Coeficientes del modelo logístico con interacciones

Parámetro	Estimación	EE	Valor p	LI 95 %	LS 95 %	OR
(Intercept)	-1.8438	0.4260	0.0000	-2.6878	-0.9998	0.1582
Age	-0.0074	0.0079	0.3498	-0.0230	0.0082	0.9926
SexFemale	0.7993	0.4825	0.1004	-0.1567	1.7553	2.2240
EmploymentUnemployed	2.4724	0.6989	0.0006	1.0877	3.8571	11.8508
EmploymentInactive	0.1739	0.3292	0.5984	-0.4784	0.8261	1.1899
household_size	0.3304	0.0852	0.0002	0.1617	0.4991	1.3915
SexFemale:household_size	-0.0926	0.1288	0.4738	-0.3477	0.1626	0.9116

En ambas tablas, la exponencial del intercepto corresponde a las *odds* del perfil de referencia, no a un *odds ratio*; en la tabla con interacción, la exponencial de `SexFemale:household_size` representa la razón entre los *odds ratios* del tamaño del hogar de ambos tipos de jefatura.

Al incorporar la interacción entre sexo y tamaño del hogar, se permite estimar una pendiente del tamaño del hogar diferente para cada tipo de jefatura. Para los hogares con jefe hombre, el *odds ratio* asociado a un integrante adicional es 1.39; para los hogares con jefa mujer, se obtiene combinando el coeficiente principal y el de interacción, y es igual a 1.27. El coeficiente de interacción tiene un valor-p de 0.474. Estos resultados no aportan evidencia suficiente de diferencias entre las pendientes al nivel del 5 %; el efecto principal del sexo, por su parte, corresponde a un tamaño del hogar igual a cero, fuera del rango observado, por lo que no debe interpretarse como una diferencia general entre jefaturas.

La figura 6.2, obtenida con el siguiente código computacional, presenta una comparación de las estimaciones de los coeficientes y sus respectivos intervalos de confianza para los modelos con y sin interacción. Al incorporar el término de interacción, cambia la interpretación de los efectos principales del sexo y del tamaño del hogar, que pasan a ser condicionales a los valores de referencia de la otra covariable. Los intervalos de confianza permiten valorar la incertidumbre asociada a estas estimaciones y al coeficiente de interacción.

```
plot_summs(
  interaction_logit_model,
  logit_model,
  scale = TRUE,
  plot.distributions = TRUE
)
```

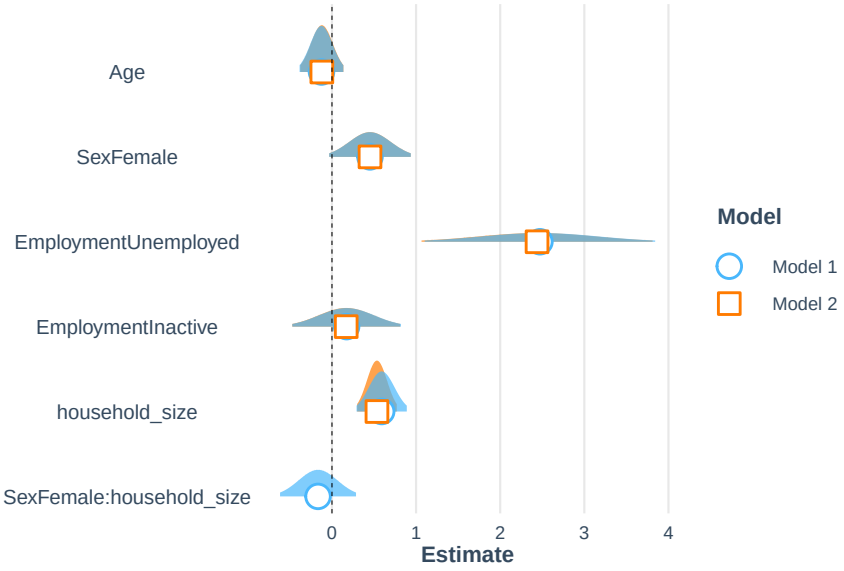


Figura 6.2.: Comparación de los parámetros del modelo logístico con y sin interacciones

Los coeficientes del modelo permiten identificar la dirección de las asociaciones entre las covariables y la condición de pobreza, pero no indican directamente la probabilidad de pobreza de un hogar. Para facilitar la interpretación, se estiman probabilidades predichas para perfiles específicos. En el siguiente ejemplo se comparan hogares con jefatura masculina o femenina, manteniendo iguales la edad del jefe, su situación laboral y el tamaño del hogar.

```
prediction_profiles <- data.frame(
  Age = c(40, 40),
  Sex = factor(
    c("Male", "Female"),
    levels = levels(household_design$variables$Sex)
  ),
  Employment = factor(
    c("Employed", "Employed"),
    levels = levels(household_design$variables$Employment)
  ),
  household_size = c(4, 4)
)

predictions <- predict(
  logit_model,
  newdata = prediction_profiles,
  type = "response",
  se.fit = TRUE
)

predicted_probability <- as.numeric(predictions)
standard_error <- as.numeric(SE(predictions))
```

```
prediction_table <- prediction_profiles %>%
  mutate(
    predicted_probability = predicted_probability,
    standard_error = standard_error,
    lower_95 = pmax(0, predicted_probability - 1.96 * standard_error),
    upper_95 = pmin(1, predicted_probability + 1.96 * standard_error)
  ) %>%
  select(
    Sex,
    Age,
    Employment,
    household_size,
    predicted_probability,
    lower_95,
    upper_95
  )
```

Los perfiles se fijan en 40 años, cuatro integrantes y jefe ocupado; cuatro integrantes corresponde a la mediana del tamaño del hogar entre los jefes seleccionados. Los niveles de `Sex` y `Employment` se conservan tal como fueron definidos para el modelo, de modo que las categorías de los perfiles coincidan con las usadas durante la estimación. A partir de las probabilidades y sus errores estándar se calculan límites aproximados del 95 % en la escala de probabilidad, restringidos al intervalo de cero a uno.

Tabla 6.3.: Probabilidades predichas de pobreza para perfiles seleccionados

Sexo de la jefatura	Edad	Situación laboral	Tamaño del hogar	Probabilidad (%)	LI 95 %	LS 95 %
Male	40	Employed	4	30.76	24.34	37.17
Female	40	Employed	4	41.11	32.41	49.82

La tabla 6.3 presenta las probabilidades e intervalos como porcentajes. Para el perfil de jefatura masculina, la probabilidad predicha de pobreza es 30.8 % (IC aproximado del 95 %: 24.3–37.2 %); para el de jefatura femenina, es 41.1 % (IC aproximado del 95 %: 32.4–49.8 %). La diferencia descriptiva es de 10.4 puntos porcentuales. Son predicciones condicionadas a los perfiles definidos, no proporciones generales de pobreza; esta diferencia por sí sola tampoco constituye una prueba de significación estadística.

6.2. Modelo de regresión multinomial

En las encuestas de hogares es frecuente encontrar variables de respuesta con más de dos categorías, como la situación laboral, cuyos posibles estados incluyen tres categorías: empleado, desempleado e inactivo. Cuando estas categorías son mutuamente excluyentes y no poseen un orden natural, la regresión logística multinomial ofrece una herramienta adecuada para modelar su relación con un

conjunto de covariables y puede entenderse como una extensión de la regresión logística binaria (McCullagh y Nelder 1989; Agresti 2019).

Este modelo permite estimar la probabilidad de pertenecer a cada categoría de la variable respuesta en función de variables explicativas de naturaleza continua o categórica. Su aplicación requiere que las categorías de respuesta sean exhaustivas y mutuamente excluyentes y que no exista multicolinealidad severa entre las covariables. Además, para las covariables continuas, se asume que existe una relación lineal entre estas y el logaritmo de las razones de probabilidades (*log-odds*) de cada categoría respecto a una categoría de referencia.

El modelo logístico multinomial especifica la probabilidad $\theta_{k(j)}$ de que la unidad k pertenezca a la categoría j, con $j = 1, \dots, J$, dado el vector de covariables $\mathbf{x}_k$, mediante la siguiente expresión:

$$Pr(Y_k = j \mid \mathbf{x}_k) = \theta_{k(j)} = \frac{\exp(\mathbf{x}_k \beta_j)}{\sum_{l=1}^{J} \exp(\mathbf{x}_k \beta_l)} \tag{6.4}$$

En donde β_j es el vector de coeficientes de regresión para la j-ésima categoría. Para que el modelo sea identificable, debe fijarse el vector de una categoría de referencia en cero; de ese modo, la expresión produce $J - 1$ conjuntos de coeficientes estimables. Aunque existen parametrizaciones alternativas que facilitan la interpretación de los parámetros, esta formulación expresa directamente las probabilidades de pertenencia a cada categoría. Con una categoría de referencia, cada conjunto de coeficientes describe cómo cambian, en escala logarítmica, las razones entre la probabilidad de pertenecer a una categoría y la probabilidad de pertenecer a la categoría de referencia (*log-odds* relativos a la referencia).

Según Heeringa et al. (2017), la estimación de los parámetros del modelo se realiza mediante el enfoque de pseudo-máxima verosimilitud, definida de la siguiente manera:

$$PL(\beta \mid \mathbf{X}) = \prod_{k} \left\{ \prod_{j=1}^{J} \theta_{k(j)}^{y_{k(j)}} \right\}^{w_k}$$

En donde k representa las unidades de observación pertenecientes a la muestra compleja. Asimismo, $y_{k(j)}$ es una variable indicadora que toma el valor de uno cuando dicha unidad pertenece a la categoría j y cero en caso contrario, y w_k corresponde al factor de expansión asociado a la unidad observada. Por conveniencia matemática y computacional, la estimación de los parámetros se realiza a partir de la pseudo-logverosimilitud, $\ell(\beta)$, cuya maximización conduce a los mismos estimadores que la pseudo-verosimilitud original.

$$\ell(\beta) = \sum_{k} w_k \sum_{j=1}^{J} y_{k(j)} \log(\theta_{k(j)}) \tag{6.5}$$

La inferencia estadística para los parámetros de interés se basa en estimaciones de varianza obtenidas mediante técnicas de linealización de Taylor que incorporan explícitamente las características del diseño muestral complejo, permitiendo calcular errores estándar, intervalos de confianza y pruebas de hipótesis apropiados para datos de encuestas. Bajo condiciones regulares, los estimadores obtenidos mediante este procedimiento son consistentes y asintóticamente normales (Molina y Skinner 1992; Binder 1983).

Como referencia inicial, el siguiente código computacional estima la distribución por estado de empleo entre las personas de 15 años o más. Los resultados se presentan en la tabla 6.4.

```
employment_proportion <- survey_design %>%
  filter(Age >= 15) %>%
  group_by(Employment) %>%
  summarise(
    proportion = survey_mean(vartype = c("se", "ci"))
  )

employment_proportions_table <- employment_proportion

employment_proportions_table
```

Tabla 6.4.: Proporción estimada de personas por estado de empleo (de 15 años o más)

Condición de actividad	Proporción	EE	LI 95 %	LS 95 %
Unemployed	0.0429	0.0071	0.0288	0.0571
Inactive	0.3840	0.0152	0.3539	0.4142
Employed	0.5731	0.0140	0.5453	0.6008

De acuerdo con Lumley (2026), para modelar una variable de respuesta multinomial se emplea la función `svy_vglm()` del paquete `svyVGAM`, que permite ajustar modelos de regresión multinomial incorporando explícitamente las características del diseño complejo de la encuesta. En este ejemplo, se especifica un modelo donde la condición de actividad se explica en función de la edad, el sexo y la zona de residencia. A diferencia de los modelos multinomiales convencionales, `svy_vglm()` calcula las varianzas de los estimadores considerando la complejidad del diseño muestral.

Las siguientes líneas de código ajustan un modelo de regresión multinomial sobre las personas de 15 años o más, susceptibles de ser clasificadas en una de las tres categorías de `Employment`. Note que el argumento `family = multinomial(refLevel = "Unemployed")` define un modelo logístico multinomial tomando la categoría `Unemployed` como referencia. Bajo esta especificación, se estiman de manera simultánea los logaritmos de las razones de probabilidades (*log-odds*) entre cada una de las categorías de `Employment` y la categoría de referencia. Los parámetros se obtienen mediante pseudo-máxima verosimilitud, incorporando los factores de expansión de la encuesta en la función objetivo.

```
library(svyVGAM)

survey_design_15 <- survey_design %>%
  filter(Age >= 15)

multinomial_model <- svy_vglm(
  formula = Employment ~ Age + Sex + Zone,
  design = survey_design_15,
  crit = "coef",
```

```
  family = multinomial(refLevel = "Unemployed")
)
```

La tabla 6.5 presenta los coeficientes estimados del modelo logístico multinomial, tomando la categoría `Unemployed` como referencia. Los errores estándar y los intervalos de confianza del 95 % se expresan en la escala de los coeficientes β. Para el intercepto, la exponencial es la razón de probabilidades del perfil de referencia, no una comparación entre perfiles. Los resultados muestran que la edad tiene una asociación positiva y estadísticamente significativa con las probabilidades relativas de pertenecer a las categorías `Inactive` y `Employed` frente a `Unemployed`. Asimismo, la variable `SexMale` presenta coeficientes negativos y significativos, indicando que, manteniendo constantes la edad y la zona, los hombres tienen menores razones relativas de estar `Inactive` o `Employed` frente a estar `Unemployed` que las mujeres. Por el contrario, la variable de zona de residencia no muestra efectos estadísticamente significativos al nivel convencional del 5 %. El siguiente código computacional prepara los coeficientes del modelo multinomial para la tabla: asigna etiquetas a las categorías de respuesta y calcula la razón de riesgo relativo como la exponencial del coeficiente.

```
multinomial_coefficients_table <- multinomial_results %>%
  mutate(
    y.level = recode(y.level, `1` = "Inactive", `2` = "Employed"),
    RRR = exp(estimate)
  ) %>%
  select(
    y.level,
    term,
    estimate,
    std.error,
    p.value,
    conf.low,
    conf.high,
    RRR
  )

multinomial_coefficients_table
```

Tabla 6.5.: Coeficientes estimados del modelo de regresión multinomial

Categoría	Parámetro	Estimación	EE	Valor p	LI 95 %	LS 95 %	RRR
Inactive	(Intercept)	2.5565	0.5500	0.0000	1.4785	3.6344	12.8902
Inactive	Age	0.0221	0.0104	0.0343	0.0016	0.0425	1.0223
Inactive	SexMale	-2.1851	0.3166	0.0000	-2.8057	-1.5646	0.1125
Inactive	ZoneUrban	-0.2536	0.4045	0.5307	-1.0464	0.5392	0.7760
Employed	(Intercept)	2.3063	0.4614	0.0000	1.4020	3.2107	10.0377
Employed	Age	0.0181	0.0088	0.0398	0.0008	0.0355	1.0183
Employed	SexMale	-0.5783	0.2766	0.0365	-1.1203	-0.0362	0.5609
Employed	ZoneUrban	0.0392	0.3605	0.9135	-0.6674	0.7457	1.0399

La columna RRR (*relative risk ratio*), se calcula como $\exp(\beta)$ e indica el factor de cambio en la razón entre la probabilidad de la categoría indicada y la de referencia, manteniendo constantes las demás covariables. En la tabla, el RRR de `SexMale` para la categoría `Employed` es 0.56. Manteniendo constantes la edad y la zona, la razón entre la probabilidad de estar empleado y la de estar desempleado para los hombres equivale a ese valor multiplicado por la razón correspondiente para las mujeres. Esto representa una razón relativa aproximadamente 43.9 % menor.

De acuerdo con Warnes et al. (2023) y Solt y Hu (2025), la figura 6.3, obtenida con el siguiente código computacional, muestra los intervalos de confianza de los coeficientes estimados para cada ecuación del modelo multinomial. Se usa `gtools::stars.pval()` para codificar la significación estadística, y la visualización se construye con `dotwhisker::dwplot()`, lo que permite comparar coeficientes e intervalos en una escala común. Las covariables cuyos intervalos no incluyen el valor cero presentan evidencia de asociación estadística significativa con la variable respuesta, mientras que aquellos cuyos intervalos contienen el cero no muestran efectos significativos al nivel de confianza considerado.

```
multinomial_results %>%
  mutate(
    model = if_else(y.level == 1, "Inactive", "Employed"),
    sig = gtools::stars.pval(p.value)
  ) %>%
  dotwhisker::dwplot(
    dodge_size = 0.3,
    vline = geom_vline(
      xintercept = 0,
      colour = "grey60",
      linetype = 2
    )
  ) +
  guides(color = guide_legend(reverse = TRUE)) +
  theme_bw() +
  theme(legend.position = "top")
```

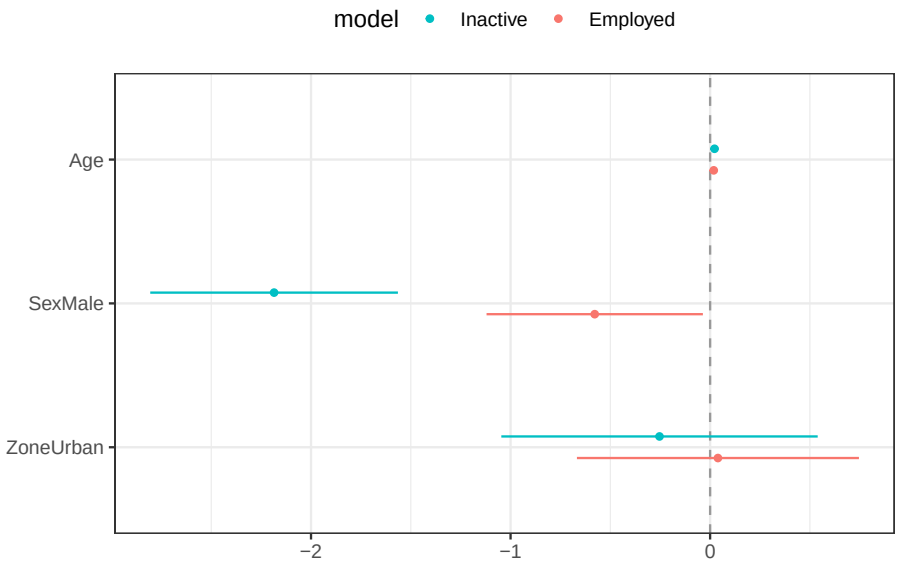


Figura 6.3.: Intervalos de confianza para los coeficientes del modelo multinomial

6.3. Modelo de regresión Gamma

La regresión Gamma constituye una extensión de los modelos lineales generalizados adecuada para variables respuesta continuas, estrictamente positivas y cuya variabilidad aumenta con la media (McCullagh y Nelder 1989). Este comportamiento es frecuente en variables económicas y sociales, como los ingresos de los hogares o los gastos en consumo.

Si Y_k, la variable de interés observada para la unidad k, sigue una distribución Gamma con media μ_k y parámetro de dispersión ϕ, el modelo relaciona el valor esperado de la variable respuesta con un conjunto de covariables mediante una función de enlace. El enlace logarítmico es una opción frecuente y garantiza predicciones positivas, aunque el enlace canónico de la familia Gamma es el inverso. En este caso, el modelo se expresa como

$$\log(\mu_k) = \mathbf{x}_k\beta \tag{6.6}$$

En donde $\mathbf{x}_k$ corresponde al vector de variables explicativas asociado a la unidad observada y β es el vector de parámetros desconocidos del modelo. De forma equivalente, se tiene que:

$$\mu_k = E(Y_k \mid \mathbf{x}_k) = \exp(\mathbf{x}_k\beta),$$

Con el enlace logarítmico, cada parámetro puede interpretarse como el efecto de una covariable sobre el logaritmo de la media esperada, de manera que $\exp(\beta_j)$ representa el cambio multiplicativo asociado a un incremento unitario en la covariable correspondiente, manteniendo constantes las demás variables del modelo. Bajo la distribución Gamma, la función de densidad condicional de Y_k puede escribirse como

$$f(y_k \mid \mu_k, \phi) = \frac{1}{\Gamma(1/\phi)(\phi\mu_k)^{1/\phi}} y_k^{\frac{1}{\phi}-1} \exp\left(-\frac{y_k}{\phi\mu_k}\right), \qquad y_k > 0,$$

donde $\Gamma(\cdot)$ denota la función Gamma y ϕ representa el parámetro de dispersión. Bajo el enfoque de inferencia basado en pseudo-máxima verosimilitud, la función objetivo que se optimiza para obtener los estimadores de los parámetros del modelo está dada por

$$\ell(\beta, \phi) = \sum_k w_k \log\left[f(y_k \mid \mu_k, \phi)\right]$$

En donde k representa las unidades de observación de la muestra y w_k corresponde al factor de expansión asociado a cada una de ellas. Esta función define el criterio de optimización utilizado para estimar los parámetros del modelo bajo el enfoque de pseudo-máxima verosimilitud, descrito para encuestas complejas por Chambers y Skinner (2003).

El siguiente código computacional ajusta, mediante `svyglm()`, un modelo de regresión Gamma para el ingreso per cápita del hogar (`Income`), incorporando el diseño complejo de la encuesta conservado en el objeto `household_design`. La unidad de análisis es el hogar, con una observación por hogar identificada mediante `PersonID == "idPer01"`, siguiendo la convención utilizada en el modelo logístico. La muestra de análisis contiene 696 hogares; las categorías de referencia son jefatura masculina y zona rural. El modelo utiliza como variables explicativas el gasto per cápita del hogar (`Expenditure`), la edad del jefe de hogar (`Age`), su sexo (`Sex`) y la zona de residencia (`Zone`). Asimismo, se especifica una función de enlace logarítmica, garantizando predicciones positivas y permitiendo interpretar los efectos de las variables explicativas en términos multiplicativos sobre el ingreso per cápita esperado. Finalmente, se reúnen los coeficientes, sus medidas de precisión y los factores multiplicativos correspondientes para presentarlos en la tabla 6.6.

```
gamma_model <- svyglm(
  formula = Income ~ Expenditure + Age + Sex + Zone,
  design = household_design,
  family = Gamma(link = "log")
)
```

```
gamma_results <- broom::tidy(
  gamma_model,
  conf.int = TRUE,
  conf.level = 0.95
)
gamma_coefficients_table <- gamma_results %>%
  mutate(factor = exp(estimate)) %>%
  select(
    term,
    estimate,
    std.error,
    p.value,
    conf.low,
    conf.high,
```

```
    factor
  )

gamma_coefficients_table
```

Tabla 6.6.: Coeficientes del modelo Gamma para el ingreso per cápita de los hogares

Parámetro	Estimación	EE	Valor p	LI 95 %	LS 95 %	Factor multiplicativo
(Intercept)	5.4392	0.1257	0.0000	5.1902	5.6882	230.2624
Expenditure	0.0019	0.0001	0.0000	0.0017	0.0021	1.0019
Age	0.0002	0.0014	0.8634	-0.0026	0.0030	1.0002
SexFemale	-0.1521	0.0785	0.0551	-0.3077	0.0034	0.8589
ZoneUrban	0.1606	0.0747	0.0336	0.0127	0.3085	1.1742

Dado que el modelo utiliza un enlace logarítmico, la columna Factor multiplicativo muestra $\exp(\beta)$, es decir, el cambio multiplicativo en el ingreso esperado asociado a una unidad adicional de una covariable, manteniendo constantes las demás; para una variable categórica, la comparación se realiza respecto de su categoría de referencia. El cambio porcentual correspondiente es $100[\exp(\beta) - 1]$. Para el intercepto, la exponencial representa la media esperada del perfil de referencia. Los errores estándar y los intervalos de confianza del 95 % permanecen en la escala de los coeficientes β. El coeficiente asociado al gasto per cápita es positivo y estadísticamente significativo (valor-p: <0.001): manteniendo constantes las demás covariables, un dólar adicional de gasto per cápita se asocia con un aumento aproximado del 0,187 % en el ingreso per cápita esperado. La residencia en zona urbana también presenta una asociación positiva y estadísticamente significativa (valor-p: 0.0336), con un ingreso per cápita esperado aproximadamente 17,4 % mayor que en la zona rural, manteniendo constantes el gasto per cápita, la edad y el sexo del jefe. En cambio, no se encuentra evidencia suficiente de asociación para la edad del jefe (valor-p: 0.863) ni para la jefatura femenina respecto de la masculina (valor-p: 0.0551) al nivel del 5 %. Estas asociaciones no establecen efectos causales.

7. Modelos multinivel

Los modelos multinivel, también conocidos como modelos jerárquicos, son una técnica estadística diseñada para el análisis de datos con estructura jerárquica, como los que provienen de encuestas de hogares, en donde las unidades de observación no son independientes entre sí (Goldstein 2011; Rabe-Hesketh y Skrondal 2012). Los individuos pertenecen a hogares, los hogares se ubican en áreas geográficas específicas (UPMs) y estas, a su vez, forman parte de unidades territoriales más amplias (estratos o dominios). Como consecuencia, las observaciones que comparten un mismo contexto suelen presentar características más similares entre sí que aquellas pertenecientes a contextos diferentes. Esta estructura de dependencia viola uno de los supuestos fundamentales de los modelos de regresión convencionales y puede conducir a estimaciones ineficientes e inferencias incorrectas.

A diferencia de los modelos de regresión convencionales, los modelos multinivel reconocen que las observaciones pueden estar agrupadas en distintos niveles y que cada uno de ellos puede contribuir a explicar la variabilidad observada. En consecuencia, permiten representar simultáneamente los efectos asociados a las características de las unidades de análisis y aquellos derivados del entorno o contexto en el que estas se encuentran. Esta formulación resulta especialmente útil cuando se busca estudiar fenómenos determinados tanto por factores individuales como por características de los hogares, comunidades o áreas geográficas.

Como explica Snijders y Bosker (2011), otra característica relevante de los modelos multinivel es que permiten cuantificar la proporción de la variabilidad asociada a cada nivel de agrupación presente en los datos. Mientras los efectos fijos resumen la relación promedio entre la variable respuesta y las covariables incluidas en el modelo, los efectos aleatorios representan las diferencias sistemáticas entre los grupos que no son explicadas por dichas covariables. Gracias a esta estructura, es posible modelar explícitamente la dependencia entre observaciones pertenecientes a un mismo grupo y obtener inferencias más adecuadas cuando los datos presentan organización jerárquica.

De acuerdo con Gelman y Hill (2006), el desarrollo teórico y metodológico de los modelos multinivel ha sido ampliamente documentado en la literatura de muestreo. Sus fundamentos conceptuales, estrategias de estimación y aplicaciones en contextos sociales y demográficos se encuentran consolidados en distintas referencias especializadas. Por otra parte, la comparación entre enfoques de estimación para modelos jerárquicos permite evaluar diferencias entre los métodos basados en máxima verosimilitud y los enfoques bayesianos (Browne y Draper 2006).

Según Merlo et al. (2006), en el ámbito de la epidemiología social, los modelos multinivel resultan útiles para estudiar fenómenos contextuales, mostrando cómo factores asociados al entorno pueden contribuir a explicar desigualdades en salud y otros resultados de interés poblacional. Además, como advierten Pfeffermann et al. (1998) y Carle (2009), es necesario distinguir entre la jerarquía sustantiva que se desea modelar y la estructura del diseño muestral: una UPM, un estrato de diseño o un dominio no constituye automáticamente un contexto intercambiable susceptible de representarse mediante un efecto aleatorio. Esa decisión requiere una justificación conceptual y suficiente información en cada grupo.

7.1. Motivación

Para iniciar este capítulo, se cargan las bibliotecas `tidyverse` para la manipulación de datos y la generación de gráficos, y `lme4` para la estimación de modelos multinivel (Bates et al. 2015). Asimismo, se importa la base de datos que será utilizada a lo largo de los ejemplos. Los títulos matemáticos de algunas figuras se formatean con `latex2exp`, llamado de forma explícita en el código.

```
library(tidyverse)
library(lme4)

survey_data <- readRDS("../data/sample.rds") %>%
  add_count(HHID, name = "household_size") %>%
  filter(PersonID == "idPer01")


survey_data <- survey_data %>%
  mutate(
    poor = ifelse(Poverty != "NotPoor", 1, 0),
    log_expenditure = log(Expenditure),
    log_income = log(Income)
  )
```

La base de análisis contiene 696 hogares, representados por una observación seleccionada mediante `PersonID == "idPer01"`. El factor de expansión `wk` de la persona principal se utiliza como aproximación al peso del hogar, siguiendo la convención y las limitaciones descritas en la sección 3.1. Antes de seleccionar ese registro, se calcula el tamaño del hogar (`household_size`) con `add_count(HHID)`, contando a todos sus integrantes. Las variables `Income` y `Expenditure` corresponden al ingreso y al gasto mensual per cápita del hogar; `Age` registra la edad de la persona principal. La selección deja un único registro por hogar. En esta base, el ingreso y el gasto son finitos y positivos, lo que permite obtener sus logaritmos naturales mediante `log()`. Los nombres y las categorías de las variables se conservan en inglés.

A partir de esta base, el capítulo desarrolla dos aplicaciones. La primera estudia la relación entre el logaritmo del gasto (`log_expenditure`) y el logaritmo del ingreso (`log_income`): la sección de motivación presenta la relación bivariada y los modelos lineales multinivel incorporan posteriormente la edad como control. La escala logarítmica permite interpretar la pendiente del ingreso como una elasticidad: un aumento del 1 % en el ingreso se asocia con un cambio aproximado del β % en el gasto típico, expresado mediante su media geométrica condicional, manteniendo constantes las demás covariables y el efecto del estrato. Además, comprime la escala de los valores elevados, aunque no garantiza el cumplimiento de los supuestos del modelo. La segunda aplicación utiliza modelos logísticos multinivel para estudiar la asociación entre el logaritmo del gasto y la condición de pobreza, controlando por el tamaño del hogar.

Con fines ilustrativos, los ajustes iniciales de esta sección utilizan los tres estratos con menor número de hogares. La base `plot_data` permite mostrar las limitaciones de los ajustes independientes en grupos pequeños y se utiliza después para visualizar los modelos multinivel. Estos últimos se estiman con los 696 hogares de todos los estratos, contenidos en `survey_data`. La selección de tres

estratos sirve para ilustrar el método y no representa por sí sola a la población. El siguiente código computacional prepara la selección de hogares y estratos que se utilizará en las ilustraciones.

```
plot_data <- survey_data %>%
  select(HHID, Stratum) %>%
  distinct() %>%
  group_by(Stratum) %>%
  tally() %>%
  arrange(n) %>%
  select(-n) %>%
  slice(1:3L) %>%
  inner_join(survey_data, by = "Stratum") %>%
  select(Income, Expenditure, log_income, log_expenditure,
         household_size, Age, Stratum, Sex, Region, Zone, poor)
```

Como punto de partida, se ajusta un modelo de regresión lineal convencional que relaciona el logaritmo del gasto per cápita de los hogares con el logaritmo de su ingreso per cápita, ignorando temporalmente la estructura jerárquica de los datos. Bajo esta especificación, se asume que todas las observaciones son independientes y que la relación entre los logaritmos del ingreso y del gasto es homogénea para todos los hogares, independientemente del estrato al que pertenezcan. La figura 7.1, obtenida con el siguiente código computacional, presenta la recta de regresión estimada junto con los datos observados.

```
simple_model <- lm(log_expenditure ~ log_income, data = plot_data)

ggplot(data = plot_data, aes(y = log_expenditure, x = log_income)) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_smooth(
    formula = y ~ x,
    method = "lm",
    se = FALSE
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

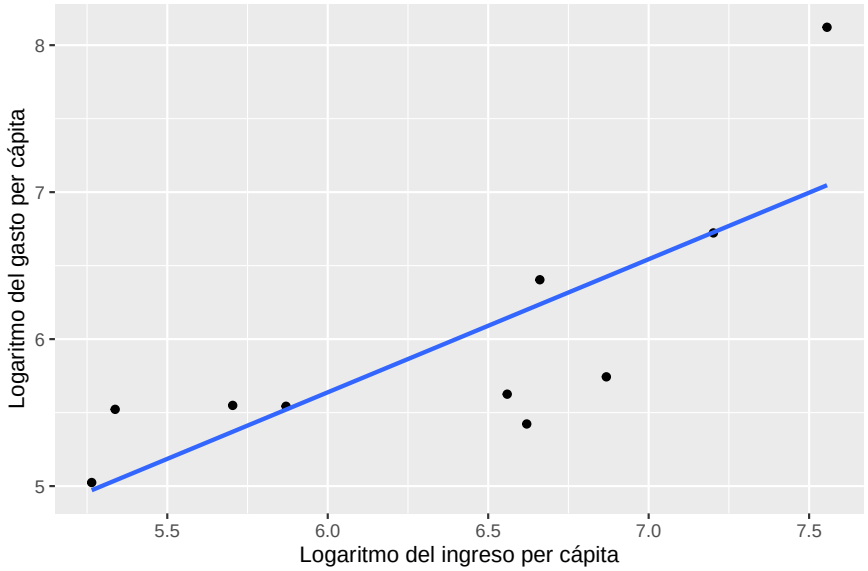


Figura 7.1.: Modelo de regresión lineal simple para el logaritmo del gasto en función del logaritmo del ingreso (sin considerar estratos)

Teniendo en cuenta los coeficientes de regresión estimados en la tabla 7.1, en este ajuste inicial un ingreso 1 % mayor se asocia con un gasto aproximadamente 0,906 % mayor. Como explica Finch et al. (2019), si bien este modelo resulta útil como referencia inicial, sus supuestos suelen ser poco realistas en el contexto de encuestas de hogares. En particular, la independencia entre observaciones puede verse comprometida cuando los hogares pertenecen a estratos que comparten características socioeconómicas, demográficas o geográficas similares. Asimismo, es posible que los niveles promedio del logaritmo del gasto difieran sistemáticamente entre estratos, aun cuando la relación entre los logaritmos del ingreso y del gasto sea semejante. Ignorar esta estructura jerárquica puede conducir a estimaciones incorrectas de los errores estándar y, en consecuencia, a inferencias estadísticas poco confiables.

Para incorporar gradualmente la estructura jerárquica de los datos, el siguiente código computacional ajusta un modelo que permite que cada estrato tenga su propio intercepto, mientras mantiene una pendiente común para todas las observaciones. Esta especificación resulta útil para visualizar cómo los niveles promedio del logaritmo del gasto pueden diferir entre estratos, aun cuando la relación entre los logaritmos del ingreso y del gasto se considere constante. Los coeficientes se utilizarán para trazar las rectas de regresión.

```
beta_1 <- coef(simple_model)[2]
model_coef <- plot_data %>%
  group_by(Stratum) %>%
  summarise(
    beta_0 = mean(log_expenditure - beta_1 * log_income)
  ) %>%
  mutate(beta_1 = beta_1)

common_slope_coefficients <- model_coef
```

De esta manera, el modelo introduce una primera fuente de heterogeneidad entre grupos y permite apreciar las limitaciones del modelo de regresión simple presentado anteriormente, el cual asumía una única recta de regresión para toda la población. La figura 7.2, obtenida con el siguiente código computacional, presenta las rectas de regresión con interceptos diferenciados por estrato.

```
ggplot(
  data = plot_data,
  aes(
    y = log_expenditure,
    x = log_income,
    colour = Stratum
  )
) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_abline(
    data = model_coef,
    mapping = aes(
      slope = beta_1,
      intercept = beta_0,
      colour = Stratum
    )
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

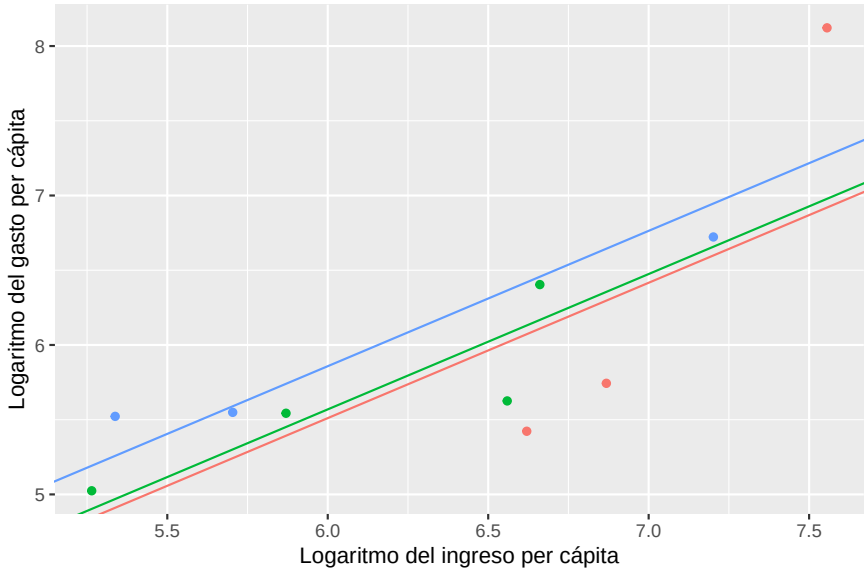


Figura 7.2.: Modelo con intercepto específico por estrato y pendiente común

Como muestra la tabla 7.1, los interceptos difieren entre estratos, mientras que la elasticidad es común. Dentro de cada estrato, un ingreso 1 % mayor se asocia con un gasto aproximadamente 0,906 % mayor, manteniendo constantes las demás variables incluidas en el modelo. Así, los estratos pueden diferir en el nivel del gasto, pero comparten su respuesta proporcional al ingreso. Como siguiente paso, se considera una especificación alternativa en la que todos los estratos comparten un mismo intercepto en la escala logarítmica, pero se permite que la relación entre los logaritmos del ingreso y del gasto varíe entre estratos mediante pendientes específicas para cada uno de ellos.

```
beta_0 <- coef(simple_model)[1]
model_coef <- plot_data %>%
  group_by(Stratum) %>%
  summarise(
    beta_1 = coef(lm(I(log_expenditure - beta_0) ~ 0 + log_income))[[1]]
  ) %>%
  mutate(beta_0 = beta_0)

common_intercept_coefficients <- model_coef
```

Bajo esta especificación, las diferencias entre estratos se manifiestan en la intensidad de la asociación entre los logaritmos del ingreso y del gasto, manteniendo fijo el intercepto. La figura 7.3, obtenida con el siguiente código computacional, permite visualizar estas diferencias en las trayectorias de regresión estimadas para cada estrato.

```
ggplot(
  data = plot_data,
  aes(
    y = log_expenditure,
    x = log_income,
    colour = Stratum
  )
) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_abline(
    data = model_coef,
    mapping = aes(
      slope = beta_1,
      intercept = beta_0,
      colour = Stratum
    )
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

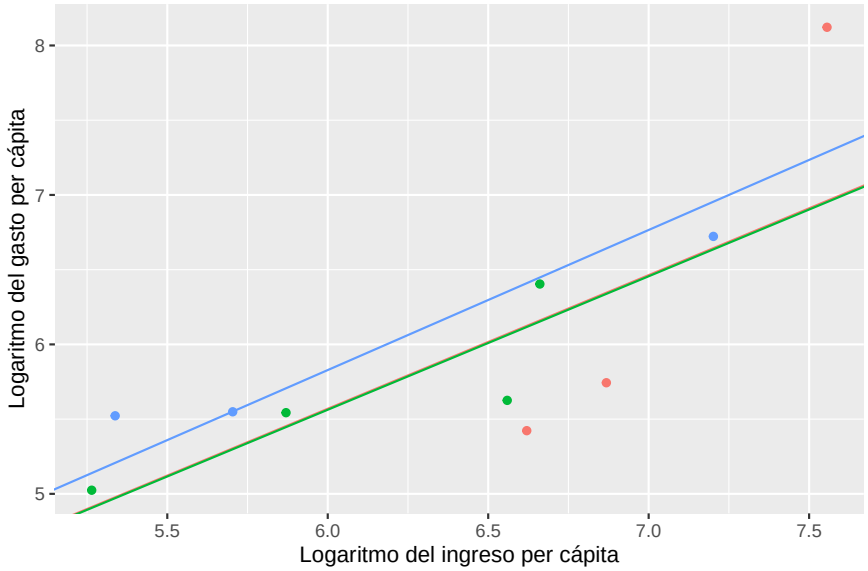


Figura 7.3.: Modelo con pendiente específica por estrato e intercepto común

Con intercepto común y pendientes específicas, cada estrato tiene una elasticidad distinta, como se observa en la tabla 7.1. Las estimaciones van de 0,893 a 0,937. Por ejemplo, en el estrato idStrt039, un ingreso 1 % mayor se asocia con un gasto aproximadamente 0,894 % mayor, manteniendo constantes las demás variables incluidas en el modelo.

Finalmente, se considera la especificación más flexible de las presentadas hasta el momento, permitiendo que tanto el intercepto del logaritmo del gasto como la relación entre los logaritmos del ingreso y del gasto varíen entre estratos. El siguiente código computacional ajusta una regresión independiente para cada estrato, de modo que cada uno tenga su propio intercepto y pendiente.

```
model_coef <- plot_data %>%
  group_by(Stratum) %>%
  summarise(
    beta_0 = coef(lm(log_expenditure ~ log_income))[1],
    beta_1 = coef(lm(log_expenditure ~ log_income))[2]
  )

separate_coefficients <- model_coef
```

Esta formulación permite capturar simultáneamente diferencias en los niveles del logaritmo del gasto y en la intensidad de su asociación con el logaritmo del ingreso. La figura 7.4, obtenida con el siguiente código computacional, muestra las rectas ajustadas para cada estrato bajo esta especificación.

```
ggplot(
  data = plot_data,
  aes(
    y = log_expenditure,
```

```
    x = log_income,
    colour = Stratum
  )
) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_abline(
    data = model_coef,
    mapping = aes(
      slope = beta_1,
      intercept = beta_0,
      colour = Stratum
    )
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

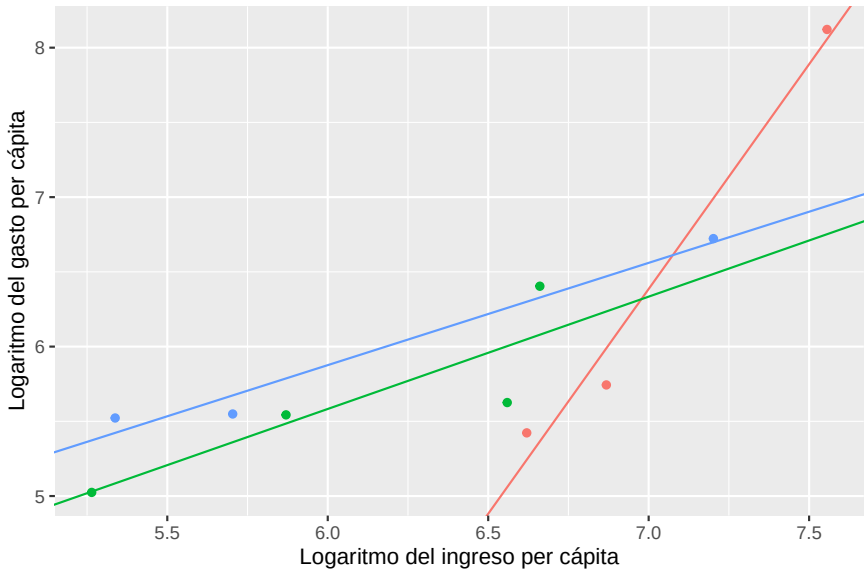


Figura 7.4.: Modelo con intercepto y pendiente específicos por estrato (ajuste independiente)

Al estimar ambos coeficientes por separado para cada estrato, las elasticidades van de 0,684 a 3,008, según la tabla 7.1. En el estrato idStrt039, un ingreso 1 % mayor se asocia con un gasto aproximadamente 3,008 % mayor, manteniendo constantes las demás variables incluidas en el modelo. Estas estimaciones corresponden a ajustes independientes en grupos pequeños y no incorporan todavía el control por edad.

Aunque esta última especificación ofrece una representación más flexible de los datos y permite capturar las particularidades de cada estrato, presenta una limitación importante: los parámetros

se estiman de manera completamente independiente para cada grupo. Como consecuencia, no se aprovecha la información compartida entre estratos que podrían presentar patrones similares, lo que puede generar estimaciones inestables, especialmente en aquellos grupos con un número reducido de observaciones. Los modelos multinivel superan esta dificultad mediante un mecanismo conocido como encogimiento (*shrinkage*), en el cual las estimaciones específicas de cada grupo se obtienen combinando la información propia del grupo con la información proveniente del conjunto de la población (Gelman y Hill 2006; Goldstein 2011). De esta manera, se logra un equilibrio entre la representación de las diferencias entre estratos y la eficiencia estadística de las estimaciones.

La tabla 7.1 reúne los coeficientes de los cuatro ajustes en el orden en que se han presentado. Como el ingreso y el gasto están en logaritmos, la pendiente es también la elasticidad y se muestra en una sola columna. El intercepto no tiene esa interpretación. El siguiente código computacional combina los coeficientes guardados durante los ajustes para facilitar su comparación.

```
motivation_models_table <- bind_rows(
  "Regresión simple" = tibble(
    Stratum = "Tres estratos juntos",
    beta_0 = unname(coef(simple_model)[1]),
    beta_1 = unname(coef(simple_model)[2])
  ),
  "Interceptos específicos y pendiente común" = common_slope_coefficients,
  "Intercepto común y pendientes específicas" = common_intercept_coefficients,
  "Interceptos y pendientes específicos" = separate_coefficients,
  .id = "model"
) %>%
  select(model, Stratum, beta_0, beta_1)

motivation_models_table
```

Tabla 7.1.: Interceptos y elasticidades de los modelos ilustrativos de la sección de motivación

Modelo	Estrato	Intercepto	Pendiente (elasticidad)
Regresión simple	Tres estratos juntos	0.205	0.906
Interceptos específicos y pendiente común	idStrt039	0.077	0.906
Interceptos específicos y pendiente común	idStrt046	0.135	0.906
Interceptos específicos y pendiente común	idStrt057	0.424	0.906
Intercepto común y pendientes específicas	idStrt039	0.205	0.894
Intercepto común y pendientes específicas	idStrt046	0.205	0.893
Intercepto común y pendientes específicas	idStrt057	0.205	0.937
Interceptos y pendientes específicos	idStrt039	-14.669	3.008

Tabla 7.1.: Interceptos y elasticidades de los modelos ilustrativos de la sección de motivación

Modelo	Estrato	Intercepto	Pendiente (elasticidad)
Interceptos y pendientes específicos	idStrt046	1.073	0.752
Interceptos y pendientes específicos	idStrt057	1.770	0.684

7.2. Incorporación de pesos de muestreo en modelos multinivel

En el contexto de los modelos multinivel con datos provenientes de encuestas, una dificultad adicional radica en la incorporación coherente de los pesos de muestreo a través de los distintos niveles de la jerarquía. La estructura agrupada de los datos implica que las observaciones no son independientes, por lo que la función de log-verosimilitud no puede descomponerse como una suma simple de contribuciones individuales. En su lugar, es necesario considerar explícitamente la dependencia entre los distintos niveles del diseño muestral para lograr inferencias adecuadas.

La incorporación de los pesos de muestreo en modelos multinivel ha recibido una atención considerable en la literatura, especialmente cuando el diseño de la encuesta puede ser informativo. En estos casos, la probabilidad de inclusión de las unidades puede estar relacionada con las variables de interés, incluso después de condicionar por las covariables incluidas en el modelo. Ignorar esta característica del diseño puede afectar la estimación de los parámetros y, en consecuencia, la validez de las inferencias obtenidas a partir del modelo (Pfeffermann et al. 1998; Asparouhov 2006).

Una de las principales alternativas consiste en extender los métodos de estimación habituales mediante procedimientos de pseudo-máxima verosimilitud, incorporando los pesos de muestreo en la función objetivo utilizada para estimar los parámetros. Como se ha mencionado a lo largo de este documento, dentro de este enfoque se han propuesto diferentes formas de ponderar las contribuciones de las unidades y de los conglomerados a la función de verosimilitud (Rabe-Hesketh y Skrondal 2006; Carle 2009). Estas estrategias buscan preservar, en la medida de lo posible, las ventajas de la modelación jerárquica al tiempo que incorporan información procedente del diseño muestral.

También se han desarrollado procedimientos de estimación basados en algoritmos iterativos, incluidos enfoques que utilizan variantes del algoritmo EM para incorporar las ponderaciones dentro de la estimación de modelos jerárquicos (Cai 2013). En conjunto, estos trabajos muestran que no existe una única manera de incorporar los pesos de muestreo en modelos multinivel. La elección del procedimiento depende, entre otros factores, de la estructura del diseño muestral, del nivel o los niveles en los que se produce la selección informativa y del objetivo inferencial del análisis. Por esta razón, más que considerar la ponderación como una corrección mecánica, resulta conveniente evaluar explícitamente las características del diseño y el posible carácter informativo del mecanismo de selección antes de definir la estrategia de estimación.

Como explica Pfeffermann (2011), para ajustar modelos multinivel con datos provenientes de encuestas complejas, una alternativa consiste en utilizar el enfoque de pesos *q-weighted*. La idea central de este método es eliminar de los pesos muestrales la componente sistemática explicada por las covariables incluidas en el modelo, de modo que los pesos resultantes conserven únicamente la parte residual atribuible al mecanismo de selección.

No obstante, este no es el único enfoque disponible para la estimación de modelos multinivel con datos de encuestas complejas y tampoco sustituye el uso de pesos condicionales o de pesos escalados en cada etapa del diseño, requeridos por algunos métodos de pseudo-verosimilitud multinivel. El procedimiento para construir los pesos *q-weighted* se resume en los siguientes pasos:

1. Ajustar un modelo de regresión para los factores de expansión finales de la encuesta, utilizando como variables explicativas el mismo conjunto de covariables que será empleado en el modelo multinivel. Siendo w_k el factor de expansión original de la unidad k y $\mathbf{x}_k$ el vector de covariables. Entonces se ajusta el modelo

$$w_k = f(\mathbf{x}_k, \beta) + \varepsilon_k,$$

   donde $f(\cdot)$ representa la relación funcional entre los pesos w_k y las covariables $\mathbf{x}_k$, a través de los coeficientes β.

2. Obtener los valores predichos del modelo para cada unidad de observación, de tal forma que:

$$\hat{w}_k = f(\mathbf{x}_k, \hat{\beta}).$$

   Estos valores representan la componente de los factores de expansión explicada por las covariables incluidas en el modelo.

3. Construir los pesos *q-weighted* dividiendo los factores de expansión originales por la estimación de su esperanza condicional en la muestra,

$$q_k = \frac{w_k}{\widehat{E}_s(w_k \mid \mathbf{x}_k)}. \tag{7.1}$$

   De esta forma, los nuevos pesos reflejan la variación residual de los factores de expansión una vez controlado el efecto de las covariables.

4. En la implementación ilustrativa de este capítulo, pasar los pesos ajustados q_k al argumento `weights` de `lmer()` y `glmer()`. Este paso no construye un objeto de diseño muestral ni incorpora por sí solo los pesos de selección por etapa o la estimación de varianza bajo el diseño complejo.

El siguiente código implementa el procedimiento de construcción de pesos *q-weighted* y fija `reference_age` en la mediana de la edad para representar los modelos lineales a una edad común. En primer lugar, ajusta un modelo de regresión lineal que explica los factores de expansión originales a partir del logaritmo del ingreso y la edad de la persona principal. De esta forma, los pesos resultantes conservan únicamente la componente de variación no explicada por las covariables incluidas en el modelo multinivel.

```
mod_qw <- lm(wk ~ log_income + Age, data = survey_data)
predicted_weights <- predict(mod_qw)
survey_data$qk <- survey_data$wk / predicted_weights
reference_age <- median(survey_data$Age)
```

El ajuste lineal de los factores de expansión según el logaritmo del ingreso y la edad constituye una aproximación para construir los pesos *q-weighted*. Para construir estos pesos, las predicciones deben ser finitas y estrictamente positivas. También debe evaluarse si el modelo representa adecuadamente $E_s(w_k \mid \mathbf{x}_k)$, pues una regresión lineal de los pesos puede producir predicciones no válidas. Además, el vector `qk` no necesariamente permite reconstruir por sí solo los pesos condicionales de cada etapa que requiere un modelo multinivel ponderado.

Para representar los modelos lineales de la siguiente sección, se utiliza `reference_age` como una edad común de la persona principal del hogar. Su valor se obtiene con `median(survey_data$Age)` y corresponde a 47 años. Al mantener fija la edad en las rectas de regresión, las comparaciones entre estratos describen la relación entre ingreso y gasto sin incorporar diferencias de edad entre los hogares representados. Esta referencia se aplica únicamente a la visualización: los modelos se estiman utilizando las edades observadas de todos los hogares.

7.3. Modelo lineal multinivel

Los modelos multinivel más utilizados en la práctica corresponden a extensiones del modelo lineal clásico para datos con estructura jerárquica. En su formulación básica, estos modelos asumen que la variable respuesta es continua y sigue una distribución normal condicional a los efectos fijos y aleatorios incluidos en el modelo. Asimismo, se supone que los efectos aleatorios y los errores residuales son independientes entre sí y se distribuyen normalmente con media cero y varianzas constantes.

En esta sección se modela el logaritmo del gasto mensual per cápita del hogar, representado por y_{kj}, donde k identifica al hogar y j al estrato. Los modelos con covariables incorporan el logaritmo del ingreso per cápita, representado por x_{kj}, y la edad de la persona principal como control. Por ello, las predicciones se obtienen inicialmente en la escala logarítmica. Al aplicarles la función exponencial, se regresa a las unidades monetarias del gasto, pero el resultado representa una media geométrica: una medida del gasto típico para hogares con esas características y ese efecto de estrato. Para estimar el gasto medio aritmético se requiere, además, considerar la variabilidad residual del modelo.

7.3.1. Modelo nulo

En el análisis de regresión multinivel, se distinguen dos tipos de parámetros: los coeficientes de regresión, conocidos como parámetros fijos, y los componentes de varianza asociados a los efectos aleatorios (Goldstein 2011; Rabe-Hesketh y Skrondal 2012, e). Una etapa inicial fundamental en este tipo de análisis consiste en descomponer la variabilidad total de la variable dependiente en los distintos niveles de la estructura jerárquica. En el contexto del ejemplo anterior, esta descomposición permite separar la variación del logaritmo del gasto en una componente atribuible a diferencias dentro de los estratos y otra asociada a diferencias entre estratos.

Según Snijders y Bosker (2011), el punto de partida para esta descomposición es el denominado modelo nulo, el cual no incorpora variables explicativas y se expresa como

$$y_{kj} = \beta_{0j} + \epsilon_{kj} \tag{7.2}$$

En donde y_{kj} denota el valor observado del logaritmo del gasto para la unidad k en el estrato j. El término β_{0j} representa el intercepto específico de cada estrato, capturando las diferencias en los niveles promedio de la variable entre grupos. Finalmente, ϵ_{kj} corresponde al error a nivel de unidad, el cual recoge la variabilidad no explicada dentro de cada estrato y se asume con media cero y varianza constante condicional al grupo.

A su vez, el intercepto por estrato puede descomponerse en una parte común a todos los estratos y una desviación específica de cada uno de ellos, de la siguiente forma:

$$\beta_{0j} = \gamma_{00} + \tau_{0j}$$

donde γ_{00} representa el intercepto promedio global y τ_{0j} es el efecto aleatorio para el intercepto que captura la desviación del estrato j, permitiendo modelar explícitamente la heterogeneidad entre estratos. Además, los componentes aleatorios del modelo se asumen distribuidos normalmente con media cero y varianzas específicas para cada nivel de la jerarquía. En particular, el efecto aleatorio asociado al intercepto por estrato cumple

$$\tau_{0j} \sim N\left(0, \sigma_\tau^2\right),$$

lo que implica que las desviaciones de cada estrato respecto al intercepto global se distribuyen alrededor de cero, con una variabilidad determinada por σ_τ^2. De manera análoga, el término de error a nivel de unidad sigue la distribución

$$\epsilon_{kj} \sim N\left(0, \sigma_\epsilon^2\right),$$

Donde σ_ϵ^2 representa la variabilidad residual dentro de los estratos. A partir de este modelo se define el coeficiente de correlación intraclase (ICC, por sus siglas en inglés), que cuantifica la proporción de la varianza total explicada por las diferencias entre estratos. Su definición se presenta a continuación:

$$\rho = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma_\epsilon^2} \tag{7.3}$$

De acuerdo con Bates et al. (2015), un valor elevado de ICC indica que una proporción importante de la variabilidad total de la variable de interés se debe a diferencias entre estratos, lo que sugiere la presencia de heterogeneidad relevante entre grupos y la necesidad de incorporar explícitamente dicha estructura en el modelo. En contraste, un ICC bajo implica que la variabilidad se concentra principalmente dentro de los estratos, los cuales presentan una mayor homogeneidad relativa entre sí.

Siguiendo con el análisis de la encuesta de ejemplo, cuando la variable de interés es el logaritmo del gasto, el modelo nulo constituye el punto de partida para cuantificar qué proporción de la variabilidad total se debe a diferencias entre estratos y qué proporción corresponde a diferencias entre hogares dentro de un mismo estrato.

La estimación de modelos multinivel en `R` se realiza mediante el paquete `lme4`. En particular, la función `lmer()` permite especificar los efectos aleatorios mediante expresiones de la forma `(efecto | grupo)`. En este contexto, la expresión `(1 | Stratum)` indica que el modelo incluye un intercepto

aleatorio para cada estrato. El valor `1` representa el intercepto del modelo, mientras que `Stratum` identifica la variable de agrupación.

Como advierte Carle (2009), en `lme4`, el argumento `weights` representa pesos previos que modifican la contribución residual, pero no implementa por sí solo la pseudo-verosimilitud multinivel con pesos de diseño por etapa ni la estimación de varianza del diseño. Por tanto, los modelos ponderados con `qk` que siguen deben interpretarse como una ilustración modelada, no como una solución general para inferencia de encuestas complejas; para ese propósito se requieren pesos escalados y software que los incorpore expresamente en la estimación multinivel. El siguiente código computacional ajusta el modelo nulo con intercepto aleatorio por estrato.

```
mod_null <- lmer(
  log_expenditure ~ (1 | Stratum),
  data = survey_data,
  weights = qk
)
```

Las tablas de coeficientes por estrato presentan las estimaciones condicionales del modelo. Cada fila identifica el estrato y el parámetro correspondiente. Los estadísticos de prueba y los valores-p de los efectos fijos corresponden a otro nivel de inferencia. El siguiente código computacional extrae los interceptos estimados por estrato y los organiza para su presentación.

```
coef_mod_null <- coef(mod_null)$Stratum
null_model_intercepts_table <- coef_mod_null %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(stratum, intercept = .data[["(Intercept)"]])

null_model_intercepts_table
```

Tabla 7.2.: Interceptos estimados por estrato bajo pesos q-weighted (modelo nulo, primeros 5 estratos)

Estrato	Intercepto (beta)
idStrt001	5.53
idStrt002	5.57
idStrt003	5.55
idStrt004	5.97
idStrt005	5.91

La tabla 7.2 presenta los interceptos estimados para los primeros 5 estratos a partir del modelo nulo. Por ejemplo, el intercepto del estrato idStrt001 es 5,527 y representa el valor esperado del logaritmo del gasto mensual per cápita en ese estrato. Como este modelo no incluye el ingreso ni otras covariables, no estima elasticidades. Su función es describir la variación del logaritmo del gasto entre estratos antes de incorporar los predictores.

El siguiente código computacional calcula la correlación intraclase a partir de los componentes de varianza del modelo nulo mediante `icc()` del paquete `performance` (Lüdecke et al. 2026). Este indicador cuantifica la proporción de la variabilidad total del logaritmo del gasto que puede atribuirse a diferencias entre estratos, constituyendo una medida de la dependencia existente entre observaciones pertenecientes a un mismo grupo. Los resultados obtenidos se presentan en la tabla 7.3.

```
null_model_icc_table <- performance::icc(mod_null) %>%
  as.data.frame()

null_model_icc_table
```

Tabla 7.3.: Correlación intraclase del modelo nulo (logaritmo del gasto por estrato)

CCI ajustado	CCI sin ajustar	Opcional
0.203	0.203	FALSE

La correlación intraclase estimada es de 0,203. Bajo esta descomposición del modelo, aproximadamente el 20 % de la variabilidad se atribuye al componente entre estratos. El modelo nulo no incluye predictores, por lo que el valor esperado del logaritmo del gasto per cápita es constante dentro de cada estrato e igual a su intercepto estimado.

7.3.2. Modelo con intercepto aleatorio

De acuerdo con Goldstein (2011) y Rabe-Hesketh y Skrondal (2012), el modelo multinivel más simple que incorpora covariables corresponde al modelo de intercepto aleatorio. En esta especificación, se asume que los efectos de las variables explicativas son comunes a todos los estratos, mientras que el nivel promedio de la variable respuesta puede variar entre ellos. El modelo se expresa como

$$y_{kj} = \beta_{0j} + \mathbf{x}_{kj}\beta + \epsilon_{kj} \tag{7.4}$$

En donde y_{kj} representa el valor observado de la variable respuesta para la unidad k perteneciente al estrato j, $\mathbf{x}_{kj}$ es el vector de covariables asociado a dicha unidad, β es el vector de coeficientes de regresión comunes a todos los estratos y ϵ_{kj} corresponde al error aleatorio a nivel de unidad.

Al igual que en el modelo nulo, el intercepto se modela como $\beta_{0j} = \gamma_{00} + \tau_{0j}$; en donde γ_{00} representa el intercepto promedio global y τ_{0j} es el efecto aleatorio asociado al estrato j, que mide la desviación de dicho estrato respecto al promedio general.

Los componentes aleatorios del modelo se asumen independientes y normalmente distribuidos, de manera que $\tau_{0j} \sim N(0, \sigma^2_\tau)$ y $\epsilon_{kj} \sim N(0, \sigma^2_\epsilon)$. Bajo estas condiciones, la variabilidad total de la variable respuesta puede descomponerse en una componente entre estratos, cuantificada por σ^2_τ, y una componente dentro de los estratos, representada por σ^2_ϵ.

El siguiente código ajusta un modelo multinivel de intercepto aleatorio, en donde el logaritmo del gasto per cápita (`log_expenditure`) se explica a partir del logaritmo del ingreso per cápita (`log_income`), controlando por la edad (`Age`) como efecto fijo común e incorporando además un

efecto aleatorio asociado al estrato (`Stratum`) y utilizando los pesos *q-weighted* almacenados en la variable `qk`. Una vez ajustado el modelo, se estima la correlación intraclase (ICC) a partir de los componentes de varianza estimados.

```
random_intercept_model <- lmer(
  log_expenditure ~ log_income + Age + (1 | Stratum),
  data = survey_data,
  weights = qk
)

random_intercept_model_icc <- performance::icc(random_intercept_model)
random_intercept_model_icc
```

Una vez controlados el logaritmo del ingreso per cápita y la edad, el ICC ajustado es 0,075. Esto indica que alrededor del 7,5 % de la variabilidad residual corresponde a diferencias entre estratos; el resto se observa entre hogares del mismo estrato. El valor es menor que en el modelo nulo, que no incluye covariables. Sin embargo, el ICC por sí solo no determina si conviene usar un modelo multinivel: también importa si los estratos son grupos adecuados para el análisis y qué muestran los diagnósticos del modelo. Los coeficientes estimados por estrato se presentan en la tabla 7.4.

La elasticidad común estimada del gasto respecto al ingreso es 0,559. Dentro de un mismo estrato y manteniendo constante la edad de la persona principal, un aumento del 1 % en el ingreso per cápita se asocia con un aumento aproximado del 0,559 % en el gasto per cápita típico, expresado mediante su media geométrica condicional. Para un aumento del 10 % en el ingreso, el cambio se calcula como $100[(1 + 0,10)^{\hat{\beta}} - 1]$, donde $\hat{\beta}$ es la elasticidad estimada. En este modelo, el resultado es 5,47 %. Esta interpretación describe una asociación, sin establecer causalidad. Los interceptos corresponden a un ingreso de una unidad monetaria y una edad de cero años; estos valores están fuera del rango observado, por lo que no deben interpretarse como el gasto habitual de los hogares.

El coeficiente de la edad es una semielasticidad y su estimación es -0,0017. Para iguales ingreso per cápita y estrato, un año adicional de edad se asocia con un cambio del -0,17 % en la media geométrica condicional del gasto. El signo negativo describe una asociación ajustada, sin implicar causalidad. El siguiente código computacional presenta en columnas separadas el intercepto, la elasticidad del ingreso y el coeficiente de edad para cada estrato.

```
random_intercept_coefficients_table <- coef(random_intercept_model)$Stratum %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(
    stratum,
    intercept = .data[["(Intercept)"]],
    income_elasticity = log_income,
    age_coefficient = Age
  )

random_intercept_coefficients_table
```

Tabla 7.4.: Interceptos, elasticidad del ingreso y coeficiente de edad por estrato (5 estratos)

Estrato	Intercepto	Elasticidad del ingreso	Coeficiente de edad
idStrt001	2.34	0.559	-0.002
idStrt002	2.34	0.559	-0.002
idStrt003	2.33	0.559	-0.002
idStrt004	2.40	0.559	-0.002
idStrt005	2.49	0.559	-0.002

En la tabla 7.4, el coeficiente de `log_income` se repite en los cinco estratos porque la elasticidad es común. Las diferencias de intercepto desplazan las rectas, pero no modifican la respuesta proporcional del gasto ante un cambio porcentual en el ingreso. Los interceptos no son elasticidades y el coeficiente de `Age` es una semielasticidad, dado que la edad se incorpora en años.

Para visualizar los resultados a una edad común en la submuestra de tres estratos definida anteriormente, el siguiente código computacional selecciona los coeficientes correspondientes del modelo ajustado.

```
estimated_coef <- inner_join(
  coef(random_intercept_model)$Stratum %>%
    tibble::rownames_to_column(var = "Stratum"),
  plot_data %>%
    select(Stratum) %>%
    distinct()
)
```

Las rectas se representan para una persona principal de 47 años, sumando al intercepto el producto del coeficiente de `Age` por `reference_age`. Los puntos muestran los datos observados de hogares con distintas edades, por lo que no son observaciones ajustadas a esa edad común. La figura 7.5, obtenida con el siguiente código computacional, muestra las rectas de regresión estimadas para cada estrato bajo el modelo de intercepto aleatorio. Se observa que las rectas comparten una misma pendiente, reflejando la asociación común entre el logaritmo del ingreso y el del gasto, pero difieren en su posición vertical debido a los interceptos específicos estimados para cada estrato.

```
ggplot(
  data = plot_data,
  aes(
    y = log_expenditure,
    x = log_income,
    colour = Stratum
  )
) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_abline(
    data = estimated_coef,
```

```
    mapping = aes(
      slope = log_income,
      intercept = `(Intercept)` + Age * reference_age,
      colour = Stratum
    )
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

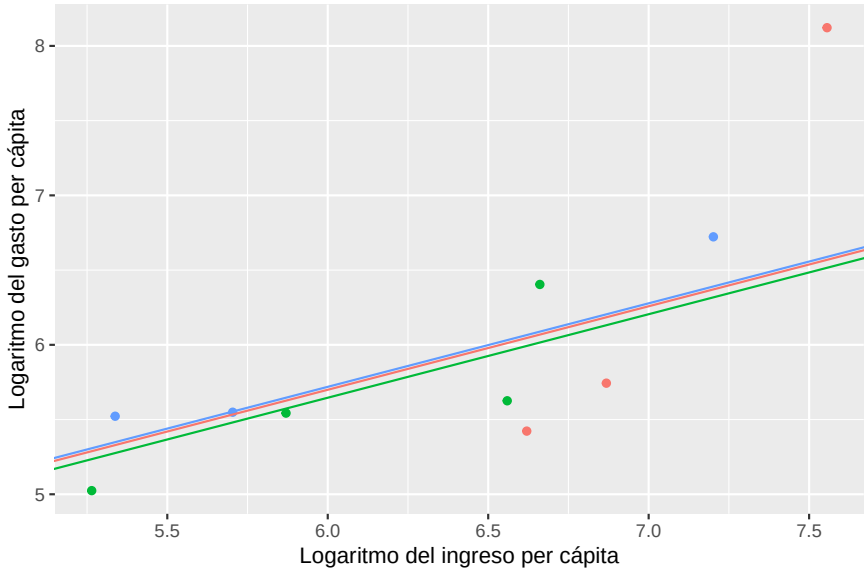


Figura 7.5.: Rectas de regresión estimadas por estrato: modelo con intercepto aleatorio

7.3.3. Modelo con intercepto y pendiente aleatoria

De acuerdo con Goldstein (2011) y Snijders y Bosker (2011), una extensión natural del modelo anterior es el modelo de intercepto y pendiente aleatorios. En esta especificación, no sólo se permite que el nivel promedio de la variable respuesta varíe entre estratos, sino también que el efecto de una o más covariables difiera entre grupos. De esta manera, cada estrato puede tener su propia recta de regresión, tanto en términos de intercepto como de pendiente. El modelo puede expresarse como

$$y_{kj} = \beta_{0j} + x_{kj}\beta_{1j} + \mathbf{z}_{kj}\beta + \epsilon_{kj}, \tag{7.5}$$

donde y_{kj} representa el valor observado de la variable respuesta para la unidad k perteneciente al estrato j, x_{kj} corresponde a la covariable cuya pendiente se permite variar entre estratos, $\mathbf{z}_{kj}$ contiene las covariables con efectos fijos comunes a todos los grupos, y ϵ_{kj} es el término de error a nivel de unidad. En este modelo, tanto el intercepto como la pendiente asociada a x_{kj} se consideran aleatorios y se descomponen de la siguiente forma:

$$\beta_{0j} = \gamma_{00} + \tau_{0j}, \qquad \beta_{1j} = \gamma_{10} + \tau_{1j}$$

donde γ_{00} y γ_{10} representan, respectivamente, el intercepto y la pendiente promedio en la población, mientras que τ_{0j} y τ_{1j} capturan las desviaciones específicas del estrato j respecto a dichos promedios. Estos efectos aleatorios se asumen normalmente distribuidos como se indica a continuación:

$$\begin{pmatrix} \tau_{0j} \\ \tau_{1j} \end{pmatrix} \sim N\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma^2_{\tau_0} & \sigma_{\tau_{01}} \\ \sigma_{\tau_{01}} & \sigma^2_{\tau_1} \end{pmatrix} \right),$$

mientras que el error a nivel de unidad satisface $\epsilon_{kj} \sim N(0, \sigma^2_\epsilon)$. En consecuencia, el modelo permite cuantificar no sólo la variabilidad entre estratos en los niveles promedio de la variable respuesta, sino también la heterogeneidad existente en el efecto de la covariable cuyo coeficiente se modela como aleatorio.

A continuación se ajusta un modelo multinivel con intercepto y pendiente aleatorios. El logaritmo del gasto per cápita (`log_expenditure`) se modela en función del logaritmo del ingreso per cápita (`log_income`), controlando por `Age` mediante un efecto fijo común. Tanto el intercepto como la pendiente del logaritmo del ingreso pueden variar entre estratos (`Stratum`). La estimación utiliza los pesos *q-weighted* almacenados en `qk`.

Nótese que en la especificación del código se incluye simultáneamente efectos fijos y efectos aleatorios para el intercepto y la variable `log_income`. Los términos ubicados fuera del paréntesis, `1 + log_income + Age`, corresponden a los efectos fijos del modelo y permiten estimar el intercepto promedio global, la pendiente promedio global asociada al logaritmo del ingreso y el coeficiente común de la edad. Por su parte, la expresión `(1 + log_income | Stratum)` incorpora las desviaciones específicas de cada estrato respecto a dichos promedios. La inclusión explícita de los efectos fijos es fundamental, ya que los efectos aleatorios se interpretan como desviaciones alrededor de una media poblacional.

```
random_slope_model <- lmer(
  log_expenditure ~ 1 + log_income + Age + (1 + log_income | Stratum),
  data = survey_data,
  weights = qk
)

random_slope_model
```

La elasticidad correspondiente al componente fijo de la pendiente es 0,561, mientras que las pendientes específicas de los estratos describen elasticidades condicionales del gasto respecto al ingreso, manteniendo constante la edad.

El coeficiente común de `Age` en este modelo es -0,0016; a iguales ingreso y estrato, un año adicional de edad se asocia con un cambio del -0,16 % en la media geométrica del gasto. Como la pendiente del ingreso varía entre estratos, la variabilidad entre ellos también depende del ingreso y no se resume en una única correlación intraclase. El siguiente código computacional presenta en columnas separadas el intercepto, la elasticidad del ingreso y el coeficiente de edad para cada uno de los primeros cinco estratos, como se muestra en la tabla 7.5.

```
random_slope_coefficients_table <- coef(random_slope_model)$Stratum %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(
    stratum,
    intercept = .data[["(Intercept)"]],
    income_elasticity = log_income,
    age_coefficient = Age
  )

random_slope_coefficients_table
```

Tabla 7.5.: Interceptos, elasticidades y coeficientes de edad del modelo con pendiente aleatoria por estrato (5 estratos)

Estrato	Intercepto	Elasticidad del ingreso	Coeficiente de edad
idStrt001	2.33	0.566	-0.002
idStrt002	2.50	0.532	-0.002
idStrt003	2.55	0.522	-0.002
idStrt004	2.16	0.600	-0.002
idStrt005	1.81	0.670	-0.002

En la tabla 7.5, cada fila corresponde a un estrato y permite comparar directamente sus tres coeficientes. La elasticidad del ingreso es específica de cada estrato: $\beta_{1j} = \gamma_{10} + \tau_{1j}$ combina la pendiente fija con la desviación aleatoria. Por ejemplo, para el estrato idStrt001, la elasticidad estimada es 0,566. Dentro de ese estrato y a igual edad, un ingreso 1 % mayor se asocia con un gasto aproximadamente 0,566 % mayor, expresado como media geométrica condicional. Entre todos los estratos, las elasticidades estimadas van de 0,213 a 0,826.

El siguiente código computacional selecciona los coeficientes del modelo con pendiente aleatoria correspondientes a los tres estratos de la submuestra utilizada en las ilustraciones.

```
estimated_coef <- inner_join(
  coef(random_slope_model)$Stratum %>%
    tibble::rownames_to_column(var = "Stratum"),
  plot_data %>%
    select(Stratum) %>%
    distinct()
)
```

Las rectas se calculan manteniendo la edad de la persona principal en 47 años; los puntos corresponden a los datos observados sin ajuste por edad. La figura 7.6, obtenida con el siguiente código computacional, presenta las rectas de regresión estimadas para cada estrato bajo el modelo de intercepto y pendiente aleatorios. A diferencia del modelo de intercepto aleatorio, en este caso las rectas pueden diferir tanto en su posición vertical como en su inclinación, de acuerdo con las variaciones estimadas para cada estrato.

```
ggplot(
  data = plot_data,
  aes(
    y = log_expenditure,
    x = log_income,
    colour = Stratum
  )
) +
  geom_point() +
  labs(x = "Logaritmo del ingreso per cápita",
       y = "Logaritmo del gasto per cápita") +
  geom_abline(
    data = estimated_coef,
    mapping = aes(
      slope = log_income,
      intercept = `(Intercept)` + Age * reference_age,
      colour = Stratum
    )
  ) +
  theme(
    legend.position = "none",
    plot.title = element_text(hjust = 0.5)
  )
```

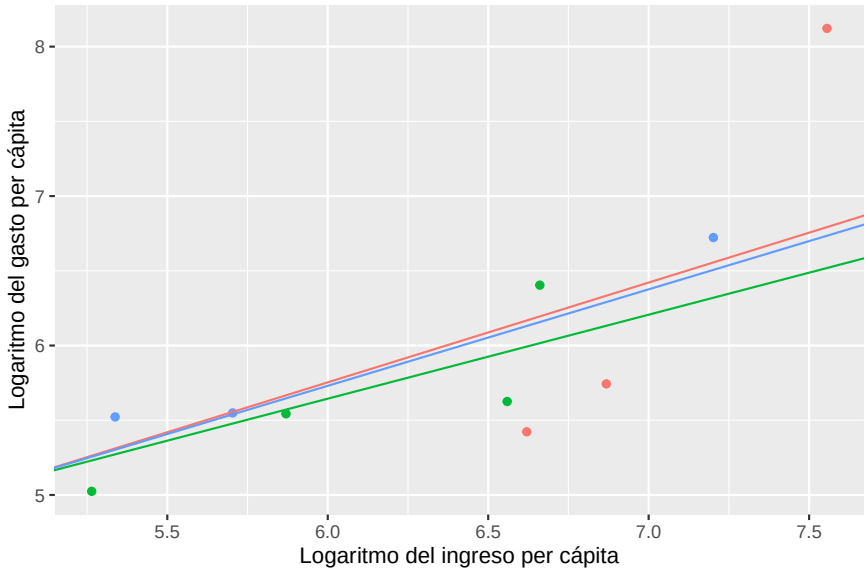


Figura 7.6.: Rectas de regresión estimadas por estrato: modelo con intercepto y pendiente aleatoria

7.4. Modelo logístico multinivel

En las secciones anteriores se modeló el gasto per cápita como una variable continua. Aquí el interés pasa a un resultado binario: la condición de pobreza del hogar. Un modelo logístico multinivel permite relacionar la probabilidad de pobreza con características del hogar y, a la vez, representar las diferencias entre estratos mediante efectos aleatorios. Para estimar estos modelos se preparan primero los pesos que se usarán en el análisis.

Para los modelos logísticos de esta sección se reconstruyen los pesos *q-weighted* utilizando el logaritmo del gasto per cápita y el tamaño del hogar como predictores, de acuerdo con su especificación. El siguiente código computacional realiza ese ajuste y calcula los pesos como el cociente entre `wk` y sus valores predichos, que deben ser finitos y positivos. También define `reference_household_size` como la mediana del tamaño del hogar, que se mantendrá fija al representar las probabilidades predichas.

```
logistic_weight_model <- lm(wk ~ log_expenditure + household_size, data = survey_data)
logistic_predicted_weights <- predict(logistic_weight_model)
survey_data$qk <- survey_data$wk / logistic_predicted_weights
reference_household_size <- median(survey_data$household_size)
```

De acuerdo con Snijders y Bosker (2011) y Rabe-Hesketh y Skrondal (2012), los modelos logísticos multinivel constituyen una extensión de los modelos multinivel para variables continuas al caso en que la variable respuesta es dicotómica. En lugar de modelar directamente el valor esperado de una variable continua, estos modelos estiman la probabilidad de ocurrencia de un evento, incorporando simultáneamente covariables individuales y efectos aleatorios asociados a los grupos de pertenencia. En el contexto de encuestas de hogares, esta formulación es especialmente útil cuando se analizan resultados binarios, como encontrarse o no en condición de pobreza, acceder o no a un servicio, participar o no en el mercado laboral, o presentar determinada característica sociodemográfica.

Al igual que en los modelos multinivel para variables continuas, el punto de partida consiste en reconocer que las unidades de observación no son independientes cuando pertenecen a un mismo grupo sustantivo. Como se advirtió al inicio, un estrato, conglomerado o dominio del diseño solo debe emplearse como nivel aleatorio cuando corresponda al contexto que se desea modelar y el supuesto de efectos intercambiables sea defendible. Sin embargo, en el caso logístico la respuesta no se representa mediante una distribución normal con un error residual aditivo, sino mediante una distribución Bernoulli condicional a la probabilidad de ocurrencia del evento. Esta probabilidad se vincula con los predictores a través de la función logit, lo que permite expresar el modelo en una escala lineal.

$$y_{kj} \mid \pi_{kj} \sim \text{Bernoulli}(\pi_{kj})$$

donde y_{kj} toma el valor uno si la unidad k del estrato j presenta el evento de interés y cero en caso contrario. La probabilidad condicional del evento se denota por $\pi_{kj} = Pr(y_{kj} = 1)$ y se relaciona con el predictor lineal mediante

$$\text{logit}(\pi_{kj}) = \log\left(\frac{\pi_{kj}}{1-\pi_{kj}}\right) = \eta_{kj}$$

En esta formulación, las *odds* son la razón $\pi_{kj}/(1-\pi_{kj})$ entre la probabilidad de pobreza y la de no pobreza. Los *log-odds* son el logaritmo natural de esa razón y coinciden con el logit, η_{kj}. Los efectos fijos y aleatorios actúan sobre esta escala, no directamente sobre la probabilidad. La transformación inversa, $\pi_{kj} = \exp(\eta_{kj})/[1+\exp(\eta_{kj})]$, permite obtener probabilidades. Por tanto, un cambio de una unidad en los log-odds no equivale a un cambio de un punto porcentual en la probabilidad. La figura 7.7, obtenida con el siguiente código computacional, presenta la relación entre el logaritmo del gasto per cápita y la probabilidad de pobreza, con una curva logística ajustada.

```
pooled_logit_model <- glm(
  poor ~ log_expenditure + household_size,
  data = survey_data,
  family = binomial(link = "logit")
)
pooled_prediction_data <- tibble(
  log_expenditure = seq(
    min(survey_data$log_expenditure),
    max(survey_data$log_expenditure),
    length.out = 100
  ),
  household_size = reference_household_size
) %>%
  mutate(
    probability = predict(
      pooled_logit_model,
      newdata = .,
      type = "response"
    )
  )
ggplot(pooled_prediction_data, aes(log_expenditure, probability)) +
  geom_line() +
  labs(y = "Probabilidad de pobreza", x = "Logaritmo del gasto per cápita")
```

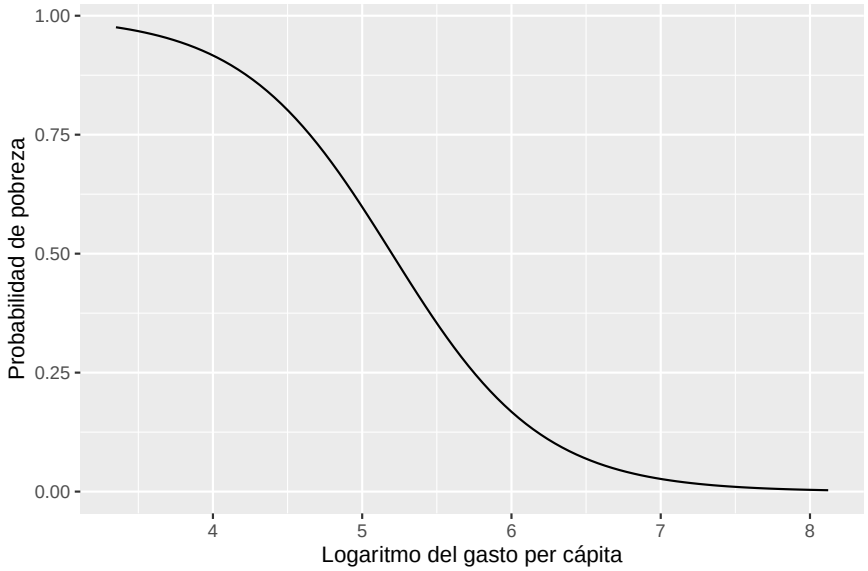


Figura 7.7.: Probabilidad de pobreza según el logaritmo del gasto, controlando por el tamaño del hogar

La curva ajustada corresponde a un modelo logístico sin efectos aleatorios ni ponderación, utilizado como referencia inicial. Manteniendo el tamaño del hogar en 4 integrantes, la probabilidad estimada de pobreza disminuye al aumentar el gasto per cápita. La inclusión del tamaño del hogar permite describir esta asociación comparando hogares con igual número de integrantes. Los modelos siguientes incorporan los estratos y los pesos ilustrativos *q-weighted*.

7.4.1. Modelo nulo logístico

Según Snijders y Bosker (2011), como en el caso de variables continuas, el modelo nulo logístico constituye el punto de partida para estudiar la estructura jerárquica de la variable respuesta. Este modelo no incorpora covariables y permite evaluar si la probabilidad promedio del evento varía entre estratos. En el ejemplo considerado, el evento de interés corresponde a la condición de pobreza, de modo que el modelo permite separar la heterogeneidad atribuible a diferencias entre estratos de la variación individual propia de una respuesta binaria.

En el modelo nulo, la variable de interés sigue la siguiente distribución Bernoulli:

$$y_{kj} \mid \pi_{kj} \sim \text{Bernoulli}(\pi_{kj})$$

En donde la probabilidad de éxito para la unidad k perteneciente al grupo j se modela mediante

$$\text{logit}(\pi_{kj}) = \beta_{0j}, \tag{7.6}$$

donde β_{0j} representa el intercepto específico del estrato j en escala logit. A su vez, dicho intercepto se descompone como

$$\beta_{0j} = \gamma_{00} + \tau_{0j}$$

siendo γ_{00} el intercepto promedio global de la población y τ_{0j} el efecto aleatorio asociado al estrato j, el cual captura las desviaciones de cada grupo respecto al promedio general. Al igual que en el modelo nulo para variables continuas, este efecto aleatorio permite modelar explícitamente la heterogeneidad entre grupos:

$$\tau_{0j} \sim N(0, \sigma_\tau^2)$$

De acuerdo con Merlo et al. (2006), a diferencia del modelo lineal multinivel, aquí no se incorpora un término residual aditivo ϵ_{kj} en la ecuación del nivel individual. La variabilidad interna en el grupo está determinada por la distribución Bernoulli de la respuesta. Para cuantificar la dependencia entre unidades pertenecientes al mismo estrato, puede utilizarse el enfoque de variable latente, bajo el cual esta varianza residual se aproxima por la varianza de la distribución logística estándar, es decir, $\pi^2/3$. Así, la correlación intraclase del modelo logístico se expresa como

$$\rho = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \frac{\pi^2}{3}} \tag{7.7}$$

Un valor elevado de ICC indica que la probabilidad del evento presenta una estructura de agrupamiento importante, es decir, que dos unidades pertenecientes al mismo estrato tienden a parecerse más entre sí que dos unidades tomadas de estratos distintos. En contraste, un valor bajo sugiere que la mayor parte de la variación se concentra a nivel individual. Este ICC es una medida en escala latente y no equivale directamente a una correlación de respuestas binarias observadas. El ajuste en `R`, mediante `glmer()`, se realiza de la siguiente manera:

```
logistic_null_model <- glmer(
  poor ~ (1 | Stratum),
  data = survey_data,
  weights = qk,
  family = binomial(link = "logit")
)

logistic_null_model_icc <- performance::icc(logistic_null_model)
logistic_null_model_icc
```

La correlación intraclase del modelo nulo logístico es de 0,056. Este valor resume la variación entre estratos en la escala latente del modelo; no representa una proporción de la varianza observada de las respuestas binarias. El siguiente código computacional extrae y organiza los interceptos por estrato del modelo logístico nulo.

```
null_logistic_intercepts_table <- coef(logistic_null_model)$Stratum %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(stratum, intercept = .data[["(Intercept)"]])
```

```
null_logistic_intercepts_table
```

Tabla 7.6.: Interceptos estimados por estrato en el modelo logístico nulo (primeros 5 estratos)

Estrato	Intercepto (beta)
idStrt001	-0.724
idStrt002	-0.504
idStrt003	-0.913
idStrt004	-1.002
idStrt005	-0.851

Los coeficientes del modelo nulo logístico por estrato se presentan en la tabla 7.6. Los interceptos de los primeros 5 estratos son negativos. Entre ellos, idStrt004 presenta el menor intercepto (aproximadamente -1,002), equivalente a una probabilidad de pobreza de 0,269; idStrt002 presenta el mayor (aproximadamente -0,504), equivalente a una probabilidad de 0,377. Estas probabilidades se obtienen aplicando la función logística a los interceptos.

7.4.2. Modelo logístico con intercepto aleatorio

De acuerdo con Snijders y Bosker (2011) y Rabe-Hesketh y Skrondal (2012), el modelo logístico con intercepto aleatorio incorpora covariables individuales o del hogar, permitiendo que el nivel base del evento varíe entre estratos. Su lógica es paralela a la del modelo con intercepto aleatorio para variables continuas: los efectos de las covariables se consideran comunes a todos los grupos, mientras que cada estrato puede tener su propio intercepto. En este caso, las diferencias entre interceptos se interpretan como diferencias en los *log-odds* base del evento.

El modelo se expresa como $y_{kj} \mid \pi_{kj} \sim \text{Bernoulli}(\pi_{kj})$. En donde $\text{logit}(\pi_{kj}) = \beta_{0j} + \mathbf{x}_{kj}\beta$ y $\beta_{0j} = \gamma_{00} + \tau_{0j}$. En este caso, $\mathbf{x}_{kj}$ representa el vector de covariables de la unidad k en el estrato j, β es el vector de efectos fijos comunes a todos los estratos y τ_{0j} captura la desviación específica del estrato respecto al intercepto promedio global. Como antes, se asume que $\tau_{0j} \sim N(0, \sigma^2_\tau)$.

Bajo esta especificación, dos estratos con los mismos valores de las covariables pueden presentar probabilidades base distintas del evento debido a sus interceptos aleatorios. Sin embargo, el efecto de cada covariable sobre la escala logit se mantiene constante entre estratos. En el ejemplo, esto equivale a permitir que la probabilidad base de pobreza cambie entre estratos, mientras que la asociación entre el logaritmo del gasto per cápita y la pobreza se estima controlando por el tamaño del hogar. Ambas pendientes son comunes a todos los estratos. El siguiente código computacional ajusta el modelo logístico con intercepto aleatorio y calcula su correlación intraclase.

```
random_intercept_logit_model <- glmer(
  poor ~ log_expenditure + household_size + (1 | Stratum),
  data = survey_data,
  family = binomial(link = "logit"),
  weights = qk
)
```

```
random_intercept_logit_model_icc <- performance::icc(random_intercept_logit_model)
random_intercept_logit_model_icc
```

Después de incorporar el logaritmo del gasto per cápita y el tamaño del hogar, la correlación intraclase ajustada es de 0,058. Este indicador resume el agrupamiento residual en la escala latente; su comparación con el modelo nulo no debe interpretarse como una proporción de variabilidad explicada por las covariables.

La tabla 7.7 presenta en columnas separadas los coeficientes comunes y los interceptos específicos de los primeros cinco estratos. Para iguales valores de gasto y tamaño del hogar, un intercepto mayor corresponde a una probabilidad más alta. El intercepto se refiere a un gasto de una unidad monetaria y un hogar de cero integrantes, valores ajenos a los perfiles observados; por ello, no representa una probabilidad habitual de pobreza. La columna OR condicional presenta la exponencial de cada pendiente. Se denomina condicional porque compara las odds de pobreza de dos hogares dentro del mismo estrato, manteniendo fijos los efectos aleatorios del estrato y las demás covariables. Por tanto, describe una asociación dentro del estrato y no un OR marginal obtenido al promediar las probabilidades sobre toda la población. Un OR menor que uno indica menores odds y uno mayor que uno indica mayores odds; no es una razón de probabilidades ni una diferencia en puntos porcentuales.

El coeficiente de `log_expenditure` representa la elasticidad de las odds de pobreza respecto al gasto, manteniendo constantes el tamaño del hogar y el efecto del estrato. Su estimación es -2,252. Manteniendo constantes el tamaño del hogar y el efecto del estrato, un aumento del 10 % en el gasto per cápita multiplica las odds de pobreza por $1.1^{\hat{\beta}}$, donde $\hat{\beta}$ es el coeficiente estimado de `log_expenditure`. En este modelo, el factor es 0,807. Es decir, las odds quedan en 80,7 % de su valor inicial. La reducción porcentual se calcula como $100[1-1.1^{\hat{\beta}}]$ y es aproximadamente 19,3 %.

El coeficiente del tamaño del hogar es 0,631. Para un mismo gasto per cápita y estrato, cada integrante adicional multiplica las odds por 1,879. Estas asociaciones no establecen causalidad y los cambios en las odds no equivalen a cambios porcentuales de igual magnitud en la probabilidad.

Para `household_size`, el OR corresponde a un integrante adicional, manteniendo constante el gasto per cápita. Para `log_expenditure`, corresponde a una unidad adicional del logaritmo natural, es decir, a multiplicar el gasto por e, manteniendo fijo el tamaño del hogar. Si se desea interpretar un aumento del 10 % en el gasto, el OR correspondiente es $\exp[\beta \log(1.1)] = 1.1^{\beta}$, como en el cálculo anterior. En este modelo, las pendientes son comunes a todos los estratos y, por ello, también lo son sus OR, aunque las probabilidades de partida difieran. Los interceptos llevan un guion en esta columna: su exponencial expresa odds de referencia y no un odds ratio. El siguiente código computacional dispone en columnas los coeficientes y sus OR condicionales para cada uno de los primeros cinco estratos.

```
random_logistic_intercept_coefficients_table <- coef(random_intercept_logit_model)$Stratum %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(
    stratum,
    intercept = .data[["(Intercept)"]],
    expenditure_coefficient = log_expenditure,
```

```
    household_size_coefficient = household_size,
    expenditure_or = exp(log_expenditure),
    household_size_or = exp(household_size)
  )

random_logistic_intercept_coefficients_table
```

Tabla 7.7.: Coeficientes y OR condicionales del modelo logístico con intercepto aleatorio (5 estratos)

Estrato	Intercepto (beta)	Log gasto (beta)	Tamaño hogar (beta)	OR log gasto	OR tamaño hogar
idStrt001	9.24	-2.25	0.631	0.105	1.879
idStrt002	9.46	-2.25	0.631	0.105	1.879
idStrt003	9.12	-2.25	0.631	0.105	1.879
idStrt004	9.24	-2.25	0.631	0.105	1.879
idStrt005	9.23	-2.25	0.631	0.105	1.879

El siguiente código computacional obtiene probabilidades predichas para los tres estratos seleccionados. `group_by(Stratum)` y `reframe()` generan, para cada estrato, una secuencia de 100 valores de `log_expenditure` entre su mínimo y su máximo observado, fijando `household_size` en `reference_household_size`. La función `predict()` utiliza esos valores y el efecto aleatorio del estrato para calcular las predicciones; con `type = "response"`, el resultado se expresa como probabilidad de pobreza.

```
prediction_data <- plot_data %>%
  group_by(Stratum) %>%
  reframe(
    log_expenditure = seq(
      min(log_expenditure),
      max(log_expenditure),
      length.out = 100
    ),
    household_size = reference_household_size
  ) %>%
  mutate(
    probability = predict(
      random_intercept_logit_model,
      newdata = .,
      type = "response"
    )
  )
```

La figura 7.8, obtenida con el siguiente código computacional, muestra las probabilidades predichas según el logaritmo del gasto para hogares de 4 integrantes en los tres estratos seleccionados. Las curvas son decrecientes y comparten una pendiente en la escala logit; sus diferencias reflejan los interceptos específicos de cada estrato.

```
ggplot(
  data = prediction_data,
  aes(
    y = probability,
    x = log_expenditure,
    colour = Stratum
  )
) +
  geom_line() +
  labs(y = "Probabilidad de pobreza", x = "Logaritmo del gasto per cápita") +
  theme(legend.position = "none")
```

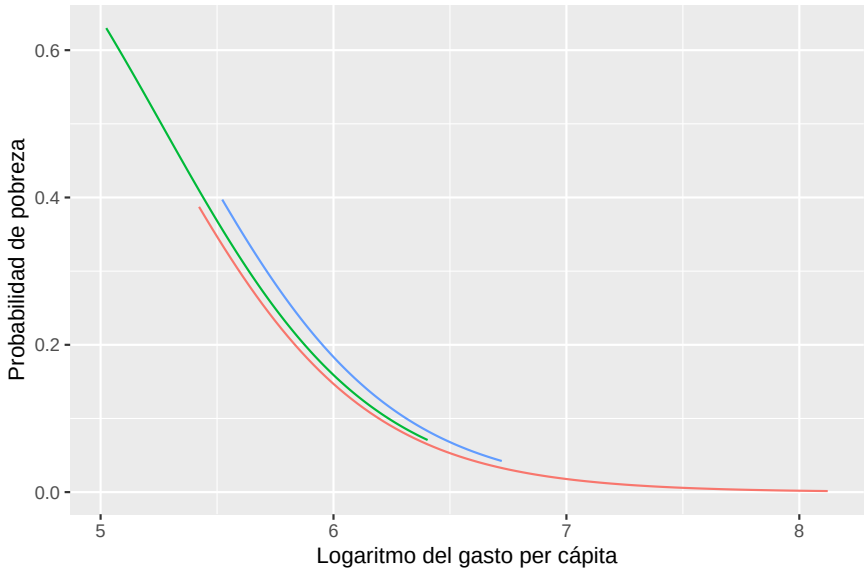


Figura 7.8.: Curvas de probabilidad predichas por estrato: modelo logístico con intercepto aleatorio

7.4.3. Modelo logístico con intercepto y pendiente aleatoria

El modelo logístico con intercepto y pendiente aleatoria extiende la especificación anterior permitiendo que no sólo varíe el nivel base del evento entre estratos, sino también el efecto de una covariable específica. Esta formulación es análoga al modelo de intercepto y pendiente aleatorios para variables continuas, con la salvedad de que las diferencias entre estratos se expresan en la escala logit y se traducen en curvas de probabilidad no lineales.

Sea x_{kj} la covariable cuyo efecto se permite variar entre estratos, y sea $\mathbf{z}_{kj}$ el conjunto de covariables con efectos fijos comunes. En este modelo, la probabilidad de éxito se asume de tal forma que $\text{logit}(\pi_{kj}) = \beta_{0j} + x_{kj}\beta_{1j} + \mathbf{z}_{kj}\beta$. En donde, β_{0j} es el intercepto específico del estrato j y β_{1j} es la pendiente específica asociada a la covariable x_{kj}.

Ambos parámetros se descomponen en una parte promedio poblacional y una desviación específica del estrato, de tal manera que $\beta_{0j} = \gamma_{00} + \tau_{0j}$ y $\beta_{1j} = \gamma_{10} + \tau_{1j}$. En donde los términos γ_{00} y γ_{10} representan, respectivamente, el intercepto promedio global y la pendiente promedio global en

escala logit. Por su parte, τ_{0j} y τ_{1j} capturan cuánto se aparta el estrato j de esos promedios. En este ejemplo, x_{kj} es el logaritmo del gasto per cápita, cuya pendiente varía entre estratos, y el tamaño del hogar se incorpora como covariable con efecto fijo común. El siguiente código computacional ajusta el modelo y calcula sus diagnósticos:

```
random_slope_logit_model <- glmer(
  poor ~ log_expenditure + household_size + (1 + log_expenditure | Stratum),
  data = survey_data,
  weights = qk,
  family = binomial(link = "logit")
)

random_slope_logit_model
```

La tabla 7.8 presenta los coeficientes y OR condicionales de los primeros cinco estratos en columnas separadas. Para el logaritmo del gasto, la pendiente del estrato j es $\beta_{1j} = \gamma_{10} + \tau_{1j}$, de modo que su OR es $\exp(\gamma_{10} + \tau_{1j})$. Se exponencia la pendiente completa que devuelve `coef()`, que combina el efecto fijo y la desviación aleatoria del estrato. Este OR compara hogares del mismo tamaño dentro de ese estrato y corresponde a multiplicar el gasto por e; para un aumento del 10 %, se utiliza $1.1^{\beta_{1j}}$. El OR del tamaño del hogar se mantiene común porque su pendiente es fija. Las diferencias entre los OR del gasto son estimaciones condicionales del modelo y deben interpretarse con cautela. El siguiente código computacional presenta en columnas separadas los coeficientes de cada estrato y los OR condicionales correspondientes.

```
random_logistic_slope_coefficients_table <- coef(random_slope_logit_model)$Stratum %>%
  tibble::rownames_to_column("stratum") %>%
  slice(1:5L) %>%
  transmute(
    stratum,
    intercept = .data[["(Intercept)"]],
    expenditure_coefficient = log_expenditure,
    household_size_coefficient = household_size,
    expenditure_or = exp(log_expenditure),
    household_size_or = exp(household_size)
  )

random_logistic_slope_coefficients_table
```

Tabla 7.8.: Coeficientes y OR condicionales del modelo logístico con pendiente aleatoria (5 estratos)

Estrato	Intercepto (beta)	Log gasto (beta)	Tamaño hogar (beta)	OR log gasto	OR tamaño hogar
idStrt001	9.17	-2.22	0.633	0.109	1.883
idStrt002	10.37	-2.40	0.633	0.090	1.883
idStrt003	7.94	-2.03	0.633	0.131	1.883
idStrt004	8.94	-2.19	0.633	0.112	1.883

Tabla 7.8.: Coeficientes y OR condicionales del modelo logístico con pendiente aleatoria (5 estratos)

Estrato	Intercepto (beta)	Log gasto (beta)	Tamaño hogar (beta)	OR log gasto	OR tamaño hogar
idStrt005	9.19	-2.22	0.633	0.108	1.883

El componente fijo de la elasticidad de las odds de pobreza respecto al gasto es -2,243. Las pendientes condicionales por estrato van de -2,803 a -1,824: todas son negativas en este ajuste. El coeficiente común del tamaño del hogar es 0,633. Cada pendiente específica representa la variación porcentual aproximada de las odds ante un aumento del 1 % en el gasto dentro del estrato, manteniendo fijo el tamaño del hogar. No representa una elasticidad constante de la probabilidad de pobreza.

El siguiente código computacional calcula las probabilidades para distintos valores del logaritmo del gasto dentro de cada estrato, manteniendo el tamaño del hogar en la misma mediana utilizada en el gráfico anterior.

```
prediction_data <- plot_data %>%
  group_by(Stratum) %>%
  reframe(
    log_expenditure = seq(
      min(log_expenditure),
      max(log_expenditure),
      length.out = 100
    ),
    household_size = reference_household_size
  ) %>%
  mutate(
    probability = predict(
      random_slope_logit_model,
      newdata = .,
      type = "response"
    )
  )
```

La figura 7.9, obtenida con el siguiente código computacional, muestra las curvas predichas para hogares de 4 integrantes. Las curvas descendentes reflejan la asociación negativa entre gasto per cápita y pobreza, controlando por tamaño del hogar.

```
ggplot(
  data = prediction_data,
  aes(
    y = probability,
    x = log_expenditure,
    colour = Stratum
  )
) +
  geom_line() +
```

```
  labs(
    y = "Probabilidad de pobreza",
    x = "Logaritmo del gasto per cápita"
  ) +
  theme(legend.position = "none")
```

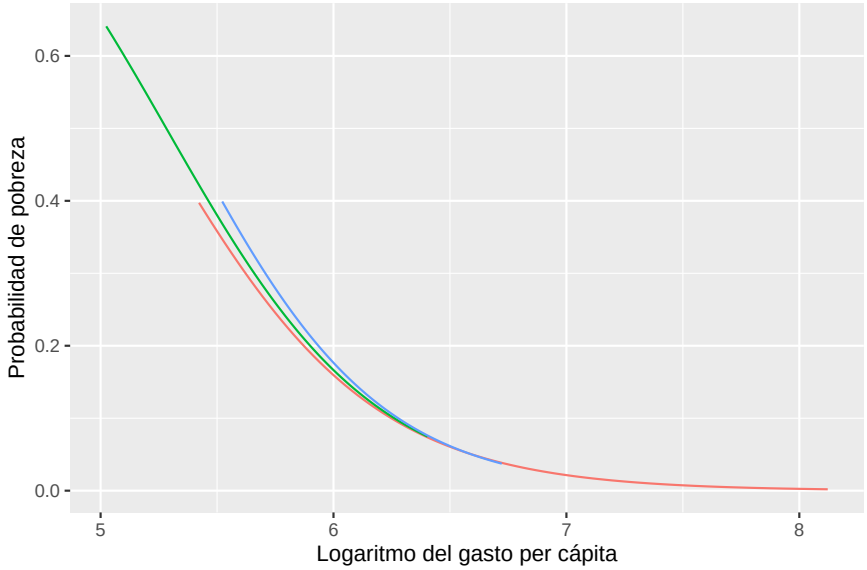


Figura 7.9.: Curvas de probabilidad predichas por estrato: modelo logístico con intercepto y pendiente aleatoria

Parte I.

Anexos

8. Manejo de bases de datos con R

R es un software estadístico ampliamente utilizado para el análisis de datos y la generación de gráficos y permite un ambiente integrado para el análisis estadístico, en particular de bases de datos (R Core Team 2026a). Esto significa que permite realizar procesos de análisis, programación, visualización y manejo de datos dentro de un mismo entorno. En este anexo se utiliza el enfoque del `tidyverse`, cuya organización de datos se relaciona con los principios expuestos por Wickham (2014), y en particular la librería `dplyr`, para organizar una secuencia lógica de trabajo con bases de datos: cargar la información, inspeccionarla, seleccionar variables, filtrar registros, ordenar filas, crear variables y producir resúmenes.

8.1. Preparación del entorno de trabajo

Dado que R es un lenguaje de programación de carácter colaborativo, permite que su comunidad de usuarios y desarrolladores contribuya continuamente mediante la creación de funciones, paquetes y librerías especializadas. Gracias a este ecosistema abierto, es posible ampliar sus capacidades para distintos tipos de análisis estadístico y procesamiento de datos. Entre las librerías más utilizadas para el análisis de bases de datos se encuentran las siguientes:

- la librería `tidyverse` corresponde a un conjunto de paquetes de R diseñados para apoyar distintas etapas del trabajo con datos, desde su importación y transformación hasta su exploración, análisis y visualización (Wickham, Averick, et al. 2026). Su uso se ha extendido ampliamente en ciencia de datos porque ofrece una forma de trabajo consistente y ordenada.
- la librería `dplyr` ofrece herramientas para organizar y transformar bases de datos rectangulares. Su utilidad radica en que reúne, en una sintaxis simple y consistente, las operaciones más frecuentes del trabajo analítico con datos: seleccionar variables, filtrar registros, crear nuevas columnas, ordenar observaciones y resumir información (Wickham, François, et al. 2026).

Antes de poder utilizar las diferentes funciones que cada librería tiene, es necesario descargarlas de antemano de la web. El comando `install.packages` permite realizar esta tarea. Note que algunas librerías pueden depender de otras, así que para poder utilizarlas es necesario instalar también las dependencias adicionales.

El siguiente código reúne los paquetes utilizados en los capítulos y apéndices del libro, incluidos los llamados mediante `paquete::función()`. La instalación se realiza una vez por equipo o biblioteca de R; `install.packages()` instala también las dependencias necesarias. El paquete `stats` forma parte de la instalación estándar de R, por lo que no se incluye en esta descarga.

```
install.packages(c(
  "biscale", "broom", "convey", "cowplot",
  "dotwhisker", "dplyr", "ggplot2", "ggstance",
  "gtools", "jtools", "knitr", "lme4",
  "patchwork", "performance", "reshape2", "sf",
  "srvyr", "survey", "svydiags", "svyVGAM",
  "TeachingSampling", "tibble", "tidyr", "tidyverse",
  "tmap"
))
```

Según Posit Software, PBC (2026), una vez instalados los paquetes, se cargan con `library()`. El primer comando limpia los objetos existentes en la sesión de trabajo, lo que ayuda a que los resultados del capítulo dependan solo del código que se ejecuta aquí. Debe tenerse en cuenta que un paquete solo puede cargarse si previamente ha sido instalado en el sistema. La opción `rm(list = ls())` no sustituye el inicio de una sesión limpia: para favorecer la reproducibilidad, conviene iniciar los proyectos con un espacio de trabajo vacío y ejecutar un guion completo y autosuficiente.

```
rm(list = ls())

library(biscale)
library(broom)
library(convey)
library(cowplot)
library(dotwhisker)
library(dplyr)
library(ggplot2)
library(ggstance)
library(gtools)
library(jtools)
library(knitr)
library(lme4)
library(patchwork)
library(performance)
library(reshape2)
library(sf)
library(srvyr)
library(stats)
library(survey)
library(svydiags)
library(svyVGAM)
library(TeachingSampling)
library(tibble)
library(tidyr)
library(tidyverse)
library(tmap)
```

El bloque anterior carga los paquetes en la sesión actual; debe ejecutarse de nuevo al iniciar una

sesión en la que se necesiten. En cada capítulo se cargan los paquetes correspondientes a sus ejemplos. Si dos paquetes ofrecen funciones con el mismo nombre, puede indicarse explícitamente cuál utilizar mediante `paquete::función()`, por ejemplo, `dplyr::select()`.

Una vez se descargan e instalan las librerías o paquetes en R, el paso recomendado es que todos los procesamientos se realicen mediante la creación de proyectos. Un proyecto de RStudio asocia un archivo `.Rproj` con un directorio de trabajo y guarda opciones del proyecto; los archivos de origen, datos y resultados permanecen como archivos separados dentro de ese directorio. Adicionalmente, contiene información que permite la compilación de cada archivo de R que se va a utilizar, mantiene la información para integrarse con sistemas de control de código fuente y ayuda a organizar la aplicación de los procesamientos en componentes lógicos.

8.2. Carga e inspección inicial de la base

De acuerdo con Wickham et al. (2023), es muy usual que al trabajar proyectos en R sea necesario importar bases de datos con información relevante para un estudio en particular. Los formatos que pueden importarse mediante R y sus paquetes son diversos; entre ellos se encuentran `.xlsx`, `.csv`, `.txt` y `.dta`, que es el formato utilizado por `Stata`. Una vez leída la base de datos en el formato pertinente es recomendable transformarla al formato nativo de R, es decir `.RDS`. Este es un formato más eficiente y propio de R, y su uso facilita la importación, la transformación y el almacenamiento dentro de un flujo reproducible de análisis.

Los ejemplos de procesamiento y visualización utilizan la base `BigCity` del paquete `TeachingSampling`. El siguiente código computacional la carga y crea una copia para trabajar con ella.

```
data(BigCity)
bigcity_data <- BigCity
```

Esta base corresponde a un conjunto de variables socioeconómicas de 150.266 personas en un año en particular.

El objeto `bigcity_data` contiene una copia de `BigCity`. El siguiente código computacional utiliza `head()` para mostrar sus primeras filas y obtener una impresión rápida de su estructura.

```
head(bigcity_data)
```

```
       HHID PersonID   Stratum     PSU  Zone    Sex Age MaritalST Income
1 idHH00001  idPer01 idStrt001 PSU0001 Rural   Male  38   Married    555
2 idHH00001  idPer02 idStrt001 PSU0001 Rural Female  40   Married    555
3 idHH00001  idPer03 idStrt001 PSU0001 Rural Female  20    Single    555
4 idHH00001  idPer04 idStrt001 PSU0001 Rural   Male  19    Single    555
5 idHH00001  idPer05 idStrt001 PSU0001 Rural   Male  18    Single    555
6 idHH00002  idPer01 idStrt001 PSU0001 Rural   Male  35   Married    298
  Expenditure Employment  Poverty
1         488   Employed  NotPoor
2         488   Employed  NotPoor
3         488   Inactive  NotPoor
```

```
4         488   Employed  NotPoor
5         488   Inactive  NotPoor
6         217   Employed Relative
```

Una primera revisión consiste en conocer las dimensiones de la base. El siguiente código computacional utiliza `nrow()` para obtener el número de registros y `ncol()` para obtener el número de variables.

```
nrow(bigcity_data)
```

```
[1] 150266
```

```
ncol(bigcity_data)
```

```
[1] 12
```

El siguiente código computacional consulta ambas dimensiones mediante `dim()`, que devuelve un vector con el número de filas en la primera posición y el número de columnas en la segunda.

```
dim(bigcity_data)
```

```
[1] 150266     12
```

En algunas ocasiones, las bases de datos pueden ser extensas, ya sea porque contienen un número considerable de variables observadas o porque el número de registros es grande. Por esta razón, para visualizarlas adecuadamente, puede ser conveniente abrirlas en una ventana independiente y explorar su contenido de forma tabular. Esto se realiza mediante la función `View`, como se muestra a continuación.

```
View(bigcity_data)
```

Para identificar las variables disponibles, el siguiente código computacional muestra sus nombres mediante `names()`.

```
names(bigcity_data)
```

```
 [1] "HHID"        "PersonID"    "Stratum"     "PSU"         "Zone"
 [6] "Sex"         "Age"         "MaritalST"   "Income"      "Expenditure"
[11] "Employment"  "Poverty"
```

La salida anterior muestra los nombres de las variables contenidas en la base de datos. En este caso, la base cuenta con 12 variables. Las primeras variables corresponden a identificadores y elementos del diseño muestral, como `HHID`, `PersonID`, `Stratum`, `PSU` y `Zone`. Luego aparecen variables sociodemográficas, como `Sex`, `Age` y `MaritalST`. Finalmente, se incluyen variables económicas y de condición laboral o social, como `Income`, `Expenditure`, `Employment` y `Poverty`.

Si se desea profundizar en el tipo de información que almacena cada variable, puede utilizarse la función `str`, la cual muestra de manera compacta la estructura de un objeto y sus componentes. Para nuestra base de datos, esta función se utilizaría de la siguiente manera:

```
str(bigcity_data)
```

```
'data.frame':   150266 obs. of  12 variables:
 $ HHID       : chr  "idHH00001" "idHH00001" "idHH00001" "idHH00001" ...
 $ PersonID   : chr  "idPer01" "idPer02" "idPer03" "idPer04" ...
 $ Stratum    : chr  "idStrt001" "idStrt001" "idStrt001" "idStrt001" ...
 $ PSU        : chr  "PSU0001" "PSU0001" "PSU0001" "PSU0001" ...
 $ Zone       : chr  "Rural" "Rural" "Rural" "Rural" ...
 $ Sex        : chr  "Male" "Female" "Female" "Male" ...
 $ Age        : int  38 40 20 19 18 35 29 14 13 6 ...
 $ MaritalST  : Factor w/ 6 levels "Partner","Married",..: 2 2 5 5 5 2 2 5 5 NA ...
 $ Income     : num  555 555 555 555 555 ...
 $ Expenditure: num  488 488 488 488 488 ...
 $ Employment : Factor w/ 3 levels "Unemployed","Inactive",..: 3 3 2 3 2 3 3 NA NA NA ...
 $ Poverty    : Factor w/ 3 levels "NotPoor","Extreme",..: 1 1 1 1 1 3 3 3 3 3 ...
```

Como se observa en la salida anterior, la función `str` permite identificar la clase de cada variable incluida en la base de datos. Por ejemplo, la variable `HHID` es de tipo carácter, al igual que la variable `Sex`, mientras que las variables `Income` y `Expenditure` son de tipo numérico. Los demás atributos asociados con las variables también pueden revisarse directamente en la salida del código. Esta función resulta especialmente útil para obtener una visión general del contenido y la estructura de una base de datos.

8.3. Encadenamiento de operaciones

Según Bache y Wickham (2026), una de las contribuciones más útiles de `R` es la incorporación de las tuberías (*pipelines*), las cuales permiten construir consultas, transformaciones y nuevos objetos a partir de una base de datos de manera más intuitiva, ordenada y fácil de interpretar. El operador de encadenamiento `%>%`, parte del paquete `magrittr` y cargado automáticamente al utilizar la librería `tidyverse`, permite enlazar varias operaciones sucesivas, de modo que el resultado obtenido en un paso se convierte en el insumo del paso siguiente. A continuación, se presenta un ejemplo sencillo de su uso con la base de datos `BigCity`, en el cual se calcula el número total de elementos que contiene la base mediante la función `count`.

```
bigcity_data %>%
  count()
```

```
       n
1 150266
```

La línea de código anterior puede interpretarse de forma sencilla: se toma la base de datos como punto de partida y, sobre ella, se realiza un conteo de sus registros. Además de la función `count`, existe una amplia variedad de funciones que pueden combinarse con el operador `%>%` para realizar consultas, transformaciones y resúmenes sobre los datos. El paquete `dplyr` toma ventaja de este operador, permitiendo organizar las operaciones más comunes sobre una base rectangular. En las siguientes subsecciones se presentan algunas de ellas, siguiendo un orden típico de trabajo: reducir observaciones, conservar variables, ordenar la información, crear nuevas columnas y producir resultados agregados.

8.3.1. `filter`: selección de registros

`filter()`, una de las funciones de transformación de `dplyr`, conserva las filas que cumplen una o varias condiciones. En el siguiente ejemplo se crean dos subconjuntos de `bigcity_data`: uno con los hombres y otro con las mujeres. El resultado son dos objetos nuevos. `male_data` contiene únicamente registros con `Sex == "Male"`, mientras que `female_data` contiene registros con `Sex == "Female"`.

```
male_data <- bigcity_data %>%
  filter(Sex == "Male")

female_data <- bigcity_data %>%
  filter(Sex == "Female")
```

El siguiente código computacional filtra la base por condición de pobreza y guarda en `nonpoor_data` los registros cuya variable `Poverty` toma el valor `"NotPoor"`, correspondiente a las personas no pobres.

```
nonpoor_data <- bigcity_data %>%
  filter(Poverty == "NotPoor")
```

La función `filter()` también permite conservar registros cuyos valores pertenecen a un conjunto específico. En los siguientes ejemplos se filtra por valores particulares de ingreso. Note que `%in%` evalúa si `Income` pertenece al conjunto indicado. Así, `working_data` conserva ingresos iguales a 265 o 600, y `income_filter_data` conserva ingresos iguales a 1000 o 2000.

```
working_data <- bigcity_data %>%
  filter(Income %in% c(265, 600))

income_filter_data <- bigcity_data %>%
  filter(Income %in% c(1000, 2000))
```

8.3.2. `select`: seleccionar variables

La función `select()` conserva columnas específicas. Para ilustrar esta operación, el siguiente código computacional retoma la base completa `bigcity_data` y se redefine `working_data`. Por tanto, este objeto ya no conserva el filtro de ingresos del ejemplo anterior. Se seleccionan variables de identificación de la persona y el hogar y otras como zona, sexo, edad e ingreso. El resultado es una base más reducida en columnas. Se mantiene `Age` porque será utilizada posteriormente para ordenar registros por edad.

```
working_data <- bigcity_data %>%
  dplyr::select(PersonID, HHID, PSU, Zone, Sex, Age, Income)
```

`select()` también permite excluir variables anteponiendo el signo menos (`-`) a sus nombres. El siguiente código computacional crea `compact_data` a partir de `working_data`, omitiendo las columnas de identificación `HHID` y `PersonID`.

```
compact_data <- working_data %>%
  dplyr::select(-HHID, -PersonID)
```

8.3.3. `arrange`: ordenamiento de filas

La función `arrange()` ordena las filas de una base según una o más variables. En el primer ejemplo, `working_data` se ordena de menor a mayor ingreso, mientras que `sorted_data` contiene las mismas columnas que `working_data`, pero sus filas quedan ordenadas por `Income`. La función `head()` muestra los primeros registros después del ordenamiento.

La base `BigCity` contiene registros a nivel de persona, por lo que un mismo `HHID` puede aparecer en varias filas, una por cada persona del hogar. `PersonID` identifica a la persona dentro de su hogar y puede repetirse en hogares distintos; por ello, la combinación `HHID` y `PersonID` identifica a cada persona. Estas repeticiones de `HHID` son parte de la estructura de la base y no indican por sí solas que haya filas duplicadas. El siguiente código computacional ordena `working_data` de menor a mayor ingreso y muestra las primeras filas del resultado.

```
sorted_data <- working_data %>%
  arrange(Income)

sorted_data %>%
  head()
```

```
  PersonID      HHID     PSU  Zone    Sex Age Income
1  idPer01 idHH01522 PSU0112 Rural Female  82   10.0
2  idPer01 idHH22167 PSU0112 Rural Female  82   10.0
3  idPer01 idHH10745 PSU0893 Rural   Male  68   11.9
4  idPer01 idHH31390 PSU0893 Rural   Male  68   11.9
5  idPer01 idHH17632 PSU1432 Rural   Male  58   12.1
6  idPer02 idHH17632 PSU1432 Rural Female  50   12.1
```

El ordenamiento también puede realizarse considerando más de una variable. En este ejemplo, la base se organiza primero según la variable `Sex` y, posteriormente, dentro de cada grupo, de acuerdo con la variable `Age`. La siguiente salida permite revisar los primeros registros después de aplicar este criterio de ordenamiento.

```
working_data %>%
  arrange(Sex, Age) %>%
  head()
```

```
  PersonID      HHID     PSU  Zone    Sex Age Income
1  idPer04 idHH00009 PSU0001 Rural Female   0    152
2  idPer04 idHH20654 PSU0001 Rural Female   0    152
3  idPer06 idHH00042 PSU0004 Rural Female   0    528
4  idPer06 idHH20687 PSU0004 Rural Female   0    528
5  idPer04 idHH00191 PSU0014 Urban Female   0    355
6  idPer04 idHH20836 PSU0014 Urban Female   0    355
```

Para ordenar los registros de mayor a menor, se utiliza la opción `desc()` dentro de la función `arrange()`. En el siguiente ejemplo, la base se organiza de manera que las personas con mayor edad aparezcan en los primeros registros. Este tipo de ordenamiento permite identificar rápidamente los valores más altos de una variable dentro de la base reducida.

```
working_data %>%
  arrange(desc(Age)) %>%
  head()
```

```
  PersonID      HHID     PSU  Zone    Sex Age Income
1  idPer02 idHH01024 PSU0076 Urban Female  98    135
2  idPer02 idHH21669 PSU0076 Urban Female  98    135
3  idPer01 idHH02916 PSU0219 Rural Female  98    137
4  idPer01 idHH23561 PSU0219 Rural Female  98    137
5  idPer01 idHH03863 PSU0290 Rural   Male  98    245
6  idPer01 idHH24508 PSU0290 Rural   Male  98    245
```

8.3.4. `mutate`: creación o transformación de variables

La función `mutate()` crea nuevas variables o modifica variables existentes. Dado que `BigCity` no incluye una variable de región geográfica explícita, se construye `Region` a partir de `Stratum`. Primero se extrae la parte numérica del estrato con `gsub("\\D", "", Stratum)`, luego se convierte a número con `as.numeric()` y finalmente se divide en cinco intervalos con `cut()`. El resultado es una nueva columna `Region` dentro de `bigcity_data`, en la que sus categorías permiten producir resúmenes regionales en los pasos siguientes. Esta variable es únicamente una recodificación didáctica de los identificadores numéricos de `Stratum`; no debe interpretarse como una región geográfica observada ni emplearse como tal en un análisis sustantivo.

```
bigcity_data <- bigcity_data %>%
  mutate(
    Region = cut( as.numeric(gsub("\\D", "", Stratum)), breaks = 5, labels = c("North", "South"
  )
```

En el análisis de bases de datos también es frecuente recodificar variables categóricas. El siguiente código crea `region_id`, una versión codificada de `Region` que conserva el orden de las regiones y asigna códigos de dos dígitos. Esta forma de recodificación facilita la presentación o el cruce con otras fuentes de información.

```
bigcity_data <- bigcity_data %>%
  mutate(
    region_id = factor(
      Region,
      levels = c("North", "South", "Center", "West", "East"),
      labels = c("01", "02", "03", "04", "05")
    )
  )
```

El siguiente ejemplo crea `log_income`, que corresponde al logaritmo natural del ingreso (transformación de la escala del ingreso). Esta operación se usa con frecuencia cuando una variable monetaria presenta alta dispersión. Luego se muestran las primeras filas de las variables relevantes. Como el logaritmo no está definido para ingresos iguales o menores que cero, esos casos se convierten explícitamente en valores faltantes antes de calcular la transformación.

```
log_income_data <- working_data %>%
  mutate(
    log_income = if_else( Income > 0, log(Income), NA_real_ )
  )

log_income_data %>%
  dplyr::select(PersonID, Income, log_income) %>%
  head()
```

```
  PersonID Income log_income
1  idPer01    555       6.32
2  idPer02    555       6.32
3  idPer03    555       6.32
4  idPer04    555       6.32
5  idPer05    555       6.32
6  idPer01    298       5.70
```

Note que `mutate()` puede crear más de una variable en el mismo paso. Además, las variables creadas al inicio de `mutate()` pueden ser utilizadas en cálculos posteriores dentro del mismo llamado. Por ejemplo, `income_2` duplica el ingreso original e `income_4` duplica `income_2`. La siguiente salida muestra que `income_4` equivale a cuatro veces el ingreso inicial.

```r
income_transform_data <- log_income_data %>%
  mutate(
    income_2 = 2 * Income,
    income_4 = 2 * income_2
  )

income_transform_data %>%
  dplyr::select(PersonID, income_2, income_4) %>%
  head()
```

```
  PersonID income_2 income_4
1  idPer01     1110     2220
2  idPer02     1110     2220
3  idPer03     1110     2220
4  idPer04     1110     2220
5  idPer05     1110     2220
6  idPer01      597     1193
```

8.3.5. `summarise`: resúmenes descriptivos

De acuerdo con Heeringa et al. (2017), la función `summarise()` permite construir una tabla resumen a partir de una o varias variables de la base de datos. En el siguiente ejemplo se calculan dos estadísticas descriptivas de la variable `Income`: el total y la media. Como resultado, se obtiene una tabla con una sola fila que contiene la suma de los ingresos observados y el ingreso promedio de los registros incluidos en la base. Estos cálculos no incorporan pesos, estratos ni conglomerados; por tanto, describen los registros de `BigCity`, pero no deben interpretarse como estimaciones de una población obtenidas bajo un diseño muestral complejo.

```r
bigcity_data %>%
  summarise(
    total_income = sum(Income),
    mean_income = mean(Income)
  )
```

```
  total_income mean_income
1     87893117         585
```

También pueden calcularse medidas de localización para describir la posición de los valores dentro de la distribución. El siguiente código computacional obtiene la mediana, el primer decil, el noveno decil y la diferencia entre estos dos últimos. El resultado permite resumir distintos puntos de la distribución del ingreso, mientras que el rango decílico muestra la distancia entre el 10 % inferior y el 10 % superior de los ingresos observados.

```
bigcity_data %>%
  summarise(
    median_income = median(Income),
    decile_1 = quantile(Income, 0.1),
    decile_9 = quantile(Income, 0.9),
    decile_range = decile_9 - decile_1
  )
```

```
  median_income decile_1 decile_9 decile_range
1           449      165     1126          961
```

El siguiente código computacional utiliza `summarise()` para calcular medidas de dispersión: la varianza, la desviación estándar, el valor mínimo, el valor máximo, el rango y el rango intercuartílico. Estas estadísticas permiten describir el grado de variabilidad del ingreso per cápita entre los registros de `BigCity`. En particular, el rango se obtiene como la diferencia entre el valor máximo y el valor mínimo, mientras que el rango intercuartílico resume la dispersión del 50 % central de la distribución.

```
bigcity_data %>%
  summarise(
    variance_income = var(Income),
    sd_income = sd(Income),
    min_income = min(Income),
    max_income = max(Income),
    range_income = max_income - min_income,
    iqr_income = IQR(Income)
  )
```

```
  variance_income sd_income min_income max_income range_income iqr_income
1          332463       577         10      32920        32910        468
```

8.3.6. `group_by`: agrupación de casos

La función `group_by()` permite agrupar la base de datos de acuerdo con una o más variables. Al combinarla con `summarise()`, las estadísticas se calculan de manera independiente dentro de cada grupo definido. En el siguiente ejemplo, se cuenta el número de registros por región y luego se ordena el resultado de mayor a menor. La siguiente salida permite identificar cuántos registros están asociados con cada región de la base de datos.

```
bigcity_data %>%
  group_by(Region) %>%
  summarise(n = n()) %>%
  arrange(desc(n))
```

```
# A tibble: 5 x 2
  Region     n
  <fct>  <int>
1 East   39160
2 West   33868
3 Center 25944
4 South  25898
5 North  25396
```

Para los conteos simples, `count()` ofrece una forma abreviada de escribir la combinación entre `group_by()` y `summarise(n = n())`. En la práctica, ambas alternativas producen el mismo resultado, pues agrupan la base de datos según una variable categórica y calculan cuántos registros pertenecen a cada grupo. Por ejemplo, el siguiente código reproduce los mismos resultados que el código anterior.

```
bigcity_data %>%
  count(Region) %>%
  arrange(desc(n))
```

```
  Region     n
1   East 39160
2   West 33868
3 Center 25944
4  South 25898
5  North 25396
```

La misma lógica de agrupación y conteo permite conocer cuántos registros corresponden a cada sexo. El siguiente código computacional agrupa la base por `Sex` y cuenta las observaciones de cada categoría.

```
bigcity_data %>%
  count(Sex) %>%
  arrange(desc(n))
```

```
     Sex     n
1 Female 79190
2   Male 71076
```

El conteo también puede realizarse según la zona geográfica. En este caso, la base se agrupa por la variable `Zone` y se calcula el número de registros correspondiente a cada una de sus categorías. La siguiente salida permite conocer cómo se distribuyen las observaciones entre las distintas zonas de la base de datos.

```
bigcity_data %>%
  count(Zone) %>%
  arrange(desc(n))
```

```
   Zone     n
1 Urban 78164
2 Rural 72102
```

Además de los conteos, pueden calcularse medidas resumen por grupo. El siguiente código computacional agrupa la base por `Region` y utiliza `summarise()` para obtener el número de registros y el ingreso medio de cada región.

```
bigcity_data %>%
  group_by(Region) %>%
  summarise(
    n = n(),
    mean_income = mean(Income)
  )
```

```
# A tibble: 5 x 3
  Region     n mean_income
  <fct>  <int>       <dbl>
1 North  25396        509.
2 South  25898        644.
3 Center 25944        701.
4 West   33868        571.
5 East   39160        530.
```

El siguiente código computacional aplica el mismo procedimiento por sexo: agrupa la base por `Sex` y calcula el promedio de `Income` para comparar el ingreso medio de cada categoría.

```
bigcity_data %>%
  group_by(Sex) %>%
  summarise(
    n = n(),
    mean_income = mean(Income)
  )
```

```
# A tibble: 2 x 3
  Sex        n mean_income
  <chr>  <int>       <dbl>
1 Female 79190        579.
2 Male   71076        591.
```

Por último, se calculan la media, la desviación estándar y el rango intercuartílico de los ingresos según la condición de ocupación. Para ello, la base se agrupa por la variable `Employment` y luego se obtienen las estadísticas descriptivas de `Income` dentro de cada grupo. La siguiente salida presenta un resumen del comportamiento de los ingresos para cada categoría de ocupación.

```r
bigcity_data %>%
  group_by(Employment) %>%
  summarise(
    n = n(),
    mean_income = mean(Income),
    sd_income = sd(Income),
    iqr_income = IQR(Income)
  )
```

```
# A tibble: 4 x 5
  Employment     n mean_income sd_income iqr_income
  <fct>      <int>       <dbl>     <dbl>      <dbl>
1 Unemployed  4630        429.      375.       392.
2 Inactive   44104        532.      553.       439.
3 Employed   62188        661.      606.       529.
4 <NA>       39344        541.      558.       407.
```

9. Inferencia en poblaciones finitas

La inferencia estadística con datos provenientes de encuestas por muestreo requiere reconocer que la aleatoriedad puede tener orígenes distintos. En la inferencia estadística clásica, las observaciones suelen concebirse como realizaciones de un modelo probabilístico que genera los datos. En la teoría de muestreo, en cambio, la población finita se considera fija y la aleatoriedad proviene del mecanismo mediante el cual se seleccionan las unidades que conforman la muestra (Gutiérrez 2016). Esta distinción resulta fundamental cuando se analizan encuestas con diseños complejos.

Este capítulo desarrolla ambos marcos inferenciales y muestra posteriormente cómo pueden integrarse. Primero se presenta la diferencia entre la inferencia basada en modelos y la inferencia basada en el diseño, utilizando ejemplos y simulaciones que permiten identificar las fuentes de aleatoriedad involucradas y observar las consecuencias de ignorar las probabilidades de selección. A continuación, se introduce la idea de inferencia doble, en la cual intervienen simultáneamente el modelo de superpoblación que genera los valores de las variables y el diseño probabilístico que determina cuáles unidades son observadas. Sobre esta base se revisan los principios de máxima verosimilitud y máxima pseudo-verosimilitud, mostrando cómo los pesos de muestreo pueden incorporarse directamente en las ecuaciones de estimación.

Los resultados desarrollados en este capítulo constituyen la base inferencial para el análisis apropiado de modelos estadísticos con datos de encuestas complejas. En particular, permiten comprender por qué la incorporación de los pesos de muestreo y de la estructura del diseño no debe limitarse a la estimación de medias, totales o proporciones, sino extenderse también a modelos de regresión lineal, modelos lineales generalizados y modelos multinivel. La máxima pseudo-verosimilitud proporciona un vínculo natural entre la teoría del muestreo y la estimación de estos modelos, al modificar las contribuciones individuales a las ecuaciones de estimación de acuerdo con las probabilidades de inclusión. Esta perspectiva permite comprender los procedimientos de estimación e inferencia utilizados en los capítulos de regresión, modelos lineales generalizados y modelos multinivel, considerando tanto el modelo estadístico como la forma en que se seleccionaron los datos.

9.1. Dos posibles inferencias

Según Särndal et al. (2003), en encuestas de hogares conviene distinguir tres objetos. Primero, la población finita, denotada como $U = \{1, 2, \ldots, N\}$, la cual contiene todas las unidades de interés. Segundo, la variable de estudio y_k, observada o definida para cada unidad $k \in U$. Tercero, el diseño muestral $p(s)$, que asigna probabilidades a las posibles muestras $s \subset U$. En la notación utilizada a lo largo de este documento, una unidad puede identificarse como k dentro del conglomerado o UPM i, perteneciente al estrato h, de modo que los estimadores ponderados suelen escribirse como sumas de la forma

$$\hat{t}_y = \sum_h \sum_i \sum_k w_{hik}\ y_{hik}$$

donde w_{hik} representa el factor de expansión o peso muestral asociado con la unidad observada. En la teoría de muestreo, los valores y_k se consideran fijos una vez definida la población. La aleatoriedad no está en los valores de la variable, sino en los indicadores de inclusión

$$I_k = \begin{cases} 1, & \text{si } k \in s, \\ 0, & \text{si } k \notin s, \end{cases}$$

que inducen la probabilidad de inclusión $\pi_k = \Pr_p(I_k = 1)$ y, a su vez, el correspondiente peso de muestreo, definido como $w_k = \frac{1}{\pi_k}$.

Un estimador que ignora los pesos de muestreo puede no representar adecuadamente a la población objetivo, especialmente cuando la muestra proviene de un diseño complejo. En la inferencia basada en el diseño, la población se considera fija y la fuente de aleatoriedad proviene del mecanismo de selección de la muestra; por ello, sus elementos centrales son las probabilidades de inclusión π_k y los pesos de muestreo w_k.

La inferencia basada en modelos considera que los valores de la variable de interés en toda la población se conciben como realizaciones de un proceso estocástico, usualmente denotado por ξ, y por ende la característica de interés se convierte en una variable aleatoria (Y_k). Entonces, en la inferencia basada en los modelos es de interés estudiar propiedades como $E_\xi(Y_k)$ y $Var_\xi(Y_k)$. A diferencia de la inferencia basada en el diseño, que se orienta a incorporar las características del plan muestral en los estimadores.

La inferencia basada en el diseño garantiza la existencia de estimadores que son exacta o aproximadamente insesgados. En particular, el estimador de Horvitz–Thompson satisface $E_p(\hat{t}_y) = t_y$ bajo probabilidades de inclusión positivas. De acuerdo con Binder (2011), esta distinción permite entender por qué, aun cuando exista un modelo razonable para la variable de interés, el diseño muestral debe incorporarse explícitamente si se desea obtener inferencias válidas para la población objetivo.

Para comprender la distinción entre inferencia basada en el modelo e inferencia basada en el diseño, partimos de un ejemplo sencillo. Supóngase que se generan $N = 100$ realizaciones independientes de una variable Bernoulli con parámetro $\theta = 0.3$, donde θ representa la proporción esperada de personas con una característica particular en una población generada por un modelo ξ. Asumiendo que $Y_k \sim Bernoulli(\theta)$, entonces bajo el modelo se tiene que $E_\xi(Y_k) = \theta$ y además $Var_\xi(Y_k) = \theta(1-\theta)$.

En la literatura especializada, el modelo ξ recibe el nombre de modelo de superpoblación, pues se asume que es un proceso generador de poblaciones finitas. De esta forma, para una población finita generada por ese modelo, la media poblacional es $\bar{Y}_U = \frac{1}{N}\sum_{k\in U} Y_k$. Nótese que, bajo el modelo ξ, esta media es insesgada para θ, puesto que

$$E_\xi(\bar{Y}_U) = E_\xi\left(\frac{1}{N}\sum_{k\in U} Y_k\right) = \frac{1}{N}\sum_{k\in U} E_\xi(Y_k) = \theta.$$

La siguiente simulación de Monte Carlo reproduce este proceso. En cada repetición se genera una población completa de tamaño $N = 100$ y se calcula su media. El promedio de esas medias poblacionales debe aproximarse a θ.

```r
set.seed(2026)
population_size <- 100
theta <- 0.3
n_sim_model <- 1000
model_estimates <- rep(NA, n_sim_model)

for (sim in seq_len(n_sim_model)) {
  outcome <- rbinom(population_size, 1, theta)
  model_estimates[sim] <- mean(outcome)
}

cbind(
  theta,
  expected_model_mean = mean(model_estimates),
  bias = mean(model_estimates) - theta
)
```

```
     theta expected_model_mean    bias
[1,]   0.3               0.302 0.00225
```

El código fija una semilla para que el ejercicio sea reproducible. Luego genera `n_sim_model` poblaciones independientes mediante `rbinom()`. La salida reporta el parámetro verdadero `theta`, el promedio de las medias simuladas `expected_model_mean` y el sesgo Monte Carlo. Como se espera bajo el modelo Bernoulli IID, `expected_model_mean` queda muy cerca de 0,3 y el sesgo es cercano a cero. Las pequeñas diferencias se deben a que se usan 1.000 simulaciones, no un número infinito de repeticiones.

En la teoría de muestreo, en cambio, las características de interés son parámetros fijos de la población. por ejemplo, si una persona está desempleada, su estado se considera un valor fijo de la población finita. Lo aleatorio es el mecanismo mediante el cual se selecciona la muestra. El total poblacional se define como $t_y = \sum_{k \in U} y_k$, mientras que la media poblacional es $\bar{y}_U = \frac{t_y}{N}$. Si se observa una muestra s, se propone estimar el total como

$$\hat{t}_y = \sum_{k \in s} \frac{y_k}{\pi_k} = \sum_{k \in s} w_k y_k.$$

Como se mencionó en los capítulos anteriores, cuando el tamaño poblacional N es desconocido, la media poblacional puede estimarse mediante el estimador de razón ponderado, definido como

$$\hat{\bar{y}} = \frac{\sum_{k \in s} w_k y_k}{\sum_{k \in s} w_k}$$

Estos estimadores incorporan las probabilidades de inclusión en su forma funcional y esa es la diferencia central frente al promedio simple no ponderado de una muestra (Cochran 1977).

Para ilustrar el impacto del diseño, supóngase que la población anterior se encuentra particionada en N_I unidades primarias de muestreo (UPM). De esta forma, se asume que la UPM i tiene tamaño N_i,

total $t_{y_i} = \sum_{k \in U_i} y_{ik}$ y media $\bar{y}_i = t_{y_i}/N_i$. Bajo un diseño de tamaño fijo que asigna probabilidades de inclusión de primer orden proporcionales a N_i, siempre que todas sean postivas y menores o iguales que uno. Estas probabilidades toman la siguiente forma:

$$\pi_{Ii} = \frac{n_I N_i}{N}$$

Cuando todos los miembros de las UPM seleccionadas son observados, el estimador de Horvitz–Thompson de la media poblacional es exactamente insesgado bajo las probabilidades de inclusión anteriores y puede escribirse como

$$\hat{\bar{y}} = \frac{1}{N} \sum_{i \in S_I} \frac{t_{y_i}}{\pi_{Ii}} = \frac{1}{N} \sum_{i \in S_I} \frac{N_i \bar{y}_i}{n_I N_i / N} = \frac{1}{n_I} \sum_{i \in S_I} \bar{y}_i.$$

Esta expresión ejemplifica por qué, bajo este diseño específico de selección proporcional al tamaño, el promedio de las medias de los conglomerados brinda insesgamiento. En contraste, el promedio simple de las personas observadas en las UPMs seleccionadas, sería:

$$\bar{y}_s = \frac{\sum_{i \in S_I} t_{y_i}}{\sum_{i \in S_I} N_i},$$

el cual trata la muestra como si fuera autoponderada. Este estimador es sesgado cuando las probabilidades de selección son desiguales, especialmente si el tamaño del conglomerado se relaciona con la variable de interés.

En este ejemplo artificial, cada hogar constituye un conglomerado y actúa como unidad primaria de muestreo. Se seleccionan hogares con probabilidades proporcionales a su tamaño y se observan todas las personas que los integran. En esta simulación, todas las personas de la población artificial pertenecen a la fuerza de trabajo; por tanto, la media de la indicadora de desocupación representa la tasa de desocupación. Este universo simulado es independiente de `sample.rds` y de su dominio `labor_force_subset`. La siguiente simulación fija una población finita y repite muchas veces la selección de hogares con probabilidades proporcionales al tamaño mediante `S.piPS()` del paquete `TeachingSampling`. En cada muestra se calculan dos estimadores: `design_estimates`, que corresponde a $\hat{\bar{y}}$, y `simple_estimates`, que corresponde al promedio simple de las personas observadas en las UPMs seleccionadas, $\bar{y}_s$. Además, estos estimadores se comparan con la tasa poblacional `unemployment_rate_population`, calculada sobre la realización finita generada con el modelo.

```
library(TeachingSampling)

set.seed(2026)
population_size <- 100
theta <- 0.3
n_sim_sampling <- 1000
design_estimates <- simple_estimates <- rep(NA, n_sim_sampling)

cluster_size <- rep(2:6, each = 5)
n_clusters <- length(cluster_size)
```

```
cluster_id <- rep(seq_len(n_clusters), cluster_size)
size_center <- weighted.mean(cluster_size, cluster_size)
prob_person <- theta + rep(
  (cluster_size - size_center) / 12,
  cluster_size
)
outcome <- rbinom(population_size, 1, prob_person)
unemployment_rate_population <- mean(outcome)
cluster_totals <- tapply(outcome, cluster_id, sum)
cluster_means <- tapply(outcome, cluster_id, mean)

sampled_cluster_count <- floor(n_clusters * 0.3)
for (sim in seq_len(n_sim_sampling)) {
  pps_sample <- S.piPS(sampled_cluster_count, cluster_size)
  sampled_clusters <- pps_sample[, 1]
  sampled_cluster_size <- cluster_size[sampled_clusters]
  sampled_cluster_total <- cluster_totals[sampled_clusters]
  sampled_cluster_mean <- cluster_means[sampled_clusters]
  design_estimates[sim] <- mean(sampled_cluster_mean)
  simple_estimates[sim] <-
    sum(sampled_cluster_total) / sum(sampled_cluster_size)
}

cbind(
  unemployment_rate_population,
  expected_pps = mean(design_estimates),
  bias_pps = mean(design_estimates) - unemployment_rate_population,
  expected_simple = mean(simple_estimates),
  bias_simple = mean(simple_estimates) - unemployment_rate_population
)
```

```
     unemployment_rate_population expected_pps bias_pps expected_simple
[1,]                          0.3        0.304  0.00368           0.358
     bias_simple
[1,]      0.0585
```

El primer bloque del código genera hogares de tamaños desiguales, entre 2 y 6 personas. Para hacer visible el efecto del diseño, la probabilidad individual de desocupación varía ligeramente con el tamaño del hogar, pero se centra de manera que el promedio esperado de la población siga siendo cercano a `theta`. Luego se calcula `unemployment_rate_population`, que es la tasa real de desocupación en esa población específica. En cada repetición, `S.piPS()` selecciona UPMs con probabilidades proporcionales al tamaño; después se calculan la media de las medias de las UPMs seleccionadas y el promedio simple de las personas observadas. La salida compara ambos estimadores con `unemployment_rate_population`. El sesgo de Monte Carlo de `expected_pps` es cercano a cero, mientras que el de `expected_simple` no lo es, mostrando resultado de ignorar el diseño en este ejercicio.

La tasa de desocupación verdadera de la población simulada es 30 %, mientras que el promedio de las estimaciones en las 1000 muestras es 30.37 %. El sesgo de Monte Carlo del estimador basado en la media de los conglomerados seleccionados es de 0.37 %.

En contraste, el promedio simple de las personas observadas estima una tasa de desocupación media de 35.85 %, con un sesgo de 5.85 %. En esta simulación, los conglomerados de mayor tamaño tienen mayor probabilidad de selección y mayor frecuencia del evento; ignorar las probabilidades de selección sobreestima la tasa poblacional.

9.2. La integración de ambas inferencias

No obstante, en muchas aplicaciones ambos marcos inferenciales no se presentan como enfoques excluyentes, sino como componentes complementarios de un mismo problema. En particular, puede considerarse que la muestra ha sido obtenida mediante un diseño probabilístico complejo y que, al mismo tiempo, los valores de la variable de interés responden a un modelo de superpoblación. Binder (2011) plantea esta formulación como un esquema de inferencia doble, en el cual la incertidumbre no proviene de una única fuente, sino de la combinación entre el mecanismo que genera los valores poblacionales (modelo de superpoblación) y el mecanismo que determina qué unidades son observadas (diseño de muestreo).

Formalmente, intervienen dos medidas de probabilidad: ξ, asociada al proceso generador de los valores Y_k, y $p(\cdot)$, asociada al diseño muestral que selecciona la muestra s. Por tanto, las propiedades de los estimadores deben evaluarse considerando simultáneamente ambas fuentes de variación. Bajo este marco, la esperanza combinada puede expresarse como

$$E_{\xi p}(\hat{\theta}) = E_{\xi}\{E_p(\hat{\theta} \mid U)\},$$

Donde primero se evalúa el comportamiento del estimador bajo el diseño, condicionado a la población finita generada, y luego se promedia sobre el modelo de superpoblación. En este contexto, la verosimilitud conjunta completa puede resultar intratable, especialmente cuando las probabilidades de inclusión dependen de variables relacionadas con la respuesta. Las ecuaciones de estimación ponderadas de Binder (1983) fundamentan la máxima pseudo-verosimilitud (MPV), que pondera las contribuciones de cada unidad por el inverso de su probabilidad de inclusión; Pfeffermann (1993) examina las condiciones y los objetivos bajo los cuales resulta pertinente incorporar esos pesos en modelos para datos de encuestas.

9.2.1. Método de la máxima verosimilitud

El método de máxima verosimilitud (Casella y Berger 2002), parte de una población $Y_1, \ldots, Y_N$ generada por un modelo ξ, que asume una distribución con densidad o función de probabilidad $f(Y;\theta)$. Si las observaciones son independientes e idénticamente distribuidas (IID), la función de verosimilitud se define como

$$L(\theta) = \prod_{k=1}^{N} f(Y_k;\theta).$$

Como los productos pueden ser difíciles de manipular, se utiliza la log-verosimilitud:

$$\ell(\theta) = \sum_{k=1}^{N} \log f(Y_k; \theta)$$

El estimador de máxima verosimilitud $\hat{\theta}$ es el valor de θ que maximiza $\ell(\theta)$. Si la función es diferenciable, este valor satisface las ecuaciones de score:

$$U(\theta) = \frac{\partial\ \ell(\theta)}{\partial\ \theta} = \sum_{k=1}^{N} u_k(\theta) = 0$$

donde $u_k(\theta) = \frac{\partial}{\partial\theta} \log f(Y_k; \theta)$ es la contribución de la unidad k al score total. En particular, para una distribución Bernoulli con parámetro θ, la función de probabilidad es $f(Y_k; \theta) = \theta^{Y_k}(1-\theta)^{1-Y_k}$, para $Y_k \in \{0, 1\}$. La log-verosimilitud es

$$\ell(\theta) = \sum_{k=1}^{N} [Y_k \log(\theta) + (1 - Y_k) \log(1 - \theta)]$$

Al derivar e igualar a cero y despejar, se obtiene el estimador MV, definido por:

$$\hat{\theta}_{MV} = \frac{1}{N} \sum_{k=1}^{N} Y_k$$

Por ende, la proporción poblacional es el estimador natural del parámetro θ en una distribución Bernoulli. El punto clave es que este resultado depende del supuesto de que las observaciones tienen igual distribución y no provienen de un diseño con probabilidades desiguales.

Por otro lado, en un modelo de regresión lineal múltiple con errores normales, se tiene que $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 I)$. En este caso, la log-verosimilitud, omitiendo constantes, puede escribirse como

$$\ell(\beta, \sigma^2) = -\frac{N}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)$$

Maximizar esta expresión respecto de β equivale a minimizar la suma de cuadrados de los residuos. Por ello, el estimador de máxima verosimilitud de β coincide con el estimador de mínimos cuadrados ordinarios $\widehat{\beta}_{MV} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$. Este resultado es importante porque muestra que muchos procedimientos estadísticos usuales pueden interpretarse como máxima verosimilitud bajo supuestos de modelo específicos. Sin embargo, si los datos provienen de una encuesta compleja, la matriz $\mathbf{X}'\mathbf{X}$ no refleja por sí sola el mecanismo de selección de la muestra.

9.2.2. Método de máxima pseudo-verosimilitud

Cuando el diseño muestral es complejo, los datos observados no satisfacen necesariamente los supuestos de independencia e idéntica distribución. Algunas unidades pueden representar a muchas personas de la población y otras a pocas. Además, dos unidades seleccionadas dentro del mismo conglomerado pueden estar correlacionadas. En este contexto, usar directamente la log-verosimilitud ordinaria puede producir estimaciones que describen la muestra, pero no la población objetivo.

La máxima pseudo-verosimilitud, desarrollada a partir de los resultados de Binder (1983), incorpora los pesos de muestreo en la log-verosimilitud. Para las unidades observadas en la muestra $k \in s$, se define la log-verosimiliutd ponderada:

$$\ell_p(\theta) = \sum_{k \in s} w_k \log f(y_k; \theta) \tag{9.1}$$

En donde el peso $w_k = 1/\pi_k$ indica cuántas unidades de la población representa la observación y_k. Por eso, la contribución de una unidad con baja probabilidad de inclusión se amplifica en la pseudo-verosimilitud. Las ecuaciones de estimación resultantes son

$$U_p(\theta) = \sum_{k \in s} w_k \; u_k(\theta) = 0 \tag{9.2}$$

La estimación MPV conserva la lógica de máxima verosimilitud, pero reemplaza el *score* ordinario por un *score* ponderado. La solución $\hat{\theta}_{MPV}$ es el valor que hace que la suma ponderada de contribuciones individuales sea igual a cero. Para una distribución Bernoulli, la pseudo-log-verosimilitud es

$$\ell_p(\theta) = \sum_{k \in s} w_k \left[y_k \log(\theta) + (1 - y_k) \log(1 - \theta) \right].$$

Al derivar e igualar a cero, se obtiene que:

$$\frac{\partial \ell_p(\theta)}{\partial \theta} = \sum_{k \in s} w_k \left[\frac{y_k}{\theta} - \frac{1 - y_k}{1 - \theta} \right] = 0$$

Cuya solución es:

$$\hat{\theta}_{MPV} = \frac{\sum_{k \in s} w_k y_k}{\sum_{k \in s} w_k} = \hat{p}_d$$

Por tanto, para una variable binaria, la MPV conduce al estimador ponderado de la proporción, equivalente al estimador de Hájek. Este resultado conecta directamente la teoría de pseudo-verosimilitud con los estimadores de proporciones presentados en los capítulos de variables categóricas.

Asimismo, para un modelo de regresión lineal múltiple, la pseudo-log-verosimilitud ponderada implica minimizar una suma de cuadrados ponderada:

$$(\mathbf{y} - \mathbf{X}\beta)'\mathbf{W}(\mathbf{y} - \mathbf{X}\beta),$$

donde

$$\mathbf{W} = \begin{pmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & w_n \end{pmatrix}.$$

La solución es el estimador de mínimos cuadrados ponderados:

$$\hat{\beta}_{MPV} = (\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}\mathbf{X}'\mathbf{W}\mathbf{y} \tag{9.3}$$

De acuerdo con Heeringa et al. (2017), este resultado extiende de manera natural el estimador ordinario al contexto de encuestas complejas: cada observación contribuye al ajuste del modelo en proporción a su peso muestral. No obstante, para la inferencia no basta con ponderar la estimación puntual; también se requiere estimar correctamente la varianza considerando estratos, conglomerados y pesos.

La siguiente simulación de Monte Carlo anidada ilustra la inferencia doble. En el ciclo externo se genera una nueva población bajo el modelo Bernoulli. En el ciclo interno se seleccionan muchas muestras por diseño y se comparan el estimador que incorpora el diseño y el promedio simple de la muestra.

```
set.seed(2026)
population_size <- 100
theta <- 0.3
n_sim_population <- 100
expected_design_estimates <-
  expected_simple_estimates <-
  population_means <-
  rep(NA, n_sim_population)

cluster_size <- rep(2:6, each = 5)
n_clusters <- length(cluster_size)
cluster_id <- rep(seq_len(n_clusters), cluster_size)
size_center <- weighted.mean(cluster_size, cluster_size)
prob_person <- theta + rep(
  (cluster_size - size_center) / 12,
  cluster_size
)
sampled_cluster_count <- floor(n_clusters * 0.3)

for (population_sim in seq_len(n_sim_population)) {
  outcome <- rbinom(population_size, 1, prob_person)
  population_means[population_sim] <- mean(outcome)
  cluster_totals <- tapply(outcome, cluster_id, sum)
```

```
  cluster_means <- tapply(outcome, cluster_id, mean)

  design_estimates <- simple_estimates <- rep(NA, 100)
  for (sample_sim in seq_len(100)) {
    pps_sample <- S.piPS(sampled_cluster_count, cluster_size)
    sampled_clusters <- pps_sample[, 1]
    sampled_cluster_size <- cluster_size[sampled_clusters]
    sampled_cluster_total <- cluster_totals[sampled_clusters]
    sampled_cluster_mean <- cluster_means[sampled_clusters]
    design_estimates[sample_sim] <- mean(sampled_cluster_mean)
    simple_estimates[sample_sim] <-
      sum(sampled_cluster_total) / sum(sampled_cluster_size)
  }
  expected_design_estimates[population_sim] <- mean(design_estimates)
  expected_simple_estimates[population_sim] <- mean(simple_estimates)
}

cbind(
  theta,
  mean_population = mean(population_means),
  expected_pps = mean(expected_design_estimates),
  bias_pps = mean(expected_design_estimates) - theta,
  expected_simple = mean(expected_simple_estimates),
  bias_simple = mean(expected_simple_estimates) - theta
)
```

```
     theta mean_population expected_pps bias_pps expected_simple bias_simple
[1,]   0.3           0.304        0.302  0.00248           0.332      0.0317
```

El código reproduce las dos fuentes de aleatoriedad. El ciclo externo representa el modelo ξ, porque genera nuevas poblaciones finitas con `rbinom()`. El ciclo interno representa el diseño p, porque para cada población se seleccionan múltiples muestras con `S.piPS()`. La salida incluye `mean_population`, que es el promedio de las medias poblacionales generadas; `expected_pps`, que resume el comportamiento del estimador que incorpora el diseño; y `expected_simple`, que resume el promedio simple de la muestra seleccionada. Cuando el diseño se incorpora correctamente, el sesgo Monte Carlo respecto de `theta` debe ser pequeño. La comparación con `expected_simple` muestra por qué la inferencia basada en encuestas requiere pesos y varianzas de diseño, incluso cuando se parte de un modelo estadístico sencillo.

Los resultados de la simulación muestran con claridad el efecto de respetar (o ignorar) el diseño complejo cuando el tamaño del conglomerado está relacionado con la variable de interés. En la simulación, el parámetro poblacional se fija en theta = 0,3 y la media observada entre las 100 poblaciones simuladas es 0,304, una pequeña diferencia atribuible a la variabilidad de Monte Carlo. El estimador basado en el promedio simple de las medias de los conglomerados seleccionados alcanza 0,302. Esto ocurre porque la probabilidad de seleccionar cada conglomerado es proporcional a su tamaño: al promediar las medias de los conglomerados seleccionados, la selección introduce precisamente la ponderación por tamaño necesaria para recuperar la media a nivel de personas. Por ello, el sesgo reportado es prácticamente nulo (0,00248).

En contraste, el estimador que combina todos los individuos pertenecientes a los conglomerados seleccionados como si constituyeran una muestra simple, tiene una media de 0,332 presentando un sesgo positivo (0,0317). El problema es que los conglomerados grandes ya tienen una probabilidad mayor de ser seleccionados por el diseño y, posteriormente, al calcular la media agrupando todos sus individuos, vuelven a recibir mayor peso debido a que contienen más personas. Se produce así una especie de doble ponderación por tamaño. El ejercicio ilustra, por tanto, que ignorar las probabilidades de selección puede producir sesgo cuando el diseño es informativo.

En síntesis, como explica Pfeffermann (1993), la máxima verosimilitud es adecuada cuando las observaciones pueden tratarse como IID bajo un modelo probabilístico. En encuestas complejas, la máxima pseudo-verosimilitud ofrece una extensión natural: conserva la estructura de las ecuaciones de estimación, pero pondera cada contribución individual por su peso muestral. La ponderación protege frente a ciertos diseños informativos o a determinadas especificaciones incorrectas, pero su necesidad y sus propiedades dependen del diseño y del modelo. Así, los modelos estadísticos se ajustan de manera más coherente con la población que la encuesta busca representar.

10. Imputación usando R

La ausencia de respuesta es un fenómeno frecuente en las encuestas de hogares, especialmente después de la pandemia de COVID-19. Sus causas son múltiples: cuestionarios extensos, renuencia de las personas encuestadas a proporcionar información sensible y dificultades para acceder a las áreas seleccionadas debido a desastres naturales o situaciones de violencia, entre otras. Una proporción elevada de valores faltantes en una variable puede comprometer la calidad de las estimaciones obtenidas con los estimadores clásicos.

El objetivo de este anexo es examinar las posibles causas de la ausencia de respuesta en las encuestas de hogares, su impacto en la estimación de indicadores y algunas alternativas para tratar los datos faltantes. Entre los avances metodológicos en el contexto de muestras complejas se encuentran la imputación múltiple (Buuren 2012; Carpenter y Kenward 2013; Berglund y Heeringa 2014; Raghunathan 2016) y la imputación fraccional (Kim y Fuller 2004; Kim y Shao 2014).

10.1. Tres patrones para la ausencia de respuesta

Para describir la ausencia de respuesta, sea $X_{n\times p} = x_{ij}$ una matriz completa (sin valores faltantes), donde X_{ij} es el valor de la variable j para el individuo i, con $j = 1, \dots, p$ e $i = 1, \dots, n$. Además, se define la matriz indicadora $M_{n\times p} = m_{ij}$, donde $m_{ij} = 1$ si el valor de x_{ij} es un dato faltante y $m_{ij} = 0$ si x_{ij} está presente. La matriz M describe el patrón de datos faltantes, y la media de cada columna representa la proporción de valores faltantes de la variable correspondiente. A continuación, se describen tres mecanismos de ausencia de respuesta:

- La matriz $M_{n\times p}$ presenta un comportamiento completamente al azar (MCAR, por sus siglas en inglés) si la probabilidad de respuesta es completamente independiente de las variables observadas y de las no observadas. En este caso, el mecanismo de respuesta es ignorable tanto para inferencias basadas en muestreo como en máxima verosimilitud.
- La matriz $M_{n\times p}$ presenta un comportamiento al azar (MAR, por sus siglas en inglés) si la probabilidad de respuesta es completamente independiente de las variables no observadas y no de las observadas. En este caso, el mecanismo de respuesta se considera ignorable para inferencias basadas en máxima verosimilitud.
- La matriz $M_{n\times p}$ presenta un comportamiento no al azar (MNAR, por sus siglas en inglés) si la probabilidad de respuesta no es completamente independiente de las variables no observadas y posiblemente también de las observadas. El mecanismo de respuesta es no ignorable.

La tabla 10.1 ilustra datos faltantes en posiciones dispersas. Cada fila representa un caso y cada columna X_j una variable. **O** indica un dato observado y **?** un dato faltante. El siguiente código computacional construye el esquema de datos observados y faltantes presentado en la tabla.

```
missing_pattern_table <- tibble::tribble(
  ~case, ~x1, ~x2, ~x3, ~x4, ~x5, ~x6, ~type,
  "1", "O", "O", "O", "O", "O", "O", "Completo",
  "2", "O", "O", "O", "O", "O", "O", "Completo",
  "3", "O", "O", "O", "O", "O", "O", "Completo",
  "4", "O", "O", "O", "O", "O", "O", "Completo",
  "5", "O", "O", "O", "O", "?", "?", "Incompleto",
  "6", "?", "O", "O", "O", "O", "O", "Incompleto",
  "7", "O", "?", "O", "O", "O", "?", "Incompleto",
  "8", "?", "O", "?", "O", "?", "?", "Incompleto"
)

missing_pattern_table
```

Tabla 10.1.: Patrón no monótono de datos faltantes. Adaptación de *Applied Survey Data Analysis* (Heeringa et al. 2017).

Caso	X_1	X_2	X_3	X_4	X_5	X_6	Tipo de caso
1	O	O	O	O	O	O	Completo
2	O	O	O	O	O	O	Completo
3	O	O	O	O	O	O	Completo
4	O	O	O	O	O	O	Completo
5	O	O	O	O	?	?	Incompleto
6	?	O	O	O	O	O	Incompleto
7	O	?	O	O	O	?	Incompleto
8	?	O	?	O	?	?	Incompleto

Como en los capítulos anteriores, se carga la base de datos de la muestra seleccionada. Para ilustrar el tratamiento de los datos faltantes, se introducirán pérdidas de información de forma simulada. La base se carga de la siguiente manera:

```
survey_data <- readRDS("../data/sample.rds")
```

La base `sample.rds` conserva los nombres de las variables y utiliza etiquetas y categorías en inglés. En `Region`, las categorías `North`, `South`, `Central`, `West` y `East` corresponden a Norte, Sur, Centro, Occidente y Oriente; `CatAge` contiene grupos decenales ordenados: `0-9`, `10-19`, `20-29`, y así sucesivamente hasta `90-99`.

El siguiente código computacional carga los paquetes y estima la tasa de desocupación antes de generar los valores faltantes. El diseño se construye con la muestra completa y luego se crea `labor_force_subset`, que contiene a las personas de 15 años o más ocupadas o desocupadas. Posteriormente, los ejercicios de imputación utilizan la población de 15 años o más, incluidas las personas inactivas.

```
library(tidyverse)
library(survey)
library(srvyr)
library(TeachingSampling)
library(patchwork)

options(survey.lonely.psu = "adjust")
survey_design <- survey_data %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  )

labor_force_subset <- survey_design %>%
  filter(Age >= 15, Employment %in% c("Employed", "Unemployed"))

unemployment_rate <- labor_force_subset %>%
  summarise(
    unemployment_rate = survey_mean( Employment == "Unemployed", proportion = TRUE, prop_metho
  )

unemployment_rate
```

```
# A tibble: 1 x 4
  unemployment_rate unemployment_rate_se unemployment_rate_low
              <dbl>                <dbl>                 <dbl>
1            0.0697               0.0110                0.0508
# i 1 more variable: unemployment_rate_upp <dbl>
```

```
survey_data <- survey_data %>%
  filter(Age >= 15)
```

La tasa de desocupación estimada es de 6.97 %, con un error estándar de 1.1 %. Como referencia para los ejercicios posteriores, el siguiente código computacional calcula también la media del ingreso en la muestra.

```
income_mean <- mean(survey_data$Income, na.rm = TRUE)
income_mean
```

```
[1] 604
```

A continuación, se genera un 20 % de valores faltantes siguiendo un mecanismo MCAR. La función `sample_frac` del paquete `dplyr` permite seleccionar aleatoriamente una fracción de las filas de un conjunto de datos.

```r
set.seed(1234)
mcar_data <- sample_frac(survey_data, 0.8)

mcar_plot_data <- bind_rows(
  list(mcar_data = mcar_data, survey_data = survey_data),
  .id = "data_source"
)
```

El siguiente código computacional compara el ingreso por zona y sexo en la base completa (`survey_data`) y en la muestra con pérdida MCAR (`mcar_data`) (figura 10.1). Las medianas y la amplitud de las cajas son similares en ambas bases. La línea roja indica la media del ingreso en la base completa.

```r
zone_income_plot <- ggplot(
  mcar_plot_data,
  aes(x = Zone, y = Income)
) +
  geom_boxplot() +
  facet_grid(. ~ data_source) +
  theme_bw() +
  geom_hline(yintercept = mean(survey_data$Income), color = "red")

sex_income_plot <- zone_income_plot + aes(x = Sex)

zone_income_plot | sex_income_plot
```

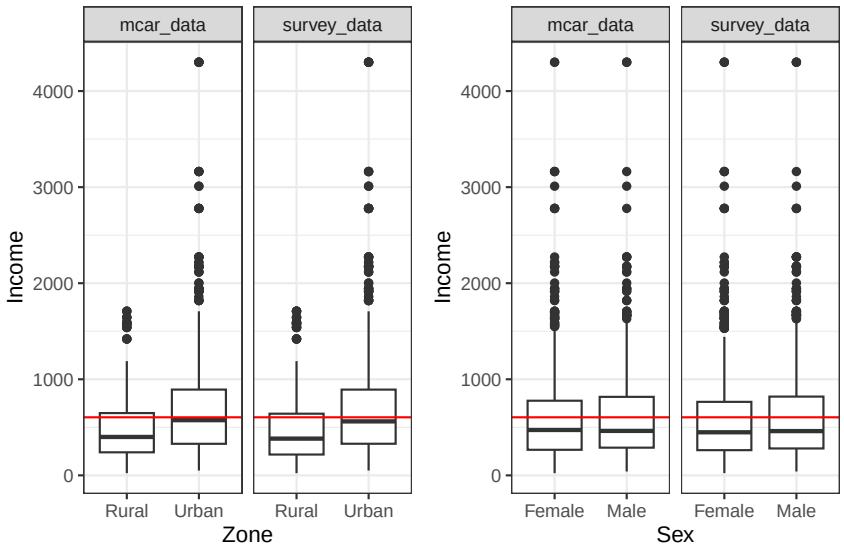


Figura 10.1.: Distribución del ingreso por zona y sexo con datos completos y bajo un patrón MCAR

El siguiente código computacional muestra las densidades del ingreso para la base completa (`survey_data`) y la muestra con pérdida MCAR (`mcar_data`), en el total y por sexo (figura 10.2).

Las curvas prácticamente se superponen, lo que indica pocos cambios en la distribución en esta simulación. La línea roja representa la media del ingreso en la base completa.

```
income_density_plot <- ggplot(
  mcar_plot_data,
  aes(x = Income, fill = data_source)
) +
  geom_density(alpha = 0.3) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red")

sex_income_density_plot <- income_density_plot +
  facet_grid(. ~ Sex) +
  theme(legend.position = "none")

income_density_plot / sex_income_density_plot
```

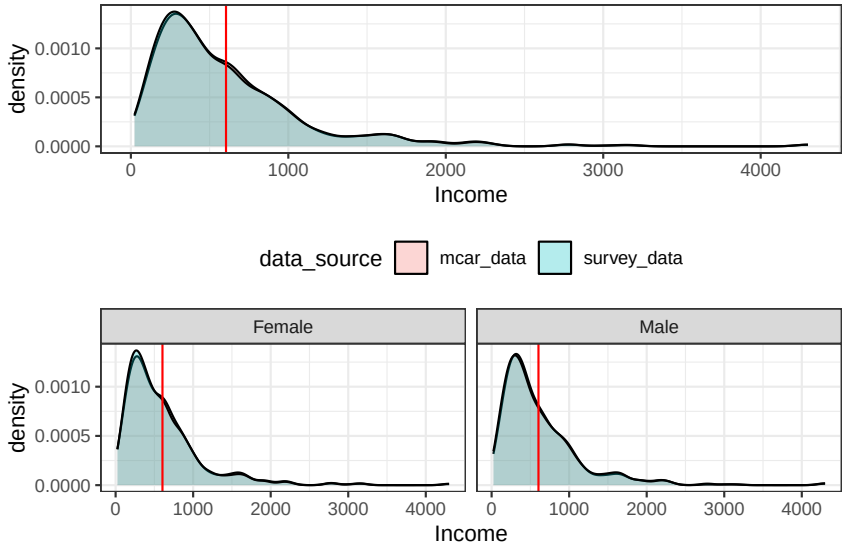


Figura 10.2.: Distribución del ingreso, total y por sexo, bajo un patrón MCAR

El siguiente código computacional compara las densidades del gasto en la base completa (`survey_data`) y la muestra con pérdida MCAR (`mcar_data`), en el total y por sexo (figura 10.3). La superposición de las curvas muestra que se conserva la forma de la distribución. La línea roja indica la media del gasto en la base completa.

```
expenditure_density_plot <- ggplot(
  mcar_plot_data,
  aes(x = Expenditure, fill = data_source)
) +
  geom_density(alpha = 0.3) +
```

```
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(
    xintercept = mean(survey_data$Expenditure),
    color = "red"
  )

sex_expenditure_density_plot <- expenditure_density_plot +
  facet_grid(. ~ Sex) +
  theme(legend.position = "none")

expenditure_density_plot / sex_expenditure_density_plot
```

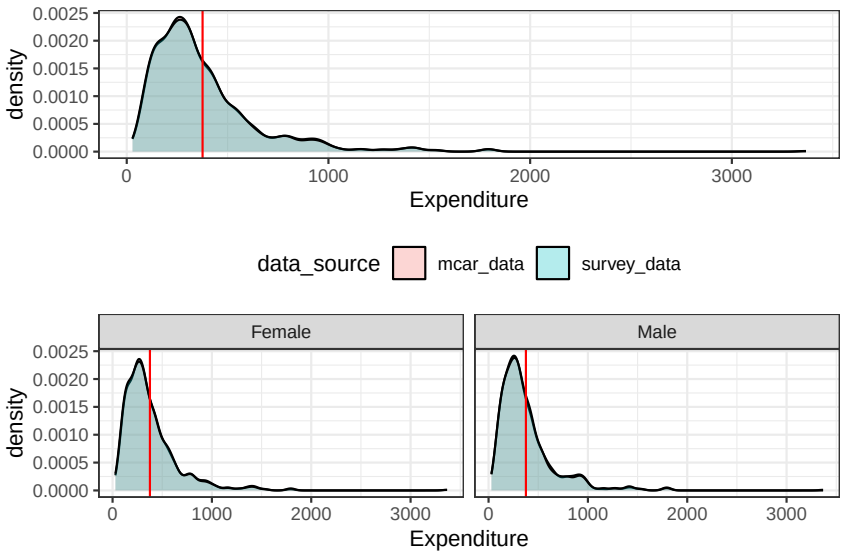


Figura 10.3.: Distribución del gasto, total y por sexo, bajo un patrón MCAR

A continuación, se simula una pérdida de información al azar (MAR) que depende de la zona y del sexo:

```
set.seed(1234)
stratum_id <- paste0(survey_data$Zone, survey_data$Sex)
stratum_sizes <- table(stratum_id)
stratum_sizes
```

```
stratum_id
RuralFemale   RuralMale UrbanFemale   UrbanMale
        481         428         531         439
```

```
sample_indices <- S.STSI(
  S = stratum_id,
  Nh = as.numeric(stratum_sizes),
  nh = c(20, 380, 20, 280)
)
mar_data <- survey_data[-sample_indices, ]

mar_plot_data <- bind_rows(
  list(mar_data = mar_data, survey_data = survey_data),
  .id = "data_source"
)
```

El código anterior utiliza el paquete `TeachingSampling` para realizar un muestreo aleatorio en cada combinación de zona y sexo. Primero, se fija la semilla en `1234` para que los resultados sean reproducibles. Luego, se crea la variable `stratum_id`, que combina `Zone` y `Sex` mediante la función `paste0` para definir los estratos. La función `table` muestra la frecuencia de cada estrato. El muestreo estratificado se realiza con `S.STSI`, cuyos argumentos son `S`, el vector de estratos; `Nh`, el número de unidades en cada estrato (481, 428, 531, 439, en el orden mostrado por `stratum_sizes`); y `nh`, el tamaño de muestra deseado en cada estrato (20, 380, 20 y 280).

El muestreo estratificado devuelve un vector con los índices de las filas seleccionadas. Estas observaciones se excluyen de la base para crear `mar_data`. Por último, la función `bind_rows` del paquete `dplyr` reúne `survey_data` y `mar_data` en `mar_plot_data`. La nueva variable `data_source` identifica la base de origen de cada observación.

El siguiente código computacional compara el gasto por zona y sexo entre la base completa (`survey_data`) y la muestra con pérdida MAR (`mar_data`) (figura 10.4). Las medianas permanecen próximas, aunque cambian la dispersión y algunos valores extremos, especialmente entre los hombres. La línea roja señala la media del gasto en la base completa.

```
mar_expenditure_boxplot <- ggplot(
  mar_plot_data,
  aes(x = data_source, y = Expenditure)
) +
  geom_hline(
    yintercept = mean(survey_data$Expenditure),
    color = "red"
  ) +
  geom_boxplot() +
  facet_grid(Zone ~ Sex) +
  theme_bw()

mar_expenditure_boxplot
```

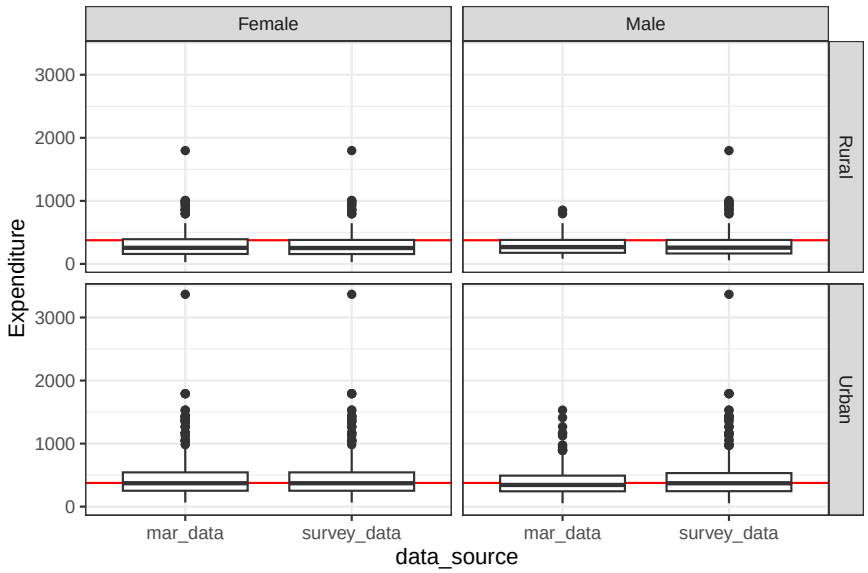


Figura 10.4.: Distribución del gasto por zona y sexo bajo un patrón MAR

El siguiente código computacional compara las densidades del ingreso de la base completa (`survey_data`) y la muestra con pérdida MAR (`mar_data`) (figura 10.5). Las diferencias son pequeñas en el total y más visibles entre los hombres, lo que muestra la utilidad de revisar las desagregaciones. La línea roja indica la media del ingreso en la base completa.

```
income_density_plot <- ggplot(
  mar_plot_data,
  aes(x = Income, fill = data_source)
) +
  geom_density(alpha = 0.3) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red")

sex_income_density_plot <- income_density_plot +
  facet_grid(. ~ Sex) +
  theme(legend.position = "none")

income_density_plot / sex_income_density_plot
```

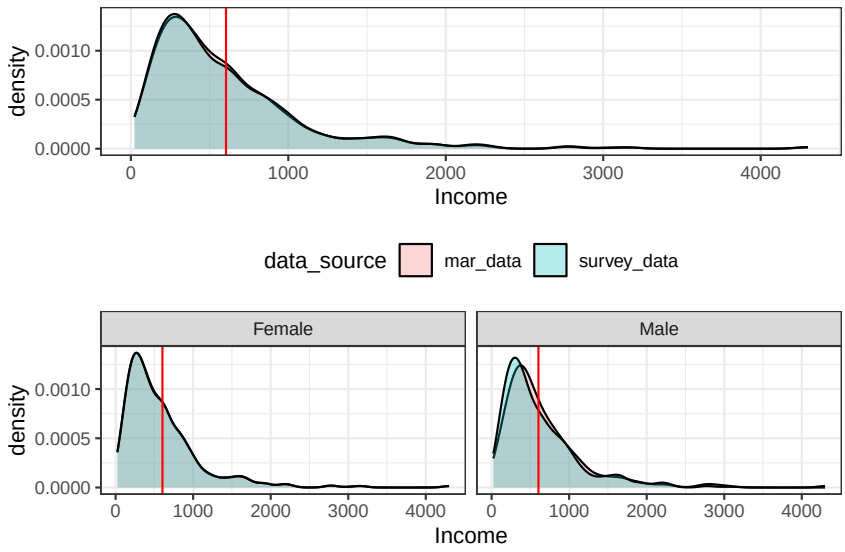


Figura 10.5.: Distribución del ingreso, total y por sexo, bajo un patrón MAR

El siguiente código computacional muestra las densidades del gasto en la base completa (`survey_data`) y la muestra con pérdida MAR (`mar_data`), en el total y por sexo (figura 10.6). Las curvas son próximas entre las mujeres y presentan diferencias más visibles entre los hombres. La línea roja representa la media del gasto en la base completa.

```
expenditure_density_plot <- ggplot(
  mar_plot_data,
  aes(x = Expenditure, fill = data_source)
) +
  geom_density(alpha = 0.3) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(
    xintercept = mean(survey_data$Expenditure),
    color = "red"
  )

sex_expenditure_density_plot <- expenditure_density_plot +
  facet_grid(. ~ Sex) +
  theme(legend.position = "none")

expenditure_density_plot / sex_expenditure_density_plot
```

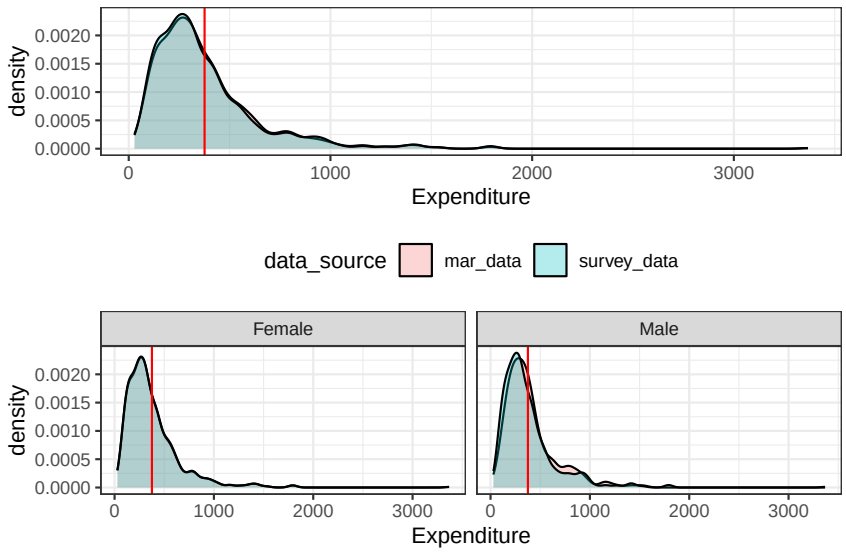


Figura 10.6.: Distribución del gasto, total y por sexo, bajo un patrón MAR

Por último, se simula una pérdida de información no al azar (MNAR). Como se explicó al inicio del anexo, en este mecanismo la probabilidad de que un dato falte está relacionada con su propio valor. Esta dependencia puede introducir un sesgo apreciable en la inferencia y el análisis estadístico de las encuestas de hogares, por lo que el tratamiento de los datos faltantes requiere especial atención. El siguiente código computacional crea `mnar_data` conservando las 1.300 observaciones con menor ingreso y la combina con la base completa para comparar ambas distribuciones.

```
mnar_data <- survey_data %>%
  arrange(Income) %>%
  slice(1:1300L)

mnar_plot_data <- bind_rows(
  list(mnar_data = mnar_data, survey_data = survey_data),
  .id = "data_source"
)
```

El código anterior conserva en `mnar_data` las 1.300 observaciones con menores ingresos y las reúne con la base completa en `mnar_plot_data`. La figura 10.7, obtenida con el siguiente código computacional, muestra cómo esta selección elimina la cola de ingresos altos y desplaza la distribución hacia valores menores. La media de los casos conservados, en azul, queda por debajo de la media de la base completa, en rojo.

```
mnar_income_density_plot <- ggplot(
  mnar_plot_data,
  aes(x = Income, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
```

```
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(xintercept = mean(mnar_data$Income), color = "blue")

mnar_income_density_plot
```

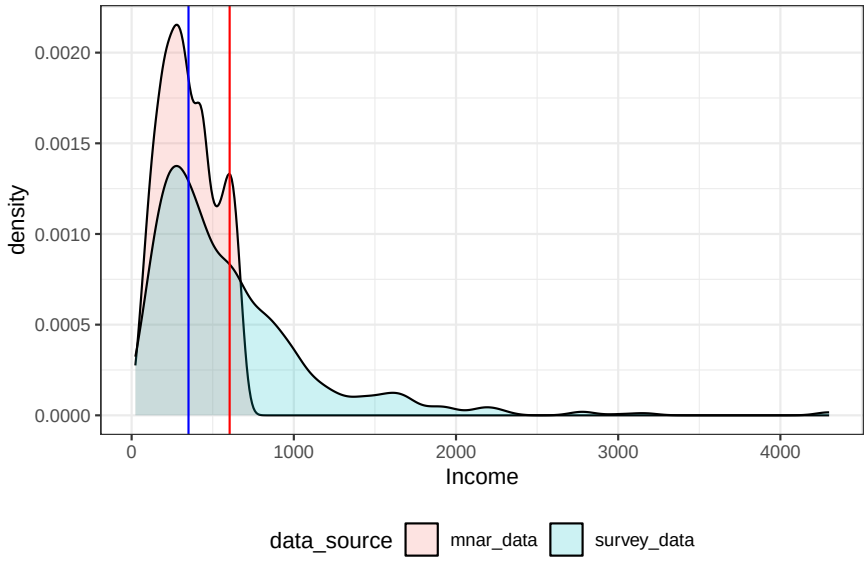


Figura 10.7.: Distribución del ingreso bajo un patrón MNAR

El siguiente código computacional compara la distribución del gasto en la base completa (`survey_data`) y entre los casos conservados bajo MNAR (`mnar_data`) (figura 10.8). La selección por ingreso también reduce la presencia de gastos altos. La línea azul señala la media del gasto de los casos conservados y la roja, la media de la base completa.

```
mnar_expenditure_density_plot <- ggplot(
  mnar_plot_data,
  aes(x = Expenditure, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(
    xintercept = mean(survey_data$Expenditure),
    color = "red"
  ) +
  geom_vline(
    xintercept = mean(mnar_data$Expenditure),
    color = "blue"
  )

mnar_expenditure_density_plot
```

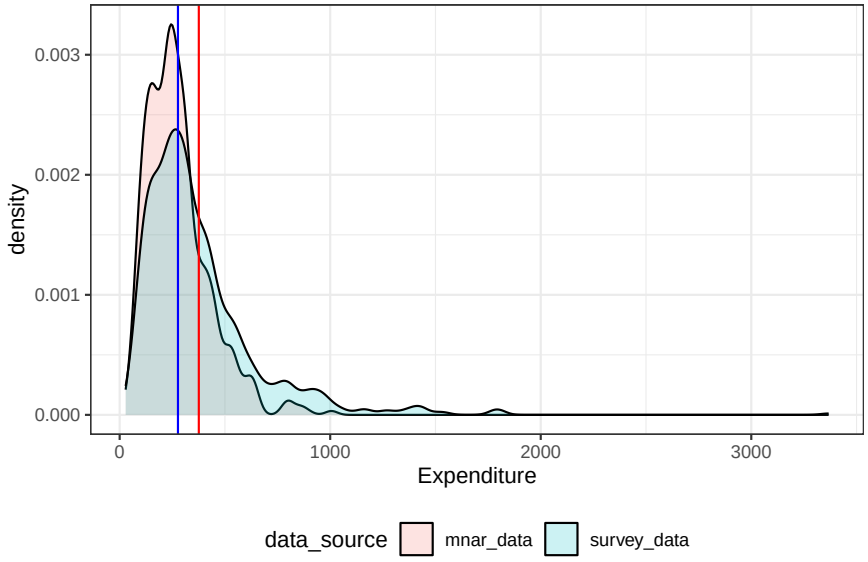


Figura 10.8.: Distribución del gasto bajo un patrón MNAR

El siguiente código computacional compara el ingreso por zona y sexo en la base completa (`survey_data`) y entre los casos conservados bajo MNAR (`mnar_data`) (figura 10.9). La eliminación de ingresos altos reduce las medianas y la dispersión, con cambios más marcados en la zona urbana. La línea roja indica la media del ingreso en la base completa.

```
mnar_income_boxplot <- ggplot(
  mnar_plot_data,
  aes(x = data_source, y = Income)
) +
  geom_hline(yintercept = mean(survey_data$Income), color = "red") +
  geom_boxplot() +
  facet_grid(Zone ~ Sex) +
  theme_bw()

mnar_income_boxplot
```

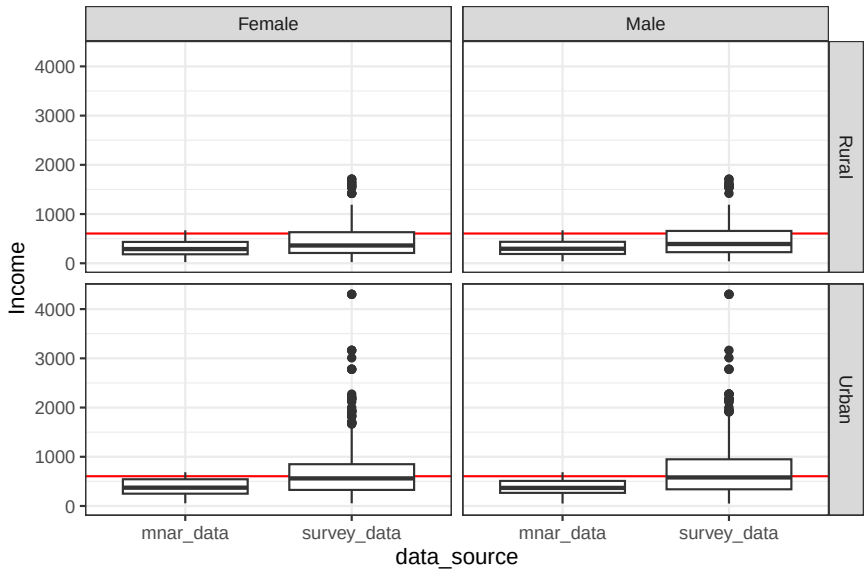


Figura 10.9.: Distribución del ingreso por zona y sexo bajo un patrón MNAR

10.2. Algunos métodos de imputación

La sección anterior mostró cómo los mecanismos MCAR, MAR y MNAR pueden afectar la distribución de los datos observados. A partir de ese diagnóstico, esta sección presenta distintos métodos para reemplazar los valores faltantes utilizando la información disponible. Mediante ejemplos en `R`, se comparan los ingresos originales con los obtenidos por imputación, prestando atención tanto a su media como a su dispersión y distribución. El recorrido comienza con métodos de imputación simple y concluye con la imputación múltiple.

10.2.1. Imputación por la media no condicional

La imputación por la media no condicional consiste en reemplazar los valores faltantes con la media aritmética de los valores observados de la variable, sin considerar otras variables. La media se calcula a partir de todos los valores disponibles, independientemente de las características de las observaciones.

Para ilustrar el tratamiento de los datos faltantes bajo un mecanismo MCAR, se construye la siguiente base de datos:

```
survey_data <- full_join(
  survey_data,
  mcar_data %>% transmute(
    HHID,
    PersonID,
    income_missing = Income,
    employment_missing = Employment
  ),
```

```
  by = c("HHID", "PersonID")
)
```

El código anterior utiliza la función `full_join` del paquete `dplyr` para combinar las dos bases de datos. Esta unión conserva todas las filas de ambas bases, combina las que tienen claves coincidentes y asigna valores faltantes donde no hay correspondencia. Para conocer el porcentaje de valores faltantes, se ejecuta el siguiente código:

```
survey_data %>%
  group_by(Zone) %>%
  summarise(
    missing_proportion = sum(is.na(income_missing) / n())
  )
```

```
# A tibble: 2 x 2
  Zone  missing_proportion
  <chr>              <dbl>
1 Rural              0.208
2 Urban              0.193
```

```
survey_data %>%
  group_by(Sex) %>%
  summarise(
    missing_proportion = sum(is.na(income_missing) / n())
  )
```

```
# A tibble: 2 x 2
  Sex    missing_proportion
  <chr>               <dbl>
1 Female              0.184
2 Male                0.219
```

La imputación por la media no condicional es un método simple y rápido. Puede resultar útil cuando la distribución de la variable no es muy asimétrica o cuando hay pocos valores faltantes en relación con el tamaño de la muestra. Sin embargo, presenta limitaciones cuando existen sesgos o patrones en los datos faltantes, o cuando las variables están muy correlacionadas. Aunque conserva la media de los valores observados, modifica la variabilidad y los percentiles, y puede afectar el sesgo. El método se aplica de la siguiente manera:

```
observed_income_mean <- mean(survey_data$income_missing, na.rm = TRUE)
survey_data <- survey_data %>%
  mutate(
    income_imputed = ifelse(
      is.na(income_missing),
      observed_income_mean,
```

```
      income_missing
    )
  )

sum(is.na(survey_data$income_imputed))
```

```
[1] 0
```

El código anterior calcula la media de los valores observados de `income_missing` y la almacena en `observed_income_mean`. Luego, reemplaza los valores faltantes con esa media y guarda el resultado en `income_imputed`. La última línea cuenta los valores faltantes de esta nueva columna de `survey_data` y confirma que no quedan datos sin imputar.

El siguiente código computacional compara el ingreso original (`Income`) con el completado mediante la media no condicional (`income_imputed`) (figura 10.10). La imputación produce una concentración artificial alrededor de la media, visible como un pico pronunciado. Las líneas roja y azul representan las medias original e imputada, respectivamente; su cercanía no implica que las distribuciones sean iguales.

```
mean_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

mean_density_plot <- ggplot(
  mean_plot_data,
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )

mean_density_plot
```

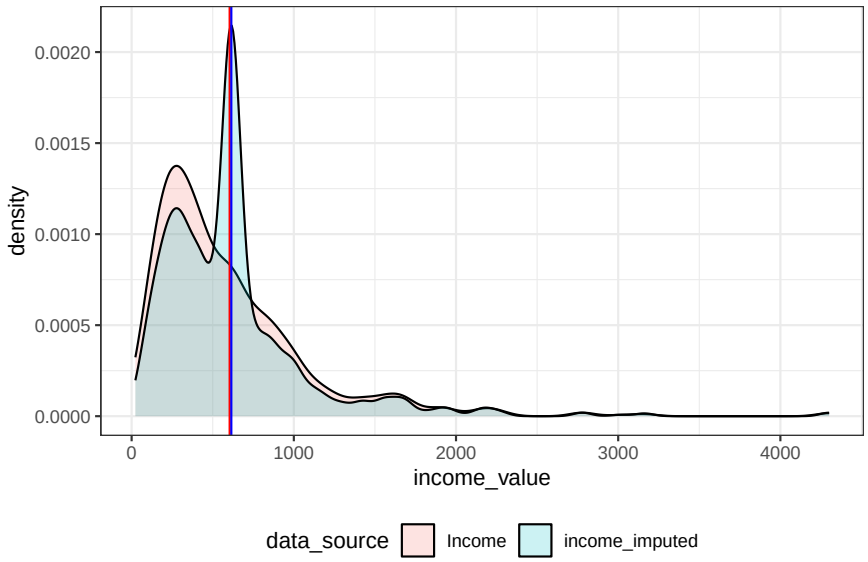


Figura 10.10.: Distribución del ingreso original e imputado por la media no condicional

El siguiente código computacional compara el ingreso original (`Income`) y el completado por la media no condicional (`income_imputed`) dentro de cada combinación de zona y sexo (figura 10.11). Las cajas muestran cambios en la mediana y la dispersión al asignar un mismo valor a todos los datos faltantes. La línea roja señala la media del ingreso original.

```
mean_boxplot <- ggplot(
  mean_plot_data,
  aes(x = data_source, y = income_value)
) +
  geom_hline(yintercept = mean(survey_data$Income), color = "red") +
  geom_boxplot() +
  facet_grid(Zone ~ Sex) +
  theme_bw()

mean_boxplot
```

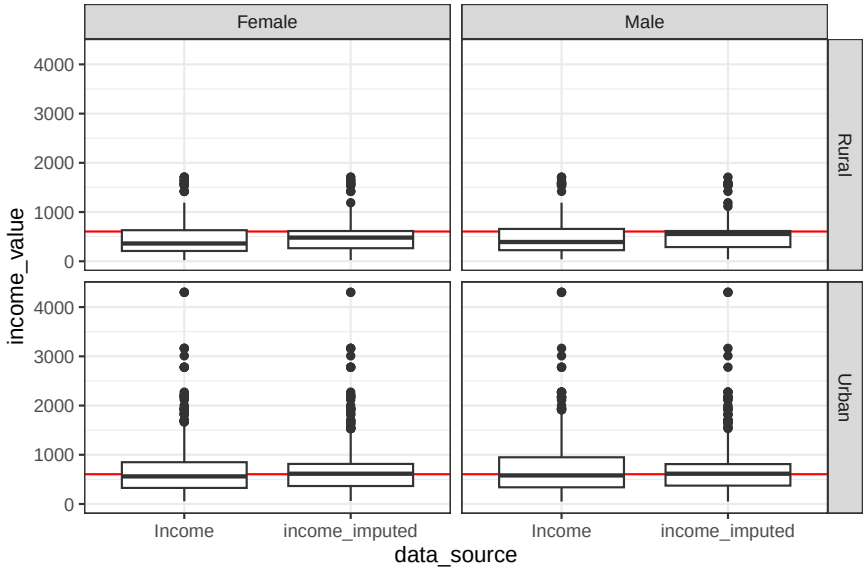


Figura 10.11.: Ingreso original e imputado por la media no condicional, por zona y sexo

10.2.2. Imputación por la media condicional

La imputación por la media condicional reemplaza los valores faltantes de una variable numérica con las medias calculadas en grupos de observaciones que comparten características. A diferencia de la media no condicional, este método considera otras variables, ya que la media de la variable de interés puede cambiar según sus valores. Puede ofrecer mayor precisión cuando las variables están correlacionadas o cuando existen patrones de ausencia de respuesta asociados con las variables de agrupación.

En el siguiente ejemplo, se calculan las medias por estrato para imputar los ingresos faltantes, bajo el supuesto de que existe una relación entre el estrato y el ingreso de los hogares:

```
survey_data <- survey_data %>%
  group_by(Stratum) %>%
  mutate(
    income_imputed = ifelse(
      is.na(income_missing),
      mean(income_missing, na.rm = TRUE),
      income_missing
    )
  ) %>%
  data.frame()

sum(is.na(survey_data$income_imputed))
```

```
[1] 0
```

```
survey_data <- survey_data %>%
  mutate(
    income_imputed = ifelse(
      is.na(income_imputed),
      observed_income_mean,
      income_imputed
    )
  )

sum(is.na(survey_data$income_imputed))
```

```
[1] 0
```

El código anterior utiliza `group_by` para agrupar las observaciones de `survey_data` por `Stratum`. Los valores faltantes de `income_missing` se reemplazan con la media de los ingresos observados en el estrato correspondiente, mientras que los valores observados se conservan. El resultado se almacena en `income_imputed`. A continuación, se calculan las medias y las desviaciones estándar de los ingresos originales y de los completados por imputación para comparar el efecto del método:

```
survey_data %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
  income_mean income_sd imputed_income_mean imputed_income_sd
1         604       513                 612               489
```

En este ejemplo, el sesgo relativo de la media del ingreso es de 1,21 %, y el de la desviación estándar es de -4,75 %. Al desagregar los resultados de la imputación por zona, se obtiene lo siguiente:

```
survey_data %>%
  group_by(Zone) %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
# A tibble: 2 x 5
  Zone  income_mean income_sd imputed_income_mean imputed_income_sd
  <chr>       <dbl>     <dbl>               <dbl>              <dbl>
1 Rural        469.      337.                478.               306.
2 Urban        731.      609.                737.               586.
```

Los sesgos relativos de la media del ingreso son del 1,87 % en la zona rural y del 0,81 % en la urbana. En ambos casos, las medias obtenidas tras la imputación son próximas a las originales.

El siguiente código computacional compara las densidades del ingreso original (`Income`) y del completado con medias por estrato (`income_imputed`) (figura 10.12). La curva imputada se aproxima a la original, aunque conserva diferencias en el tramo central. Las líneas roja y azul señalan las medias original e imputada, respectivamente.

```
conditional_mean_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

conditional_mean_density_plot <- ggplot(
  conditional_mean_plot_data,
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )

conditional_mean_density_plot
```

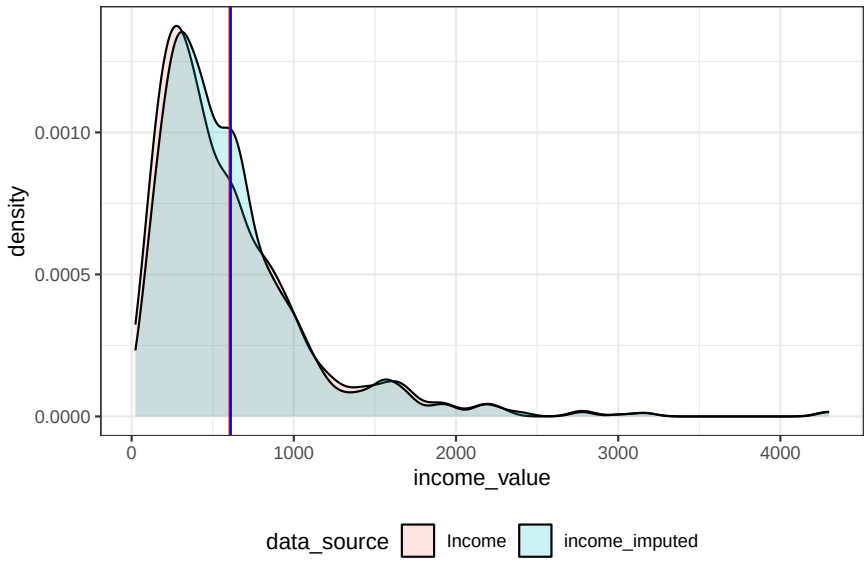


Figura 10.12.: Distribución del ingreso original e imputado por la media condicional

El siguiente código computacional compara el ingreso original (`Income`) y el completado con medias por estrato (`income_imputed`), desagregados por zona y sexo (figura 10.13). Las medianas son

próximas y persisten algunas diferencias en la amplitud de las cajas. La línea roja indica la media del ingreso original en toda la muestra.

```
conditional_mean_boxplot <- ggplot(
  conditional_mean_plot_data,
  aes(x = data_source, y = income_value)
) +
  geom_hline(yintercept = mean(survey_data$Income), color = "red") +
  geom_boxplot() +
  facet_grid(Zone ~ Sex) +
  theme_bw()

conditional_mean_boxplot
```

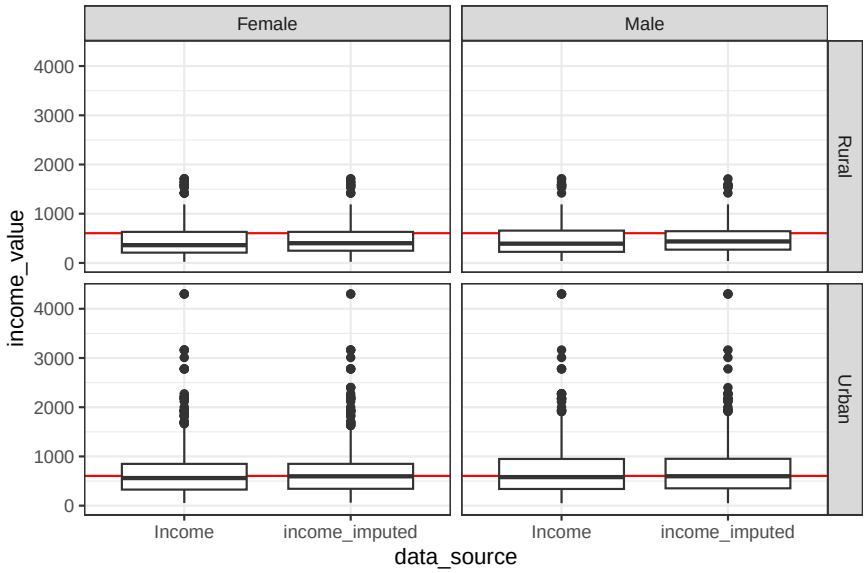


Figura 10.13.: Ingreso original e imputado por la media condicional, por zona y sexo

10.2.3. Imputación por *hot-deck*

La imputación por *hot-deck* reemplaza los valores faltantes de una unidad que no respondió (el receptor) con valores observados de otra unidad (el donante). En la variante aleatoria no condicionada, el donante se selecciona al azar entre todos los registros con información disponible. Otras variantes restringen la selección a grupos con características similares, como edad, sexo o zona de residencia, para aprovechar su relación con la variable que se desea imputar.

El término *hot-deck* hace referencia a las tarjetas perforadas utilizadas en los primeros sistemas informáticos para almacenar y recuperar datos. Esta técnica es relativamente simple y eficaz en conjuntos de datos pequeños o medianos, y se utiliza con frecuencia en encuestas y estudios de investigación social. Sin embargo, puede resultar menos eficaz en conjuntos grandes o complejos cuando es difícil encontrar observaciones similares o definir y medir las características relevantes de manera confiable.

El siguiente código ilustra el hot-deck aleatorio no condicionado: para cada ingreso faltante se selecciona un donante entre todos los registros con ingreso observado, sin formar grupos ni comparar características auxiliares.

```
donor_indices <- which(!is.na(survey_data$income_missing))
recipient_indices <- which(is.na(survey_data$income_missing))
survey_data$income_imputed <- survey_data$income_missing

set.seed(1234)
for (i in recipient_indices) {
  donor_index <- sample(x = donor_indices, size = 1)
  survey_data$income_imputed[i] <- survey_data$income_missing[donor_index]
}

sum(is.na(survey_data$income_imputed))
```

```
[1] 0
```

El código anterior identifica las observaciones con y sin valores faltantes en `income_missing` y crea `income_imputed` para almacenar los resultados. Luego, un bucle `for` recorre las observaciones receptoras. En cada iteración, la función `sample` selecciona aleatoriamente un donante entre las observaciones con ingreso disponible.

Una vez realizada la imputación, el siguiente código computacional compara la media y la desviación estándar del ingreso original con las del ingreso completado.

```
survey_data %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
  income_mean income_sd imputed_income_mean imputed_income_sd
1         604       513                 618               528
```

El sesgo relativo de la media del ingreso es del 2,32 %. Al desagregar los resultados por zona, se obtiene lo siguiente:

```
survey_data %>%
  group_by(Zone) %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
# A tibble: 2 x 5
  Zone  income_mean income_sd imputed_income_mean imputed_income_sd
  <chr>       <dbl>     <dbl>               <dbl>             <dbl>
1 Rural        469.      337.                504.              369.
2 Urban        731.      609.                726.              624.
```

El sesgo relativo de la media del ingreso es del 7,37 % en la zona rural y del -0,71 % en la urbana. El siguiente código computacional extiende la comparación de estos resúmenes a los grupos definidos por sexo.

```
survey_data %>%
  group_by(Sex) %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
# A tibble: 2 x 5
  Sex    income_mean income_sd imputed_income_mean imputed_income_sd
  <chr>        <dbl>     <dbl>               <dbl>             <dbl>
1 Female        589.      504.                603.              503.
2 Male          622.      523.                636.              556.
```

El siguiente código computacional compara la densidad del ingreso original (`Income`) con la del ingreso completado mediante donantes aleatorios (`income_imputed`) (figura 10.14). Las curvas prácticamente se superponen en esta simulación, conservando la asimetría y la cola de ingresos altos. Las líneas roja y azul representan las medias original e imputada, respectivamente.

```
hot_deck_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

hot_deck_density_plot <- ggplot(
  hot_deck_plot_data,
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )
```

```
hot_deck_density_plot
```

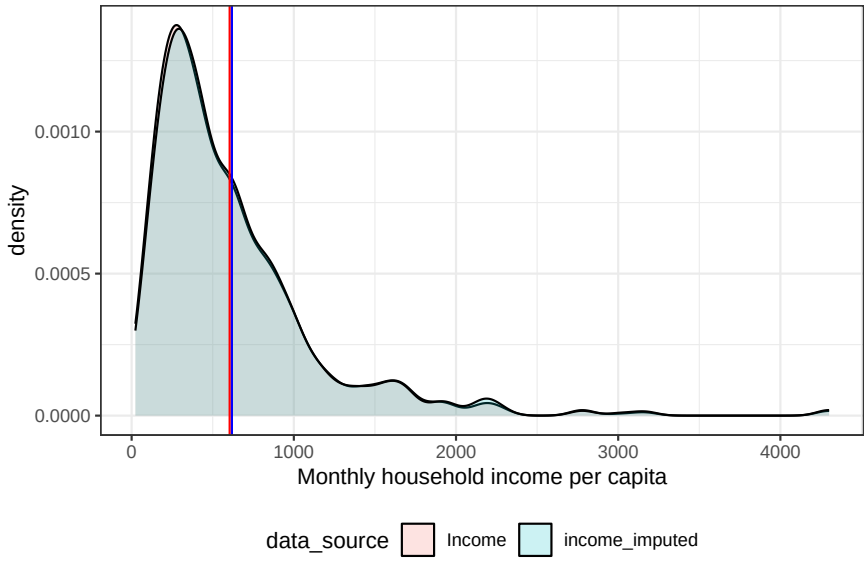


Figura 10.14.: Distribución del ingreso original e imputado mediante hot-deck

10.2.4. Imputación por regresión

La imputación por regresión utiliza las variables auxiliares disponibles para predecir los valores faltantes de la variable de interés. Primero, se identifican las variables predictoras relacionadas con ella. Luego, se ajusta un modelo con los valores observados y se utilizan sus coeficientes para predecir los valores faltantes.

El siguiente código computacional ajusta un modelo de regresión lineal múltiple para imputar el ingreso, utilizando la zona, el sexo y el gasto como covariables.

```
survey_data$income_imputed <- survey_data$income_missing
observed_data <- filter(survey_data, !is.na(income_missing))
missing_data <- filter(survey_data, is.na(income_missing))

imputation_model <- lm(
  Income ~ Zone + Sex + Expenditure,
  data = observed_data
)
```

Una vez ajustado el modelo, el siguiente código computacional obtiene las predicciones y las utiliza para completar los ingresos faltantes.

```
predicted_income <- predict(
  imputation_model,
  newdata = missing_data
)
missing_data$income_imputed <- predicted_income
survey_data <- bind_rows(observed_data, missing_data)
```

A continuación, se calculan la media y la desviación estándar de los ingresos originales y de los completados por imputación:

```
survey_data %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
  income_mean income_sd imputed_income_mean imputed_income_sd
1         604       513                 612               498
```

El sesgo relativo de la media del ingreso es del 1,24 %. El siguiente código computacional compara por zona los resúmenes del ingreso original y del completado por regresión.

```
survey_data %>%
  group_by(Zone) %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
# A tibble: 2 x 5
  Zone  income_mean income_sd imputed_income_mean imputed_income_sd
  <chr>       <dbl>     <dbl>               <dbl>             <dbl>
1 Rural        469.      337.                476.              317.
2 Urban        731.      609.                739.              595.
```

El siguiente código computacional compara las densidades del ingreso original (`Income`) y del completado con predicciones del modelo de regresión (`income_imputed`) (figura 10.15). La forma general es similar, aunque aparecen diferencias alrededor del tramo central de la distribución. Las líneas roja y azul indican las medias original e imputada, respectivamente.

```r
regression_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

regression_density_plot <- ggplot(
  regression_plot_data,
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )

regression_density_plot
```

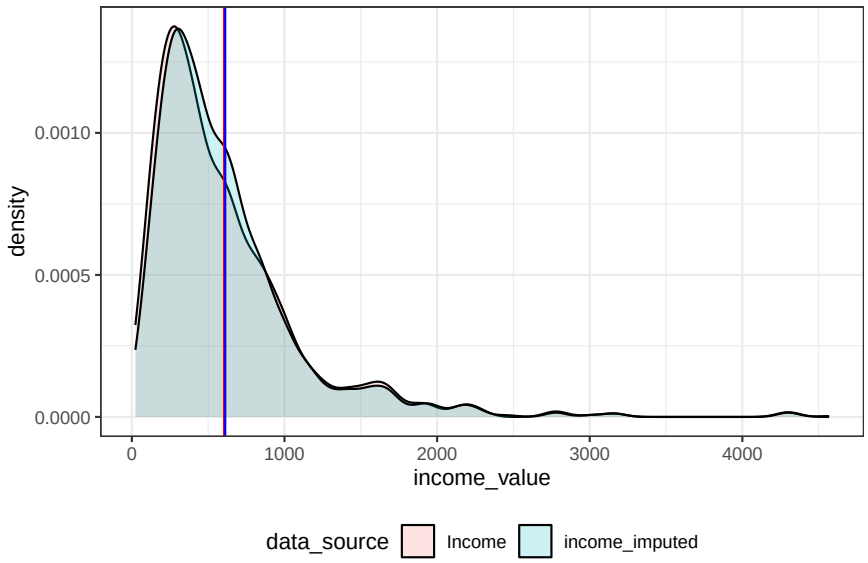


Figura 10.15.: Distribución del ingreso original e imputado por regresión

10.2.5. Imputación por el vecino más cercano

La imputación por el vecino más cercano reemplaza los valores faltantes con información de observaciones similares. El método se basa en la idea de que los registros con características semejantes tienden a tener valores similares en la variable de interés. En su versión con varios vecinos, se identifican los k registros más próximos al receptor y se utilizan sus valores para estimar el dato faltante.

Para calcular la similitud entre observaciones, se pueden utilizar diferentes medidas de distancia, como la distancia euclidiana o la distancia de Manhattan. La técnica también permite ajustar el valor de k, que representa el número de vecinos más cercanos utilizados para estimar el valor faltante.

Este método es relativamente simple y fácil de implementar. Sin embargo, su eficacia depende de la cantidad y la calidad de los datos disponibles, así como del número de vecinos y de la medida de distancia elegidos. Por ello, conviene evaluar tanto la calidad de los datos como los resultados de la imputación.

La aplicación del método con un solo vecino comprende tres pasos:

1. Definir una medida de distancia, como la euclidiana, para comparar las observaciones.
2. Identificar, para cada receptor, el donante más cercano según la medida elegida.
3. Reemplazar el valor faltante con el valor observado del donante.

En el siguiente ejemplo, se imputa el ingreso utilizando el gasto del individuo como variable auxiliar y la distancia euclidiana como medida de similitud.

```
survey_data$income_imputed <- survey_data$income_missing
observed_data <- filter(survey_data, !is.na(income_missing))
missing_data <- filter(survey_data, is.na(income_missing))

for (i in seq_len(nrow(missing_data))) {
  recipient_expenditure <- missing_data$Expenditure[[i]]
  donor_index <- which.min(abs(recipient_expenditure - observed_data$Expenditure))
  missing_data$income_imputed[[i]] <-
    observed_data$income_missing[[donor_index]]
}

survey_data <- bind_rows(observed_data, missing_data)
```

Las medias y las desviaciones estándar de los ingresos originales y de los completados por imputación se calculan de la siguiente manera:

```
survey_data %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
  income_mean income_sd imputed_income_mean imputed_income_sd
1         604       513                 611               514
```

La media imputada supera a la original en aproximadamente 6,3 unidades monetarias. El siguiente código computacional compara por zona los resúmenes del ingreso original y del completado con donantes.

```
survey_data %>%
  group_by(Zone) %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
# A tibble: 2 x 5
  Zone  income_mean income_sd imputed_income_mean imputed_income_sd
  <chr>       <dbl>     <dbl>               <dbl>             <dbl>
1 Rural        469.      337.                478.              344.
2 Urban        731.      609.                735.              607.
```

La media imputada supera a la original en aproximadamente 8,8 unidades monetarias en la zona rural y 3,9 en la urbana.

El siguiente código computacional compara la densidad del ingreso original (`Income`) y la del ingreso imputado con donantes de gasto similar (`income_imputed`) (figura 10.16). Las curvas son muy próximas y conservan la cola de ingresos altos. Las líneas roja y azul muestran las medias original e imputada, respectivamente.

```
nearest_neighbor_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

nearest_neighbor_density_plot <- ggplot(
  nearest_neighbor_plot_data,
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )

nearest_neighbor_density_plot
```

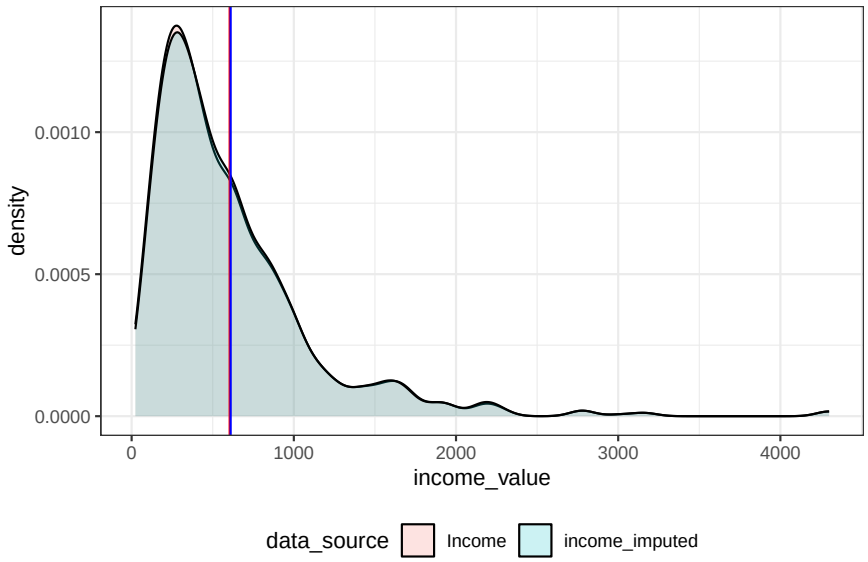


Figura 10.16.: Distribución del ingreso original e imputado por el vecino más cercano

10.2.6. Imputación por el vecino más cercano con regresión

La imputación por el vecino más cercano con regresión comprende los siguientes pasos:

1. Ajustar un modelo de regresión entre la variable de interés y las covariables auxiliares.
2. Predecir los valores de la variable de interés para las observaciones con y sin datos faltantes.
3. Comparar las predicciones de los posibles donantes con las de los receptores.
4. Identificar, para cada receptor, el donante cuya predicción sea más cercana a la suya.
5. Reemplazar el valor faltante con la información observada proveniente del donante.

En el siguiente ejemplo, se imputan los ingresos mediante un modelo que utiliza el sexo, la zona y el gasto como covariables:

```
survey_data$income_imputed <- survey_data$income_missing
observed_data <- filter(survey_data, !is.na(income_missing))
missing_data <- filter(survey_data, is.na(income_missing))

imputation_model <- lm(
  Income ~ Zone + Sex + Expenditure,
  data = observed_data
)
```

Con el modelo ajustado, el siguiente código computacional predice los ingresos de las observaciones con y sin datos faltantes. Para cada receptor, identifica al donante con la predicción más cercana y utiliza su ingreso observado para completar el valor faltante.

```
observed_predictions <- predict(
  imputation_model,
  newdata = observed_data
)
missing_predictions <- predict(
  imputation_model,
  newdata = missing_data
)

for (i in seq_len(nrow(missing_data))) {
  donor_index <- which.min(abs(missing_predictions[i] - observed_predictions))
  missing_data$income_imputed[[i]] <-
    observed_data$income_missing[[donor_index]]
}

survey_data <- bind_rows(observed_data, missing_data)
```

Como en los ejemplos anteriores, el siguiente código computacional compara la media y la desviación estándar del ingreso original con las del ingreso completado, en este caso mediante donantes seleccionados por la proximidad de sus predicciones.

```
survey_data %>%
  summarise(
    income_mean = mean(Income),
    income_sd = sd(Income),
    imputed_income_mean = mean(income_imputed),
    imputed_income_sd = sd(income_imputed)
  )
```

```
  income_mean income_sd imputed_income_mean imputed_income_sd
1         604       513                 608               516
```

La diferencia entre la media del ingreso original y la obtenida tras la imputación es de aproximadamente 4,0 unidades monetarias.

El siguiente código computacional compara el ingreso original (`Income`) con el completado mediante donantes cuyas predicciones son próximas a las del receptor (`income_imputed`) (figura 10.17). Las densidades prácticamente se superponen en esta simulación. Las líneas roja y azul representan las medias original e imputada, respectivamente.

```
predictive_matching_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, Income, income_imputed) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

predictive_matching_density_plot <- ggplot(
  predictive_matching_plot_data,
```

```
  aes(x = income_value, fill = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_vline(xintercept = mean(survey_data$Income), color = "red") +
  geom_vline(
    xintercept = mean(survey_data$income_imputed),
    color = "blue"
  )

predictive_matching_density_plot
```

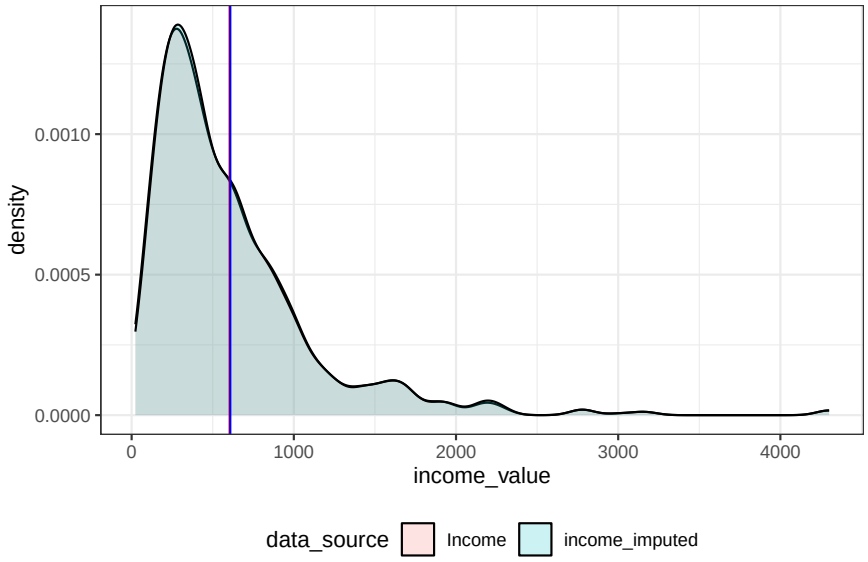


Figura 10.17.: Distribución del ingreso original e imputado por el vecino más cercano con regresión

10.2.7. Imputación múltiple

La imputación múltiple crea varias copias del conjunto de datos y completa los valores faltantes de cada una mediante modelos estadísticos basados en las relaciones entre las variables. Cada copia se analiza por separado y los resultados se combinan para obtener una estimación final que refleje la incertidumbre asociada con la imputación.

La imputación múltiple permite tratar los datos faltantes y puede ofrecer resultados más precisos y menos sesgados que la eliminación de las observaciones incompletas. Sin embargo, requiere recursos computacionales y conocimientos estadísticos para su aplicación adecuada. Esta técnica fue propuesta por Rubin (1987) y consiste en generar $M > 1$ conjuntos de valores para los datos faltantes.

Para ilustrar el método, se considera un conjunto de n observaciones de dos variables, X e Y, relacionadas mediante el siguiente modelo de regresión lineal simple:

$$y_i = \beta x_i + \varepsilon_i$$

El modelo se aplica a cada individuo $i = 1, \ldots, n$, con errores de distribución normal tales que $E(\varepsilon) = 0$ y $Var(\varepsilon) = \sigma^2$. Se define Y_{Obs} como un vector que contiene los valores observados para un conjunto de individuos de tamaño n_1, y Y_{NoObs} como el vector de los valores no observados de tamaño n_0, es decir, $n_1 + n_0 = n$. Además, se supone que fue posible observar los valores de la covariable X para todos los individuos en la muestra.

Los conjuntos completados se analizan por separado. Luego se combinan las estimaciones del parámetro de interés y sus varianzas, conservando la información sobre la variación entre imputaciones. Para la pendiente de la regresión lineal simple β, la esperanza condicional se expresa como:

$$E(\hat{\beta}|Y_{obs}) = E(E(\hat{\beta}|Y_{obs}, Y_{mis})|Y_{obs})$$

Esta expresión se estima mediante el promedio de las M estimaciones puntuales de $\hat{\beta}$ sobre las M imputaciones, dado por:

$$\bar{\hat{\beta}} = \frac{1}{M}\sum_{m=1}^{M}\hat{\beta}_m \tag{10.1}$$

La varianza estimada al utilizar la metodología de imputación múltiple está dada por la siguiente expresión:

$$V(\hat{\beta}|Y_{obs}) = E(V(\hat{\beta}|Y_{obs}, Y_{mis})|Y_{obs}) + V(E(\hat{\beta}|Y_{obs}, Y_{mis})|Y_{obs})$$

El primer término de la expresión anterior se estima como el promedio de las varianzas muestrales de $\hat{\beta}$ sobre las M imputaciones, dado por:

$$\bar{U} = \frac{1}{M}\sum_{m=1}^{M}\widehat{Var}(\hat{\beta}_m)$$

El segundo término se estima como la varianza muestral de las M estimaciones puntuales de $\hat{\beta}$ sobre las M imputaciones, dada por:

$$B = \frac{1}{M-1}\sum_{m=1}^{M}(\hat{\beta}_m - \bar{\hat{\beta}})^2$$

Es necesario tener en cuenta un factor de corrección (puesto que M es finito). Por tanto, la estimación del segundo término viene dada por la siguiente expresión:

$$(1 + \frac{1}{M})B$$

Por tanto, la varianza estimada es igual a:

$$\hat{V}(\hat{\beta}|Y_{obs}) = \bar{U} + (1 + \frac{1}{M})B \tag{10.2}$$

El siguiente ejemplo aplica la imputación múltiple a los datos de la encuesta:

```
survey_data$income_imputed <- survey_data$income_missing
survey_data$employment_imputed <- survey_data$employment_missing
observed_data <- filter(survey_data, !is.na(income_missing))
missing_data <- filter(survey_data, is.na(income_missing))
n_missing <- nrow(missing_data)
n_observed <- nrow(observed_data)
```

Primero, se separan las observaciones con y sin valores faltantes y se calcula el número de observaciones de cada grupo. El siguiente código computacional genera los valores imputados a partir del modelo y los incorpora a los conjuntos de datos completados.

```
n_imputations <- 10
set.seed(1234)

for (i in seq_len(n_imputations)) {
  imputation_column <- paste0("income_draw_", i)

  bootstrap_data <- observed_data %>%
    sample_n(size = n_observed, replace = TRUE)

  imputation_model <- lm(
    Income ~ Zone + Sex + Expenditure,
    data = bootstrap_data
  )

  missing_data[[imputation_column]] <- predict(
    imputation_model,
    missing_data
  )
  observed_data[[imputation_column]] <- observed_data$Income
}
```

El código anterior ajusta modelos de regresión lineal con `Income` como variable de respuesta y `Zone`, `Sex` y `Expenditure` como covariables. Estos modelos permiten predecir los ingresos faltantes en `missing_data`. El siguiente código computacional permite revisar los ingresos originales junto con algunos de los valores imputados.

```
dplyr::select(missing_data, Income, matches("income_draw_"))[1:10, 1:4]
```

```
   Income income_draw_1 income_draw_2 income_draw_3
1   409.9           550           566           568
2   409.9           561           529           542
3    90.9           211           226           164
4    90.9           221           189           138
5    90.9           211           226           164
6   135.3           223           238           178
7   135.3           223           238           178
8  1539.8           785           801           847
9   336.0           508           473           440
10  685.5           593           558           541
```

El siguiente código computacional compara la densidad del ingreso original, representada por la línea negra, con las de los 10 conjuntos completados, representadas por las líneas de colores (`income_draw_1` a income_draw_10) (figura 10.18). Las curvas mantienen una forma similar, con pequeñas diferencias en el tramo central que reflejan la variación entre las imputaciones.

```
survey_data <- bind_rows(observed_data, missing_data)

multiple_imputation_plot_data <- survey_data %>%
  dplyr::select(Zone, Sex, matches("income_draw_")) %>%
  tidyr::gather(data_source, income_value, -Zone, -Sex)

multiple_imputation_density_plot <- ggplot(
  multiple_imputation_plot_data,
  aes(x = income_value, color = data_source)
) +
  geom_density(alpha = 0.2) +
  theme_bw() +
  theme(legend.position = "bottom") +
  geom_density(
    data = survey_data,
    aes(x = Income),
    color = "black",
    linewidth = 1.2
  )

multiple_imputation_density_plot
```

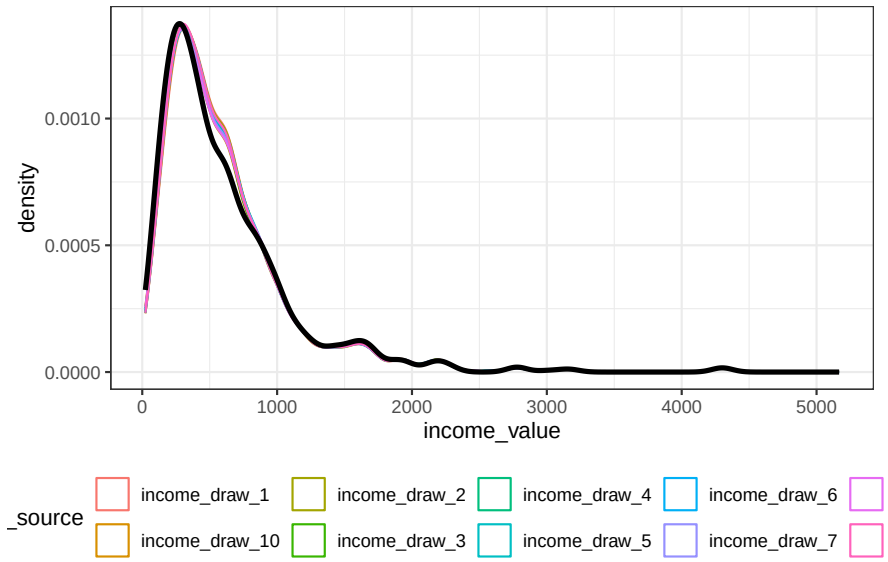


Figura 10.18.: Distribución del ingreso original y de los valores obtenidos mediante imputación múltiple

Con los conjuntos de datos completados, el siguiente código computacional define el diseño muestral que se utilizará para estimar los parámetros de interés.

```
survey_design <- survey_data %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
    nest = TRUE
  )
```

A partir de este diseño, el siguiente código computacional estima la media del ingreso y su varianza en cada conjunto de datos completado.

```
mean_estimates <- survey_design %>%
  summarise(
    across(
      starts_with("income_draw_"),
      ~ survey_mean(.x, vartype = "var")
    )
  ) %>%
  tidyr::gather() %>%
  separate(
    key,
    c(NA, NA, "imputation", "statistic"),
    fill = "right"
  ) %>%
```

```
  mutate(
    imputation = as.numeric(imputation),
    statistic = ifelse(is.na(statistic), "mean", "var")
  ) %>%
  spread(statistic, value)

mean_estimates
```

```
# A tibble: 10 x 3
   imputation  mean   var
        <dbl> <dbl> <dbl>
 1          1  619.  846.
 2          2  618.  845.
 3          3  617.  868.
 4          4  618.  857.
 5          5  620.  858.
 6          6  617.  853.
 7          7  618.  861.
 8          8  619.  868.
 9          9  617.  850.
10         10  616.  870.
```

El siguiente código computacional combina las medias estimadas y sus varianzas mediante las reglas de imputación múltiple descritas anteriormente.

```
pooled_mean <- mean(mean_estimates$mean)
within_variance <- mean(mean_estimates$var)
between_variance <- var(mean_estimates$mean)

within_variance
```

```
[1] 857
```

```
between_variance
```

```
[1] 1.65
```

```
pooled_mean_variance <- within_variance +
  (1 + 1 / n_imputations) * between_variance
pooled_results <- data.frame(
  pooled_mean = pooled_mean,
  mean_se = sqrt(pooled_mean_variance)
)
pooled_results
```

```
  pooled_mean mean_se
1         618    29.3
```

```
variance_estimates <- survey_design %>%
  summarise_at(vars(matches("income_draw")), survey_var, vartype = "var")
```

Otro parámetro de interés es la varianza del ingreso, que mide su dispersión entre las personas de la muestra. Se sigue el mismo procedimiento utilizado para la media: el siguiente código computacional reorganiza las estimaciones de la varianza del ingreso y sus medidas de incertidumbre para combinarlas por imputación.

```
variance_estimates <- variance_estimates %>%
  tidyr::gather() %>%
  separate(
    key,
    c(NA, NA, "imputation", "statistic"),
    fill = "right"
  ) %>%
  mutate(
    statistic = ifelse(is.na(statistic), "mean", "var"),
    imputation = as.numeric(imputation)
  ) %>%
  spread(statistic, value)

variance_estimates
```

```
# A tibble: 10 x 3
   imputation    mean         var
        <dbl>   <dbl>       <dbl>
 1          1 262690. 3074674460.
 2          2 263092. 3079895581.
 3          3 274370. 3237991671.
 4          4 269127. 3164842634.
 5          5 270450. 3165285304.
 6          6 264993. 3106582542.
 7          7 270916. 3175865575.
 8          8 276070. 3251836316.
 9          9 265061. 3111426636.
10         10 275462. 3258214990.
```

Por último, el siguiente código computacional combina las estimaciones de la varianza del ingreso y su incertidumbre mediante las expresiones anteriores.

```
pooled_variance <- mean(variance_estimates$mean)
within_variance <- mean(variance_estimates$var)
between_variance <- var(variance_estimates$mean)
```

```r
pooled_variance_variance <- within_variance +
  (1 + 1 / n_imputations) * between_variance

pooled_results$pooled_variance <- pooled_variance
pooled_results$variance_se <- sqrt(pooled_variance_variance)
cbind(pooled_variance, pooled_variance_variance)
```

```
     pooled_variance pooled_variance_variance
[1,]          269223               3191037330
```

Referencias

Agresti, Alan. 2019. *An Introduction to Categorical Data Analysis*. 3.ª ed. John Wiley & Sons. https://doi.org/10.1002/9781119405283.

Alexander, Charles H. 1987. «A Class of Methods for Using Person Controls in Household Weighting». *Survey Methodology* 13 (2): 183-98. https://www150.statcan.gc.ca/n1/pub/12-001-x/1987002/article/14606-eng.pdf.

Anyanwu, John C. 2014. «Marital Status, Household Size and Poverty in Nigeria: Evidence from the 2009/2010 Survey Data». *African Development Review* 26 (1): 118-37. https://doi.org/10.1111/1467-8268.12069.

Asparouhov, Tihomir. 2006. «General Multi-Level Modeling with Sampling Weights». *Communications in Statistics, Theory and Methods* 35 (3): 439-60. https://doi.org/10.1080/03610920500476598.

Bache, Stefan Milton, y Hadley Wickham. 2026. *magrittr: A Forward-Pipe Operator for R*. https://doi.org/10.32614/CRAN.package.magrittr.

Bates, Douglas, Martin Mächler, Ben Bolker, y Steve Walker. 2015. «Fitting Linear Mixed-Effects Models Using lme4». *Journal of Statistical Software* 67 (1): 1-48. https://doi.org/10.18637/jss.v067.i01.

Berglund, Patricia, y Steven Heeringa. 2014. *Multiple Imputation of Missing Data Using SAS*. SAS Institute Inc. https://support.sas.com/content/dam/SAS/support/en/books/multiple-imputation-of-missing-data-using-sas/65370_excerpt.pdf.

Binder, David A. 1983. «On the variances of asymptotically normal estimators from complex surveys». *International Statistical Review/Revue Internationale de Statistique*, 279-92.

Binder, David A. 2011. «Estimating model parameters from a complex survey under a model-design randomization framework». *Pakistan Journal of Statistics* 27 (4).

Binder, David A., y Milorad S. Kovačević. 1995. «Estimating Some Measures of Income Inequality from Survey Data: An Application of the Estimating Equations Approach». *Survey Methodology* 21 (2): 137-45. https://www150.statcan.gc.ca/n1/en/catalogue/12-001-X199500214396.

Browne, William J., y David Draper. 2006. «A Comparison of Bayesian and Likelihood-Based Methods for Fitting Multilevel Models». *Bayesian Analysis* 1 (3): 473-514. https://doi.org/10.1214/06-BA117.

Bruch, Christian, Ralf Münnich, y Stefan Zins. 2011. «Variance estimation for complex surveys». *Deliverable D3* 1.

Buuren, Stef van. 2012. *Flexible Imputation of Missing Data*. Chapman & Hall/CRC. https://doi.org/10.1201/b11826.

Cai, Tianji. 2013. «Investigation of Ways to Handle Sampling Weights for Multilevel Model Analyses». *Sociological Methodology* 43 (1): 178-219. https://doi.org/10.1177/0081175013490035.

Carle, Adam C. 2009. «Fitting Multilevel Models in Complex Survey Data with Design Weights: Recommendations». *BMC Medical Research Methodology* 9: 49. https://doi.org/10.1186/1471-2288-9-49.

Carpenter, James R., y Michael G. Kenward. 2013. *Multiple Imputation and its Application*. John Wiley & Sons. https://doi.org/10.1002/9781119942283.

Casella, George, y Roger L. Berger. 2002. *Statistical Inference*. 2.ª ed. Duxbury.

CEPAL. 2023. *Diseño y análisis estadístico de las encuestas de hogares de América Latina*. Metodologías de la CEPAL 5. Naciones Unidas. https://repositorio.cepal.org/server/api/core/bitstreams/14d443ec-8f1e-44a7-b22b-9f124f205abe/content.

CEPAL. 2025. *Panorama Social de América Latina y el Caribe, 2025: cómo salir de la trampa de alta desigualdad, baja movilidad social y débil cohesión social*. Comisión Económica para América Latina y el Caribe. https://repositorio.cepal.org/server/api/core/bitstreams/61e9dfa1-de2a-4af6-b670-0e2ed9b00cfe/content.

Chambers, Raymond L., y Chris J. Skinner, eds. 2003. *Analysis of Survey Data*. John Wiley & Sons. https://doi.org/10.1002/0470867205.

Cochran, William Gemmell. 1977. *Sampling techniques*. John Wiley & Sons.

Comisión Económica para América Latina y el Caribe. 2022. «Panorama del envejecimiento y tendencias demográficas en América Latina y el Caribe». https://www.cepal.org/es/enfoques/panorama-envejecimiento-tendencias-demograficas-america-latina-caribe.

Deaton, Angus. 1997. *The Analysis of Household Surveys: A Microeconometric Approach to Development Policy*. World Bank; The Johns Hopkins University Press.

Deville, Jean-Claude, y Carl-Erik Särndal. 1992. «Calibration Estimators in Survey Sampling». *Journal of the American Statistical Association* 87 (418): 376-82. https://doi.org/10.1080/01621459.1992.10475217.

Díaz Monroy, Luis Guillermo, Mario Alfonso Morales Rivera, y Leidy Rocío León Dávila. 2018. *Análisis estadístico de datos categóricos*. 1.ª ed. Editorial Universidad Nacional de Colombia. https://portaldelibros.unal.edu.co/gpd-anyalisis-estadyustico-de-datos-categy-ricos-9789587834376-667e35367b60f.html.

Dorfman, Alan H., y Richard Valliant. 1993. «Quantile Variance Estimators in Complex Surveys». *Proceedings of the Survey Research Methods Section*, 866-71.

Efron, Bradley. 1979. «Bootstrap methods: Another look at the jackknife». *The Annals of Statistics* 7 (1): 1-26. https://doi.org/10.1214/aos/1176344552.

FAO. 2026. *Indicador 2.1.1: Prevalencia de la subalimentación*. https://www.fao.org/sustainable-development-goals-data-portal/data/indicators/2.1.1-prevalence-of-undernourishment/es.

Fay, Robert E. 1979. «On Adjusting the Pearson Chi-Square Statistic for Cluster Sampling». *Proceedings of the Social Statistics Section, American Statistical Association*, 402-5.

Fellegi, Ivan P. 1980. «Approximate Tests of Independence and Goodness of Fit Based on Stratified Multistage Samples». *Journal of the American Statistical Association* 75 (370): 261-68. https://doi.org/10.2307/2287405.

Ferreira, Juan Pablo. 2026. *weightflow: Declarative API for Staged Survey Weights*. https://doi.org/10.32614/CRAN.package.weightflow.

Finch, W. Holmes, Jocelyn E. Bolin, y Ken Kelley. 2019. *Multilevel Modeling Using R*. 2.ª ed. CRC Press.

Fox, John, y Sanford Weisberg. 2019. *An R Companion to Applied Regression*. 3.ª ed. SAGE Publications.

Freedman Ellis, Greg, y Ben Schneider. 2026. *srvyr: 'dplyr'-Like Syntax for Summary Statistics of Survey Data*. https://doi.org/10.32614/CRAN.package.srvyr.

Fuller, Wayne A. 1975. «Regression analysis for sample survey». *Sankhya, Series C* 37: 117-32.

Fuller, Wayne A. 2002. «Regression estimation for survey samples». *Survey Methodology* 28 (1): 5-23.

Fuller, Wayne A. 2009. *Sampling Statistics*. Wiley Series en Survey Methodology. John Wiley & Sons. https://doi.org/10.1002/9780470523551.

Gambino, Jack G, y Pedro Luis do Nascimento Silva. 2009. «Sampling and estimation in household surveys». En *Handbook of Statistics*, vol. 29. Elsevier.

Gelman, Andrew, y Jennifer Hill. 2006. *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press.

Goldstein, Harvey. 2011. *Multilevel Statistical Models*. 4.ª ed. John Wiley & Sons.

Groves, Robert M., Floyd J. Fowler, Mick P. Couper, James M. Lepkowski, Eleanor Singer, y Roger Tourangeau. 2009. *Survey Methodology*. 2.ª ed. John Wiley & Sons.

Gutiérrez, Andrés. 2016. *Estrategias de muestreo: diseño de encuestas y estimación de parámetros*.

Segunda edición. Ediciones de la U.

Gutiérrez, Andrés. 2020. *TeachingSampling: Selection of Samples and Parameter Estimation in Finite Population*. https://doi.org/10.32614/CRAN.package.TeachingSampling.

Gutiérrez, Andrés, y Giovany Babativa-Márquez. 2023. *Efectos de diseño para indicadores sociales en América Latina: función generalizada de varianza para estimadores directos provenientes de encuestas de hogares*. LC/TS.2023/95 No. 106. CEPAL - Serie Estudios Estadísticos. CEPAL. https://repositorio.cepal.org/server/api/core/bitstreams/feb8c8be-6434-41f2-8fd9-f12f71a0739a/content.

Hansen, Morris H, William N Hurwitz, William G Madow, et al. 1953. *Sample survey methods and theory*.

Heeringa, Steven G., Brady T. West, y Patricia A. Berglund. 2017. *Applied Survey Data Analysis*. 2.ª ed. Chapman & Hall/CRC. https://doi.org/10.1201/9781315153278.

Henry, Lionel, Hadley Wickham, y Winston Chang. 2024. *ggstance: Horizontal 'ggplot2' Components*. https://doi.org/10.32614/CRAN.package.ggstance.

Horvitz, Daniel G., y Donovan J. Thompson. 1952. «A Generalization of Sampling Without Replacement from a Finite Universe». *Journal of the American Statistical Association* 47 (260): 663-85. https://doi.org/10.1080/01621459.1952.10483446.

Jacob, Guilherme, Djalma Pessoa, y Anthony Damico. 2024. *convey: Income Concentration Analysis with Complex Survey Samples*. https://doi.org/10.32614/CRAN.package.convey.

Kalton, Graham, y Ismael Flores-Cervantes. 2003. «Weighting methods». *Journal of official statistics* 19 (2): 81.

Kim, Jae Kwang, y Wayne Fuller. 2004. «Fractional Hot Deck Imputation». *Biometrika* 91 (3): 559-78. https://doi.org/10.1093/biomet/91.3.559.

Kim, Jae Kwang, y Jun Shao. 2014. *Statistical Methods for Handling Incomplete Data*. Chapman & Hall/CRC.

Kish, Leslie. 1965. *Survey Sampling*. Wiley.

Kish, Leslie, y Martin R. Frankel. 1974. «Inference from complex samples». *Journal of the Royal Statistical Society, Series B* 36: 1-37.

Korn, Edward L., y Barry I. Graubard. 1999. *Analysis of Health Surveys*. John Wiley & Sons. https://doi.org/10.1002/9781118032619.

Korn, Edward L, y Barry I Graubard. 1995. «Analysis of large health surveys: accounting for the sampling design». *Journal of the Royal Statistical Society: Series A (Statistics in Society)* 158 (2): 263-95.

Kovačević, Milorad S., y David A. Binder. 1997. «Variance Estimation for Measures of Income Inequality and Polarization: The Estimating Equations Approach». *Journal of Official Statistics* 13 (1): 41-58.

Kovar, JG, JNK Rao, y CFJ Wu. 1988. «Bootstrap and other methods to measure errors in survey estimates». *Canadian Journal of Statistics* 16 (S1): 25-45.

Langel, Matti, y Yves Tillé. 2013. «Variance Estimation of the Gini Index: Revisiting a Result Several Times Published». *Journal of the Royal Statistical Society: Series A (Statistics in Society)* 176 (2): 521-40. https://doi.org/10.1111/j.1467-985X.2012.01048.x.

Li, Jianzhu, y Richard Valliant. 2015. «Linear Regression Diagnostics in Cluster Samples». *Journal of Official Statistics* 31 (1): 61-75. https://doi.org/10.1515/jos-2015-0003.

Long, Jacob A. 2026. *jtools: Analysis and Presentation of Social Scientific Data*. https://doi.org/10.32614/CRAN.package.jtools.

Lorenz, Max O. 1905. «Methods of Measuring the Concentration of Wealth». *Publications of the American Statistical Association* 9 (70): 209-19. https://doi.org/10.2307/2276207.

Lüdecke, Daniel, Mattan S. Ben-Shachar, Indrajeet Patil, Philip Waggoner, y Dominique Makowski. 2026. *performance: Assessment of Regression Models Performance*. https://doi.org/10.32614/CRAN.package.performance.

Lumley, Thomas. 2010. *Complex Surveys: A Guide to Analysis Using R: A Guide to Analysis Using R*. John Wiley & Sons.

Lumley, Thomas. 2026. *svyVGAM: Design-Based Inference in Vector Generalised Linear Models*. https://doi.org/10.32614/CRAN.package.svyVGAM.

Lumley, Thomas, Peter Gao, Ben Schneider, y Stas Kolenikov. 2026. *survey: Analysis of Complex Survey Samples*. https://doi.org/10.32614/CRAN.package.survey.

McCullagh, Peter, y John A. Nelder. 1989. *Generalized Linear Models*. 2.ª ed. Chapman & Hall. https://doi.org/10.1007/978-1-4899-3242-6.

Merlo, Juan, Basile Chaix, Henrik Ohlsson, et al. 2006. «A Brief Conceptual Tutorial of Multilevel Analysis in Social Epidemiology: Using Measures of Clustering in Multilevel Logistic Regression to Investigate Contextual Phenomena». *Journal of Epidemiology & Community Health* 60 (4): 290-97. https://doi.org/10.1136/jech.2004.029454.

Molina, Elizabeth A., y Chris J. Skinner. 1992. «Pseudo-likelihood and quasi-likelihood estimation for complex sampling schemes». *Computational Statistics & Data Analysis* 13: 395-405.

Naciones Unidas. 2005. *Designing Household Survey Samples: Practical Guidelines*. Studies en Methods, Series F, No. 98. United Nations.

Naciones Unidas. 2009. *Diseño de Muestras para Encuestas de Hogares: Directrices Prácticas*. Estu-

dios de Métodos, Serie F 98. Naciones Unidas. https://unstats.un.org/unsd/publication/seriesf/seriesf_98s.pdf.

Naciones Unidas. 2021. *Report of the Intersecretariat Working Group on Household Surveys*. E/CN.3/2021/16. United Nations Statistical Commission.

Naciones Unidas. 2026. *Handbook of Surveys on Households and Individuals Foundations and Emerging Approaches*. Naciones Unidas.

Nelder, John A., y Robert W. M. Wedderburn. 1972. «Generalized Linear Models». *Journal of the Royal Statistical Society: Series A (General)* 135 (3): 370-84. https://doi.org/10.2307/2344614.

OECD. 2013. *OECD Framework for Statistics on the Distribution of Household Income, Consumption and Wealth*. OECD Publishing. https://doi.org/10.1787/9789264194830-en.

Osier, Guillaume. 2009. «Variance estimation for complex indicators of poverty and inequality using linearization techniques». *Survey research methods* 3: 167-95.

Park, Inho, Marianne Winglee, Jay Clark, Keith Rust, Andrea Sedlak, y David Morganstein. 2003. «Design Effects and Survey Planning». *Proceedings of the Section on Survey Research Methods*, 3179-86. https://www.asasrms.org/Proceedings/y2003/Files/JSM2003-000156.pdf.

Pebesma, Edzer. 2018. «Simple Features for R: Standardized Support for Spatial Vector Data». *The R Journal* 10 (1): 439-46. https://doi.org/10.32614/RJ-2018-009.

Pebesma, Edzer, Roger Bivand, Etienne Racine, et al. 2026. *sf: Simple Features for R*. https://doi.org/10.32614/CRAN.package.sf.

Pedersen, Thomas Lin. 2025. *patchwork: The composer of plots*. https://doi.org/10.32614/CRAN.package.patchwork.

Pfeffermann, Danny. 1993. «The Role of Sampling Weights When Modeling Survey Data». *International Statistical Review* 61 (2): 317-37. https://doi.org/10.2307/1403631.

Pfeffermann, Danny. 2011. «Modelling of complex survey data: Why model? Why is it a problem? How can we approach it?» *Survey Methodology* 37 (2): 115-36.

Pfeffermann, Danny, Chris J. Skinner, David J. Holmes, Harvey Goldstein, y Jon Rasbash. 1998. «Weighting for Unequal Selection Probabilities in Multilevel Models». *Journal of the Royal Statistical Society: Series B* 60 (1): 23-40. https://doi.org/10.1111/1467-9868.00106.

Posit Software, PBC. 2026. *RStudio Projects*. Posit Software, PBC. https://docs.posit.co/ide/user/ide/guide/code/projects.html.

Prener, Christopher, Timo Grossenbacher, y Angelo Zehr. 2025. *biscale: Tools and Palettes for Bivariate Thematic Mapping*. https://doi.org/10.32614/CRAN.package.biscale.

R Core Team. 2026a. *R: A Language and Environment for Statistical Computing*. R Foundation for

Statistical Computing. https://www.R-project.org/.

R Core Team. 2026b. *Serialization Interface for Single Objects*. R Foundation for Statistical Computing. https://stat.ethz.ch/R-manual/R-devel/library/base/html/readRDS.html.

Rabe-Hesketh, Sophia, y Anders Skrondal. 2006. «Multilevel Modelling of Complex Survey Data». *Journal of the Royal Statistical Society: Series A* 169 (4): 805-27. https://doi.org/10.1111/j.1467-985X.2006.00426.x.

Rabe-Hesketh, Sophia, y Anders Skrondal. 2012. *Multilevel and Longitudinal Modeling Using Stata*. 3.ª ed. Stata Press.

Raghunathan, Trivellore. 2016. *Missing Data Analysis in Practice*. Chapman & Hall/CRC. https://www.routledge.com/Missing-Data-Analysis-in-Practice/Raghunathan/p/book/9780429171673.

Rao, J. N. K., y Isabel Molina. 2015. *Small Area Estimation*. 2.ª ed. John Wiley & Sons. https://doi.org/10.1002/9781118735855.

Rao, J. N. K., y Alastair J. Scott. 1981. «The Analysis of Categorical Data From Complex Sample Surveys: Chi-Squared Tests for Goodness of Fit and Independence in Two-Way Tables». *Journal of the American Statistical Association* 76 (374): 221-30. https://doi.org/10.1080/01621459.1981.10477633.

Rao, J. N. K., C. F. J. Wu, y K. Yue. 1992. «Some recent work on resampling methods for complex surveys». *Survey Methodology* 18: 209-17.

Rao, Jon N. K., y Alastair J. Scott. 1984. «On chi-squared tests for multiway contingency tables with cell proportions estimated from survey data». *The Annals of Statistics* 12 (1): 46-60.

Rubin, Donald B. 1987. *Multiple Imputation for Nonresponse in Surveys*. Wiley Series en Probability y Statistics. John Wiley & Sons. https://doi.org/10.1002/9780470316696.

Rust, Keith F., y J. N. K. Rao. 1996. «Variance Estimation for Complex Surveys Using Replication Techniques». *Statistical Methods in Medical Research* 5 (3): 283-310. https://doi.org/10.1177/096228029600500305.

Särndal, Carl-Erik, y Sixten Lundström. 2005. *Estimation in surveys with nonresponse*. John Wiley & Sons.

Särndal, Carl-Erik, Bengt Swensson, y Jan Wretman. 2003. *Model assisted survey sampling*. Springer Science & Business Media.

SAS Institute Inc. 2012. *Estimating the Standard Deviation of a Variable in a Finite Population*. SAS Support, Sample 45701. https://support.sas.com/kb/45/701.html.

Schulze Waltrup, Linda, y Göran Kauermann. 2016. «A Short Note on Quantile and Expectile Estimation in Unequal Probability Samples». *Survey Methodology* 42 (1): 179-87. https://www150.statcan.gc.ca/n1/en/catalogue/12-001-X201600114545.

Shah, Babubhai V., Maurice M. Holt, y Ralph F. Folsom. 1977. «Inference about regression models from sample survey data». *Bulletin of the International Statistical Institute* 41 (3): 43-57.

Skinner, Chris J., David Holt, y Tom M. F. Smith, eds. 1989. *Analysis of complex surveys*. John Wiley & Sons.

Snijders, Tom AB, y Roel Bosker. 2011. *Multilevel analysis: An introduction to basic and advanced multilevel modeling*.

Solt, Frederick, y Yue Hu. 2025. *dotwhisker: Dot-and-Whisker Plots of Regression Results*. https://doi.org/10.32614/CRAN.package.dotwhisker.

Tennekes, Martijn. 2018. «tmap: Thematic Maps in R». *Journal of Statistical Software* 84 (6): 1-39. https://doi.org/10.18637/jss.v084.i06.

Tennekes, Martijn. 2026. *tmap: Thematic Maps*. https://doi.org/10.32614/CRAN.package.tmap.

Thomas, D. Roland, y Jon N. K. Rao. 1987. «Small-sample comparisons of level and power for simple goodness-of-fit statistics under cluster sampling». *Journal of the American Statistical Association* 82 (398): 630-36.

Tillé, Yves, y Alina Matei. 2025. *sampling: Survey Sampling*. https://doi.org/10.32614/CRAN.package.sampling.

Tukey, John W. 1977. *Exploratory Data Analysis*. Addison-Wesley.

UNECE. 2011. *Canberra Group Handbook on Household Income Statistics*. 2.ª ed. United Nations Economic Commission for Europe.

Valliant, Richard. 2024. *svydiags: Regression Model Diagnostics for Survey Data*. https://doi.org/10.32614/CRAN.package.svydiags.

Valliant, Richard, y Jill A. Dever. 2017. *Survey Weights: A Step-by-step Guide to Calculation*. 1 edition. Stata Press.

Valliant, Richard, Jill A. Dever, y Frauke Kreuter. 2018. *Practical Tools for Designing and Weighting Survey Samples*. Statistics for Social y Behavioral Sciences. Springer International Publishing. https://doi.org/10.1007/978-3-319-93632-1.

Warnes, Gregory R., Ben Bolker, Thomas Lumley, et al. 2023. *gtools: Various R Programming Tools*. https://doi.org/10.32614/CRAN.package.gtools.

Wickham, Hadley. 2014. «Tidy Data». *Journal of Statistical Software* 59 (10): 1-23. https://doi.org/10.18637/jss.v059.i10.

Wickham, Hadley, Mara Averick, Jennifer Bryan, et al. 2026. *tidyverse: Easily Install and Load the Tidyverse*. https://doi.org/10.32614/CRAN.package.tidyverse.

Wickham, Hadley, Mine Çetinkaya-Rundel, y Garrett Grolemund. 2023. *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. 2.ª ed. O'Reilly Media. https://r4ds.hadley.nz/.

Wickham, Hadley, Winston Chang, Lionel Henry, et al. 2026. *ggplot2: Create Elegant Data Visualisations Using the Grammar of Graphics*. https://doi.org/10.32614/CRAN.package.ggplot2.

Wickham, Hadley, Romain François, Lionel Henry, Kirill Müller, y Davis Vaughan. 2026. *dplyr: A Grammar of Data Manipulation*. https://doi.org/10.32614/CRAN.package.dplyr.

Wilke, Claus O. 2025. *cowplot: Streamlined Plot Theme and Plot Annotations for 'ggplot2'*. https://doi.org/10.32614/CRAN.package.cowplot.

Wilkinson, Leland. 2005. *The grammar of graphics*. 2.ª ed. Springer.

Wolter, Kirk M. 2007. *Introduction to Variance Estimation*. 2.ª ed. Springer Series en Statistics. Springer. https://doi.org/10.1007/978-0-387-35099-8.

Woodruff, Ralph S. 1952. «Confidence Intervals for Medians and Other Position Measures». *Journal of the American Statistical Association* 47 (260): 635-46. https://doi.org/10.1080/01621459.1952.10483443.

Woodruff, Ralph S. 1971. «A Simple Method for Approximating the Variance of a Complicated Estimate». *Journal of the American Statistical Association* 66 (334): 411-14. https://doi.org/10.1080/01621459.1971.10482279.

Wooldridge, Jeffrey M. 2020. *Introductory Econometrics: A Modern Approach*. 7.ª ed. Cengage Learning. https://www.cengage.com/c/introductory-econometrics-a-modern-approach-7e-wooldridge/9781337558860.